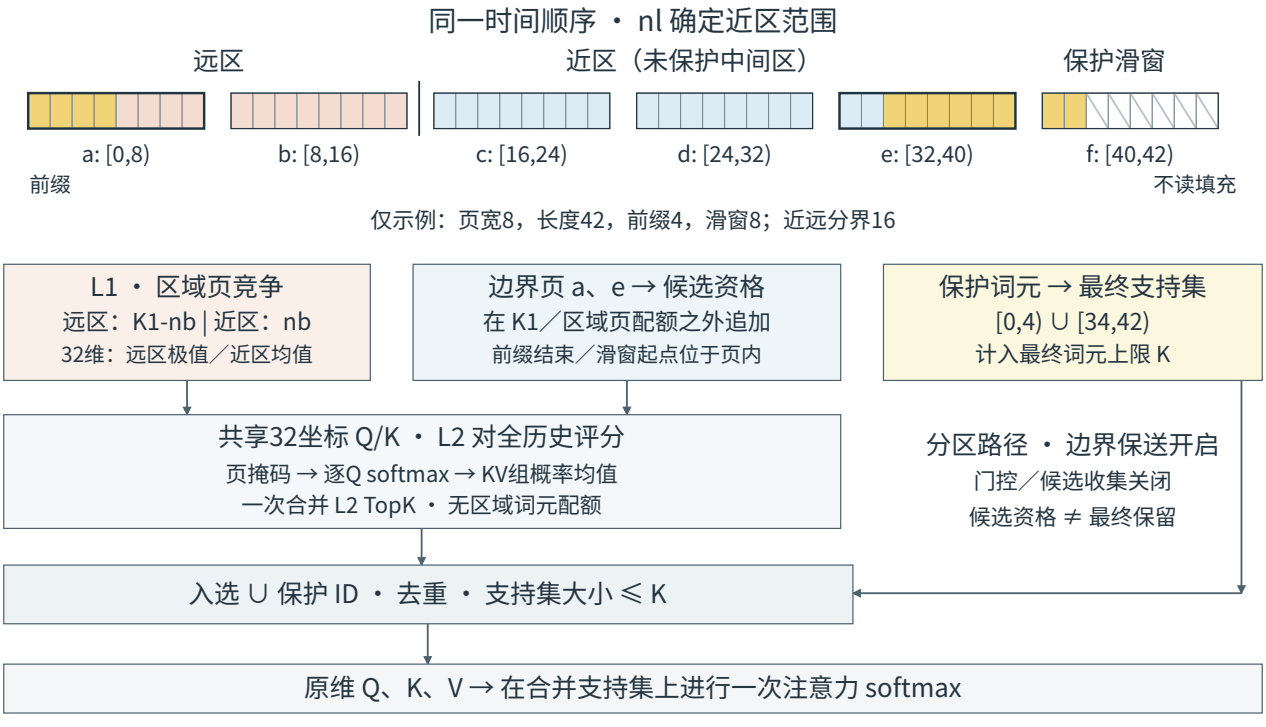

同一时间顺序 · nl 确定近区范围
远区
近区（未保护中间区）
保护滑窗
a: [0,8)
前缀
b: [8,16)
c: [16,24)
d: [24,32)
e: [32,40)
f: [40,42)
不读填充
仅示例：页宽8，长度42，前缀4，滑窗8；近远分界16
L1 · 区域页竞争
远区：K1-nb | 近区：nb
32维：远区极值／近区均值
边界页 a、e → 候选资格
在 K1／区域页配额之外追加
前缀结束／滑窗起点位于页内
保护词元 → 最终支持集
[0,4) ∪ [34,42)
计入最终词元上限 K
共享32坐标 Q/K · L2 对全历史评分
页掩码 → 逐Q softmax → KV组概率均值
一次合并 L2 TopK · 无区域词元配额
分区路径 · 边界保送开启
门控／候选收集关闭
候选资格 ≠ 最终保留
入选 ∪ 保护 ID · 去重 · 支持集大小 ⩽ K
原维 Q、K、V → 在合并支持集上进行一次注意力 softmax