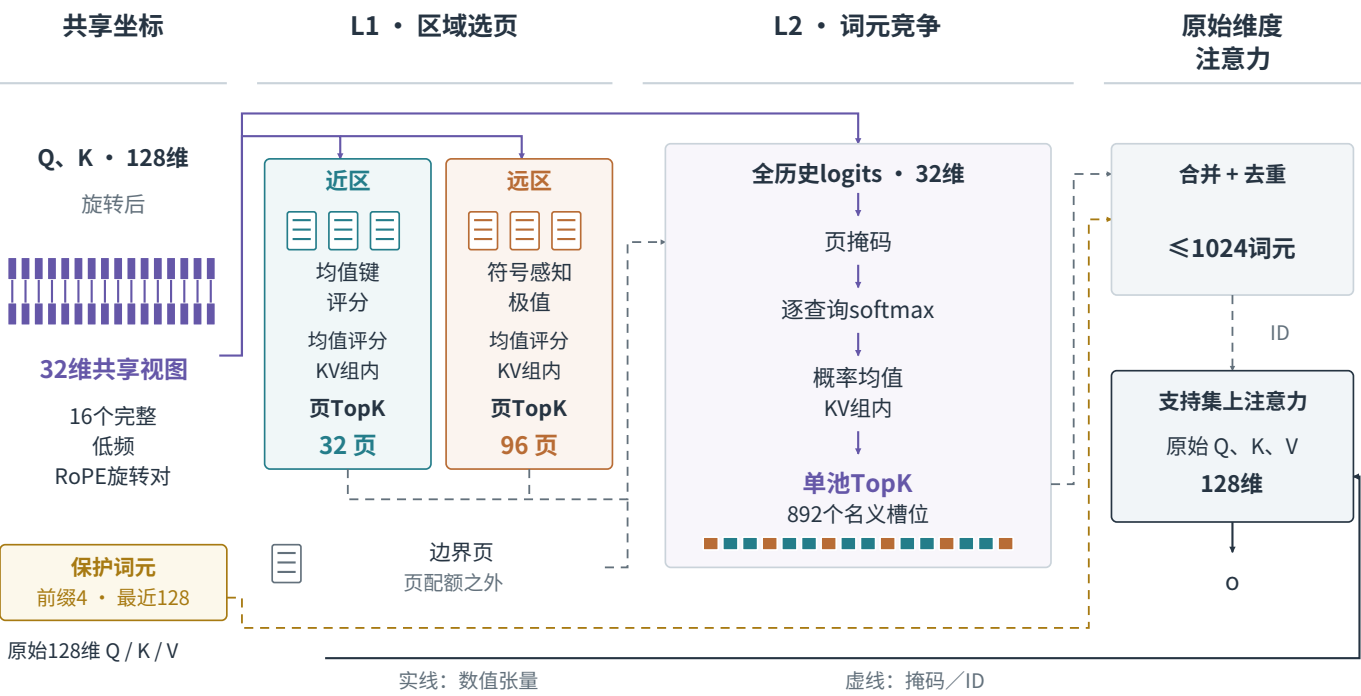

共享坐标
L1 · 区域选页
L2 · 词元竞争
原始维度
注意力
Q、K · 128维
旋转后
32维共享视图
16个完整
低频
RoPE旋转对
近区
均值键
评分
均值评分
KV组内
页TopK
32 页
远区
符号感知
极值
均值评分
KV组内
页TopK
96 页
全历史logits · 32维
页掩码
逐查询softmax
概率均值
KV组内
单池TopK
892个名义槽位
合并 + 去重
≤1024词元
ID
支持集上注意力
原始 Q、K、V
128维
o
保护词元
前缀4 · 最近128
边界页
页配额之外
原始128维 Q / K / V
实线：数值张量
虚线：掩码／ID