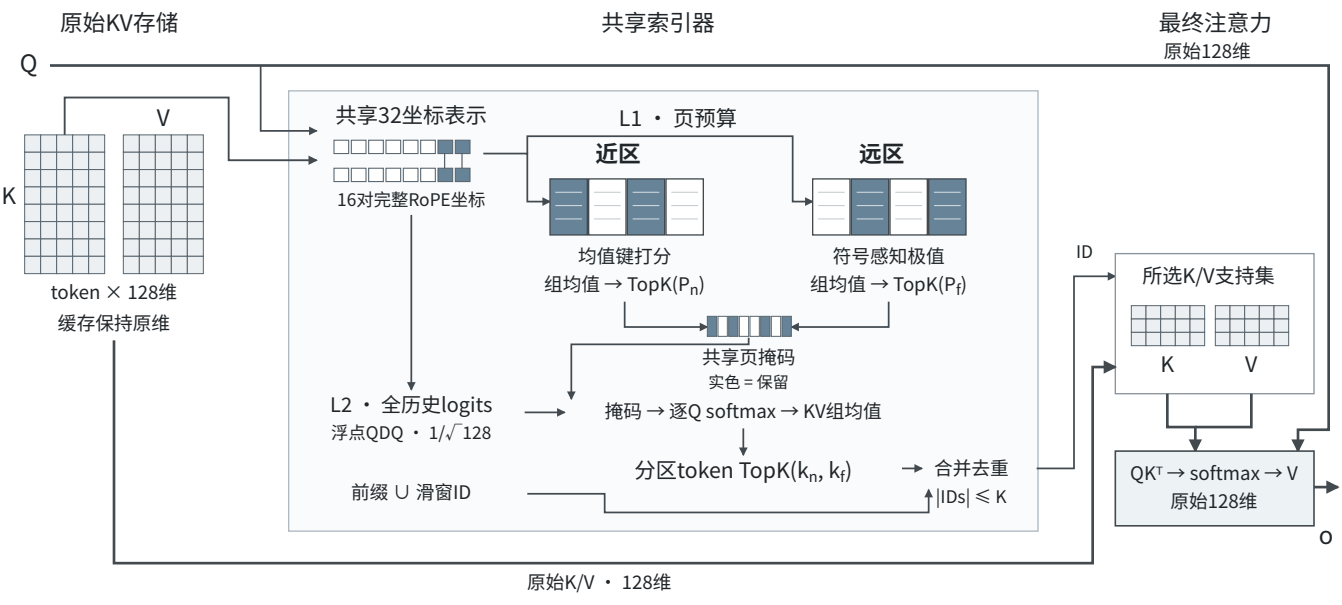

原始KV存储
共享索引器
最终注意力
原始128维
Q
V
K
token × 128维
缓存保持原维
共享32坐标表示
16对完整RoPE坐标
L1 · 页预算
近区
远区
均值键打分
组均值 → TopK(Pn)
符号感知极值
组均值 → TopK(Pf)
共享页掩码
实色 = 保留
L2 · 全历史logits
浮点QDQ · 1/√128
掩码 → 逐Q softmax → KV组均值
分区token TopK(kn, kf)
合并去重
前缀 ∪ 滑窗ID
|IDs| ⩽ K
ID
所选K/V支持集
K
V
QKᵀ → softmax → V
原始128维
O
原始K/V · 128维