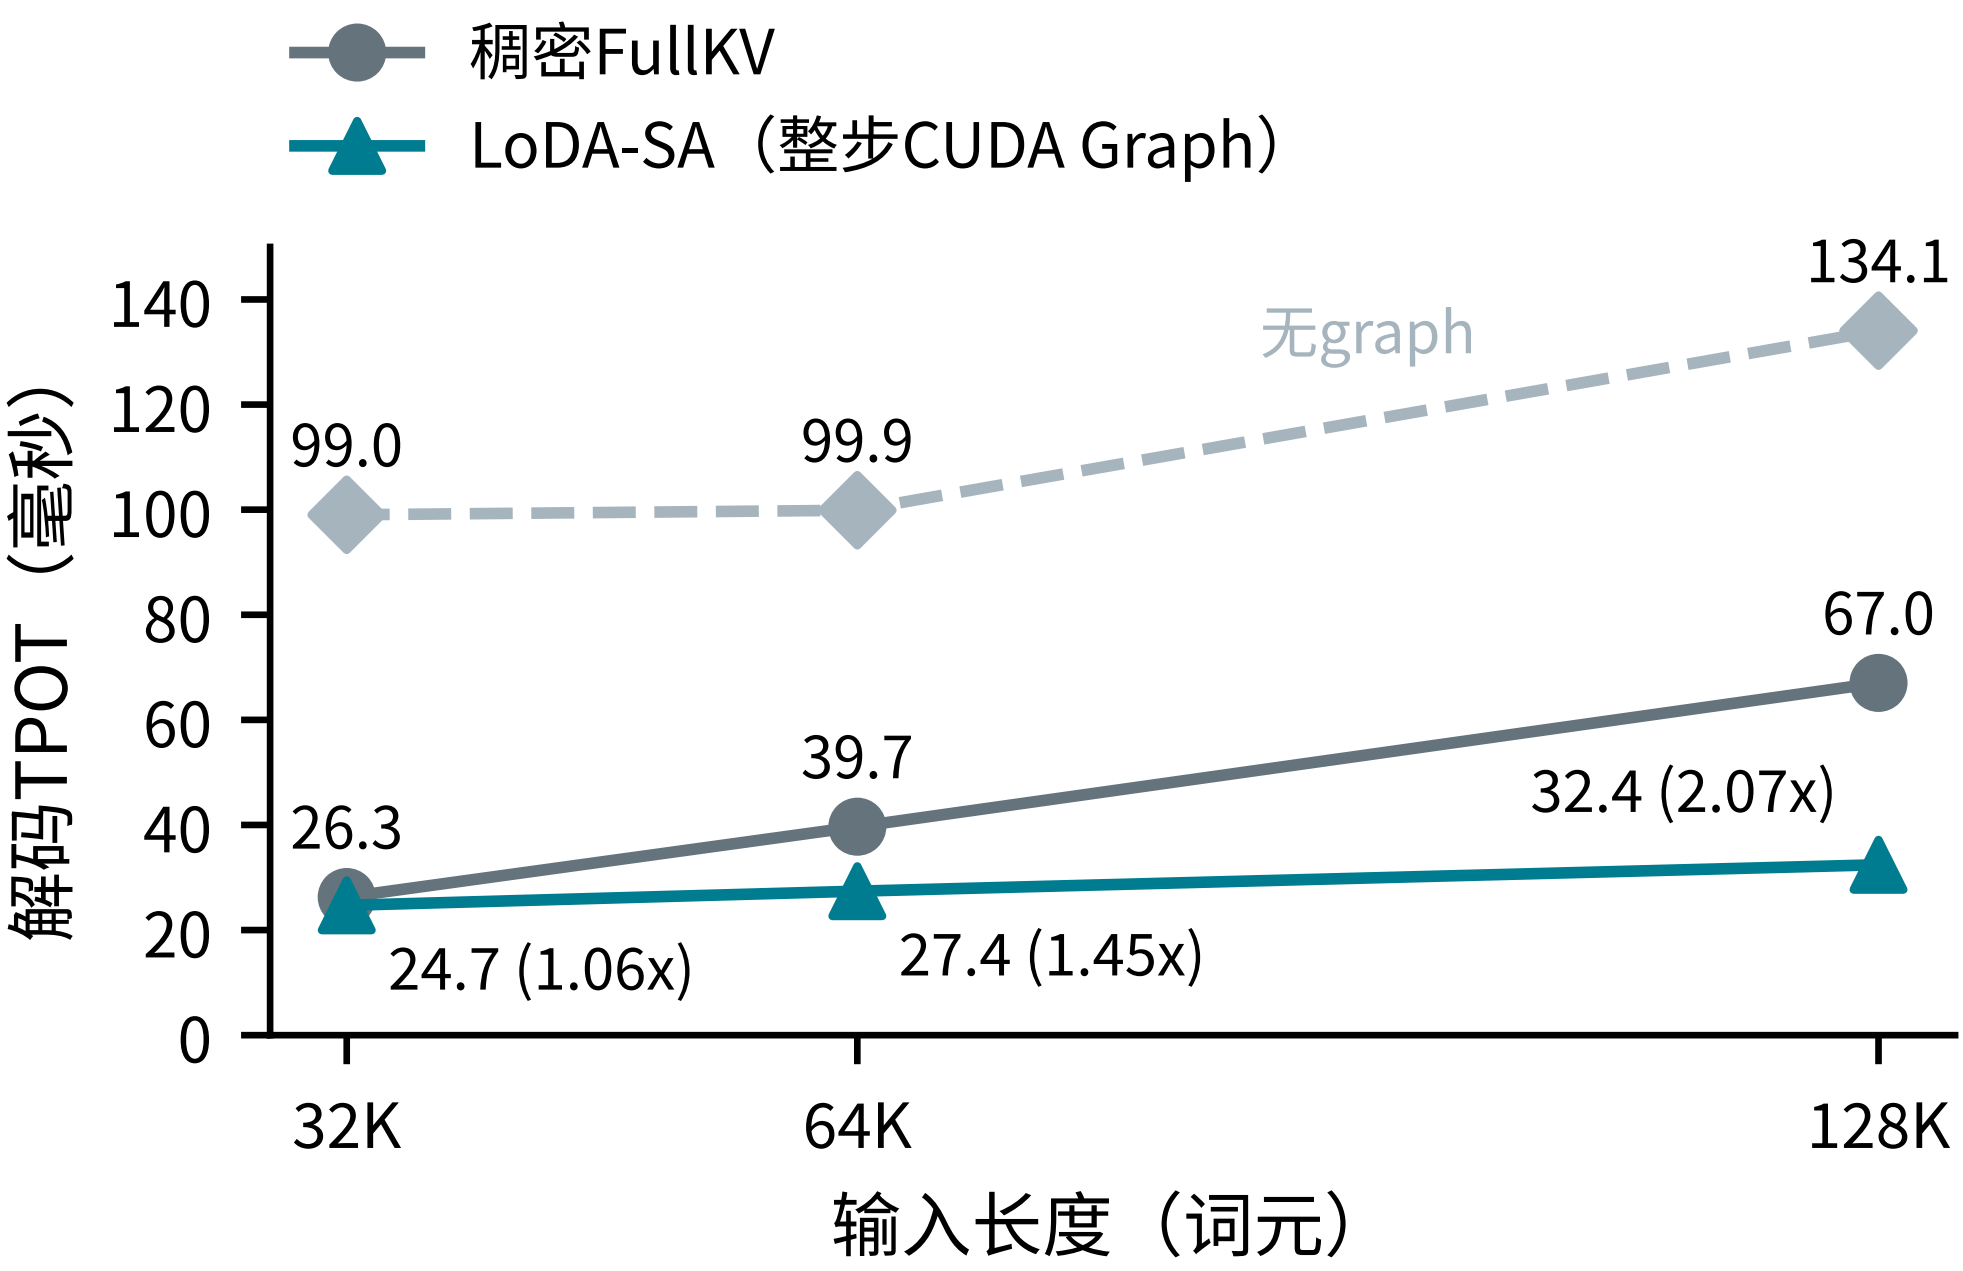
稠密FullKV
LoDA-SA（整步CUDA Graph）
解码TPOT（毫秒）
输入长度（词元）
140
120
100
80
60
40
20
0
32K
64K
128K
无graph
134.1
99.0
99.9
67.0
39.7
32.4 (2.07x)
26.3
24.7 (1.06x)
27.4 (1.45x)