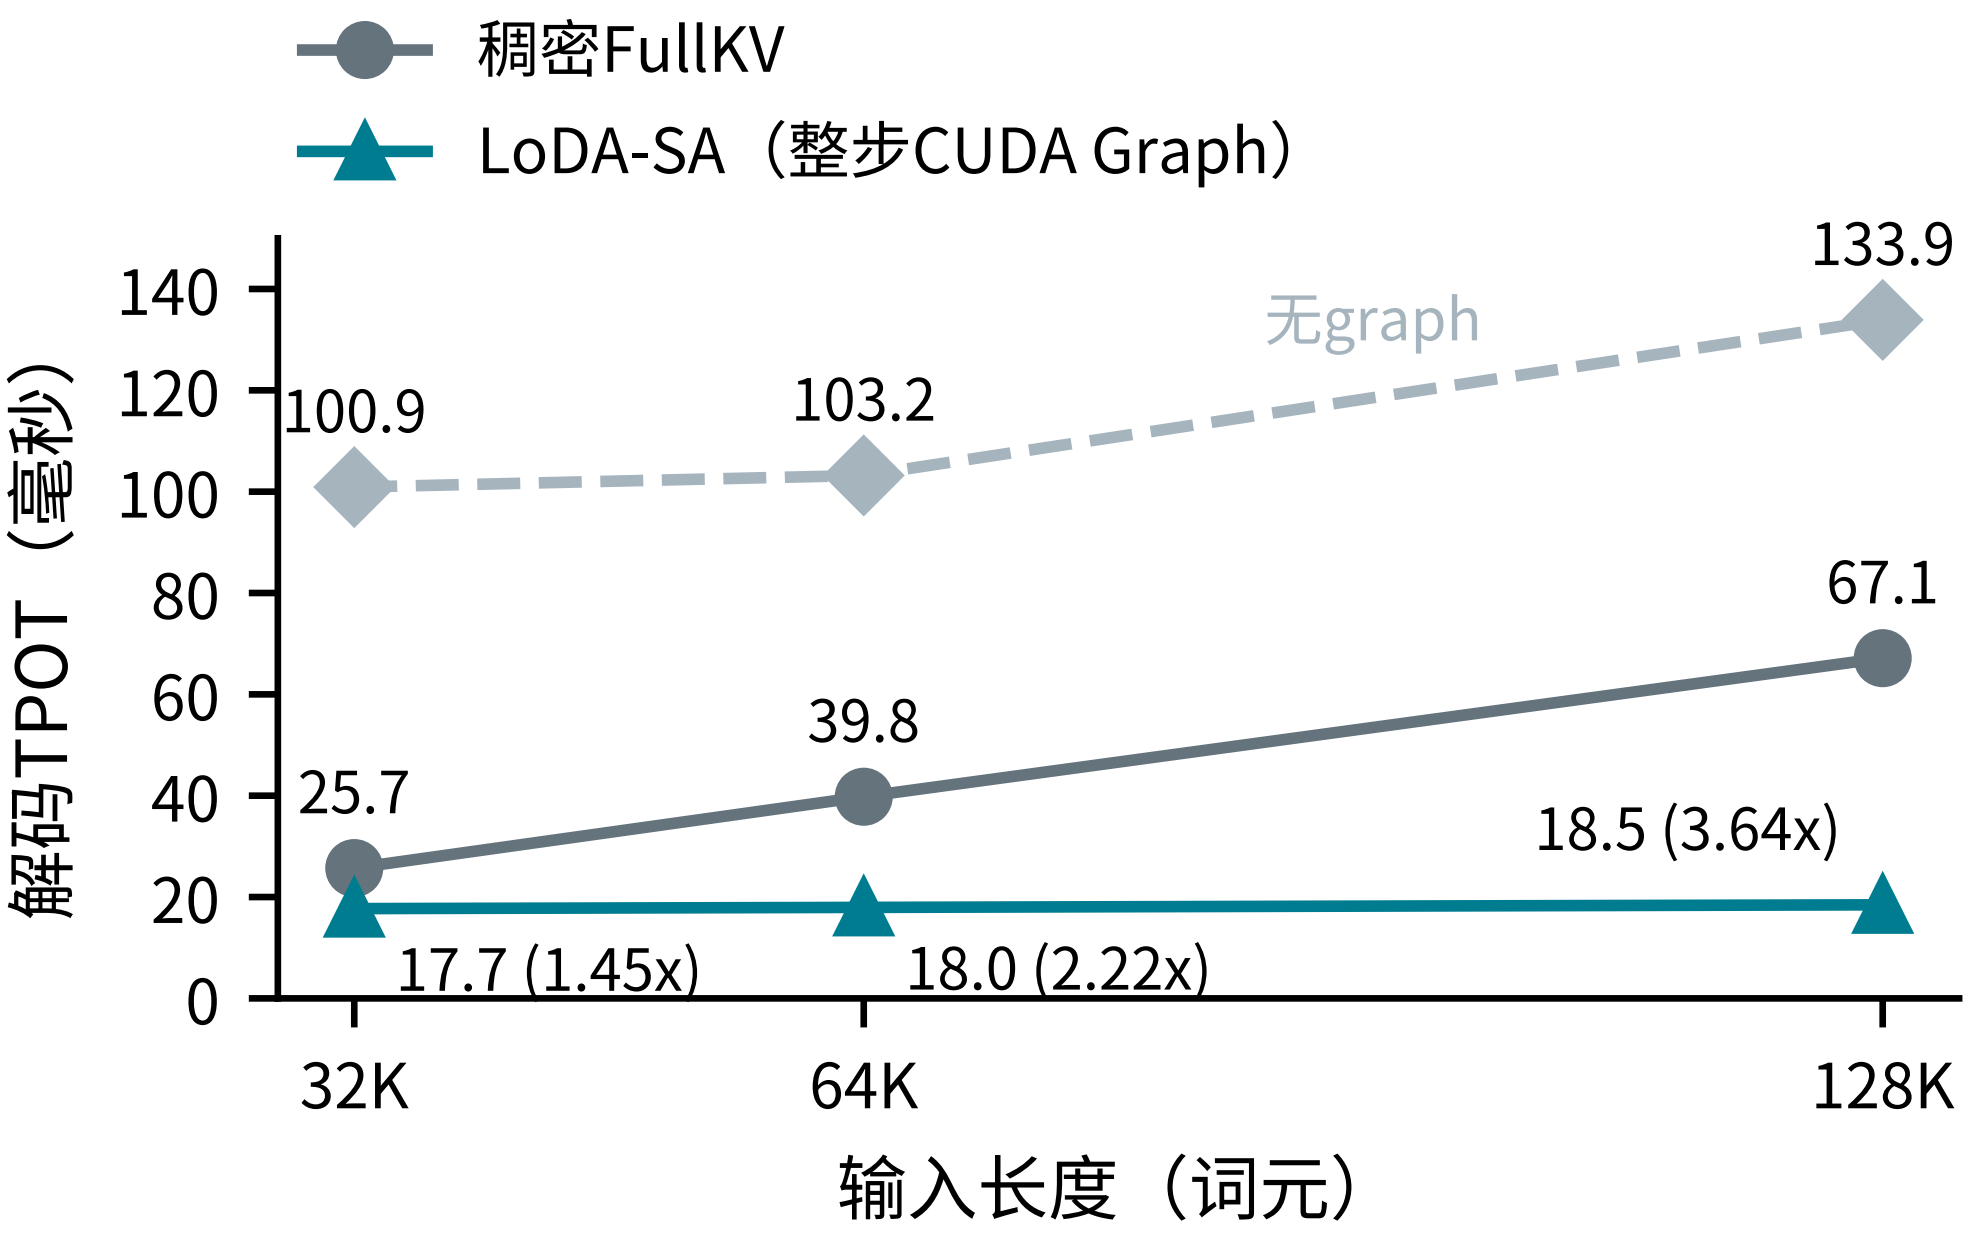
稠密FullKV
LoDA-SA（整步CUDA Graph）
解码TPOT（毫秒）
140
120
100
80
60
40
20
0
无graph
133.9
100.9
103.2
67.1
39.8
25.7
18.5 (3.64x)
17.7 (1.45x)
18.0 (2.22x)
32K
64K
128K
输入长度（词元）