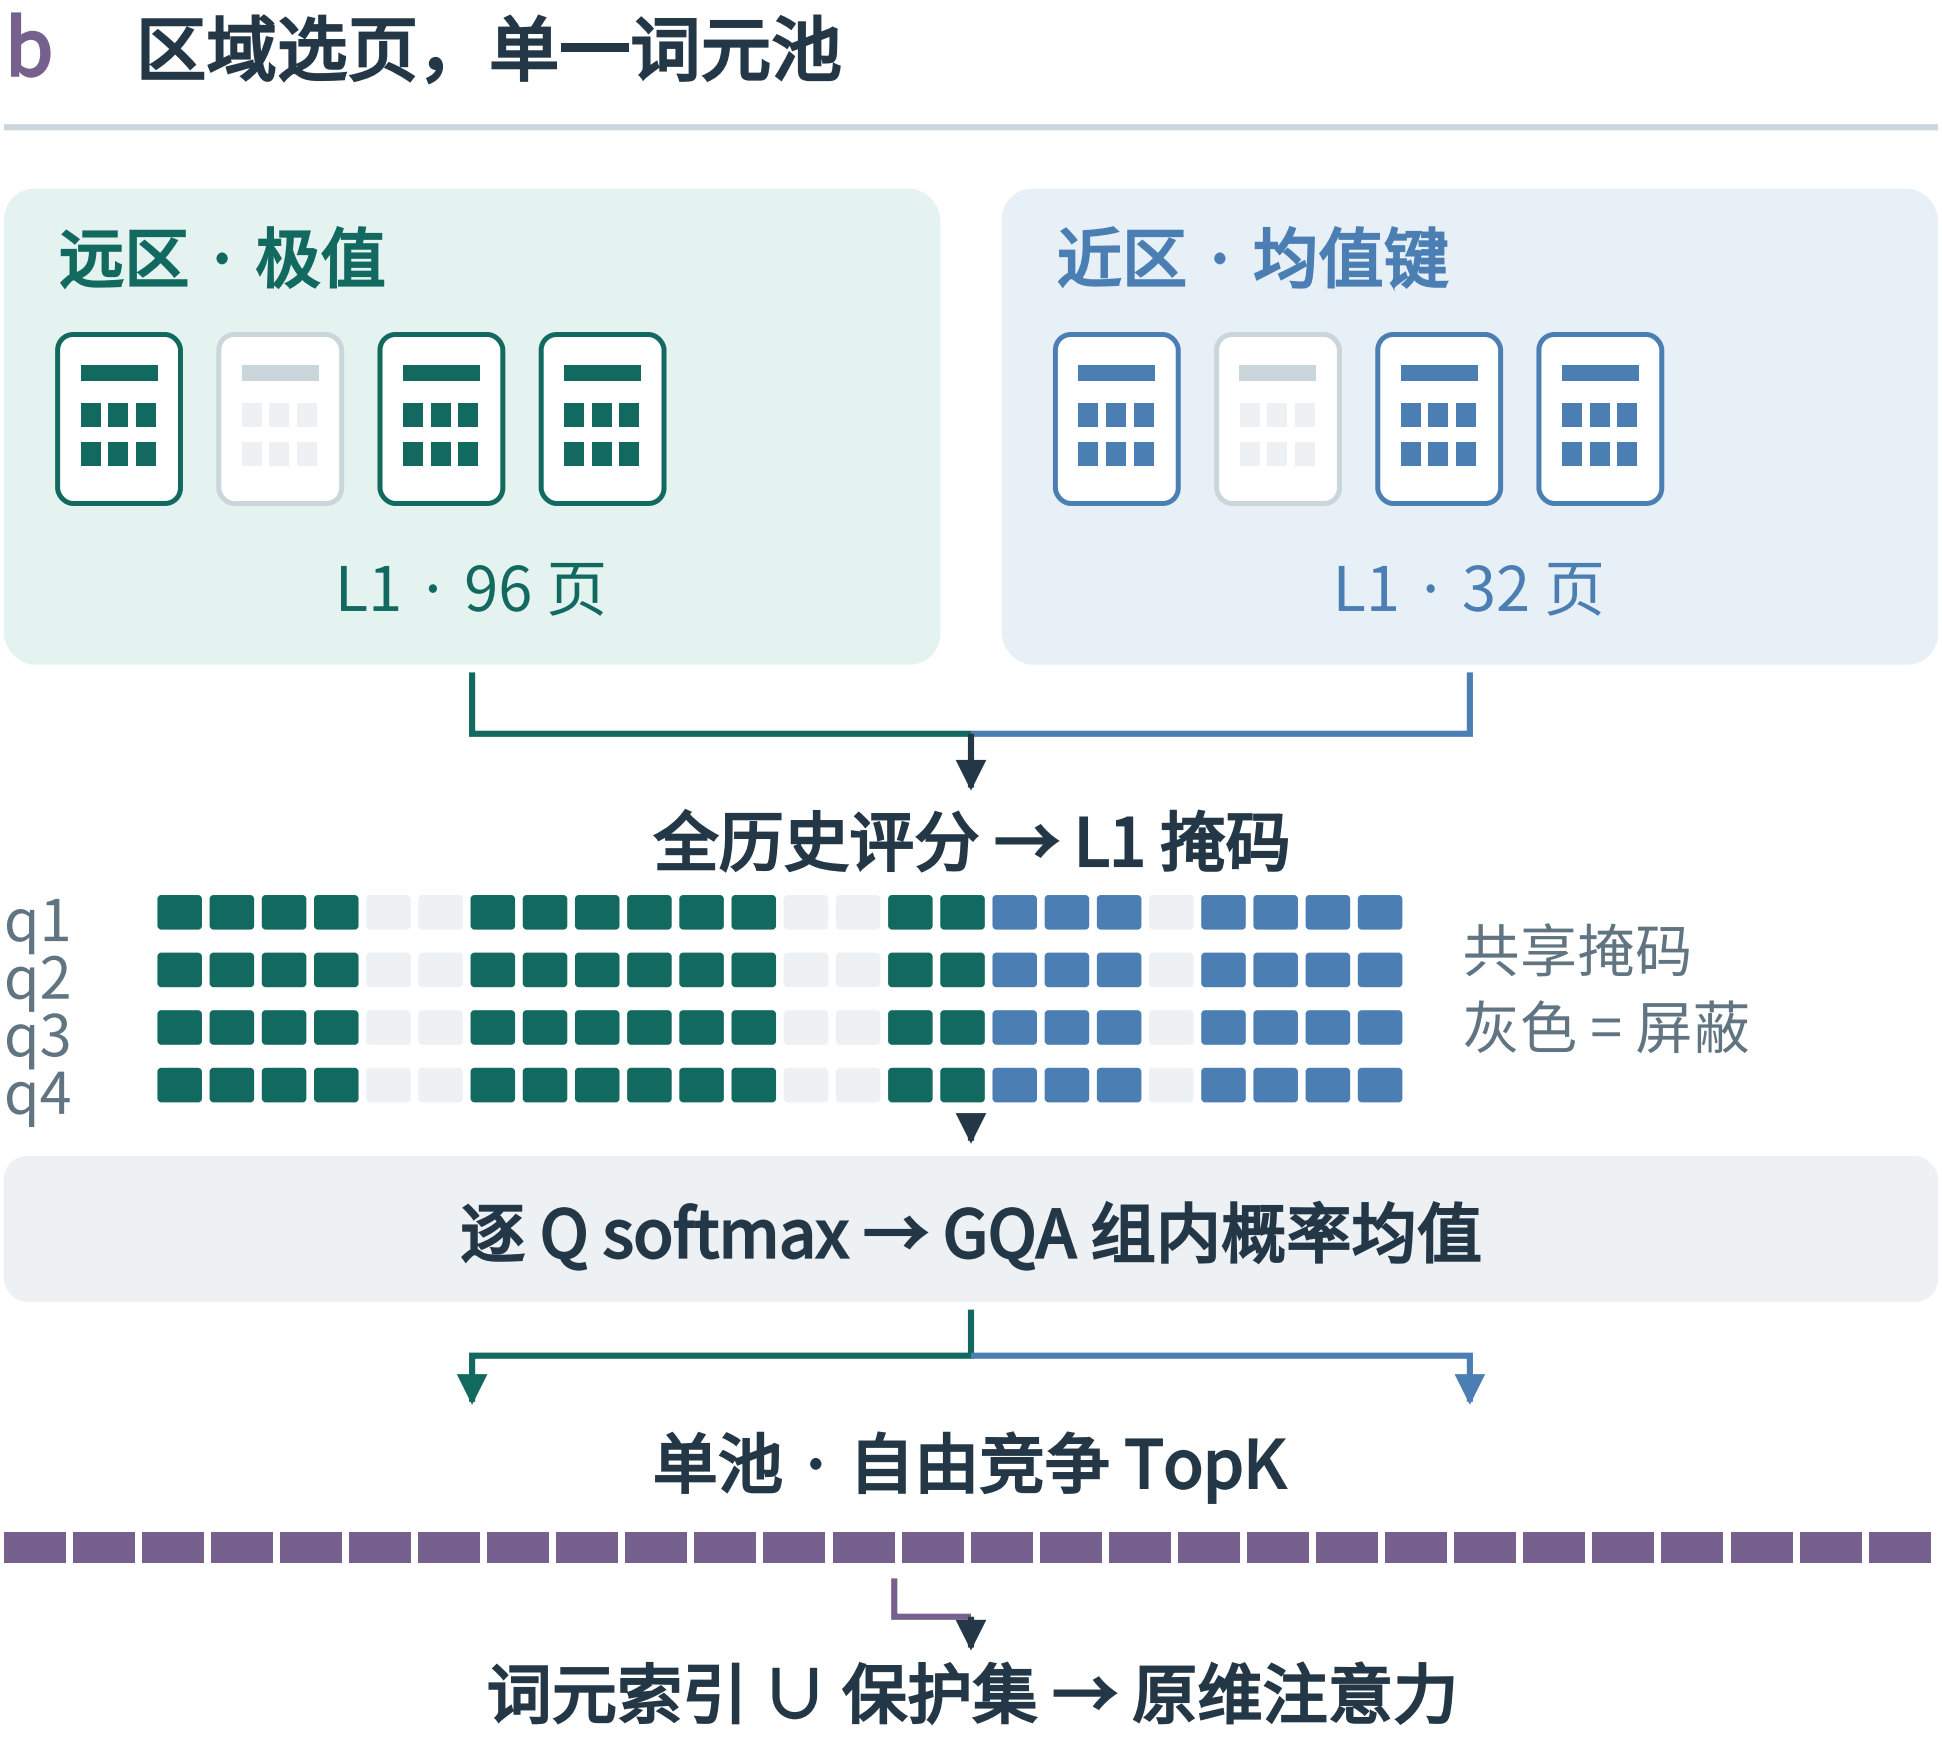

b 区域选页，单一词元池
远区 · 极值
L1 · 96 页
近区 · 均值键
L1 · 32 页
全历史评分 → L1 掩码
q1
q2
q3
q4
共享掩码
灰色 = 屏蔽
逐 Q softmax → GQA 组内概率均值
单池 · 自由竞争 TopK
词元索引 ∪ 保护集 → 原维注意力