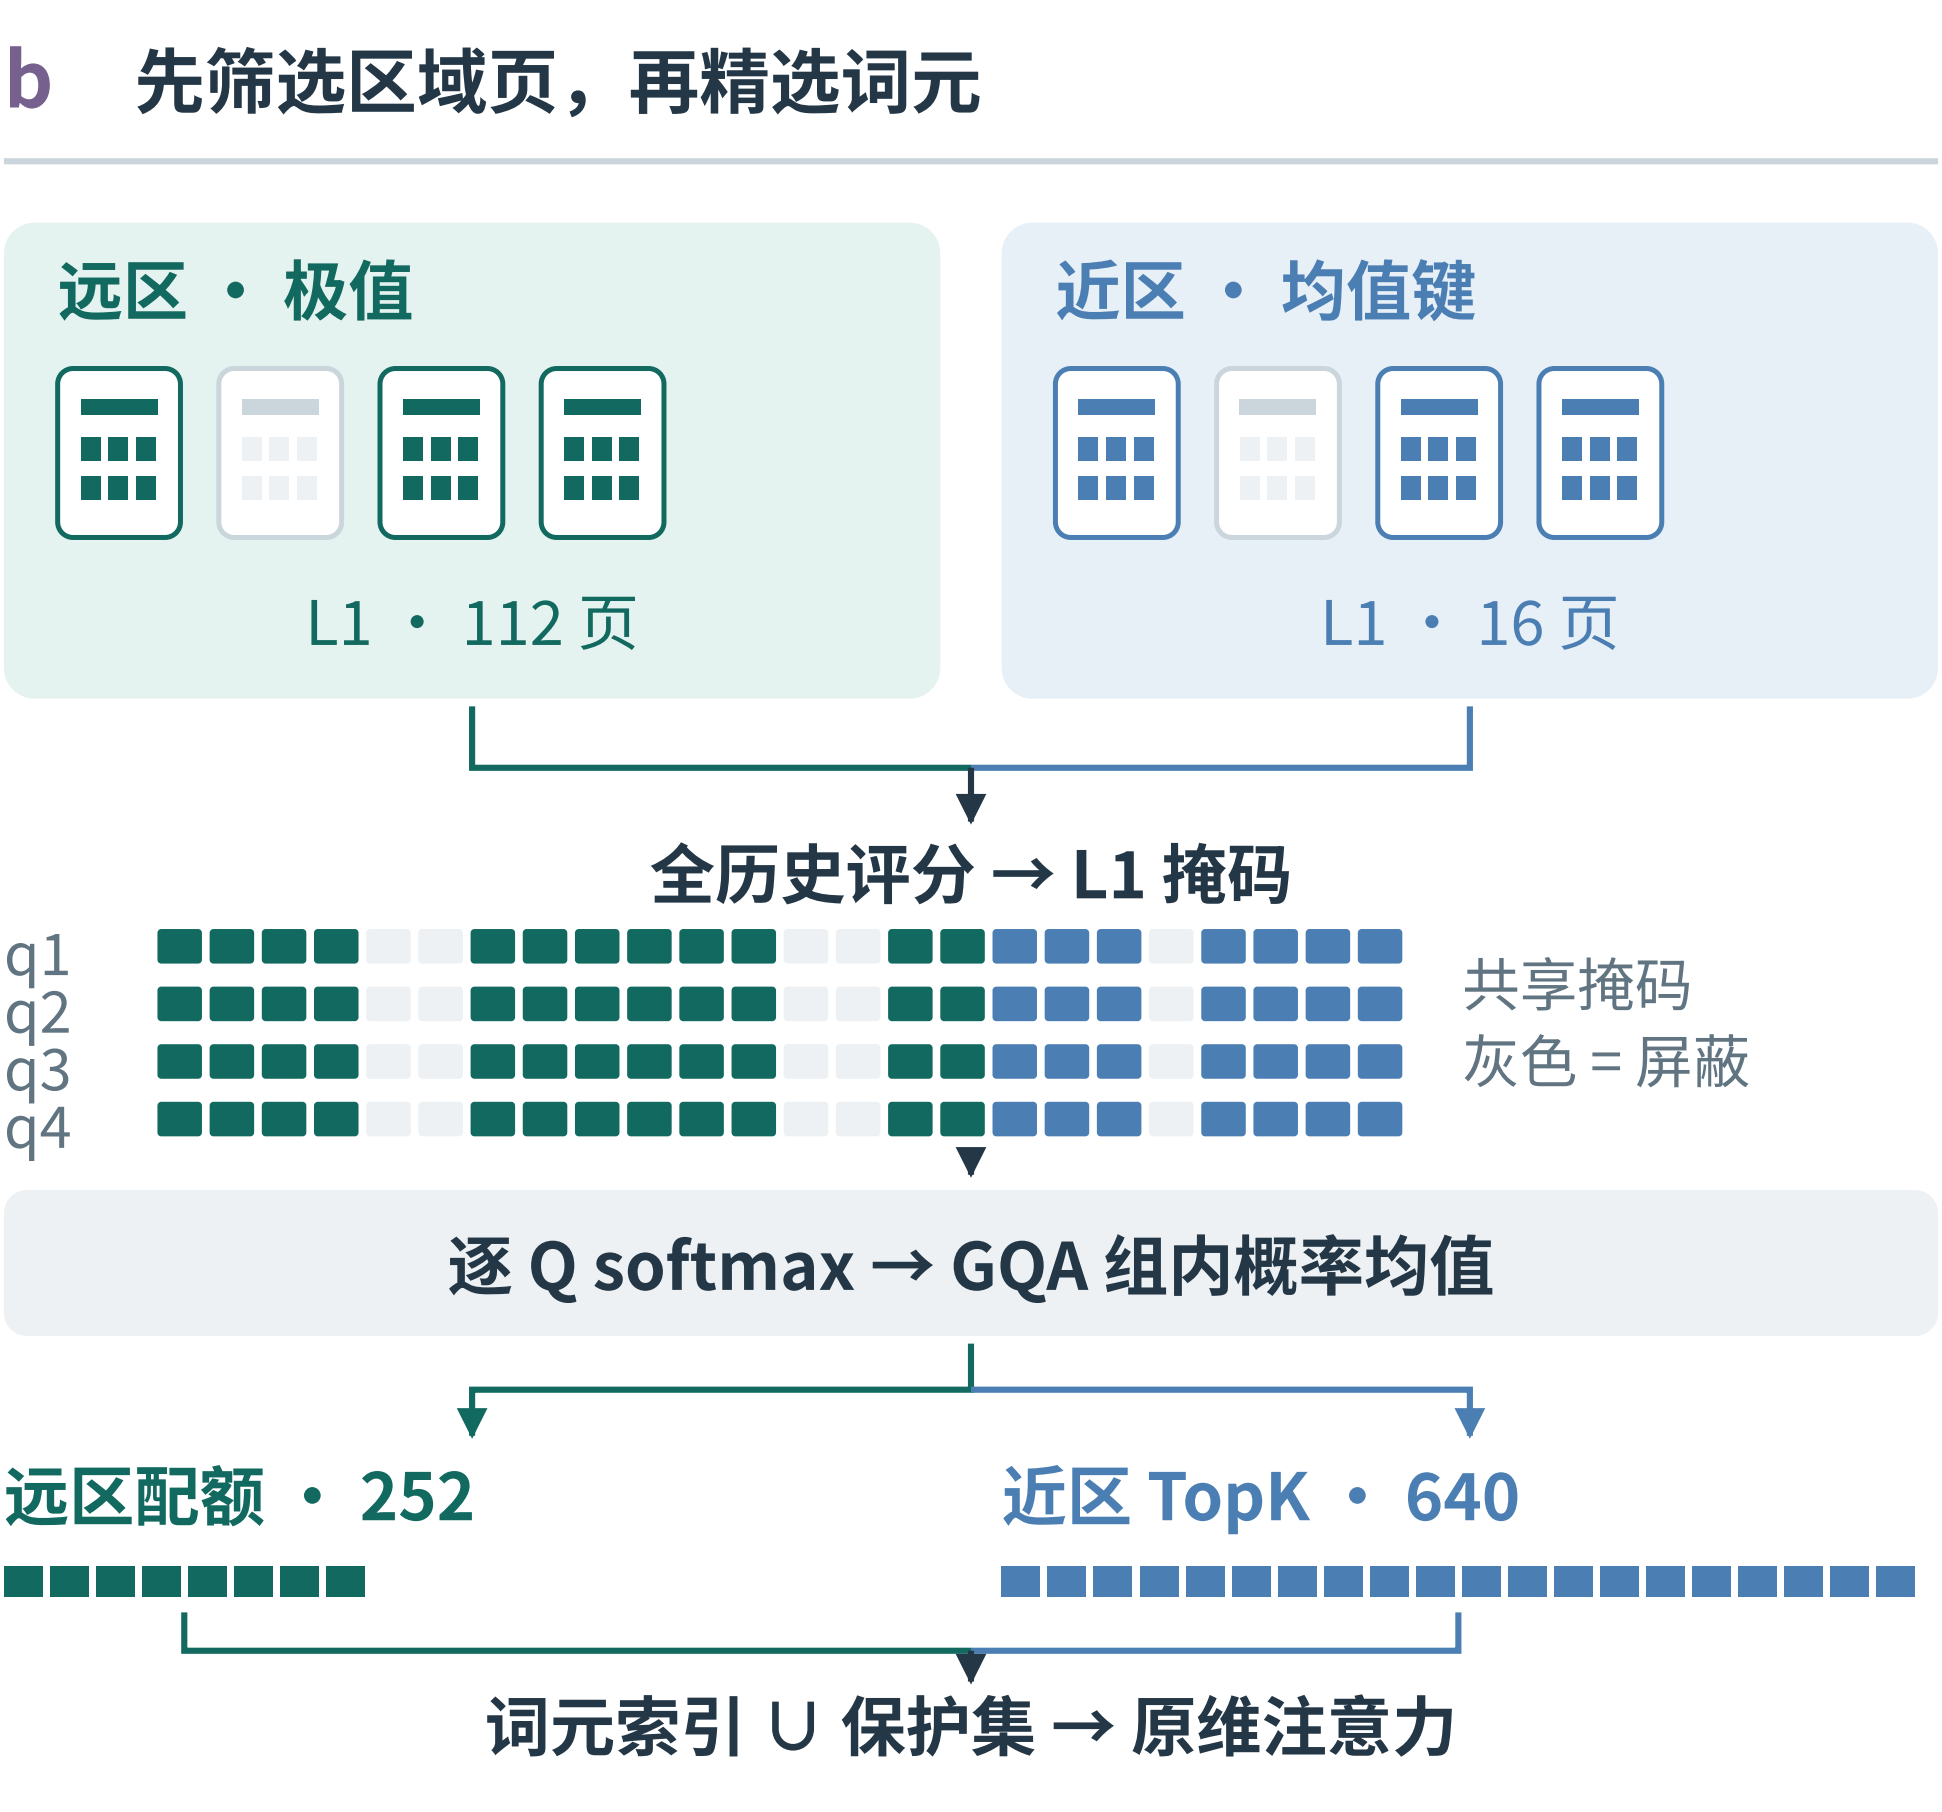
b 先筛选区域页，再精选词元
远区 · 极值
L1 · 112 页
近区 · 均值键
L1 · 16 页
全历史评分 → L1 掩码
q1
q2
q3
q4
共享掩码
灰色 = 屏蔽
逐 Q softmax → GQA 组内概率均值
远区配额 · 252
近区 TopK · 640
词元索引 ∪ 保护集 → 原维注意力