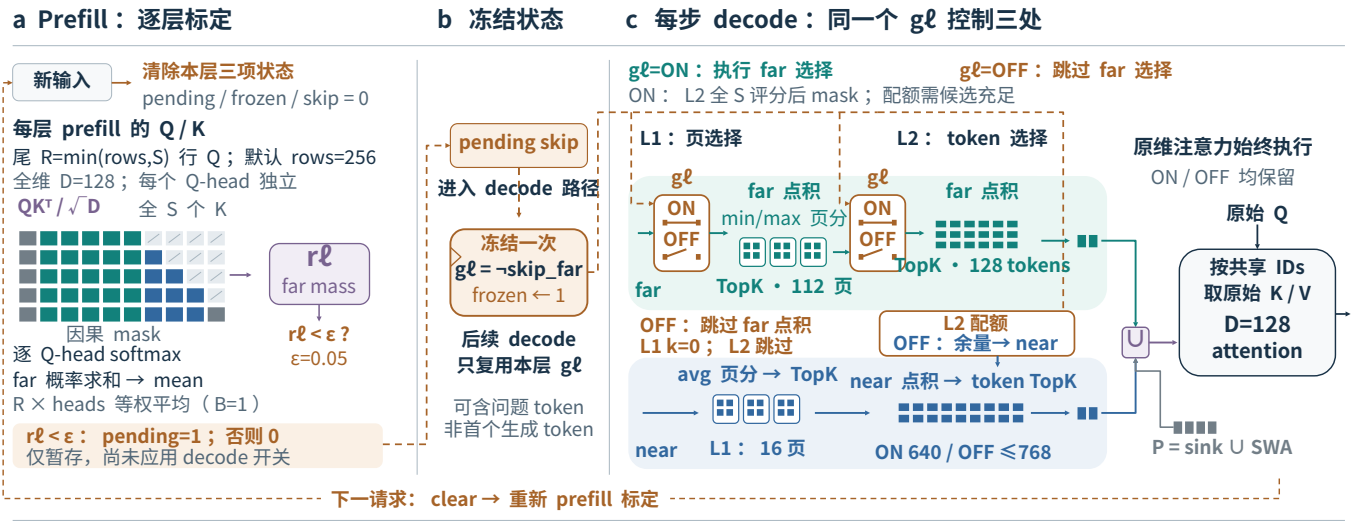

a Prefill： 逐层标定
b 冻结状态
c 每步 decode： 同一个 gℓ 控制三处
新输入
清除本层三项状态
pending / frozen / skip = 0
每层 prefill 的 Q / K
尾 R=min(rows,S) 行 Q； 默认 rows=256
全维 D=128； 每个 Q-head 独立
QKᵀ / √D
全 S 个 K
因果 mask
逐 Q-head softmax
far 概率求和 → mean
R × heads 等权平均（B=1）
rℓ
far mass
rℓ < ε ?
ε=0.05
rℓ < ε： pending=1； 否则 0
仅暂存，尚未应用 decode 开关
pending skip
进入 decode 路径
冻结一次
gℓ = ¬skip_far
frozen ← 1
后续 decode
只复用本层 gℓ
可含问题 token
非首个生成 token
gℓ=ON： 执行 far 选择
ON： L2 全 S 评分后 mask； 配额需候选充足
gℓ=OFF： 跳过 far 选择
L1： 页选择
L2： token 选择
gℓ
ON
OFF
far 点积
min/max 页分
far
TopK · 112 页
TopK · 128 tokens
OFF： 跳过 far 点积
L1 k=0； L2 跳过
L2 配额
OFF： 余量→ near
avg 页分→ TopK
near 点积→ token TopK
near
L1： 16 页
ON 640 / OFF ⩽768
U
原维注意力始终执行
ON / OFF 均保留
原始 Q
按共享 IDs
取原始 K / V
D=128
attention
P = sink ∪ SWA
下一请求： clear→ 重新 prefill 标定