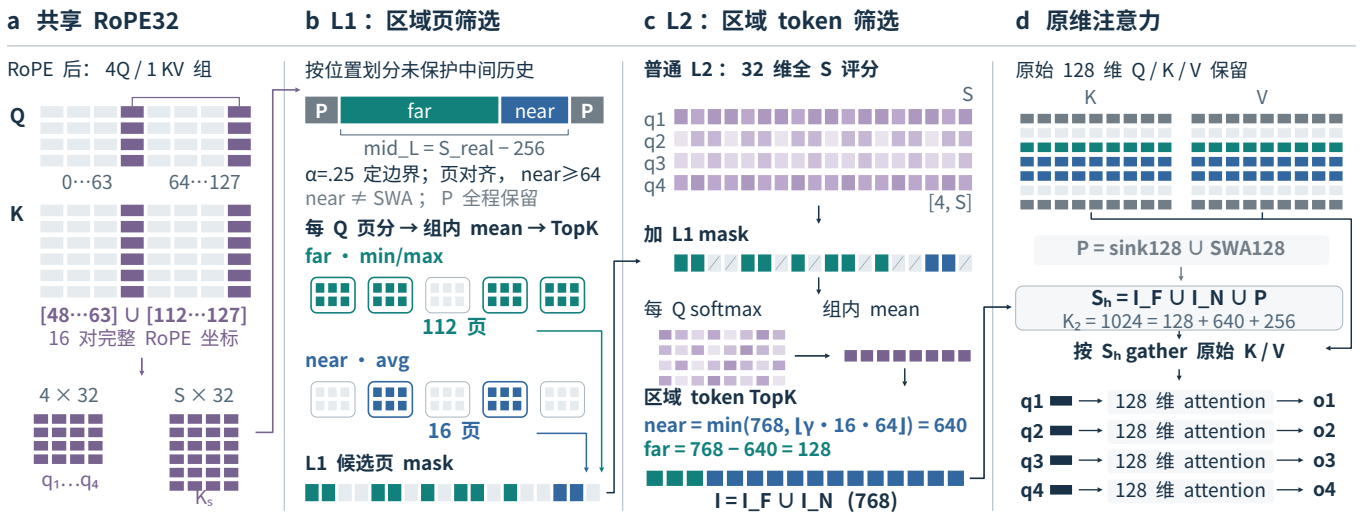

a 共享 RoPE32
RoPE 后：4Q / 1 KV 组
Q
K
0···63
64···127
[48···63] ∪ [112···127]
16 对完整 RoPE 坐标
4 × 32
S × 32
q1…q4
Ks
b L1：区域页筛选
按位置划分未保护中间历史
P
far
near
P
mid_L = S_real − 256
α=.25 定边界；页对齐， near≥64
near ≠ SWA； P 全程保留
每 Q 页分 → 组内 mean → TopK
far · min/max
112 页
near · avg
16 页
L1 候选页 mask
c L2：区域 token 筛选
普通 L2： 32 维全 S 评分
S
q1
q2
q3
q4
[4, S]
加 L1 mask
每 Q softmax
组内 mean
区域 token TopK
near = min(768, ⌊γ · 16 · 64⌋) = 640
far = 768 − 640 = 128
I = I_F ∪ I_N (768)
d 原维注意力
原始 128 维 Q / K / V 保留
K
V
P = sink128 ∪ SWA128
Sh = I_F ∪ I_N ∪ P
K2 = 1024 = 128 + 640 + 256
按 Sh gather 原始 K / V
q1 → 128 维 attention → o1
q2 → 128 维 attention → o2
q3 → 128 维 attention → o3
q4 → 128 维 attention → o4
L1 / L2 复用同一 RoPE32
K1=128； β=.125 → near16 / far112 页
4Q 共享 IDs，各自计算
最终 attention 权重