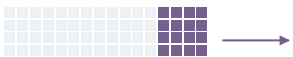
共享子空间近远区域选择

01 共享评分视图

RoPE 后 Q / K



128 维 → 32 维

16 个完整旋转对

原始 Q/K/V

02 区域 L1

远区：极值



96 页

近区：均值键



16 页

03 词元 L2



全历史评分

掩码 → 逐 Q softmax

→ GQA 概率均值

单池 TopK



04 原维注意力

词元索引 ∪ 保护集



聚集原始 K/V

原始 Q · 128 维

每个 Q 独立注意力

原始 Q/K/V 旁路 · 始终保留保护词元

可选远区门控：prefill → 冻结 → 复用；OFF 跳过远区 L1 + L2

默认不启用