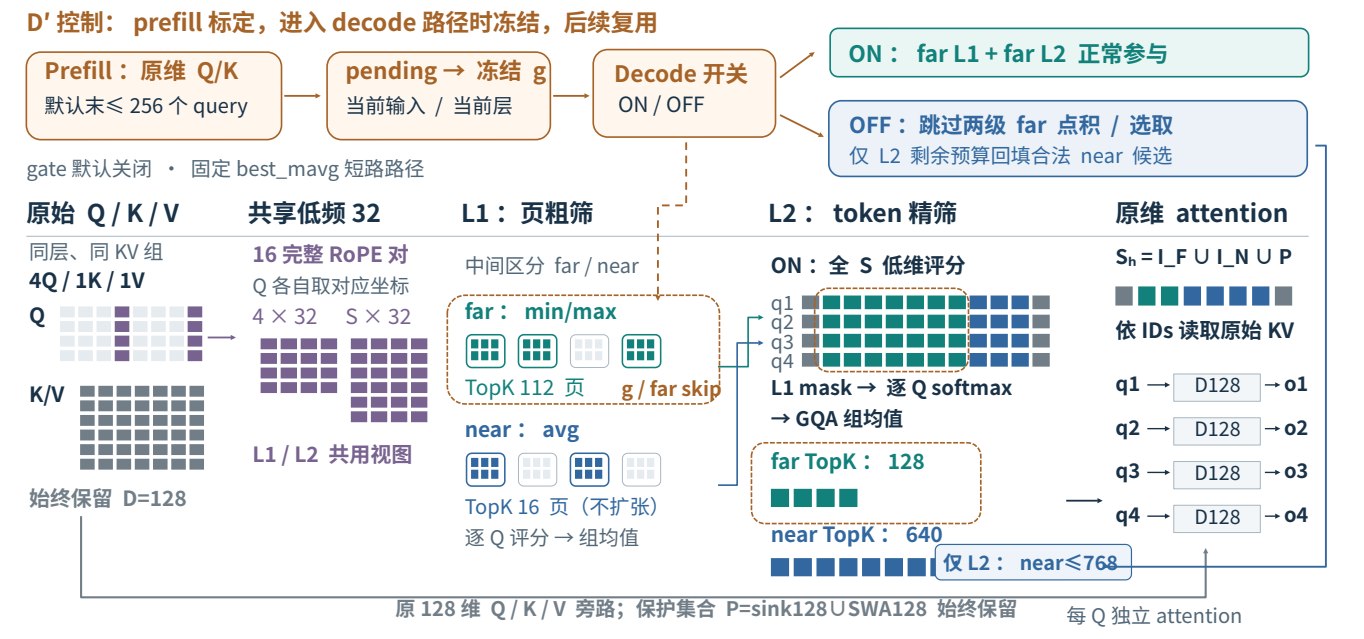

D′ 控制： prefill 标定，进入 decode 路径时冻结，后续复用
Prefill： 原维 Q/K
默认末≤ 256 个 query
pending → 冻结 g
当前输入 / 当前层
Decode 开关
ON / OFF
ON： far L1 + far L2 正常参与
OFF： 跳过两级 far 点积 / 选取
仅 L2 剩余预算回填合法 near 候选
gate 默认关闭 · 固定 best_mavg 短路路径
原始 Q / K / V
同层、同 KV 组
4Q / 1K / 1V
Q
K/V
始终保留 D=128
共享低频 32
16 完整 RoPE 对
Q 各自取对应坐标
4 × 32 S × 32
L1 / L2 共用视图
L1： 页粗筛
中间区分 far / near
far： min/max
TopK 112 页 g / far skip
near： avg
TopK 16 页（不扩张）
逐 Q 评分 → 组均值
L2： token 精筛
ON： 全 S 低维评分
q1
q2
q3
q4
L1 mask → 逐 Q softmax
→ GQA 组均值
far TopK： 128
near TopK： 640
仅 L2： near≤768
原维 attention
Sh = I_F ∪ I_N ∪ P
依 IDs 读取原始 KV
q1 → D128 → o1
q2 → D128 → o2
q3 → D128 → o3
q4 → D128 → o4
原 128 维 Q / K / V 旁路；保护集合 P=sink128∪SWA128 始终保留
每 Q 独立 attention