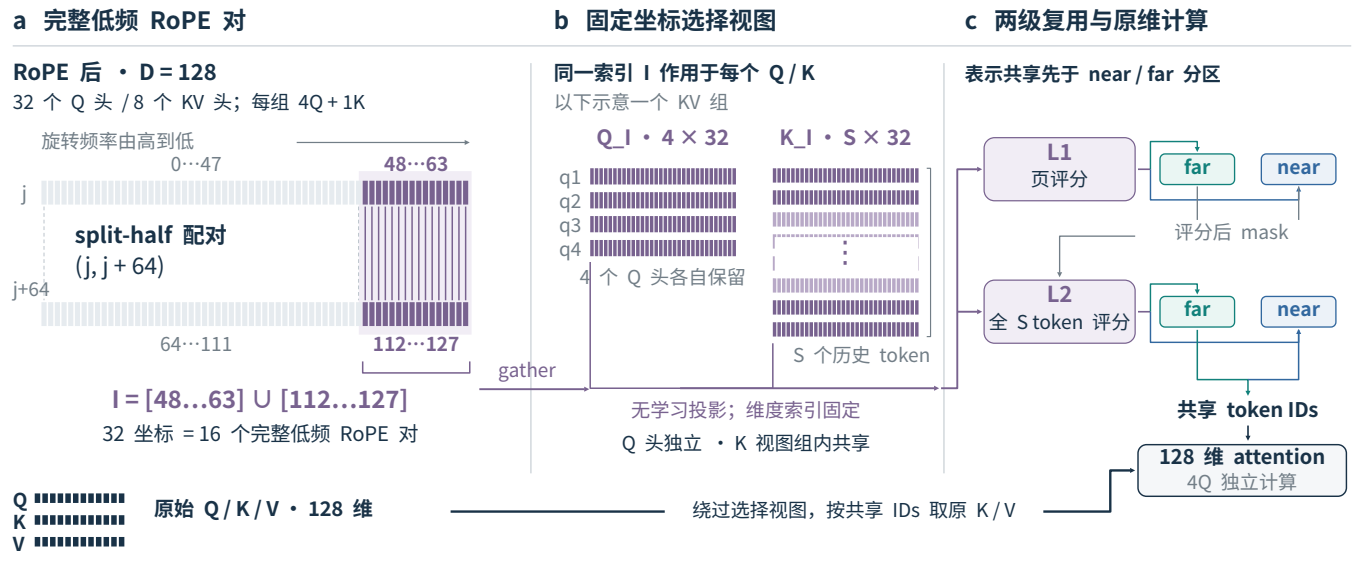

a 完整低频 RoPE 对
RoPE 后 · D = 128
32 个 Q 头 / 8 个 KV 头；每组 4Q + 1K
旋转频率由高到低
0⋯47
48⋯63
j
split-half 配对
(j, j + 64)
j+64
64⋯111
112⋯127
I = [48...63] ∪ [112...127]
32 坐标 = 16 个完整低频 RoPE 对
b 固定坐标选择视图
同一索引 I 作用于每个 Q / K
以下示意一个 KV 组
Q_I · 4 × 32
K_I · S × 32
q1
q2
q3
q4
4 个 Q 头各自保留
S 个历史 token
gather
无学习投影；维度索引固定
Q 头独立 · K 视图组内共享
c 两级复用与原维计算
表示共享先于 near / far 分区
L1
页评分
far
near
评分后 mask
L2
全 S token 评分
far
near
共享 token IDs
128 维 attention
4Q 独立计算
Q
K
V
原始 Q / K / V · 128 维
绕过选择视图，按共享 IDs 取原 K / V