基于低频RoPE子空间的近远分区稀疏注意力

匿名作者

摘要—**稀疏注意力的页筛选可能在精筛之前丢弃有用的远端词元，因此评分表示是候选选择的重要设计要素。本文研究一种近远分区级联，其页筛选与词元精筛共享32个低频RoPE坐标，组成16个完整旋转对。独立的区域页配额为近端和远端历史保留候选访问机会，最终注意力使用选中词元的原始全维键和值。在Qwen3-8B的五项LongBench任务上，共享子空间配置在页评分和词元评分中各采用32个有效坐标，平均得分47.588；名义全维页评分变体（128/32个有效坐标）与名义全维词元评分变体（32/128）分别为47.910和47.666。现有记录不足以确认配置匹配，因此这些分数差异仅作描述性比较。独立合成实验中，共享子空间配置相对名义全维页评分变体所报的选择器时延没有下降。这些结果表明，紧凑评分需要与选择质量、包含准备的成本共同评估，尚未建立联合质量–时延优势。**

Index Terms—**稀疏注意力，共享表示，区域检索，长上下文推理**

I. 引言

长上下文稀疏注意力需要保留有用历史，并使选择成本低于省去的注意力成本。两级选择器的页粗筛决定哪些词元进入精筛，下一阶段无法恢复被排除的页。评分维度控制每次比较的算术量，准备、排序与访存也共同构成时延。因此，本文分别研究评分表示与候选分配。

本文研究三项相互关联的选择：共享评分坐标、区域候选配额，以及可选的预填充远区门控（图2）。默认近远级联采用前两项，门控作为单独扩展。每层、每KV头的页筛选和词元精筛采用同一组完整RoPE坐标对。级联为近期未保护历史与其余历史分别分配页配额，使远端词元即使在近区主导页选择时仍能进入精筛。最终注意力在所选词元集合上使用原始全维查询、键和值。共享评分视图减少设计中的表示重复，区域配额控制候选访问机会；二者本身均不保证时延下降或任务质量不变。

区域注意力需求促使我们将候选分配与评分表示分别考察。因此，本文关注区域页配额如何改变固定最终词元预算下的检索、共享紧凑坐标能否保留有用候选，以及注意力节省能否覆盖准备和选择成本。存档坐标诊断为这种区分提供动机，但不能将频率效应与坐标配对结构分离，也不能代表实际区域评分器的表现。逐层预填充统计同样为测试可选门控提供动机；门控属于近似策略，不假定预填充统计能够约束解码阶段的远区需求（补充注S6）。受ClusterKV词元／页视角 [7]启发，图1展示Qwen3-8B归档稠密参考的距离密度与可行整箱捕获诊断。所观察的区域注意力保留率不同，但不能证明选择器保真或任务质量，现有得分与局部计时也不能隔离阶段效应或建立联合质量–时延优势。

II. 相关工作

Quest、SparQ与HISA等查询感知检索方法通过近似选择缩小注意力集合 [1], [2], [3]。AsyncTLS提供了页到词元级联稀疏选择的先例 [4]。本文关注共享低频RoPE评分视图与近远区域独立页配额，能否在固定最终词元预算下保留有用候选。这一区分将评分表示、区域分配与执行调度分别考察；其质量与包含准备的成本仍需匹配评估。

KV压缩与放置方法关注互补的存储容量和数据移动约束 [5], [6], [7]。本文保留原始键和值，改变的是词元选择。因此，紧凑评分表示不会相应缩减原始KV缓存容量。

III. 共享子空间内的近远筛选

图2区分共享子空间评分与原维注意力。L1预留近远区域页，L2沿用相同坐标对词元排序。选中词元索引与保护集定义原始K/V注意力集合，各查询使用自身原始Q。区域配额控制候选访问机会，普通L2仍先计算全历史评分再施加掩码。

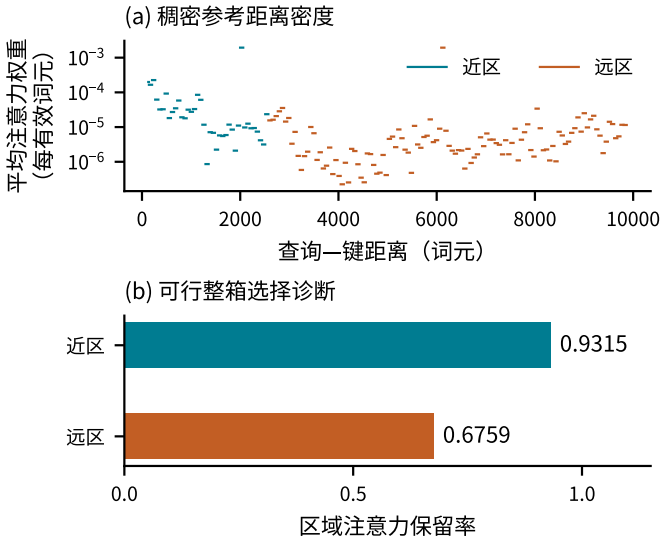


图 1. Qwen3-8B归档诊断，保护为128/128。(a) 一个MuSiQue查询（样本1、层24、位置9996）的每个有效词元的平均注意力权重。(b) 四条源序列贡献128条相关查询／层观测。近区／远区注意力保留率，均为同一全局整箱选集在该区域的选中权重和除以区域总权重（每条观测中间词元上限2048）。选择作用于查询头及八个KV组平均后的概率（补充注S6）。这不是方法的$K = 1024$策略、最优参照或精确集中度。

A. 共享低频坐标

本文评估的Qwen3-8B表示从128维RoPE后Q/K中选择 $J = \{48, \dots, 63, 112, \dots, 127\}$，即16个完整低频旋转对。较慢的位置相位变化为考察这组紧凑评分坐标提供了动机，但不保证更高的检索保真度，后者仍取决于查询与键的内容。它不是连续最后32维，也不是学习投影。当前共享子空间实现紧凑存储32坐标；历史LongBench实现则在128维L2张量中保留32个有效坐标（补充注S7）。令$E_J \in \mathbb{R}^{128\times 32}$为坐标选择矩阵，则$z_q = E_J^\top q$、$z_i = E_J^\top k_i$。每层、每KV头为两区域和两阶段准备同一键视图，查询头各自保留评分分布（图2a及补充图S1）。最终注意力及后续查询仍可访问原始全维KV，因此本设计不节省原KV缓存容量。

两级使用同一固定坐标映射E_J。对键矩阵$\mathbf{K}$和区域行选择算子R，$R(\mathbf{K}E_J) = (R\mathbf{K})E_J$：区域选择保持评分坐标一致。L1从这些坐标派生页摘要，L2派生量化–反量化词元键，两者无须共享物理缓冲区。最终词元掩码指向原始全维键和值。追加键、移动区域边界及改变坐标映射时，派生视图、逻辑词元索引和区域归属须保持一致；该恒等式本身并未规定增量维护方式。净时延取决于这些视图的准备与维护、选择及后端KV访问，尚未证实有所下降。

B. 区域页配额与词元配额

在解码过程中，令t表示当前词元在完整序列中从0计数的位置（包含预填充词元），于是$S = t + 1$表示包含当前位置、排除填充位置的有效缓存位置数。s与w分别表示受保护前缀和近期窗

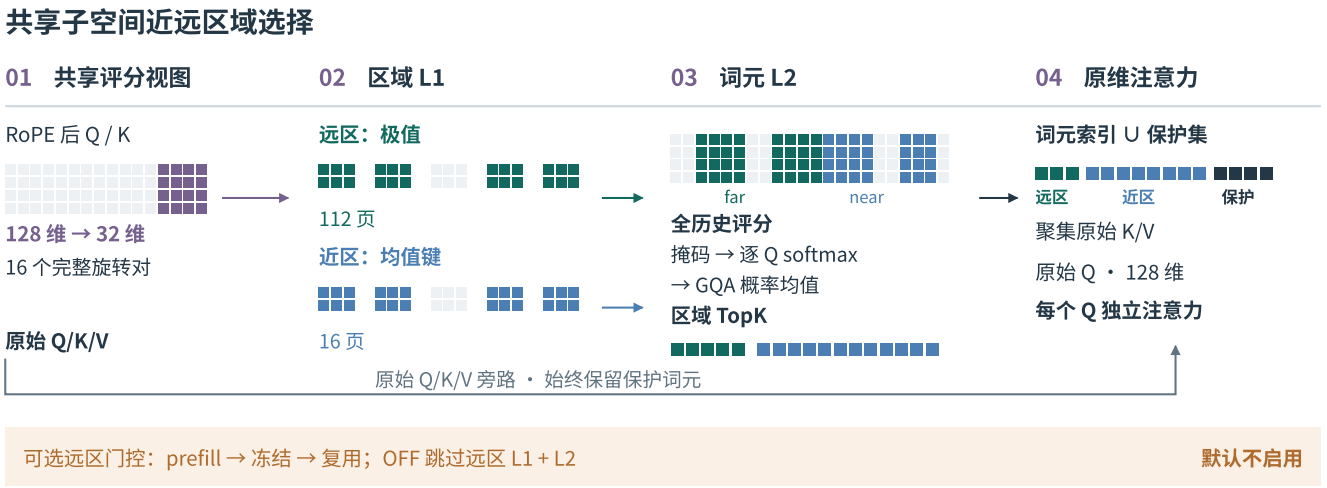


图 2. 共享子空间筛选与原始Q/K/V旁路。L1保留区域页；L2对全历史评分施加掩码，逐查询在共享候选集上归一化，再对KV组内概率取均值并精选区域词元。可选门控为OFF时，跳过远区评分，并将可用L2余量回填近区候选。图中配额为候选充足时的示例。

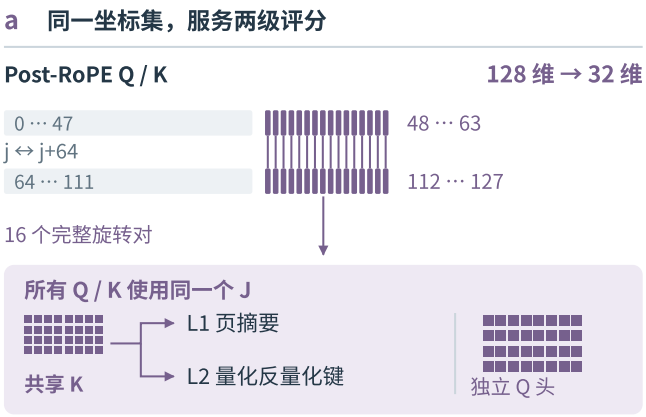


图 2a. 16个完整split-half RoPE旋转对构成32坐标评分视图。每层、每KV头基于相同坐标生成L1页摘要与量化–反量化的L2键，查询视图各自保留。原始Q/K/V绕过这些派生视图（图2）。

口的长度。保护并集与未保护中间区为：

$$\mathcal{P}_t = \{i : 0 \le i \le t,\ i < s \text{ 或 } i > t - w\}, \tag{1}$$

$$\mathcal{M}_t = \{0, \dots, t\} \setminus \mathcal{P}_t. \tag{2}$$

保护重叠仅计一次。近区是未保护中间历史的后缀，远区为其余部分；近区与受保护滑动窗口不同。近区边界由未保护历史的比例α结合最小页与页对齐规则确定；中间长度为$\max(0, S - |\mathcal{P}_t|)$。默认参数见实验设置。

图2b展示区域级联。近区采用平均键页评分，远区在共享空间采用符号感知极值。对非空区域页b定义$m_{b,j} = \min_{i \in b} z_{i,j}$与$M_{b,j} = \max_{i \in b} z_{i,j}$，Quest极值构造 [1]给出

$$U_b(z_q) = \sum_j (z^+_{q,j} M_{b,j} + z^-_{q,j} m_{b,j}), \tag{3}$$

其中$z^+ = \max(z, 0)$、$z^- = \min(z, 0)$。它仅上界未量化共享空间点积，不自动上界原维logits或另行量化的评分。不同维极值可能来自不同词元，有限页筛选仍会漏掉重要词元；平均键评分也不继承该上界。

$K_1 = 128$、$\beta = .125$分配近区16页与远区112页。区域保留提供候选访问机会，却不保证质量：远端页会占用本可分给近端的容量。L1丢弃某页后，后续词元配额不能恢复其词元；因此区域L1与先全局筛页再分区属于不同策略。

对每个KV头h，设计上的区域候选集由保留页中的有效词元构成。下述示例假定这些候选足以填满配额。在支持的预算范围$K \ge |\mathcal{P}_t|$内，中间配额为$K_{\text{mid}} = K - |\mathcal{P}_t|$。在源码推导的历史长度充足示例中，每头总配额$K = 1024$扣除不重叠保护后，中间名义配额剩892（补充图S2）。在候选充足的标准配置下，$\gamma = .625$作用于近区页容量，产生$16 \cdot 64 \cdot .625 = 640$个近区与252个远区槽位。当前选定配置保护4个前缀和128个近期词元。4个前缀不足一整页，远区选择可能再次选中至多4个保护位置；252属于名义配额，并非保证得到252个非保护远区词元。候选不足及零值并列行为详见补充注S7。

C. GQA聚合与原维注意力

在分组查询注意力（GQA）中，32个查询头与8个KV头对应每个KV组4个查询头。L1对组内查询的页分数取平均再做区域TopK。普通L2对每个查询计算全历史低维分数，施加共享L1掩码，并在KV组内对各查询独立归一化后的概率取平均。在该Qwen3实现中，L2 logits在逐查询softmax前仍使用原始头维度对应的$1/\sqrt{128}$缩放，包括采用32个坐标评分的情形。这种概率聚合不同于先平均logits再做softmax。因此，共享坐标仍保留查询各自的分布；而全历史评分意味着，缩小页候选集本身并不会减少L2点积工作量。

组内唯一选集$\mathcal{S}_{t,h}$包含保护与区域选中词元索引，受总配额约束。组内各查询g使用相同词元索引，但以头维度$d = 128$独立重算原维注意力：

$$o_{h,g} = \sum_{i \in \mathcal{S}_{t,h}} \frac{e^{q_{h,g}^\top k_{i,h}/\sqrt{d}}}{\sum_{j \in \mathcal{S}_{t,h}} e^{q_{h,g}^\top k_{j,h}/\sqrt{d}}} v_{i,h}. \tag{4}$$

先合并词元索引再softmax，避免直接相加各区域独立归一化输出 [8]。保留词元使用原KV logit，但缩减分母仍会改变注意力输出。共享词元索引定义相同的原维注意力集合。物理聚集与复用取决于注意力后端和序列长度；所检查的实现还包含短序列稠密回退路径。实际16级表示是浮点量化反量化，不是打包四位存储或INT4算术。

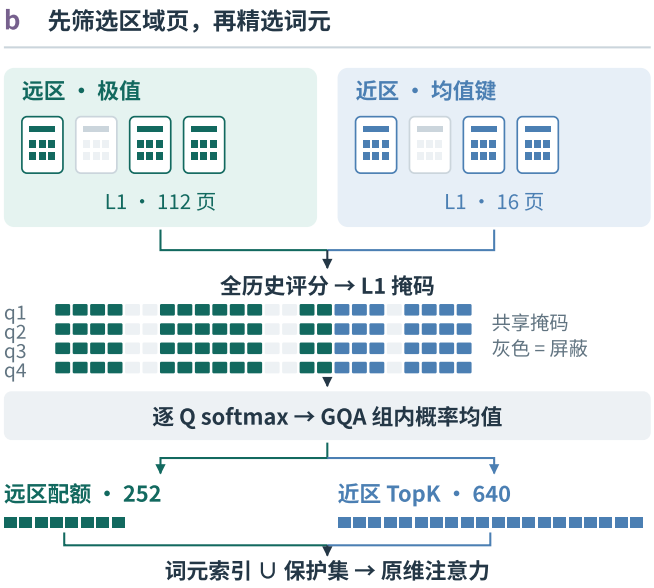


图 2b. 区域筛选与全历史L2评分。彩色单元表示合法候选，并非实测分数。候选容量充足时，当前4/128前缀／近期配置采用远／近区112/16页及名义252/640个区域槽位，另有132个保护词元，总上限$K = 1024$。不足整页的前缀可能重复占用至多4个远区槽位。近区不包含受保护的近期窗口。

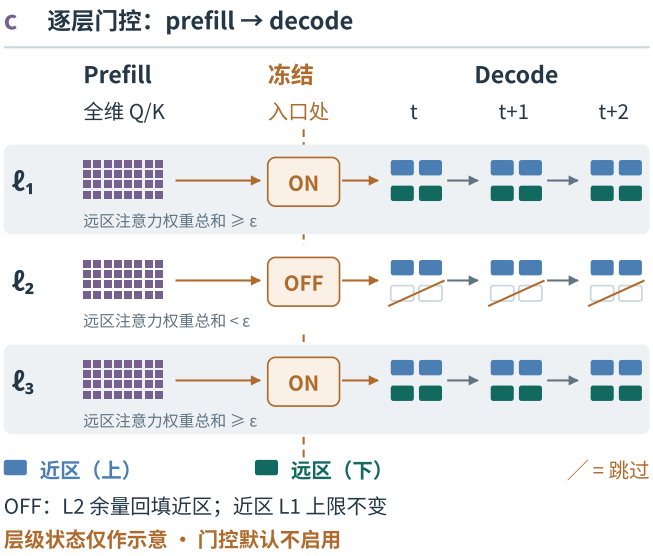


图 2c. 可选远区控制，默认不启用。全维因果预填充远区注意力权重总和在末尾至多256个查询行和全部查询头上取均值，为每个输入、每层确定决策；解码入口冻结，新输入清空。OFF跳过远区L1/L2，在近区页集合不变的前提下回填近区L2。层级状态仅作示意，每对小格分别表示L1/L2。该统计量不约束解码误差。

D. 基于预填充观测的远区门控

可选远区门控（图2）考察预填充观测能否识别可省略重复远区筛选的层。对每个输入、每层，预填充平均远区注意力权重总和低于ϵ时设为OFF，否则继续远区选择；决策在解码入口冻结并复用。该功能默认不启用。在支持的固定数值配额实现上，OFF跳过远区两级评分与选取，并将可用L2余量回填近区候选，近区页预算保持不变。表示准备、序列全长评分缓冲及归一化仍然保留。

图2c展示门控决策与回填。本文实现了单序列门控扩展，其观测边界与状态转换见补充注S5。阈值约束的是预填充统计量，而非后续注意力误差。因此，门控是一种近似策略，其质量和总成本影响需要与默认非门控方法分别评估。

IV. 实验设置

选定的Qwen3-8B候选采用稠密预填充与稀疏解码，固定保护最前面的4个注意力汇聚词元和最近128个词元（表I）。两者去重后的并集计入总词元上限$K = 1024$，其余槽位通过基于内容的选择分配。下述归档五任务得分保留原有配置证据：其中共享子空间运行采用128/128保护，以及128维、32个有效坐标的填零L2键；这些得分不能验证当前4/128候选。选择器在浮点张量中使用16级量化–反量化数值，区别于打包INT4算术。配置与实现细节见补充注S7。

表示与质量。稠密FullKV保留完整注意力范围，作为质量参照；全维稀疏对照则保留稀疏选择，在两级使用全维评分。受控L1/L2双因素比较需要四种模式，并固定评分规则、保护集与模型设置，下文描述性得分尚未完成该比较。稀疏基线的公平性以每个查询注意力行的最终去重词元配额K（含保护）对齐，并采用相同模型、输入、解码阶段和稠密层策略。本文选择器在每个KV组内使用同一选集；同K不意味着跨查询头选集并集或KV访存量相同。内部候选页配额属于方法参数，无须在不同方法间相同，但其评分和访存成本必须计入。匹配比较须分别报告实际词元数、页取整以及逐Q头／共享KV头选集差异（补充注S7）。

表 I
当前选定候选设置：M为实验配置，C为源码行为。K包含去重保护词元。

参数	设置／证据
最终词元上限K	1024（M）
页长；L1页上限K_1	64；128（M）
α, β, γ	.25、.125、.625（M）
L1/L2有效坐标	32/32（C）
前缀／近期保护	4/128（M）
预填充；解码层	稠密（M）；全层稀疏（C）
L2评分范围	完整历史评分后施加掩码（C）

对照设计。固定词元索引回放在相同解码步数、坐标映射、摘要与量化规则、选中词元索引和最终注意力下比较复用与重建，并计入初始准备与逐步维护，以隔离复用成本。若要隔离L1区域分配的作用，区域／全局对照则固定页长、L1总上限K_1、表示、保护、L2精筛及其词元配额、最终上限K，仅改变L1区域分配。两个配置对全部历史使用同一页评分函数，候选不足反映在实际词元数中。这些机制消融固定项不要求不同稀疏方法采用相同K_1。门控仍比较启用远区、关闭远区并回填近区配额、关闭远区且不回填配额，因为移除远区也可能改变近区排序。

成本与不确定性。完整请求时间包含表示准备、维护、标定、选择、KV聚集、注意力和同步，重叠工作只计一次。TTFT表示首个词元的返回时间，TPOT为后续词元返回间隔的均值。质量与时延的联合比较要求相同模型、输入、生成设置和评分方式。任务分数差的不确定性还需考虑同一源文档内多个问题的依赖关系；非劣检验需要在查看确认结果前指定可接受退化界限。本文分别报告表示分数与选择器局部计时，不据此估计联合的端到端质量–时延前沿。实验配置与复现细节见补充注S6。

V. 初步结果

配置得分比较。在HotpotQA、Qasper、MuSiQue、GovReport和RepoBench-P五项任务 [9]上，平均得分为47.588（共享子空间配置）、47.910（名义全维页评分变体）与

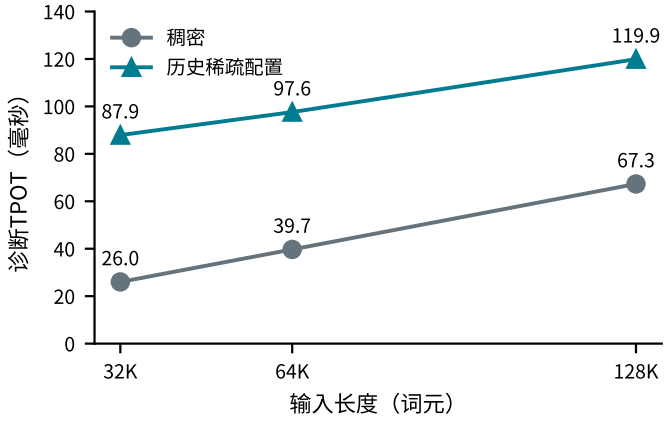


图 3. 作者报告的历史稀疏配置与稠密FullKV模型级解码TPOT，采用Qwen3-8B及动态缓存。固定输出128词元，对应127个首输出后间隔，包含设备同步与argmax。历史(.125, .375, .625)设置不同于当前4/128候选。这些中位数不测量完整请求E2E，也不建立匹配质量–成本比较；来源限制见补充注S6。

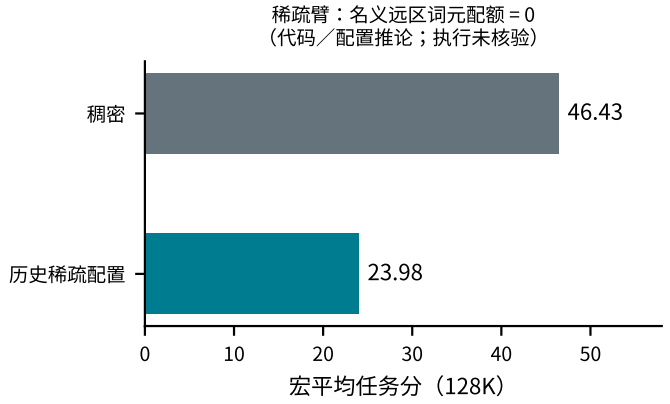


图 4. 作者报告的RULER 128K得分：11任务，每任务每臂100例。历史稀疏配置比稠密FullKV低22.45分，宏平均任务分之比为51.6%。报告的$\beta = .375$、$K_1 = 128$及128/128保护按已检查公式推得名义远区词元配额为0（中间预算768；补充注S6）。这是代码／报告配置推论，不是执行验证或因果归因。该历史设置不验证当前4/128候选，也不支持样本配对推断。

47.666（名义全维词元评分变体）。后两者相对共享子空间配置分别高0.322与0.078分，名义全维词元评分变体比名义全维页评分变体低0.244分。两种名义变体运行尚未核实为仅改变页评分或词元评分维度的受控配置。因此，这些得分差值仅作描述，不能隔离任一级的作用（补充图S4及补充注S7）。归档共享子空间配置得分不能直接验证当前紧凑实现。这些配置均不等于稠密FullKV。

当前所选共享子空间配置与FullKV之间仍缺经核验的匹配测量。图4保留历史128K得分。将报告的$\beta = .375$、$K_1 = 128$、页长64、$\gamma = .625$及128/128保护代入已检查的配额公式，在768个中间词元预算下推得名义远区词元配额为0。这项代码／报告配置推论不验证实际执行路径，也不隔离得分差的原因。另外，五任务的配置均值不能建立稠密注意力质量保持结论。任务级bootstrap汇总描述的是这五项任务间的变化，不构成文档配对的非劣检验。

模型级解码诊断。图3以各输入长度的稠密注意力为参照，比较作者报告的历史稀疏配置动态缓存TPOT。32K、64K、128K下，稀疏中位数为87.9、97.6、119.9毫秒，稠密为26.0、39.7、67.3毫秒，报告中位数的稀疏／稠密比值依次为3.38、2.46、1.78。在这三个报告长度上，比值减小，但稀疏TPOT仍上升且始终高于稠密TPOT。这项同步诊断不含分词、输入传输及文本输出，并非完整请求时延。汇总中位数不能识别因果瓶颈；原始重复记录未在所检查快照中恢复，执行路径仍未核验。这些计时未关联匹配的质量运行，也未核实为当前4/128候选的测量。

选择器局部成本。独立合成实验采用单层、批量大小为1、单查询、64K长度QKV，两轮稳态汇总为：名义全维页评分变体1.3502毫秒，共享子空间配置1.3598毫秒，名义全维词元评分变体1.4634毫秒。在此设置下，共享子空间选择器的所报时间未低于名义全维页评分变体。这一排序不能定位瓶颈阶段，且尚未解决的采样协议差异使小幅计时差异无法得到可靠解释（补充注S6）。这些算子计时未与LongBench质量实验配对，也未测量完整请求成本。

保护与预填充门控的局限。仅保留保护词元的配置得分26.09，对照参考为47.91，同时使用的词元数由1024变为256，因此该差值混合了检索策略与预算效应。预填充统计量也不能约束后续远区需求：一条预填充远区注意力权重总和低于.05的记录，在解码阶段达到.1678。相对所报告的47.910参考分数，门控阈值.05和.10对应的均值分别下降.034和.218分，每个配置的五项任务均有三项下降，其中HotpotQA分别下降1.05和1.26分。较大的逐任务损失表明，小幅均值变化可能掩盖任务敏感性。这些门控汇总未明确完整的评分配置，因此其结果不能归属于门控共享子空间方法（补充注S6）。

适用范围。上述结果描述了所研究Qwen3配置的得分和预填充门控局限，尚未建立相对稠密FullKV的非劣性、区域页配额的独立收益或完整请求成本下降。现有128K RULER汇总 [10] 尚未建立针对当前紧凑配置的已核验匹配比较（补充注S6）。结论限于已报告的配置和工作负载。

VI. 结论

本文研究了两级共享同一低频RoPE评分视图的近远分区选择。该设计缩小评分宽度，同时保留原始全维KV；普通实现仍对完整历史进行词元评分。现有配置得分差值不能隔离阶段效应，独立合成计时实验也未报告共享子空间配置的时延优势。因此，这些表示与分配选择能否形成有竞争力的折中，取决于匹配最终去重词元预算下的任务质量及包含准备的请求成本，并须在评估前规定可接受的质量退化。

Content Generated by AI

通过Codex使用的OpenAI语言模型参与全文起草和修订、中英文翻译、图与LaTeX代码生成，并辅助来源核对及算术复算。界面未提供可核实的底层模型版本标识。

References

[1] J. Tang, Y. Zhao, K. Zhu, G. Xiao, B. Kasikci, and S. Han, "Quest: Query-Aware Sparsity for Efficient Long-Context LLM Inference," in ICML, 2024. https://arxiv.org/abs/2406.10774.

[2] L. Ribar, I. Chelombiev, L. Hudlass-Galley, C. Blake, C. Luschi, and D. Orr, "SparQ Attention: Bandwidth-Efficient LLM Inference," in ICML, 2024, pp. 42558–42583. https://proceedings.mlr.press/v235/ribar24a.html.

[3] Y. Xu et al., "HISA: Efficient Hierarchical Indexing for Fine-Grained Sparse Attention," in COLM, 2026. https://arxiv.org/abs/2603.28458.

[4] Hu et al., "AsyncTLS: Efficient Generative LLM Inference with Asynchronous Two-level Sparse Attention," arXiv:2604.07815v1, Apr. 9, 2026. https://arxiv.org/abs/2604.07815v1.

[5] H. Sun et al., "ShadowKV: KV Cache in Shadows for High-Throughput Long-Context LLM Inference," in ICML, 2025, pp. 57355–57373. https://proceedings.mlr.press/v267/sun25b.html.

[6] Z. Wang et al., "MILLION: MasterIng Long-Context LLM Inference Via Outlier-Immunized KV Product QuaNtization," in 2025 62nd ACM/IEEE Design Automation Conference (DAC), 2025, pp. 1–7, doi: 10.1109/DAC63849.2025.11132862.

[7] G. Liu, C. Li, J. Zhao, C. Zhang, and M. Guo, "ClusterKV: Manipulating LLM KV Cache in Semantic Space for Recallable Compression," in DAC, 2025. https://doi.org/10.1109/DAC63849.2025.11132479.

[8] G. Shen, J. Zhao, Q. Chen, J. Leng, C. Li, and M. Guo, "SALO: An Efficient Spatial Accelerator Enabling Hybrid Sparse Attention Mechanisms for Long Sequences," in DAC, 2022, pp. 571–576. https://doi.org/10.1145/3489517.3530504.

[9] Y. Bai et al., "LongBench: A Bilingual, Multitask Benchmark for Long Context Understanding," in ACL, 2024, pp. 3119–3137. https://aclanthology.org/2024.acl-long.172/.

[10] C.-P. Hsieh et al., "RULER: What' s the Real Context Size of Your Long-Context Language Models?," in COLM, 2024. https://arxiv.org/abs/2404.06654.

[11] G. Xiao, Y. Tian, B. Chen, S. Han, and M. Lewis, "Efficient Streaming Language Models with Attention Sinks," in ICLR, 2024. https://arxiv.org/abs/2309.17453v4.