基于低频RoPE子空间的近远分区稀疏注意力

匿名作者

摘要—**页到词元的稀疏注意力面临两项关联决策：如何低成本地对长历史评分，以及如何在最终注意力计算前分配有限候选。本文研究一种近远级联：页筛选与词元精筛使用相同的32个低频RoPE坐标，为两个区域分别保留页配额，最终以原始全维查询、键和值重算注意力。Qwen3-8B诊断揭示了两项决策的相互作用：区域预留使远区平均注意力保留率从.6759升至.7207，但128条相关观测中有43条下降。预算分析进一步表明，保留远区页并不必然留下远区词元配额。历史五任务LongBench平均分为47.588（共享子空间评分）和47.910/47.666（名义全维页／词元评分变体），但这些比较不能隔离表示效应。独立计时研究中，共享子空间选择器未比名义全维页评分更快，稀疏解码时间也高于稠密注意力。因此，缩小评分维度与保留区域访问机会，尚不足以建立高效的稀疏解码器。采用4/128前缀／近期保护的紧凑实现仍需匹配的质量评估及包含准备开销的成本评估。**

Index Terms—**稀疏注意力，共享表示，区域检索，长上下文推理**

I. 引言

长上下文解码反复访问先前生成的键和值。稀疏注意力通过选择较小词元集合减少这部分工作，但选择本身需要评分、排序与访存。页到词元级联首先决定哪些页能够向精筛提供候选词元。因此，设计需要在固定最终词元预算下保留有用候选，同时使检索成本低于省去的注意力计算。

紧凑页摘要降低评分成本，却可能掩盖少数高分词元。均值可能稀释它们的响应；来自不同词元的逐坐标极值可能产生松上界，使并无相应高分词元的页入选。沿用ClusterKV的词元／页分析视角 [7]，图1(a)显示，均值与极值选集都漏掉了同一页权重排序参考中的部分页。在正概率候选足以填满配额时，精筛无法找回被排除页中的未保护词元。因此，页摘要需要同时按候选访问与评分成本评价。

全局TopK预算允许一侧的高分候选占据名额，却不为另一侧保证最低容量。图1(b)中，分别预留近远容量使远区平均保留率从.6759升至.7207，同时使128条相关观测中的43条下降。这种可控制的覆盖取舍要求明确页级与词元级容量：仅预留远区页并不保证最终保留远区词元。

据此，本文在级联中设置两项明确控制：用固定的完整低频RoPE旋转对为两级提供评分坐标，以独立近远页配额控制各区域进入词元精筛的机会。图1(c)的坐标诊断为紧凑视图提供动机，但随机基线未保留旋转对，不能将频率作用与配对结构分离。最终注意力仍使用原始全维Q/K/V，近似通过词元选择引入。此外，本文考察基于预填充观测的可选远区门控。(d)中的历史层间差异为该扩展提供动机，但采用不同的单查询统计；门控默认关闭，需要独立评估。

本文给出共享坐标区域筛选的具体形式，分析页与词元预算如何共同约束检索。评估考察任务质量、区域覆盖与执行成本。Qwen3诊断显示覆盖发生变化，但历史得分不能隔离任一机制的作用，稀疏解码也慢于稠密注意力。紧凑4/128保护实现仍缺少匹配的质量–成本评估。

II. 相关工作

Quest、SparQ与HISA通过查询感知的近似选择缩小注意力集合 [1], [2], [3]。本文采用Quest的符号感知页极值构造为远区页评分。AsyncTLS已结合页到词元级联、坐标选择、量化、逐查询归一化后GQA概率聚合，以及使用原始KV的最终注意力 [4]，这些组成部分属于已有先例。本文研究的是将它们与两级共享的固定完整低频RoPE旋转对、独立近远页配额结合。普通L2路径仍对全历史评分后施加掩码，因此选页约束候选访问，却不省去这些点积。

减少注意力访存还需考虑选择器自身读取什么。TokenPicker利用部分键比特估计概率，并按需调度后续访问 [12]；本文的坐标评分器则保留全维KV，并派生辅助评分视图。KV压缩与放置方法关注互补的存储和数据移动约束 [5], [6], [7]。因此，本设计中较小的评分视图既不减少原始KV容量，也不能单独保证完整请求时延下降。

III. 共享子空间内的近远筛选

级联沿一条数据路径执行（图2）。首先，固定坐标映射为两级提供评分表示；L1按独立配额筛选近远页，L2使用同一映射及保留页候选集对词元排序；随后将选中索引与保护位置合并，各查询以原始全维Q/K/V重算注意力。这一区分使近似评分不直接进入保留词元的最终logit，但排除候选仍属于近似。普通L2仍先计算全历史评分再施加掩码，因此L1控制候选访问，而不是省去这些点积。

A. 共享低频坐标

对 Qwen3-8B，从 128 维 RoPE 后查询与键中选择$J = \{48, \dots, 63, 112, \dots, 127\}$。这16个完整低频旋转对既不是连续后缀，也不是学习投影（图2a）。令$E_J \in \mathbb{R}^{128\times 32}$为坐标选择矩阵，评分向量为$z_q = E_J^\top q$与$z_i = E_J^\top k_i$。每层、每KV头的两个区域和两个阶段使用同一映射，查询头仍保留各自评分。较慢的位置相位变化为这一选择提供动机，但不保证检索保真度。紧凑实现使用32维评分张量，而历史质量运行在128维L2张量中保留32个有效坐标（S7）。

L1从同一坐标映射派生页摘要，L2派生量化–反量化词元键。两种表示可以分别存储，并在不改变所选坐标的前提下划分近远区域。原始键和值仍保持全维。因此，该方法增加的是辅助评分表示，而非压缩原始KV缓存；这些表示的准备与维护应计入总执行成本（S7）。

B. 区域页配额与词元配额

在解码过程中，令t表示当前词元在完整序列中从0计数的位置（包含预填充词元），于是$S = t+1$表示包含当前位置、排除填充位置的有效缓存位置数。s与w分别表示受保护前缀和近期窗口的长度。保护并集与未保护中间区为：

$$\mathcal{P}_t = \{i : 0 \le i \le t,\ i < s \text{ 或 } i > t - w\}, \tag{1}$$

$$\mathcal{M}_t = \{0, \dots, t\} \setminus \mathcal{P}_t. \tag{2}$$

保护重叠仅计一次。近区是未保护中间历史的后缀，远区为其余部分；近区与受保护滑动窗口不同。近区边界由未保护历史的比例α结合最小页与页对齐规则确定；中间长度为$\max(0, S - |\mathcal{P}_t|)$。选定配置参数见实验设置。

图2b展示区域级联。近区采用平均键页评分，远区在共享空间采用符号感知极值。对非空区域页b定义$m_{b,j} = \min_{i\in b} z_{i,j}$与$M_{b,j} = \max_{i\in b} z_{i,j}$，Quest极值构造 [1]给出

$$U_b(z_q) = \sum_j (z_{q,j}^+ M_{b,j} + z_{q,j}^- m_{b,j}), \tag{3}$$

其中$z^+ = \max(z, 0)$、$z^- = \min(z, 0)$。它仅上界未量化共享空间点积，不自动上界原维logits或另行量化的评分。不同维极值可能来自不同词元，有限页筛选仍会漏掉重要词元；平均键评分也不继承该上界。

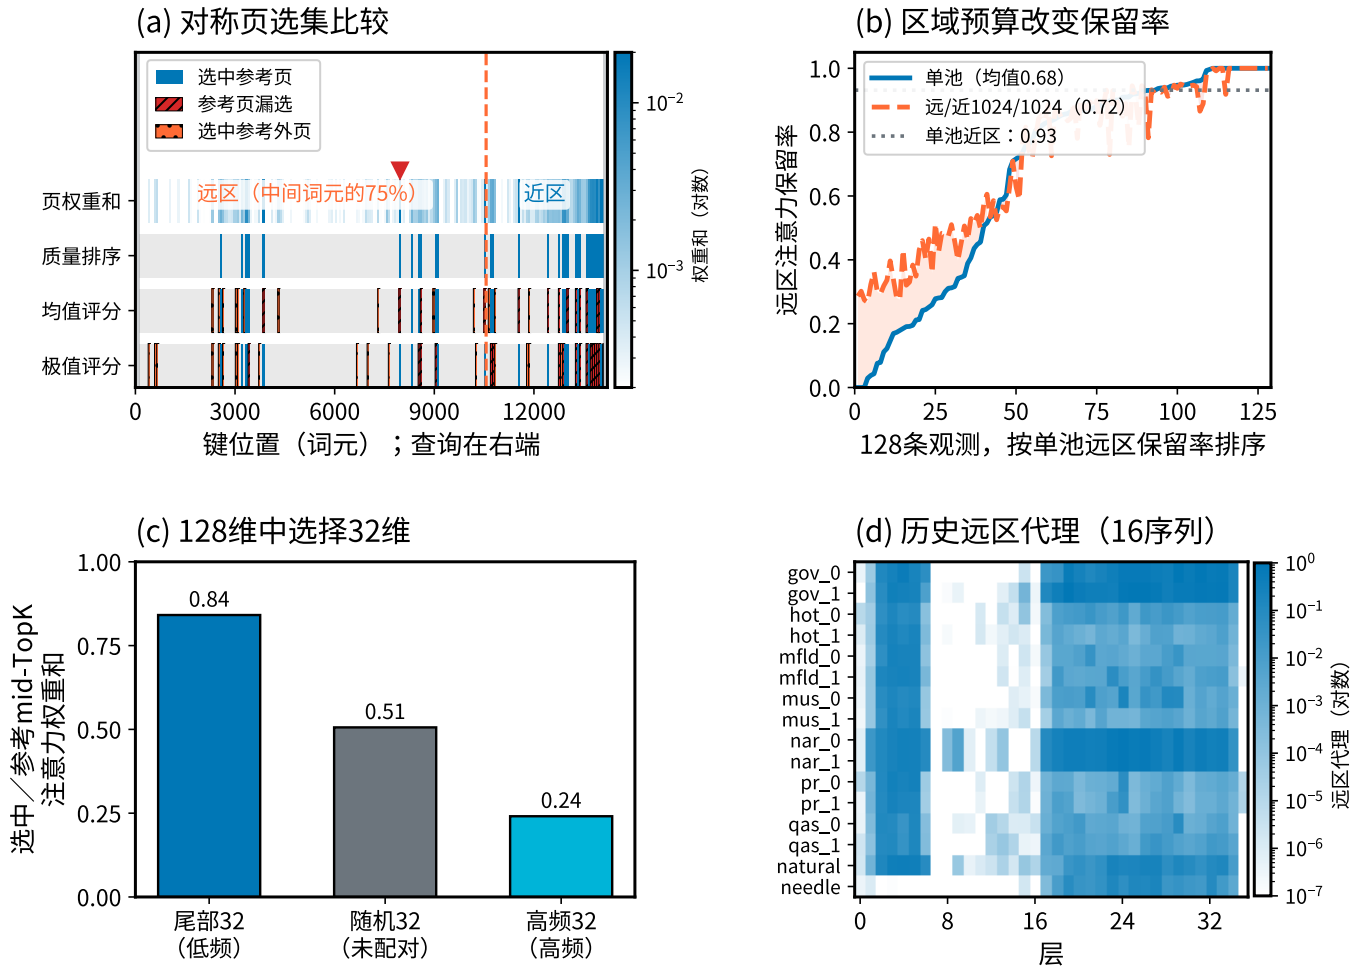


图 1. 四项设计动机诊断，模型为Qwen3-8B；(a)–(c)前缀／近期保护各128。(a) MuSiQue样本1、层24、查询14212。顶行是逐页注意力权重和，不是选集；下三行为注意力权重排序参考、均值与极值选集，均32页，在2048上限下实际使用1989/1989/2048词元。蓝色为选中参考页，红色斜线为参考漏页，橙色点纹为参考外入选页。整页注意力权重排序只是比较参考，并非最优oracle、精确词元TopK或DSA；这些保存选集的表示与池化选择不同，漏页现象不能隔离池化效应，也不能判定质量优劣。(b) 四序列贡献128条相关观测，按全局远区保留率排序；比较2048全局整箱上限与远／近各1024的独立上限，不回填；红色填充为保留率下降。保留率为区域选中权重和除以区域总权重和，点线为全局选择的近区均值。(c) 选中权重和相对全维参考mid-TopK权重和；随机32不保留RoPE配对。(d) 同一16×36历史单查询代理矩阵中，24/36层的中位值低于.01，每序列有12–32个低代理值层；使用最后采样查询、组内logits先求和后softmax及旧远区$[64, t-2048)$，不同于当前门控（S6）。这些选择和统计不构成任务质量或解码安全结果。

对总上限$K \geq |\mathcal{P}_t|$，定义中间词元预算$K_{\text{mid}} = K - |\mathcal{P}_t|$。三项参数控制两级分配：$\alpha$决定近区范围，$\beta$决定近区占L1页上限的比例，$\gamma$将保留的近区页容量换算为L2词元配额。设页长为$B$，在两个区域页数充足时，$P_n = \max(1, \text{round}(\beta K_1))$、$P_f = \max(0, K_1 - P_n)$。对整数$K_1 \geq 1$、$\alpha > 0$、$0 < \beta \leq 1$及$\gamma \geq 0$，在远区选择启用且无配额覆盖项的分区固定配额路径上，round采用半整数取偶规则。合法候选充足时，令$k_n = \min(\lfloor \gamma P_n B \rfloor, K_{\text{mid}})$、$k_f = \max(0, K_{\text{mid}} - k_n)$。因此，$P_f > 0$并不意味着$k_f > 0$：页访问和词元访问是两个独立约束。$K_1 = 128$、$\beta = .125$时，L1保留16个近区页和112个远区页。在正概率候选足够时，后续词元配额不能恢复被L1排除的页；候选不足及掩码后零值并列的实现边界见S7。

当历史足够长、保护不重叠且合法候选充足时，选定配置（$K = 1024$、$s = 4$、$w = 128$）为每个KV头留下892个中间词元槽位。其中$\gamma = .625$给出$16 \cdot 64 \cdot .625 = 640$个近区与252个远区槽位（补充图S2）。4个前缀不足一整页，远区选择可能再次选中至多4个保护位置；252属于名义配额，并非保证得到252个非保护远区词元。候选不足及零值并列行为详见补充注S7。

C. GQA聚合与原维注意力

在分组查询注意力（GQA）中，32个查询头与8个KV头对应每个KV组4个查询头。L1对组内查询的页分数取平均再做区域TopK。普通L2对每个查询计算全历史低维分数，施加共享L1掩码，并在KV组内对各查询独立归一化后的概率取平均。在该Qwen3实现中，L2 logits在逐查询softmax前仍使用原始头维度对应的$1/\sqrt{128}$缩放，包括采用32个坐标评分的情形。这种概率聚合不同于先平均logits再做softmax。因此，各查询头在组内平均前保留各自近似评分的归一化结果。由于评分覆盖全历史，缩小页候选集本身不会减少L2点积工作量。

组内唯一选集$\mathcal{S}_{t,h}$包含保护与区域选中词元索引，受总配额约束。组内各查询g使用相同词元索引，但以头维度$d = 128$独立重算原维注意力：

$$o_{h,g} = \sum_{i \in \mathcal{S}_{t,h}} \frac{e^{q_{h,g}^{\top} k_{i,h}/\sqrt{d}}}{\sum_{j \in \mathcal{S}_{t,h}} e^{q_{h,g}^{\top} k_{j,h}/\sqrt{d}}} v_{i,h}. \tag{4}$$

先合并词元索引再softmax，避免直接相加各区域独立归一化输

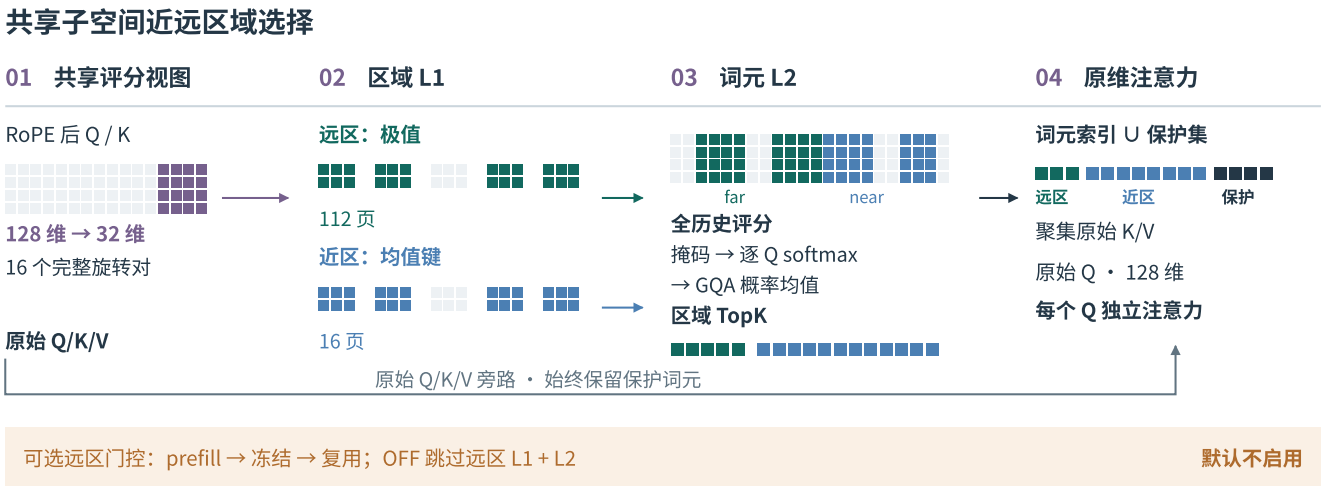


图 2. 共享子空间筛选与原始Q/K/V旁路。L1保留区域页；L2对全历史评分施加掩码，逐查询在共享候选集上归一化，再对KV组内概率取均值并精选区域词元。可选门控为OFF时，跳过远区评分，并将可用L2余量回填近区候选。图中配额为候选充足时的示例。

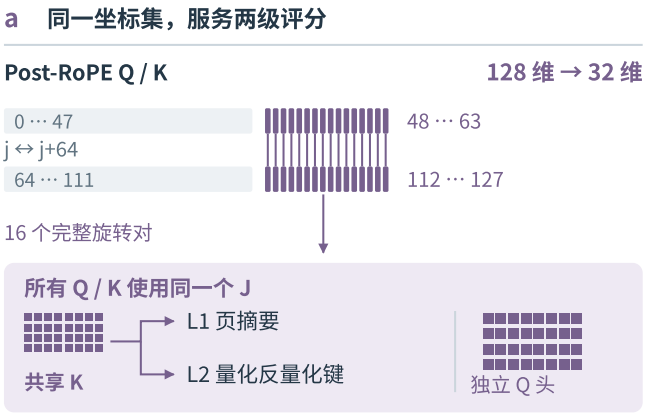


图 2a. 16个完整split-half RoPE旋转对构成32坐标评分视图。每层、每KV头基于相同坐标生成L1页摘要与量化–反量化的L2键，查询视图各自保留。原始Q/K/V绕过这些派生视图（图2）。

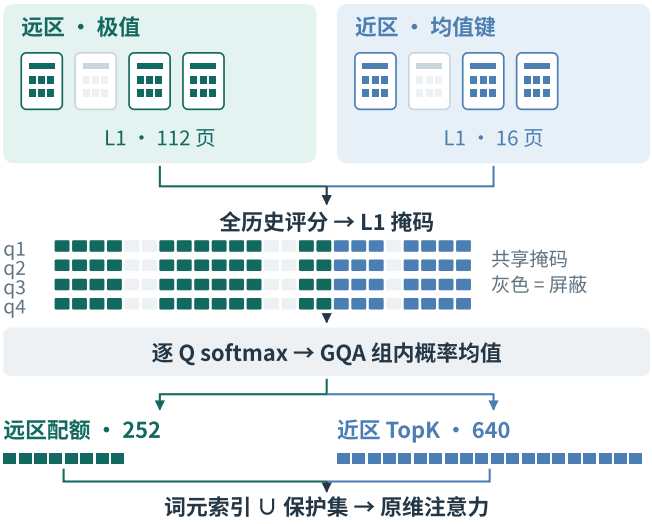


图 2b. 区域筛选与全历史L2评分。彩色单元表示合法候选，并非实测分数。候选容量充足时，当前4/128前缀／近期配置采用远／近区112/16页及名义252/640个区域槽位，另有132个保护词元，总上限$K = 1024$。不足整页的前缀可能重复占用至多4个远区槽位。近区不包含受保护的近期窗口。

出 [8]。保留词元使用原KV logit，但缩减分母仍会改变注意力输出。共享词元索引定义相同的原维注意力集合。物理聚集与复用取决于注意力后端和序列长度；所检查的实现还包含短序列稠密回退路径。实际16级表示是浮点量化反量化，不是打包四位存储或INT4算术。

D. 基于预填充观测的远区门控

可选远区门控（图2）考察预填充观测能否识别可省略重复远区筛选的层。对每个输入、每层，预填充平均远区注意力权重总和低于ϵ时设为OFF，否则继续远区选择；决策在解码入口冻结并复用。该功能默认不启用。在支持的固定数值配额实现上，OFF跳过远区两级评分与选取，并将可用L2余量回填近区候选，近区页预算保持不变。表示准备、序列全长评分缓冲及归一化仍然保留。

图2c展示门控决策与回填。本文实现了单序列门控扩展，其观测边界与状态转换见补充注S5。阈值约束的是预填充统计量，而非后续注意力误差。因此，门控是一种近似策略，其质量和总成本影响需要与默认非门控方法分别评估。

IV. 实验设置

本文分别评估任务质量、区域候选覆盖与执行成本。表I定义紧凑Qwen3-8B设计：稠密预填充、稀疏解码，1024词元上限包含4个前缀与128个近期词元。现有LongBench测量采用较早的共享子空间实现：128/128保护，并在填零的128维L2键中存放32个有效坐标。对照中的“全维页评分”和“全维词元评分”是报告给出的变体标签，完整执行配置尚不具备，因此下文沿用其名义标签，不将这些运行视为受控的单阶段消融。合成选择器计时与模型级解码计时来自独立研究，均未提供紧凑设计的匹配质量与成本。配置与测量细节见S6/S7。

工作负载与对照。质量证据包括五项LongBench任务，以及

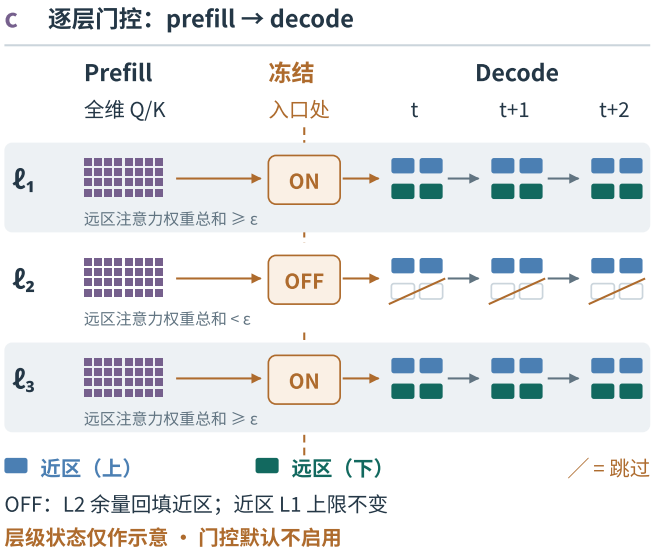


图 2c. 可选远区控制，默认不启用。全维因果预填充远区注意力权重总和在末尾至多256个查询行和全部查询头上取均值，为每个输入、每层确定决策；解码入口冻结，新输入清空。OFF跳过远区L1/L2，在近区页集合不变的前提下回填近区L2。层级状态仅作示意，每对小格分别表示L1/L2。该统计量不约束解码误差。

表 I
紧凑设计的参数与执行策略。这些设置定义所提出的实现，并非历史运行配置。K包含去重保护词元。

参数	设置
最终词元上限K	1024
页长；L1页上限K_1	64；128
α, β, γ	.25、.125、.625
L1/L2有效坐标	32/32
前缀／近期保护	4/128
预填充；解码层	稠密；全层稀疏
L2评分范围	完整历史评分后施加掩码

历史11任务RULER [10] 128K比较。LongBench得分比较三种名义稀疏评分配置；稠密FullKV在RULER与解码计时中作为单独参照。这些记录尚未构成页评分和词元评分的完整双因素消融。稀疏比较须对齐含保护的最终去重词元上限K、模型、输入与阶段策略。不同方法的内部页预算不必相同，但实际词元数与头共享粒度会影响候选访问和KV流量（S7）。

指标。质量采用任务得分的无权均值，并在记录具备时给出逐任务变化。候选保留率为选中注意力权重和除以对应区域的全量权重和。选择器时间覆盖合成的单层操作；同步TPOT测量模型在首个输出词元之后的生成间隔。二者均不同于完整请求时延，后者还包含准备、维护及输入输出工作。由于质量与计时研究未配对，它们不能定义质量–时延前沿。五个任务均值也不能建立文档配对非劣性，后者需要匹配预测与事前规定的可接受损失界限。

V. 评估与讨论

A. Q1：缩小评分宽度能否保留任务质量?

在 HotpotQA、Qasper、MuSiQue、GovReport 和 RepoBench-P 五项任务 [9] 上，共享子空间评分平均分为47.588，名义全维页评分与词元评分变体分别为47.910和47.666（补充图S4）。共享子空间得分分别低0.322与0.078分。这些差值描述所记录的配置，不能说明缩小评分宽度保持了

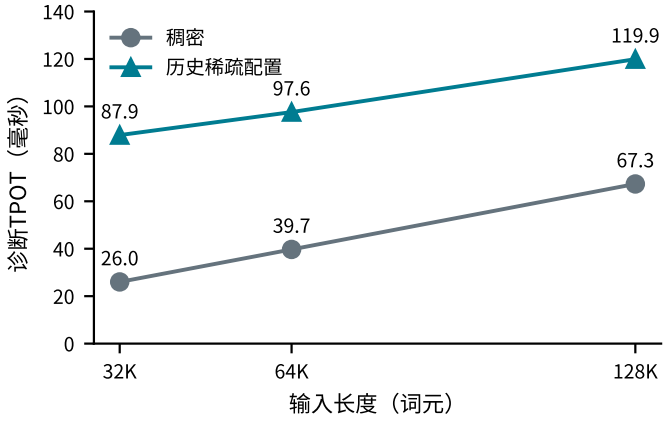


图 3. 作者报告的历史稀疏配置与稠密FullKV模型级解码TPOT，采用Qwen3-8B及动态缓存。固定输出128词元，对应127个首输出后间隔，包含设备同步与argmax。历史$(.125, .375, .625)$设置不同于当前4/128候选。这些中位数不测量完整请求E2E，也不建立匹配质量–成本比较；来源限制见补充注S6。

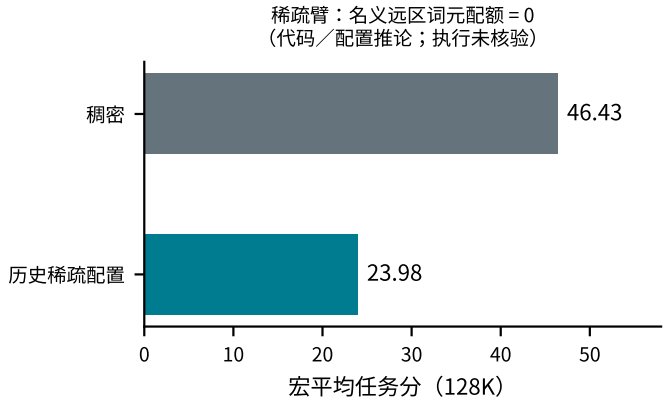


图 4. 作者报告的RULER 128K得分：11任务，每任务每臂100例。历史稀疏配置比稠密FullKV低22.45分，宏平均任务分之比为51.6%。报告的$\beta = .375$、$K_1 = 128$及128/128保护按已检查公式推得名义远区词元配额为0（中间预算768；补充注S6）。这是代码／报告配置推论，不是执行验证或因果归因。该历史设置不验证当前4/128候选，也不支持样本配对推断。

质量：变体未被确认为单因素干预，共享子空间运行也采用较早的128/128保护实现。因此，这一比较既不能隔离任一级的表示效应，也不能推断紧凑4/128设计的质量。三者均为稀疏配置，稠密FullKV是另一类参照。

B. Q2：区域预算如何约束候选访问?

区域预留改变远端词元的可达范围。图1(b)中，独立配额提高了远区平均保留率，却使43/128条观测下降，体现固定预算重新分配的代价。该诊断在四条序列上进行整箱选择，并不测量生产选择器的任务质量。两级预算公式还揭示另一项约束：近区配额耗尽K_{mid}时，即使保留远区页，也不会分配名义远区词元槽位。代入历史RULER配置（$\beta = .375$、$K_1 = 128$、$B = 64$、$\gamma = .625$、保护128/128），得到$K_{\text{mid}} = 768$与$k_f = 0$。图4报告该配置得分23.98，稠密注意力为46.43，下降22.45分，但仅靠代数推导既不能验证实际执行路径，也不能将下降归因于此配额。当前紧凑候选仍缺少匹配的稠密对照。

仅保留保护词元的配置得分26.09，对照参考为47.91，同时使用的词元数由1024变为256，因此该差值混合了检索策略与预算效应。

C. Q3：紧凑评分能否降低执行成本?

模型级解码。在每个测量长度上，所报告的稀疏配置均慢于稠密FullKV（图3）。32K、64K与128K下，稀疏TPOT中位数为87.9、97.6和119.9毫秒，稠密为26.0、39.7和67.3毫秒，比值依次为3.38、2.46和1.78。相对代价随长度减小，但稀疏TPOT绝对值仍增加。因此，这些测量未显示该实现的解码时间收益。计时包含设备同步与argmax，不含分词、输入传输和文本输出，且配置不同于紧凑4/128设计。汇总中位数不能定位变慢的原因，也不能预测紧凑实现的性能；重复记录与执行路径细节见S6。

选择器局部成本。独立合成实验采用单层、批量大小为1、单查询、64K长度QKV，两轮稳态汇总为：名义全维页评分变体1.3502毫秒，共享子空间配置1.3598毫秒，名义全维词元评分变体1.4634毫秒。在此设置下，共享子空间选择器的所报时间未低于名义全维页评分变体。这一排序不能定位瓶颈阶段，且尚未解决的采样协议差异使小幅计时差异无法得到可靠解释（补充注S6）。这些算子计时未与LongBench质量实验配对，也未测量完整请求成本。

D. 可选门控：预填充不保证解码需求

预填充统计量也不能约束后续远区需求：一条预填充远区注意力权重总和低于.05的记录，在解码阶段达到.1678。相对所报告的47.910参考分数，门控阈值.05和.10对应的均值分别下降.034和.218分，每个配置的五项任务均有三项下降，其中HotpotQA分别下降1.05和1.26分。较大的逐任务损失表明，小幅均值变化可能掩盖任务敏感性。这些门控汇总未明确完整的评分配置，因此其结果不能归属于门控共享子空间方法（补充注S6）。

设计启示与局限。上述分析给出三项约束。首先，评分宽度决定排序使用的表示，但当前L2路径仍执行全历史评分与归一化。其次，区域页访问和区域词元访问需要分别分配预算，满足前者并不保证后者。最后，准备和使用选择器的成本需要由省去的注意力工作抵消，而现有计时未显示这种收益。缺少紧凑实现的匹配评估，使质量–成本结论仍无法成立；历史门控汇总也未明确共享子空间配置。现有证据支持机制描述与上述约束，尚不能确定这一组合相对已有方法的收益。

VI. 结论

本文将稀疏注意力视为表示与分配的联合问题：共享低频坐标映射用于页与词元评分，区域配额控制进入精筛的机会，最终注意力使用原始全维Q/K/V。分析区分了低维排序与实际执行工作减少，也区分了远区页预留与最终远区词元覆盖。Qwen3诊断展示了这些取舍，包括区域保留率下降、历史配置的大幅质量损失及更慢的稀疏解码。要确定紧凑4/128设计是否存在有用的运行点，仍需在同一配置下测量质量及包含准备开销的成本；现有独立研究尚未建立这一收益。

Content Generated by AI

通过Codex使用的OpenAI语言模型参与全文起草和修订、中英文翻译、图与LaTeX代码生成，并辅助来源核对及算术复算。界面未提供可核实的底层模型版本标识。

References

[1] J. Tang, Y. Zhao, K. Zhu, G. Xiao, B. Kasikci, and S. Han, "Quest: Query-Aware Sparsity for Efficient Long-Context LLM Inference," in ICML, 2024. https://arxiv.org/abs/2406.10774.

[2] L. Ribar, I. Chelombiev, L. Hudlass-Galley, C. Blake, C. Luschi, and D. Orr, "SparQ Attention: Bandwidth-Efficient LLM Inference," in ICML, 2024, pp. 42558–42583. https://proceedings.mlr.press/v235/ribar24a.html.

[3] Y. Xu et al., "HISA: Efficient Hierarchical Indexing for Fine-Grained Sparse Attention," in COLM, 2026. https://arxiv.org/abs/2603.28458.

[4] Hu et al., "AsyncTLS: Efficient Generative LLM Inference with Asynchronous Two-level Sparse Attention," arXiv:2604.07815v1, Apr. 9, 2026. https://arxiv.org/abs/2604.07815v1.

[5] H. Sun et al., "ShadowKV: KV Cache in Shadows for High-Throughput Long-Context LLM Inference," in ICML, 2025, pp. 57355–57373. https://proceedings.mlr.press/v267/sun25b.html.

[6] Z. Wang et al., "MILLION: MasterIng Long-Context LLM Inference Via Outlier-Immunized KV Product QuaNtization," in 2025 62nd ACM/IEEE Design Automation Conference (DAC), 2025, pp. 1–7, doi: 10.1109/DAC63849.2025.11132862.

[7] G. Liu, C. Li, J. Zhao, C. Zhang, and M. Guo, "ClusterKV: Manipulating LLM KV Cache in Semantic Space for Recallable Compression," in DAC, 2025. https://doi.org/10.1109/DAC63849.2025.11132479.

[8] G. Shen, J. Zhao, Q. Chen, J. Leng, C. Li, and M. Guo, "SALO: An Efficient Spatial Accelerator Enabling Hybrid Sparse Attention Mechanisms for Long Sequences," in DAC, 2022, pp. 571–576. https://doi.org/10.1145/3489517.3530504.

[9] Y. Bai et al., "LongBench: A Bilingual, Multitask Benchmark for Long Context Understanding," in ACL, 2024, pp. 3119–3137. https://aclanthology.org/2024.acl-long.172/.

[10] C.-P. Hsieh et al., "RULER: What' s the Real Context Size of Your Long-Context Language Models?," in COLM, 2024. https://arxiv.org/abs/2404.06654.

[11] G. Xiao, Y. Tian, B. Chen, S. Han, and M. Lewis, "Efficient Streaming Language Models with Attention Sinks," in ICLR, 2024. https://arxiv.org/abs/2309.17453v4.

[12] J. Park, M. Kang, Y. Han, Y.-G. Kim, J. Shin, and L.-S. Kim, "Token-Picker: Accelerating Attention in Text Generation with Minimized Memory Transfer via Probability Estimation," in DAC, 2024, doi: 10.1145/3649329.3655953.