基于低频RoPE子空间的近远分区稀疏注意力

匿名作者

摘要—稀疏注意力需要以低选择成本保留有用候选。本文研究近远页到词元级联，共享32个低频RoPE评分坐标，并在选中词元上使用原维注意力。近远覆盖存在取舍，保留远区页并不必然保留远区词元容量。作者报告的11任务RULER 32K AVG在Qwen3-8B两种页／词元分配下分别为58.30与59.29；一项Qwen3-32B比较中稀疏为50.64、稠密为52.22。这些描述性比较既未隔离机制，也未建立统计非劣结论。独立历史计时显示稀疏解码更慢。要确认紧凑4/128保护设计的收益，仍需匹配的质量与含准备开销的完整请求成本评估。

Index Terms—稀疏注意力，共享表示，区域检索，长上下文推理

I. 引言

在稠密长上下文解码中，每个新词元都对不断增长的缓存键和值进行注意力计算。稀疏注意力将最终计算限制在入选词元上，但选择这些词元仍需要评分、排序与访存。设计目标是在固定预算内保留与任务相关的词元，并使选择成本低于省去的注意力计算成本。除了最终注意力集合的大小，候选选择过程也是核心设计问题。

AsyncTLS等级联使用低成本页摘要筛选候选页，再进行词元精筛 [4]。均值池化与符号感知极值都不按页内注意力权重总和排序，本文的选择器也采用这两类摘要。沿用ClusterKV的词元／页分析视角 [7]，图1(a)中的单个Qwen3查询显示：按注意力权重总和排序的参考页漏选更少时，漏失的参考页权重反而更多。由于区域分配与实际词元数不同，这一诊断不是评分规则或任务质量的受控比较。它促使我们考察评分选择与页／词元预算如何共同影响候选进入后续筛选的机会。

候选能否进入后续筛选，还取决于近期与远端历史之间如何分配容量。全局TopK可能将全部可用名额分配给一个区域，区域配额则可以为两侧分别预留名义容量。图1(b)按整箱选择的诊断中，分别预留近远容量使远区注意力权重的平均保留比例从.6759升至.7207，但128条相关观测中仍有43条下降。设计必须兼顾两级筛选：允许远区页进入候选集，本身并不为页内词元预留最终名额。

本文研究一种将共享评分视图与显式区域预算结合的两级选择器。两级共用一组固定的32个坐标，即16个完整的低频RoPE旋转对；独立近远页配额分别限制近区和远区可供词元精筛的页数。图1(c)的三个32坐标子集中，低频配对的选中／参考注意力权重比的均值最高；随机子集未保留RoPE配对。扣除前缀与近期词元保护后，区域词元配额分配剩余最终预算；入选词元使用原始全维Q/K/V完成一次最终注意力计算。紧凑坐标缩短评分点积的维度，但普通词元评分仍在掩码前遍历完整历史，因此减少候选页本身不会省去这部分工作。本文还给出由图1(d)中历史层间差异提供动机的预填充远区门控扩展；该门控默认关闭，需要单独评估。

本文的贡献是给出共享坐标区域选择器，分析页／词元容量的联合约束，并分别评估任务质量、区域覆盖和执行成本。在完整11任务RULER32K集合上，已报告的Qwen3-8B AVG在$\beta = .0625$时比$\beta = .125$高0.99点，配额同时改变。另一项Qwen3-32B的11任务RULER32K比较中，稀疏臂比稠密注意力低1.58点。这些描述性比较不能隔离任一机制的作用，归档稀疏配置在所有已测长度上的解码也均慢于稠密注意力。要证明紧凑4/128保护设计的质量–时延收益，需要匹配的任务质量与完整请求测量，包括准备、维护与选择。

II. 相关工作

Quest以符号感知页极值为远区页评分提供构造保证，SparQ从查询选定的键坐标近似注意力，HISA则按层级剪枝注意力集合 [1], [2], [3]。AsyncTLS已结合页到词元级联、坐标选择、量化、逐查询归一化后分组查询注意力（GQA）概率聚合，以及使用原始KV的最终注意力 [4]，这些组成部分属于已有先例。SparQ还保护近期词元窗口，HISA则将首尾块强制纳入粗筛候选集 [2], [3]。本文不提出新级联，而是研究将这些已有组成部分与两级共享的完整低频RoPE旋转对、分别设置的近远L1名义页配额结合，并区分页级候选资格与最终词元容量。这些页配额本身不保证最终远区词元容量；普通L2仍对全历史评分后施加掩码。

减少注意力访存还需考虑选择器自身读取什么。TokenPicker从部分键比特块构造保守概率估计，对被剪枝词元停止后续键比特块和value的传输 [12]。与按部分键比特剪枝词元传输不同，本文的选择器在页与词元预算约束下使用固定坐标子集对候选排序，并保留原维KV供最终注意力使用。KV压缩与放置方法关注互补的存储和数据移动约束 [5], [6], [7]。本设计中较小的评分视图不减少原始KV容量，单凭这一变化也不能证明完整请求时延收益。

III. 共享子空间内的近远筛选

为同时控制选择成本与候选访问，级联采用两项显式机制：共享评分视图与区域页配额。同一32坐标映射用于L1页筛选和L2词元精筛，将低维筛选与原维注意力分开（图2）。级联仅在解码阶段执行；预填充保持稠密。L1为近区和远区分配独立页配额，使一个区域的页面不争用另一区域的配额。普通L2路径先对全历史评分，再施加保留页掩码并选择区域词元。选中词元索引与保护位置合并去重后，使用原始Q、K、V计算注意力；重算保留词元的logits并不能恢复被遗漏的词元。

A. 共享低频坐标

每层、每KV头的两个区域和两个筛选阶段采用相同的坐标映射，各查询头仍独立评分。对Qwen3-8B，从128维RoPE后查询与键中选择$J = \{48, \dots, 63, 112, \dots, 127\}$。这些索引保留16个完整的低频split-half RoPE旋转对（补充图S1）。令$E_J \in \mathbb{R}^{128\times 32}$为坐标选择矩阵，评分向量为$z_q = E_J^\top q$与$z_i = E_J^\top k_i$。所保留旋转对的位置旋转较慢，为这一选择提供动机，但不保证保留重要词元。紧凑实现使用32维评分张量，而历史质量运行在128维L2张量中保留32个有效坐标（S7）。

L1将选定的键坐标聚合为页摘要，用于粗粒度排序；L2则使用量化–反量化词元键进行精筛。L2键采用16级浮点量化–反量化值，并非打包四位存储或INT4算术（S7）。两种评分视图分别存储。原始键和值仍保持全维。紧凑实现将每次评分点积缩窄至四分之一，但辅助视图的准备与维护增加工作，并未压缩原始KV缓存（S7）。

B. 区域页配额与词元配额

在解码过程中，令t表示当前词元在完整序列中从0计数的位置（包含预填充词元）。s与w分别表示受保护前缀和近期窗口的长度。保护并集与未保护中间区为：

$$\mathcal{P}_t = \{i : 0 \le i \le t,\ i < s \text{ 或 } i > t - w\}, \tag{1}$$

$$\mathcal{M}_t = \{0, \dots, t\} \setminus \mathcal{P}_t. \tag{2}$$

保护重叠仅计一次。近区是$\mathcal{M}_t$的后缀，远区为它在$\mathcal{M}_t$内的补集。因此，近区不包含受保护的近期窗口。实现按未保护长度的

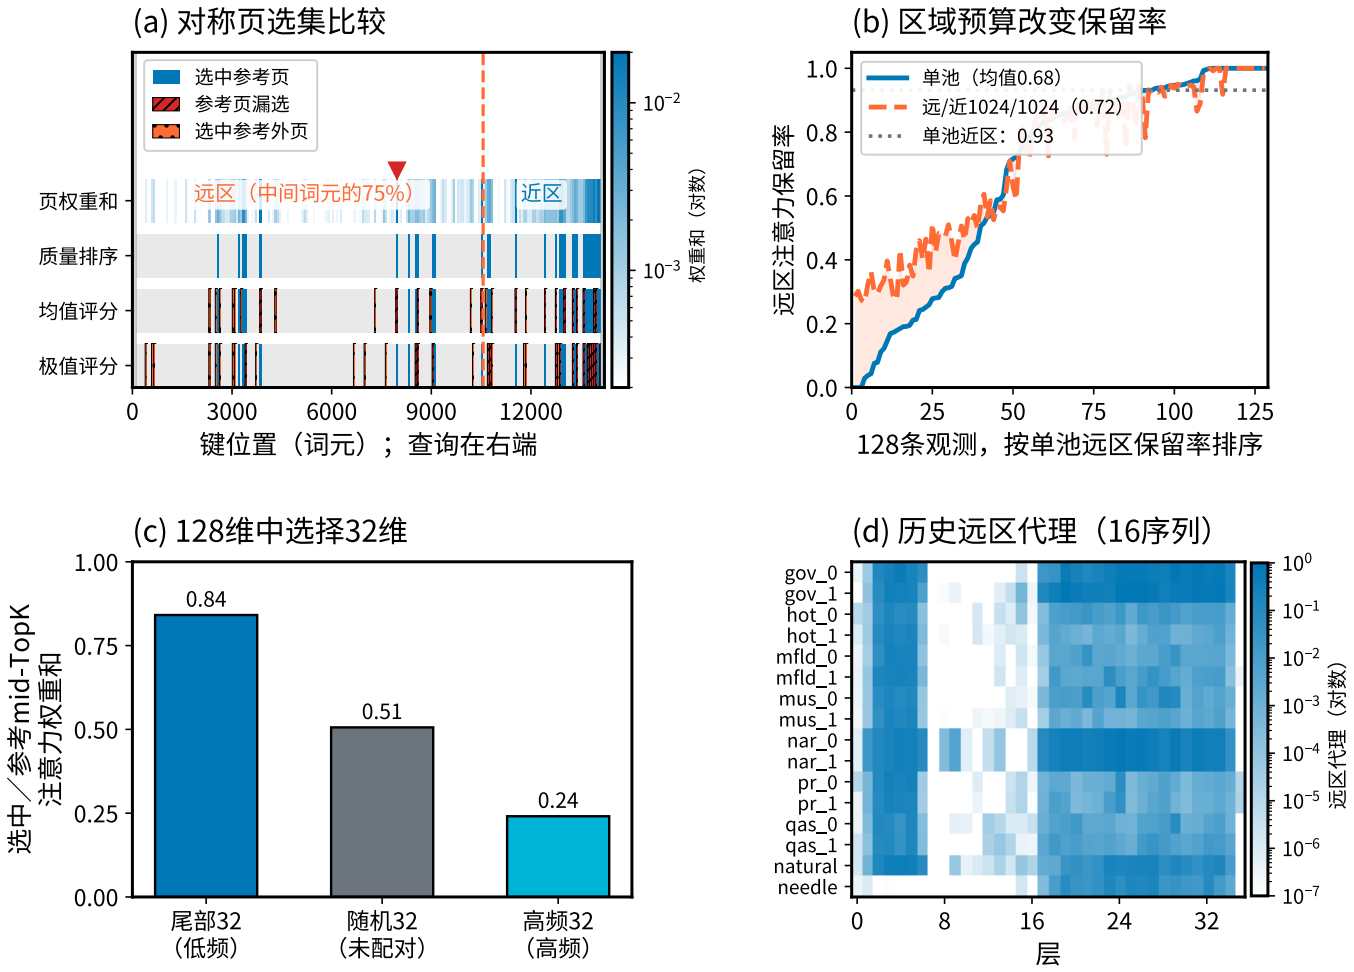


图 1. 四项设计动机诊断，模型为Qwen3-8B；(a)–(c)前缀／近期保护各128。(a) MuSiQue样本1、层24、查询14212。顶行是逐页注意力权重和，不是选集；下三行为注意力权重排序参考、均值与极值选集，均32页，在2048上限下实际使用1989/1989/2048词元。均值／极值分别漏选13／17个参考页，其中包含参考页注意力权重总和的59.65%／26.46%。蓝色为选中参考页，红色斜线为参考漏页，橙色点纹为参考外入选页。整页注意力权重排序只是比较参考，并非最优oracle、精确词元TopK或DSA；均值与极值共享32坐标及头聚合，参考采用全维注意力权重。实际区域分配和词元数不同，漏页不能证明近远分工或任务质量优劣。(b) 四序列贡献128条相关观测，按全局远区保留率排序；比较2048全局整箱上限与远／近各1024的独立上限，不回填；红色填充为保留率下降。保留率为区域选中权重和除以区域总权重和，点线为全局选择的近区均值。(c) 选中权重和相对全维参考mid-TopK权重和；随机32不保留RoPE配对。(d) 单张16×36历史单查询代理矩阵中，24/36层的中位值低于.01，每序列有12–32个低代理值层；使用最后采样查询、组内logits先求和后softmax及旧远区$[64, t-2048)$，不同于当前门控（S6）。这些选择和统计不构成任务质量或解码安全结果。

比例α确定近区长度，施加一页的最小值，再将近区起点向下对齐到页边界（S7）。选定参数见实验设置。

级联分别为近区与远区历史设置页上限和词元配额（补充图S2）。近区页采用查询与平均键的点积汇总页级相关性；远区页采用符号感知极值来上界未量化的共享空间词元分数。这一区域分工属于评分启发式。页摘要覆盖完整物理页，包括边界页内的保护位置；L2另行施加词元区域边界（S7）。对这样的非空页b，定义$m_{b,j} = \min_{i \in b} z_{i,j}$与$M_{b,j} = \max_{i \in b} z_{i,j}$。Quest极值构造 [1]给出

$$U_b(z_q) = \sum_j (z_{q,j}^+ M_{b,j} + z_{q,j}^- m_{b,j}), \tag{3}$$

其中$z^+ = \max(z, 0)$、$z^- = \min(z, 0)$。对页b中所表示的每个未量化共享空间键z_i，都有$z_q^\top z_i \le U_b(z_q)$，因为每个带符号坐标项均由所选极值上界。这不构成对原维logits或另行量化评分的相应保证。由于各坐标极值可能来自不同词元，U_b可能高估页内所有词元的分数，因此只保留评分最高的页仍可能漏掉重要词元。平均键页评分不提供这一逐词元上界。

对总上限$K \ge |\mathcal{P}_t|$，定义中间词元预算$K_{\text{mid}} = K - |\mathcal{P}_t|$。三项参数控制区域访问：$\alpha$决定近区范围，$\beta$分配近区占总L1页上限$K_1$的比例，$\gamma$将保留的近区页容量换算为名义L2词元配额。考虑远区选择启用、无配额覆盖项的分区固定配额路径，并令整数$K_1 \ge 1$、$\alpha > 0$、$0 < \beta \le 1$、$\gamma \ge 0$。页长为B且两区页数充足时，$P_n = \max(1, \text{round}(\beta K_1))$、$P_f = \max(0, K_1 - P_n)$，其中round采用半整数取偶规则。提高$\beta$不会减小名义近区页配额，也不会增大远区页配额；取整可能使二者保持不变。合法词元候选充足时，$k_n = \min(\lfloor \gamma P_n B \rfloor, K_{\text{mid}})$、$k_f = \max(0, K_{\text{mid}} - k_n)$。因此，$P_f > 0$并不意味着$k_f > 0$：页访问和词元访问是两个独立约束。例如，$K_1 = 128$时$\beta$从.125降到.0625使近区页配额从16减半到8，故在页上限不变时远区页由112增至120。当正概率候选足以填满配额时，L2无法恢复被L1排除页中的未保护词元。候选不足与掩码后零值并列需单独处理，详见S7。

当历史足够长、前缀与近期保护不重叠且合法候选充足时，选定紧凑配置（$K = 1024$、$s = 4$、$w = 128$）为每个KV头留下892个中间词元槽位。其中$\gamma = .625$给出$16 \cdot 64 \cdot .625 = 640$个近

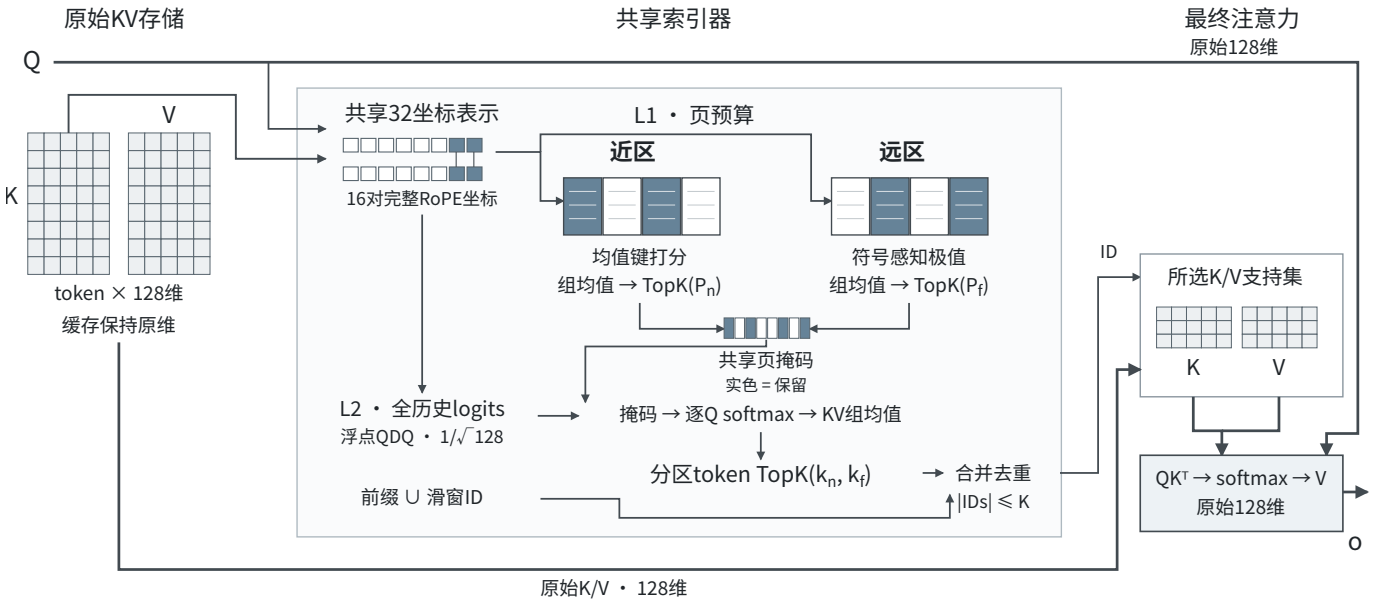


图 2. 共享子空间筛选架构，展示可选门控未启用时的路径。共享坐标表示用于区域L1页评分和普通全历史L2评分。页掩码限制候选资格；逐查询softmax及KV组概率均值后进行区域词元选择。保护位置与索引合并去重后满足K。近区不含保护滑窗。索引定义原维K/V支持集，物理聚集或带掩码稠密计算由后端决定；原始Q走独立路径。阵列均为示意。

区与252个远区槽位（补充图S2）。4个前缀不足一整页，远区选择可能再次选中至多4个保护位置；252属于名义配额，并非保证得到252个非保护远区词元。

C. GQA聚合与原维注意力

GQA将32个查询头按每个KV组4个分到8个KV头。L1对组内查询的页分数取平均再做区域TopK。普通L2先为每个查询计算全历史词元logits，施加共同的保留页掩码，并在该支持集上归一化；随后在KV组内对概率取均值，再进行区域词元TopK。在该Qwen3实现中，L2 logits在逐查询softmax前仍使用原始头维度对应的$1/\sqrt{128}$缩放，包括采用32个坐标评分的情形。由于先逐查询softmax再做组内平均，该规则通常不同于对组内平均logits施加softmax。32维评分减少每次点积使用的坐标数，但普通L2仍沿全历史执行点积；因此，更小的L1候选页集合缩小的是候选资格范围，而非L2词元点积的数量。

对KV组h，令$\mathcal{S}_{t,h}$为保护位置与区域选中词元索引的去重并集，并满足$|\mathcal{S}_{t,h}| \le K$。组内各查询$g$使用相同词元索引，但以头维度$d = 128$独立重算原维注意力：

$$o_{h,g} = \sum_{i \in \mathcal{S}_{t,h}} \frac{e^{q_{h,g}^{\top} k_{i,h}/\sqrt{d}}}{\sum_{j \in \mathcal{S}_{t,h}} e^{q_{h,g}^{\top} k_{j,h}/\sqrt{d}}} v_{i,h}. \tag{4}$$

每个查询在合并后的索引上统一施加softmax，而非直接相加各区域独立归一化的输出 [8]。保留词元的Q/K logits采用原维计算，但缩小支持集会改变分母，并可能改变注意力输出。这些索引定义共同的逻辑支持集；KV的物理聚集与复用取决于后端和序列长度，短序列可使用带掩码的稠密路径。

D. 基于预填充观测的远区门控

在评分与预算之外，层间差异提供第二类节省机会。可选门控考察预填充阶段较低的远区注意力能否识别可在解码时省略远区选择的层，默认不启用。对每个输入和层，若平均远区注意力代理统计量低于ϵ，则将门控设为OFF；否则继续远区选择。标定按词元定义区域，可能不同于按页对齐的跳过区域（S5）。决策在首次进入解码路径时冻结，并复用至新输入将其清空（图2；S5）。在支持的固定配额路径上，OFF跳过远区L1/L2评分与选取，并在近区页预算不变的前提下，用可用L2余量回填近区候选。移除远区支持集还可能改变逐查询softmax分母及组内平均后的近区排名（S5）。表示准备、序列全长评分缓冲及归一化仍然保留。

已实现门控支持单序列；S5给出观测与执行条件，其中固定配额跳过路径要求有效长度和非空远区历史（补充图S3）。对预填充统计量施加阈值并不约束后续解码误差；因此，门控的质量与总成本影响需要与默认非门控方法分别评估。

表 I
紧凑设计的参数与执行策略。这些设置定义所提出的实现，并非历史运行配置。K包含去重保护词元。

参数	设置
最终词元上限K	1024
页长；L1页上限K_1	64；128
α, β, γ	.25、.125、.625
L1/L2有效坐标	32/32
前缀／近期保护	4/128
预填充；解码层	稠密；全层稀疏
L2评分范围	完整历史评分后施加掩码

IV. 实验设置

本文分别评估任务质量（Q1）、区域候选覆盖（Q2）与执行成本（Q3）。表I定义紧凑Qwen3-8B设计：稠密预填充、稀疏解码，1024词元上限包含4个前缀与128个近期词元，下文统称4/128保护设计。历史五任务LongBench比较中的共享子空间臂关联到较早的实现：128/128保护，并在填零的128维L2键中存放32个有效坐标。对照中的“全维页评分”和“全维词元评分”是报告给出的变体标签，完整执行配置尚不具备，因此下文沿用其名义标签，不将这些运行视为受控的单阶段消融。合成选择器计时与模型级解码计时来自独立研究，均未提供紧凑设计的匹配质量与成本。配置与测量细节见S6/S7。

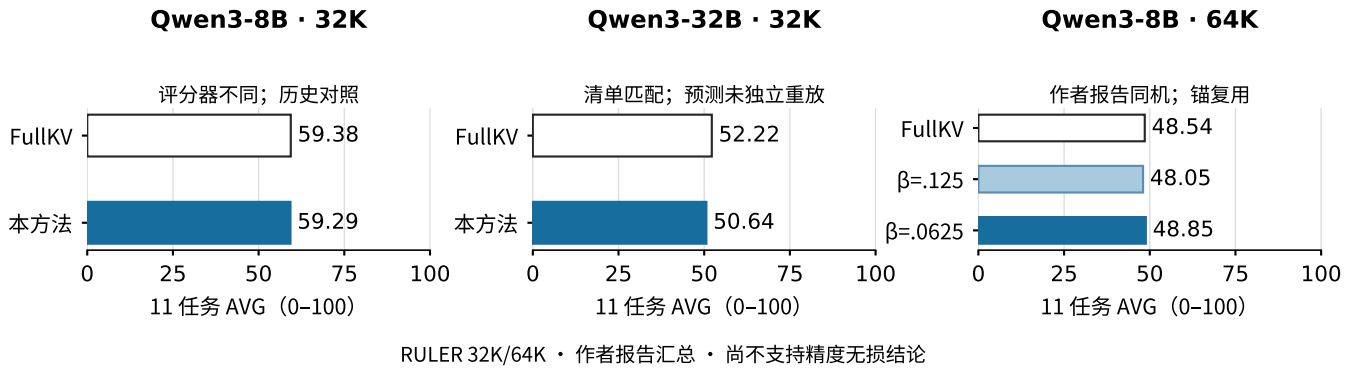


图 3. 作者报告的RULER 32K/64K结果：11任务算术AVG，每任务每臂100例。FullKV为稠密参照；方法臂报告$K = 1024$、4/128保护；32K下8B的$\beta = .0625$，32B为.125，64K的8B展示两种β。两组32K比较均跨机器。8B源数据哈希匹配，但评分器不同且输入身份不完整，分差仅属历史描述，非严格配对。32B清单匹配，但预测尚未独立重放。作者报告64K稀疏两臂同机，其FullKV锚来自另一次运行。门控状态和实际评分维数未核。结果不构成非劣性或匹配质量–成本收益；逐任务得分与配置来源见补充图S8。

工作负载与对照。作者报告的质量记录覆盖五项LongBench任务（问答、摘要与代码补全） [9]，以及Qwen3-8B在32K／64K和历史128K、Qwen3-32B在32K上的11任务RULER [10]集合，另含移植的Quest/AsyncTLS/JSSA基线与Llama-3.1-8B迁移臂（32K）。LongBench的三种名义稀疏变体不构成已验证的完整双因素消融；FullKV是RULER与解码计时中的稠密参照，不设稀疏词元上限。原生方法比较要求保留并披露各方法的预填充／解码路径；统一阶段策略后的适配结果须单独报告。同预算稀疏解码须对齐含保护位置的最终去重词元上限K；粗候选覆盖量和名义标签不能证明这一对齐。解释KV流量还需实际选集大小和头间共享粒度，内部页上限不必一致。仅匹配K不能证明质量相同，也不能建立准备、选择及完整请求成本的匹配比较（S7）。

指标。主要质量指标为每项基准与长度比较中固定任务集合上各任务得分AVG。逐任务增减用于解释AVG，不要求每项任务均零掉分。阶段策略匹配的受控比较须匹配模型、样本、长度、评分器与阶段策略，并对齐稀疏方法的词元预算。未完成的集合不构成完整集合的AVG。图1(b)的区域保留率以选中权重和除以区域全量权重和；图1(c)则以全维参考mid-TopK权重和为分母。选择器时间覆盖合成单层操作；同步TPOT测量首输出后的模型级生成间隔。二者均不测量计入准备、维护及输入输出工作的完整请求时延。未配对的质量与计时研究不能定义质量–时延前沿。AVG差异属于描述性比较，不构成统计非劣性证据。

V. 评估与讨论

A. Q1：缩小评分宽度能否保留任务质量?

五项任务均值在三种名义评分配置间的描述性差距不超过0.33分。在HotpotQA、Qasper、MuSiQue、GovReport和RepoBench-P [9]上，共享子空间评分平均分为47.588，名义全维页评分与词元评分变体分别为47.910和47.666（补充图S4），共享子空间臂分别低0.322与0.078分。这些差值描述已记录配置，并非缩小评分宽度保持质量的证据：变体未被确认为单因素干预，共享子空间运行也采用较早的128/128保护实现。两级表示效应与紧凑设计的质量均不能由此推断；三者均为稀疏配置，稠密FullKV是另一类参照。

B. Q2：区域预算如何约束候选访问?

区域预留提高远区平均保留率，却使43/128条相关观测下降；这是候选访问诊断，非任务质量（图1(b)）。作者报告的8B 32K研究中，在$K_1 = 128$、$K = 1024$、4/128保护下，$\beta = .125 \rightarrow .0625$使AVG从58.30变为59.29。近／远页由16/112变为8/120，词元配额由640/252变为320/572，归因存在混杂。

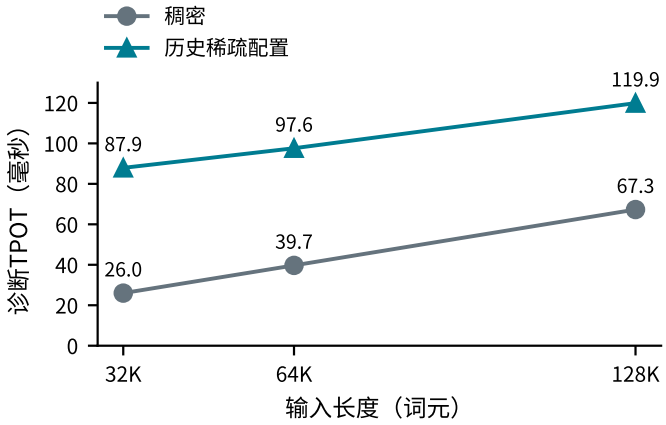


图 4. 作者报告的历史稀疏配置与稠密FullKV模型级解码TPOT，采用Qwen3-8B及动态缓存。固定输出128词元，对应127个首输出后间隔，包含设备同步与argmax。历史$(.125, .375, .625)$设置不同于当前4/128候选。这些中位数不测量完整请求E2E，也不建立匹配质量–成本比较；来源限制见补充注S6。

在$\beta = .03125$下，AVG降至58.96（$K_1 = 256$）与58.07（$K_1 = 128$、远区词元732），两臂夹出$\beta = .0625$峰值；CWE升3.9分、FWE降9.67分。这些稀疏臂的数据／评分器记录匹配，但预测未独立重放。

图3报告32K下相对稠密FullKV的AVG差值：8B为−0.09分（评分器不同），32B为−1.58分（清单匹配），两组均跨机。64K下，8B的$\beta = .0625/.125$两臂AVG为48.85/48.05，另一次运行的稠密锚为48.54。报告同机的稀疏两臂评分器哈希相同，但预测生成脚本与有效配置不同；稠密锚的评分器不同，输入身份仅为legacy-partial。这些描述性比较的预测未重放，也无配对区间，既未隔离分配因果，也不构成统计非劣（S8）。

预算对齐比较。移植的32K基线得分为JSSA 58.7（预算1024）、AsyncTLS 50.09（词元预算512）与Quest 42.85，对照$\beta = .0625$选择器的59.29；与AsyncTLS词元预算对齐的半预算$K = 512$臂得56.00（+5.91），$K = 384$则崩塌至15.00；将$\beta = .0625$迁移到Llama-3.1-8B使AVG从86.19降至83.88。移植出处、CWE 43.4分下降与缺失的配对区间见S8。

同机128K重跑对得45.73（$\beta = .0625$）对46.02（$\beta = .125$），保持46.43锚的98.49%。历史128K RULER报告稀疏臂得分23.98，报告预算推得保留远区页时$k_f = 0$，但既未验证执

行，也未解释22.45分损失（S6）。另一组五任务LongBench比较中，仅保护词元的平均分为26.09，复用的稀疏检索参照为47.91；两者预算分别为256和1024词元，因此检索与预算同时变化。

C. Q3：紧凑评分能否降低执行成本?

模型级解码。在每个测量长度上，所报告的稀疏配置均慢于稠密FullKV（图4）。32K、64K与128K下，稀疏TPOT中位数为87.9、97.6和119.9毫秒，稠密为26.0、39.7和67.3毫秒。相对代价随长度减小，但稀疏TPOT绝对值仍增加。因此，这些测量未显示该实现的解码时间收益。计时包含设备同步与argmax，不含分词、传输与输出，且配置不同于紧凑4/128设计。汇总中位数不能定位原因，也不能预测紧凑实现的性能（S6）。

选择器局部成本。在合成研究中，一项独立的两轮实验（单层、批量大小为1、单查询、64K长度QKV）给出稳态汇总：名义全维页评分1.3502毫秒，共享子空间评分1.3598毫秒，名义全维词元评分1.4634毫秒，因此共享子空间汇总时间高于页评分变体。共享子空间评分第一轮慢0.0237毫秒、第二轮快0.0046毫秒，未显示跨轮次的一致优势。原始采样序列缺失且采样协议差异尚未解决，因而无法可靠评估这些小幅差异，也不能据此认定计时等价（补充注S6）。这些局部计时不能定位瓶颈，未与LongBench质量评估配对，也未测量完整请求成本。

D. 可选门控：预填充不保证解码需求

低预填充注意力并不能证明解码时可安全跳过远区选择。一条归档输入–层记录的预填充远区注意力代理量低于.05，而所报告的解码尾部五个查询均值为.1678；这是代理量跨阶段变化，并非测得的任务质量损失。门控阈值.05和.10对应五任务AVG为47.876和47.692，相对复用的47.910参考分别下降.034和.218分。虽然AVG降幅不大，每臂仍有三项任务下降，其中HotpotQA分别下降1.05和1.26分；AVG仍是主判据，描述任务异质性，不设逐任务零损门槛。小幅AVG变化或包含零的任务自助法区间均不能证明统计非劣。完整评分配置、配对预测与匹配成本缺失，门控共享子空间的质量与净节省仍未验证（补充注S6）。

设计启示与局限。评分与分配规则揭示了两项不同约束。缩小评分宽度会减少单次点积的维度，但普通L2仍对完整历史评分与归一化。远区页配额允许候选进入精筛，但不保证最终远区词元容量。有用的运行点应在匹配的任务质量下减少完整请求时延，准备、维护与选择开销只计一次。所报告的历史稀疏配置解码慢于稠密注意力，而单独测量的选择器时间并未建立完整请求时延收益。紧凑4/128设计仍缺匹配的任务质量与完整请求测量；历史门控汇总也缺少完整的共享子空间配置身份。

VI. 结论

本文研究共享低频页／词元评分与区域分配，并在选中词元上保留原维注意力计算。分析区分了评分维度缩小与执行工作减少，以及远区页预留与远区词元覆盖。作者报告的11任务RULER 32K比较中，Qwen3-8B的$\beta = .0625$稀疏分配比$\beta = .125$稀疏分配的AVG高0.99分，页与词元配额同时改变；$\beta = .03125$两臂得58.07/58.96，夹出峰值。另一项Qwen3-32B稀疏配置则比稠密注意力低1.58分。同机128K对保持稠密锚的98.49%；将$\beta = .0625$迁移到Llama-3.1-8B损失2.31分。这些描述性结果既未隔离机制，也未建立统计非劣结论。历史128K损失与较慢的稀疏解码仍是其配置的局限。要确认紧凑4/128设计的收益，仍需匹配的质量与完整请求成本评估。

AI生成内容。通过Codex使用的OpenAI语言模型参与起草、修订、翻译、图与LaTeX代码生成、来源核对及算术复算；界面未提供可核实的模型版本标识。

References

[1] J. Tang, Y. Zhao, K. Zhu, G. Xiao, B. Kasikci, and S. Han, "Quest: Query-Aware Sparsity for Efficient Long-Context LLM Inference," in ICML, 2024. https://arxiv.org/abs/2406.10774.

[2] L. Ribar, I. Chelombiev, L. Hudlass-Galley, C. Blake, C. Luschi, and D. Orr, "SparQ Attention: Bandwidth-Efficient LLM Inference," in ICML, 2024, pp. 42558–42583. https://proceedings.mlr.press/v235/ribar24a.html.

[3] Y. Xu et al., "HISA: Efficient Hierarchical Indexing for Fine-Grained Sparse Attention," in COLM, 2026. https://arxiv.org/abs/2603.28458v4.

[4] Hu et al., "AsyncTLS: Efficient Generative LLM Inference with Asynchronous Two-level Sparse Attention," arXiv:2604.07815v1, Apr. 9, 2026. https://arxiv.org/abs/2604.07815v1.

[5] H. Sun et al., "ShadowKV: KV Cache in Shadows for High-Throughput Long-Context LLM Inference," in ICML, 2025, pp. 57355–57373. https://proceedings.mlr.press/v267/sun25b.html.

[6] Z. Wang et al., "MILLION: MasterIng Long-Context LLM Inference Via Outlier-Immunized KV Product QuaNtization," in 2025 62nd ACM/IEEE Design Automation Conference (DAC), 2025, pp. 1–7, doi: 10.1109/DAC63849.2025.11132862.

[7] G. Liu, C. Li, J. Zhao, C. Zhang, and M. Guo, "ClusterKV: Manipulating LLM KV Cache in Semantic Space for Recallable Compression," in DAC, 2025. https://doi.org/10.1109/DAC63849.2025.11132479.

[8] G. Shen, J. Zhao, Q. Chen, J. Leng, C. Li, and M. Guo, "SALO: An Efficient Spatial Accelerator Enabling Hybrid Sparse Attention Mechanisms for Long Sequences," in DAC, 2022, pp. 571–576. https://doi.org/10.1145/3489517.3530504.

[9] Y. Bai et al., "LongBench: A Bilingual, Multitask Benchmark for Long Context Understanding," in ACL, 2024, pp. 3119–3137. https://aclanthology.org/2024.acl-long.172/.

[10] C.-P. Hsieh et al., "RULER: What' s the Real Context Size of Your Long-Context Language Models?," in COLM, 2024. https://arxiv.org/abs/2404.06654.

[11] G. Xiao, Y. Tian, B. Chen, S. Han, and M. Lewis, "Efficient Streaming Language Models with Attention Sinks," in ICLR, 2024. https://arxiv.org/abs/2309.17453v4.

[12] J. Park, M. Kang, Y. Han, Y.-G. Kim, J. Shin, and L.-S. Kim, "Token-Picker: Accelerating Attention in Text Generation with Minimized Memory Transfer via Probability Estimation," in DAC, 2024, doi: 10.1145/3649329.3655953.