基于低频RoPE子空间的近远分区稀疏注意力

匿名作者

摘要—**稀疏注意力的页筛选可能在精筛之前丢弃有用的远端词元，因此评分表示是候选选择的重要设计要素。本文研究一种近远分区级联，其页筛选与词元精筛共享32个低频RoPE坐标，组成16个完整旋转对。独立的区域页配额为近端和远端历史保留候选入口，最终注意力使用选中词元的原始全维键和值。在Qwen3-8B的五项LongBench任务上，页／词元评分维度为32/32的配置（sub/sub）平均得分47.588；名义128/32（full/sub）与名义32/128（sub/full）配置分别为47.910和47.666。由于配置绑定不完整，这些差值仅支持描述性比较。独立合成实验中，sub/sub相对full/sub所报的选择器时延没有下降。这些结果表明，紧凑评分需要与选择质量、包含准备的成本共同评估，尚未建立联合质量–时延优势。**

Index Terms—**稀疏注意力，共享表示，区域检索，长上下文推理**

I. 引言

长上下文稀疏注意力需要保留有用历史，同时使词元选择成本低于其省去的注意力计算成本。对两级选择器而言，这一目标涉及两项决策。页粗筛决定哪些词元能够进入精筛：被排除的页无法在下一阶段恢复。评分表示决定每次比较的算术量，而表示准备、排序与访存也共同构成时延。因此，本文将评分维度和候选分配作为两项不同的设计选择来研究。

本文研究用于近远分区级联的共享低频表示。每层、每KV头的页筛选和词元精筛采用同一组完整RoPE坐标对。级联为近期未保护历史与其余历史分别分配页配额，使远端词元即使在近区主导页选择时仍能进入精筛。最终注意力在所选词元集合上使用原始全维Q/K/V。共享评分视图减少设计中的表示重复，区域配额控制候选入口；二者本身均不保证时延下降或任务质量不变。

这一设计提出三个问题：紧凑坐标能否保留有用候选，固定最终词元预算时区域配额能否改善检索，以及省去的注意力成本能否覆盖表示准备和选择开销。图1区分检索需求与评分保真：距离条件注意力描述完整参考概率质量在历史中的分布，等维的完整坐标对比较则测量选中词元保留了多少参考概率质量。这些诊断仍待完成；现有任务得分与局部计时尚不能隔离阶段效应，也不能建立联合质量–时延优势。

II. 相关工作

Quest、SparQ与HISA等查询感知检索方法通过近似选择缩小注意力集合 [1], [2], [3]。AsyncTLS结合了KV组共享的页／词元选集、逐查询头概率的组内平均，以及最终全维注意力 [4]。本文沿用这种级联结构，研究不同的表示与分配选择：

(a) 距离相关的注意力分布

待结果

横轴：query–key距离（tokens）

纵轴：full-reference每token概率质量

(b) 完整配对坐标的检索保真

待结果

横轴：低频／高频／成对随机（均32维）

纵轴：保留的full-reference注意力概率质量

成对随机：待实现验收

图 1. 检索需求与坐标选择的诊断视角（待实验结果）。距离箱概率质量除以各箱内的有效词元数。保留质量是在选中有效ID上求和的原维完整参考注意力概率；其归一化范围是全部有效因果历史，而非所选集合。坐标比较采用相同Q/K、合法历史与预算，但各自生成选中ID；保护词元的概率质量单列。

两级筛选采用共同的低频RoPE坐标对，并为近区和远区分别保留页配额。AsyncTLS则采用全维页评分、校准的精筛通道和异步执行。这些差异使表示选择与具体执行调度的收益成为可区分的问题。

KV压缩与放置方法关注互补的存储容量和数据移动约束 [5], [6], [7]。本文保留原始键和值，改变的是词元选择。因此，紧凑评分表示不会相应缩减原始KV缓存容量。

III. 共享子空间内的近远筛选

选择器构造共享低频评分视图，并将未受保护的历史划分为近区和远区。每个区域依次进行页粗筛（L1）和词元精筛（L2）；选中IDs用于聚集原始全维K/V并计算注意力（图2）。L1决定哪些词元有资格被选取，但普通L2实现仍先计算完整历史分数，再施加页掩码。

A. 共享低频坐标

本文评估的Qwen3-8B表示从128维RoPE后Q/K中选择 $J = \{48, \dots, 63, 112, \dots, 127\}$，即16个完整低频旋转对。较慢的位置相位变化为考察这组紧凑评分坐标提供了动机，但不保证更高的检索保真度，后者仍取决于查询与键的内容。它不是连续最后32维，也不是学习投影；Q/K评分张量实际紧凑为32维。令$E_J \in \mathbb{R}^{128\times 32}$为坐标选择矩阵，则$z_q = E_J^\top q$、$z_i = E_J^\top k_i$。每层、每KV头为两区域和两阶段准备同一键视图，查询头各自保留评分分布（图2及补充图S1）。最终注意力及后续查询仍可访问原始全维KV，因此本设计不节省原KV缓存容量。

令$\mathbf{K}$为键矩阵。固定的词元无关坐标映射与行选择算子R满足$R(\mathbf{K}E_J) = (R\mathbf{K})E_J$。因此，同一紧凑键视图可以服务于两个区域，而无需改变坐标选择操作。页摘要与量化–反量化的词元键仍是不同的派生表示。词元追加、区域边界变化与坐标映射更新，均要求维护相应表示及逻辑ID。这些维护和原始KV聚集成本共同决定表示复用能否缩短执行路径。

B. 区域页配额与词元配额

在解码过程中，令t表示当前词元在完整序列中从0计数的位置（包含prefill词元），于是$S = t + 1$表示包含当前位置、排除padding的有效缓存位置数。s与w分别表示受保护前缀和近期窗口的长度。保护并集与未保护中间区为：

$$\mathcal{P}_t = \{i : 0 \le i \le t,\ i < s \text{ 或 } i > t - w\}, \tag{1}$$

$$\mathcal{M}_t = \{0, \dots, t\} \setminus \mathcal{P}_t. \tag{2}$$

保护重叠仅计一次。near是未保护middle历史的后缀，far为其余部分；near与受保护SWA不同。near边界由未保护历史的比例α结合最小页与页对齐规则确定；middle长度为$\max(0, S - |\mathcal{P}_t|)$。默认参数见实验设置。

near采用平均键页评分，far在共享空间采用符号感知极值。对非空区域页b定义$m_{b,j} = \min_{i\in b} z_{i,j}$与$M_{b,j} = \max_{i\in b} z_{i,j}$，Quest极值构造 [1]给出

$$U_b(z_q) = \sum_j (z_{q,j}^+ M_{b,j} + z_{q,j}^- m_{b,j}), \tag{3}$$

其中$z^+ = \max(z, 0)$、$z^- = \min(z, 0)$。它仅上界未量化共享空间点积，不自动上界原维logits或另行量化的评分。不同维极值可能来自不同词元，有限页筛选仍会漏掉重要词元；平均键评分也不继承该上界。

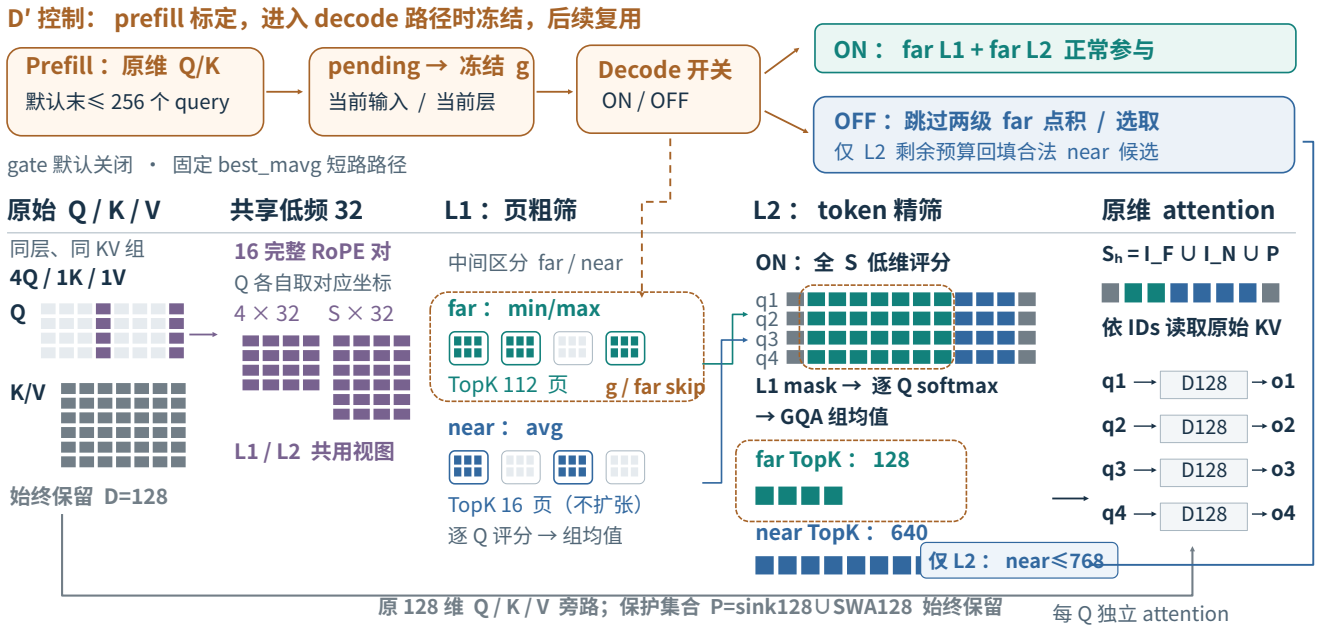


图 2. 共享子空间近远筛选。两级筛选采用同一组RoPE坐标对；选中IDs聚集原始全维K/V，各查询以自身原始全维Q计算最终注意力。可选的prefill门控省略远区筛选，并将空余词元配额分配给已保留的近区页。普通精筛实现先计算完整历史分数，再施加页掩码。

$K_1 = 128$、$\beta = .125$分配near16页与far112页。区域保留提供候选入口，却不保证质量：远端页会占用本可分给近端的容量。L1丢弃某页后，后续词元配额不能恢复其词元；因此区域L1与先全局筛页再分区属于不同策略。

对每个KV头h，区域选择仅允许保留页中的有效词元参与。在支持的预算范围$K \geq |\mathcal{P}_t|$内，middle配额为$K_{\text{mid}} = K - |\mathcal{P}_t|$。在源码推导的历史长度充足示例中，每头总配额$K = 1024$扣除不重叠保护后，middle剩768（补充图S2）。正常候选充足路径下，$\gamma = .625$作用于near页容量，产生$16 \cdot 64 \cdot .625 = 640$个near与128个far词元。短历史或候选不足会降低实际占用。保护与IDs仅合并一次，padding排除，重复ID不额外消耗预算。

C. GQA聚合与原维注意力

在分组查询注意力（GQA）中，32个查询头与8个KV头对应每个KV组4个查询头。L1对组内查询的页分数取平均再做区域TopK。普通L2对每个查询计算全历史低维分数，施加共享L1掩码，并在KV组内对各查询独立归一化后的概率取平均。这种概率聚合不同于先平均logits再做softmax。因此，共享坐标仍保留查询各自的分布；而全历史评分意味着，缩小页候选集本身并不会减少L2点积工作量。

组内唯一选集$\mathcal{S}_{t,h}$包含保护与区域胜出IDs，受总配额约束。组内各查询g使用相同IDs，但以头维度$d = 128$独立重算原维注意力：

$$o_{h,g} = \sum_{i \in \mathcal{S}_{t,h}} \frac{e^{q_{h,g}^{\top} k_{i,h}/\sqrt{d}}}{\sum_{j \in \mathcal{S}_{t,h}} e^{q_{h,g}^{\top} k_{j,h}/\sqrt{d}}} v_{i,h}. \tag{4}$$

先合并IDs再softmax，避免直接相加各区域独立归一化输出 [8]。保留词元使用原KV logit，但缩减分母仍会改变注意力输出。共享IDs提供相同的聚集集合；实际KV流量取决于内核的加载与复用行为。实际16级表示是浮点量化反量化，不是打包四位存储或INT4算术。

表 I
Sub/sub设置：M为保存的manifest，C为记录源码推断。K包含去重保护词元。

参数	设置／证据
最终词元上限K	1024（M）
页长；L1页上限K_1	64；128（M）
α, β, γ	.25、.125、.625（M）
L1/L2评分坐标	32/32（C）
前缀／近期保护	128/128（C）
Prefill；decode层	dense（M）；全层稀疏（C）
L2评分范围	完整历史评分后mask（C）

D. 基于prefill观测的远区门控

即使某层很少关注远区，逐步decode仍需承担远区筛选工作。可选门控（图2中记为D′）检验能否通过prefill观测识别可省略far选择的层。对每个输入的每一层，若prefill观测的平均远区注意力概率质量低于ϵ，则判定为OFF并在后续decode中复用，否则保留far选择。该功能默认不启用，此时仍执行普通近远筛选。在支持的路径上，OFF跳过far两级评分与选取，并将可用L2余量回填合法near词元，near页预算保持不变。

本文实现了单序列门控扩展，其观测边界与状态转换见补充注S5。阈值约束的是prefill统计量，而非后续注意力误差。因此，门控是一种近似策略，其质量和总成本影响需要与默认非门控方法分别评估。

IV. 实验设置

Sub/sub采用Qwen3-8B与表I中的设置。保存的manifest明确dense prefill与共享KV头选集；记录的生产源码给出128词元前缀、近期窗口及32维表示。这些属于源码推断设置，并非逐步运行核验。选择器在浮点张量中使用16级量化–反量化数值，其执行区别于packed INT4算术。其他结果族及未明确设置列于补充注S7。

表示与质量。稠密FullKV保留完整注意力范围，作为质量参照；full/full则保留稀疏选择，在两级使用全维评分。受控L1/



图 3. 完整请求与解码成本（待实验结果）。两面板均采用与质量比较相同的工作负载。请求时间包含准备成本；每词元时间为首输出之后返回间隔的均值。

L2双因素比较需要四种模式，并固定评分规则、保护集与模型设置，下文描述性得分尚未完成该比较。稀疏基线的公平性以每个查询注意力行的最终去重词元配额K（含保护）对齐，并采用相同模型、输入、解码阶段和dense层策略。本文选择器在每个KV组内使用同一选集；同K不意味着跨查询头选集并集或KV访存量相同。内部候选页配额属于方法参数，无须在不同方法间相同，但其评分和访存成本必须计入。匹配比较须分别报告实际词元数、页取整以及逐Q头／共享KV头选集差异（补充注S7）。

对照设计。固定IDs回放在相同坐标映射、摘要与量化规则、选中IDs和最终注意力下比较复用与重建，以隔离复用成本。若要隔离L1区域分配的作用，区域／全局对照则固定页长、L1总上限K_1、表示、保护、L2精筛及其词元配额、最终上限K，仅改变L1区域分配。两臂对全部历史使用同一页scorer，候选不足反映在实际词元数中。这些机制消融固定项不要求不同稀疏方法采用相同K_1。门控仍比较far-on、off-refill和off-no-refill，因为移除far也可能改变near排序。

成本与不确定性。完整请求时间包含表示准备、维护、标定、选择、KV聚集、注意力和同步，重叠工作只计一次。TTFT表示首个词元的返回时间，TPOT为后续词元返回间隔的均值。质量与时延的联合比较要求相同模型、输入、生成设置和评分方式。任务分数差的不确定性还需考虑同一源文档内多个问题的依赖关系；非劣检验需要在查看确认结果前指定可接受退化界限。本文分别报告表示分数与选择器局部计时，不据此估计联合的端到端质量–时延前沿。实验配置与复现细节见补充注S6。

V. 初步结果

配置得分比较。在HotpotQA、Qasper、MuSiQue、GovReport和RepoBench-P五项任务 [9]上，平均得分为47.588（sub/sub）、47.910（名义full/sub）与47.666（名义sub/full）。后两者相对sub/sub分别高0.322与0.078分，sub/full比full/sub低0.244分。名义full/sub与sub/full运行尚未核实为仅改变页评分或词元评分维度的受控配置。因此，这些得分差值仅作描述，不能隔离任一级的作用（补充图S4及补充注S7）。这些配置均不等于稠密FullKV。

图4中的sub/sub–FullKV差值尚无经核验匹配条件下的测量。因此，三臂均值不能建立dense注意力质量保持结论。任务级bootstrap汇总描述的是这五项任务间的变化，不构成文档配对的非劣检验。

选择器局部成本。独立合成实验采用单层、batch1、单query、64K长度QKV，两轮稳态汇总为：full/sub 1.3502毫秒，sub/sub 1.3598毫秒，sub/full 1.4634毫秒。在此设置下，共享子空间选择器的所报时间未低于full/sub。这一排序不能定位瓶颈阶段，且尚未解决的采样协议差异使小幅计时差异无法得到可靠解释（补充注S6）。这些算子计时未与LongBench质量实验配对，也未测量完整请求成本。

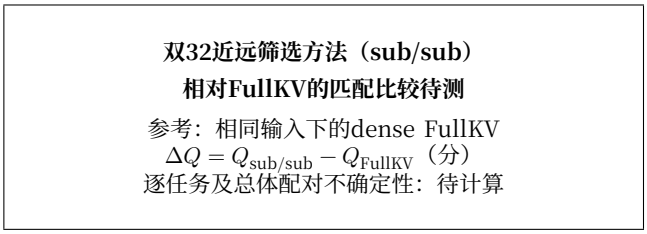


图 4. Sub/sub相对dense FullKV的质量（待匹配实验结果）。目标量为相同输入上的任务分数差及文档配对不确定性。Full/full是稀疏选择中的表示控制，并非dense参照。

保护与prefill门控的局限。保护only配置得分26.09，对照参考为47.91，同时使用的词元数由1024变为256，因此该差值混合了检索策略与预算效应。Prefill统计量也不能约束后续远区需求：一条prefill远区概率质量低于.05的记录，在decode阶段达到.1678。相对复用的47.910参考值，门控阈值.05和.10对应的均值分别下降.034和.218分，每臂五项任务均有三项下降，其中HotpotQA分别下降1.05和1.26分。较大的逐任务损失表明，小幅均值变化可能掩盖任务敏感性。这些门控汇总未明确完整的评分配置，因此其结果不能归属于门控双32方法（补充注S6）。

适用范围。上述结果描述了所研究Qwen3配置的得分和prefill门控局限，尚未建立相对dense FullKV的非劣性、区域页配额的独立收益或完整请求成本下降。现有128K RULER记录 [10]缺少身份明确的可比稀疏臂，因此不纳入定量比较。结论限于已报告的配置和工作负载。

VI. 结论

本文研究了两级共享同一低频RoPE评分视图的近远分区选择。该设计缩小评分宽度，同时保留原始全维KV；普通实现仍对完整历史进行词元评分。现有配置得分差值不能隔离阶段效应，独立合成计时实验也未报告sub/sub的时延优势。因此，这些表示与分配选择能否形成有竞争力的折中，取决于匹配最终去重词元预算下的任务质量及包含准备的请求成本，并须在评估前规定可接受的质量退化。

Content Generated by AI

通过Codex使用的OpenAI语言模型参与全文起草和修订、中英文翻译、图与LaTeX代码生成，并辅助来源核对及算术复算。界面未提供可核实的底层模型版本标识。

References

[1] J. Tang, Y. Zhao, K. Zhu, G. Xiao, B. Kasikci, and S. Han, "Quest: Query-Aware Sparsity for Efficient Long-Context LLM Inference," in ICML, 2024. https://arxiv.org/abs/2406.10774.

[2] L. Ribar, I. Chelombiev, L. Hudlass-Galley, C. Blake, C. Luschi, and D. Orr, "SparQ Attention: Bandwidth-Efficient LLM Inference," in ICML, 2024, pp. 42558–42583. https://proceedings.mlr.press/v235/ribar24a.html.

[3] Y. Xu et al., "HISA: Efficient Hierarchical Indexing for Fine-Grained Sparse Attention," in COLM, 2026. https://arxiv.org/abs/2603.28458.

[4] Hu et al., "AsyncTLS: Efficient Generative LLM Inference with Asynchronous Two-level Sparse Attention," arXiv:2604.07815v1, Apr. 9, 2026. https://arxiv.org/abs/2604.07815v1.

[5] H. Sun et al., "ShadowKV: KV Cache in Shadows for High-Throughput Long-Context LLM Inference," in ICML, 2025, pp. 57355–57373. https://proceedings.mlr.press/v267/sun25b.html.

[6] Z. Wang et al., "MILLION: MasterIng Long-Context LLM Inference Via Outlier-Immunized KV Product QuaNtization," in 2025 62nd ACM/IEEE Design Automation Conference (DAC), 2025, pp. 1–7, doi: 10.1109/DAC63849.2025.11132862.

[7] G. Liu, C. Li, J. Zhao, C. Zhang, and M. Guo, "ClusterKV: Manipulating LLM KV Cache in Semantic Space for Recallable Compression," in DAC, 2025. https://doi.org/10.1109/DAC63849.2025.11132479.

[8] G. Shen, J. Zhao, Q. Chen, J. Leng, C. Li, and M. Guo, "SALO: An Efficient Spatial Accelerator Enabling Hybrid Sparse Attention Mechanisms for Long Sequences," in DAC, 2022, pp. 571–576. https://doi.org/10.1145/3489517.3530504.

[9] Y. Bai et al., "LongBench: A Bilingual, Multitask Benchmark for Long Context Understanding," in ACL, 2024, pp. 3119–3137. https://aclanthology.org/2024.acl-long.172/.

[10] C.-P. Hsieh et al., "RULER: What's the Real Context Size of Your Long-Context Language Models?," in COLM, 2024. https://arxiv.org/abs/2404.06654.