基于低频RoPE子空间的近远分区稀疏注意力

匿名作者

摘要—稀疏注意力需要以低选择成本保留有用候选。本文研究近远页到词元级联，共享32个低频RoPE评分坐标，选中词元用原维注意力，预算全部以绝对量给出：保护前缀与近期窗口长度、近区范围、显式近区页与词元配额，远区容量按差值确定。比例耦合的参数化会静默重分配远区容量：一个表达式把远区词元预算连到三个旋钮，归档诊断展示了全部三种失效，包括一个精确整数阈值。绝对配额使两侧容量显式且构造上非负。作者报告的11任务RULER 32K AVG在Qwen3-8B两种近区配额(16,640)与(8,320)下分别为58.30与59.29；一项Qwen3-32B比较中稀疏为50.64、稠密为52.22。这些描述性比较既未隔离机制，也未建立统计非劣结论，独立历史计时显示稀疏解码更慢。要确认紧凑4/128保护设计的收益，仍需匹配的质量与含准备开销的完整请求成本评估。

Index Terms—稀疏注意力，共享表示，区域检索，长上下文推理

I. 引言

在稠密长上下文解码中，每个新词元都对不断增长的缓存键和值进行注意力计算。稀疏注意力将最终计算限制在入选词元上，但选择这些词元仍需要评分、排序与访存。设计目标是在固定预算内保留与任务相关的词元，并使选择成本低于省去的注意力计算成本；候选选择与注意力集合大小都是核心设计问题。

AsyncTLS等级联使用低成本页摘要筛选候选页，再进行词元精筛 [4]。均值池化与符号感知极值都不按页内注意力权重总和排序，本文的选择器也采用这两类摘要。沿用ClusterKV的词元／页分析视角 [8]，图1(a)中的单个Qwen3查询显示：按注意力权重总和排序的参考页漏选更少时，漏失的参考页权重反而更多。由于区域分配与实际词元数不同，这一诊断不是受控比较，但促使我们考察评分与预算如何共同影响候选进入后续筛选的机会。

候选能否进入后续筛选，还取决于近期与远端历史之间如何分配容量。全局TopK可能将全部可用名额分配给一个区域，区域配额则可以为两侧分别预留名义容量。图1(b)按整箱选择的诊断中，分别预留近远容量使远区注意力权重的平均保留比例从.6759升至.7207，但128条相关观测中仍有43条下降。设计必须兼顾两级筛选；其参数化与取值同样重要，因为比例派生的配额会静默重分配对侧容量，且允许远区页进入候选集本身并不为页内词元预留最终名额。

本文研究一种将共享评分视图与绝对区域预算结合的两级选择器。两级共用一组固定的32个坐标，即16个完整的低频RoPE旋转对；近区页与近区词元获得显式整数配额，远区容量按总上限差值确定。图1(c)的三个32坐标子集中，低频配对平均保留全维参考mid-TopK权重和的.84，随机坐标.51，高频配对.24；随机子集未保留RoPE配对。入选词元使用原始全维Q/K/V完成一次最终注意力计算。紧凑坐标缩短评分点积的维度，但普通词元评分仍在掩码前遍历完整历史，因此减少候选页本身不会省去这部分工作。本文还给出由图1(d)中历史层间差异提供动机的预填充远区门控扩展；该门控默认关闭，需要单独评估。

本文的贡献是给出绝对预算的两级共享坐标选择器、比例参数化中隐式预算耦合的统一分析，并分别评估任务质量、区域覆盖和执行成本。在归档比例界面下，一个由页上限、近区份额与填充比组成的表达式决定远区词元预算，因此上调三者之一都可能将其压至零。在完整11任务RULER32K集合上，已报告的Qwen3-8B AVG在近区配额(8,320)下比(16,640)高0.99点，配额同时改变。另一项Qwen3-32B的11任务RULER32K比较中，稀疏臂比稠密注意力低1.58点。这些描述性比较不能隔离任一机制的作用，归档稀疏配置在所有已测长度上的解码也均慢于稠密注意力。要证明紧凑4/128保护设计的质量–时延收益，需要匹配的任务质量与完整请求测量，包括准备、维护与选择。

II. 相关工作

Quest以符号感知页极值为远区页评分提供构造保证，SparQ从查询选定的键坐标近似注意力，HISA则按层级剪枝注意力集合 [1], [2], [3]；SparQ保护近期词元窗口，HISA将首尾块强制纳入粗筛候选集。AsyncTLS已结合页到词元级联、坐标选择、量化、逐查询归一化后分组查询注意力（GQA）概率聚合，以及使用原始KV的最终注意力 [4]，这些组成部分属于已有先例。本文不提出新级联，而是研究将这些已有组成部分与两级共享的完整低频RoPE旋转对、显式绝对近远预算结合，并区分页级候选资格与最终词元容量。

选择器自身读取什么同样重要。Token-Picker从部分键比特块构造保守概率估计，对被剪枝词元停止后续键比特块和value的传输 [13]；本文的选择器则在页与词元预算约束下用固定坐标子集对候选排序，并保留原维KV。TLI两级选择均保持bf16。AsyncTLS词元键为INT4，FFD扫描2-bit键，HISA官方实现以FP8池化块摘要 [4], [5], [3]；我们的效率来自候选结构、区域配额与页级收窄，而非数值压缩。KV压缩与放置方法关注互补的存储和数据移动约束 [6], [7], [8]；较小的评分视图不减少原始KV容量，也不能据此证明完整请求时延收益。

III. 共享子空间内的近远筛选

为同时控制选择成本与候选访问，级联采用两项显式机制：共享评分视图与绝对区域预算。同一32坐标映射用于L1页筛选和L2词元精筛，将低维筛选与原维注意力分开（图2）。级联仅在解码阶段执行；预填充保持稠密。L1为近区和远区分配独立页配额，使一个区域的页面不争用另一区域的配额。普通L2先对全历史评分，再施加保留页掩码并选择区域词元；选中词元索引与保护位置合并去重后，使用原始Q、K、V计算注意力，重算保留词元的logits并不能恢复被遗漏的词元。

A. 共享低频坐标

每层、每KV头的两个区域和两个筛选阶段采用相同的坐标映射，各查询头仍独立评分。对Qwen3-8B，从128维RoPE后查询与键中选择$J = \{48, \dots, 63, 112, \dots, 127\}$。这些索引保留16个完整的低频split-half RoPE旋转对（补充图S1）。令$E_J \in \mathbb{R}^{128\times 32}$为坐标选择矩阵，评分向量为$z_q = E_J^\top q$与$z_i = E_J^\top k_i$。所保留旋转对的位置旋转较慢，为这一选择提供动机，但不保证保留重要词元。紧凑实现使用32维评分张量，而历史质量运行在128维L2张量中保留32个有效坐标（S7）。

L1将选定的键坐标聚合为页摘要，用于粗粒度排序；L2在同一坐标视图中用逐词元分数精筛。两种评分视图分别存储。原始键和值仍保持全维。紧凑实现将每次评分点积缩窄至四分之一，但辅助视图的准备与维护增加工作，并未压缩原始KV缓存（S7）。

B. 绝对预算与区域资格

在解码过程中，令t表示当前词元在完整序列中从0计数的位置（包含预填充词元）。s与w分别表示受保护前缀和近期窗口的长度，保护集$\mathcal{P}_t = \{i : 0 \le i \le t,\ i < s \text{ 或 } i > t - w\}$，未保护中间区$\mathcal{M}_t = \{0, \dots, t\} \setminus \mathcal{P}_t$；保护重叠仅计一次。近区是$\mathcal{M}_t$的显

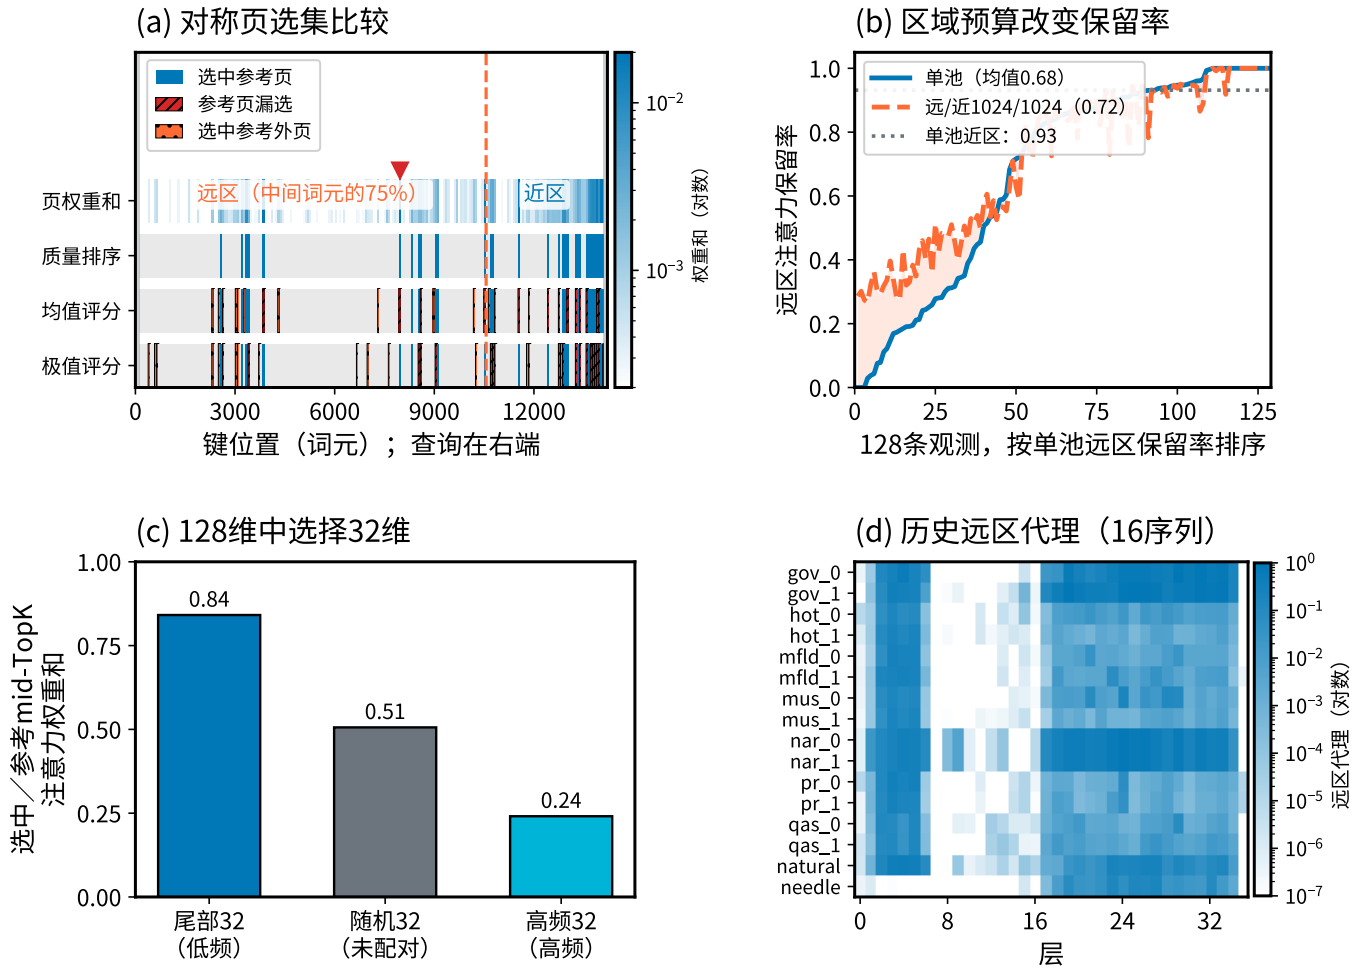


图 1. 四项设计动机诊断，模型为Qwen3-8B；(a)–(c)前缀／近期保护各128。(a) MuSiQue样本1、层24、查询14212。顶行是逐页注意力权重和，不是选集；下三行为注意力权重排序参考、均值与极值选集，均32页，在2048上限下实际使用1989/1989/2048词元。均值／极值分别漏选13／17个参考页，其中包含参考页注意力权重总和的59.65%／26.46%。蓝色为选中参考页，红色斜线为参考漏页，橙色点纹为参考外入选页。整页注意力权重排序只是比较参考，并非最优oracle、精确词元TopK或DSA；均值与极值共享32坐标及头聚合，参考采用全维注意力权重。实际区域分配和词元数不同，漏页不能证明近远分工或任务质量优劣。(b) 四序列贡献128条相关观测，按全局远区保留率排序；比较2048全局整箱上限与远／近各1024的独立上限，不回填；红色填充为保留率下降。保留率为区域选中权重和除以区域总权重和，点线为全局选择的近区均值。(c) 选中权重和相对全维参考mid-TopK权重和；随机32不保留RoPE配对。(d) 单张16×36历史单查询代理矩阵中，24/36层的中位值低于.01，每序列有12–32个低代理值层；使用最后采样查询、组内logits先求和后softmax及旧远区$[64, t-2048)$，不同于当前门控（S6）。这些选择和统计不构成任务质量或解码安全结果。

式页对齐后缀，长度L_n；远区为其余部分。近区不包含受保护的近期窗口。

级联分别为近区与远区历史设置页上限和词元配额（补充图S2）。近区页采用查询与平均键的点积汇总页级相关性；远区页采用符号感知极值来上界共享空间词元分数，这一区域分工属于评分启发式。页摘要覆盖完整物理页，包括边界页内的保护位置；L2另行施加词元区域边界（S7）。对这样的非空页b，定义$m_{b,j} = \min_{i \in b} z_{i,j}$与$M_{b,j} = \max_{i \in b} z_{i,j}$。Quest极值构造 [1] 给出

$$U_b(z_q) = \sum_j (z_{q,j}^{+} M_{b,j} + z_{q,j}^{-} m_{b,j}), \tag{1}$$

其中$z^{+} = \max(z, 0)$、$z^{-} = \min(z, 0)$。对页b中所表示的每个共享空间键z_i，都有$z_q^{\top} z_i \le U_b(z_q)$，因为每个带符号坐标项均由所选极值上界。这不构成对原维logits的相应保证。由于各坐标极值可能来自不同词元，U_b可能高估页内所有词元的分数，因此只保留评分最高的页仍可能漏掉重要词元。平均键页评分不提供这一逐词元上界。

对总上限$K \ge |\mathcal{P}_t|$，定义中间词元预算$K_{\text{mid}} = K - |\mathcal{P}_t|$。界面给出绝对量：近区页配额$n_p$、近区词元配额$n_k$（$0 \le n_k \le K_{\text{mid}}$），远区容量按差值确定，即远区页$K_1 - n_p$、远区词元$K_{\text{mid}} - n_k$。各配额均为显式值；不显式改动某一侧的参数，该侧容量就不会改变。当正概率候选足以填满配额时，L2无法恢复被L1排除页中的未保护词元。候选不足与掩码后零值并列需单独处理，详见S7。

比例耦合的界面隐藏了这一差值。归档参数化按$n_p = \max(1, \text{round}(\beta K_1))$与$n_k = \min(\lfloor \gamma n_p B \rfloor, K_{\text{mid}})$（半整数取偶）派生配额，因此远区词元预算化为

$$k_f = \max(0,\ K_{\text{mid}} - \min(\gamma n_p B,\ K_{\text{mid}})). \tag{2}$$

K_1、β与γ三个旋钮由此通过同一表达式重分配远区容量，而$k_f = 0$时远区页仍被接纳：页资格与词元容量是两个独立约束。归档诊断展示了全部三种重分配，包括上调K_1使远区词元归零的精确整数阈值（Q2、S6）。显式配额在构造上免疫：n_k以K_{mid}为界，远区容量是陈述值而非派生值。

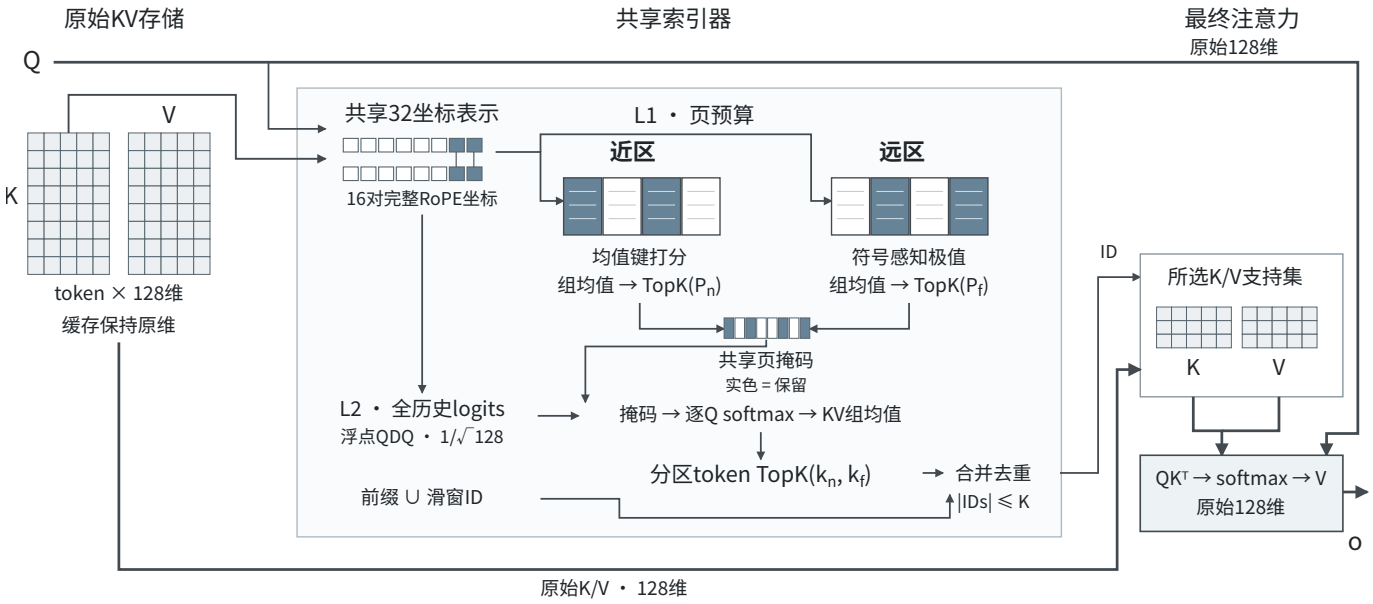


图 2. 共享子空间筛选架构，展示可选门控未启用时的路径。共享坐标表示用于区域L1页评分和普通全历史L2评分。页掩码限制候选资格；逐查询softmax及KV组概率均值后进行区域词元选择。保护位置与索引合并去重后满足K。近区不含保护滑窗。索引定义原维K/V支持集，物理聚集或带掩码稠密计算由后端决定；原始Q走独立路径。阵列均为示意。

当历史足够长、前缀与近期保护不重叠且合法候选充足时，选定紧凑配置（$K = 1024$、$s = 4$、$w = 128$）为每个KV头留下892个中间词元槽位。近区配额$(n_p, n_k) = (8, 320)$留下572个远区槽位，$(16, 640)$备选留下252个（补充图S2）。4个前缀不足一整页，远区选择可能再次选中至多4个保护位置，因此远区覆盖属于名义值。

C. GQA聚合与原维注意力

GQA将32个查询头按每个KV组4个分到8个KV头。L1对组内查询的页分数取平均再做区域TopK。普通L2先为每个查询计算全历史词元logits，施加共同的保留页掩码，并在该支持集上归一化；随后在KV组内对概率取均值，再进行区域词元TopK。在该Qwen3实现中，L2 logits在逐查询softmax前仍使用原始头维度对应的$1/\sqrt{128}$缩放，包括采用32个坐标评分的情形。由于先逐查询softmax再做组内平均，该规则通常不同于对组内平均logits施加softmax。更小的L1候选页集合缩小的是候选资格范围，而非普通L2沿全历史的词元点积数量。

对KV组h，令$\mathcal{S}_{t,h}$为保护位置与区域选中词元索引的去重并集，并满足$|\mathcal{S}_{t,h}| \le K$。组内各查询$g$使用相同词元索引，但以头维度$d = 128$独立重算原维注意力：

$$o_{h,g} = \sum_{i \in \mathcal{S}_{t,h}} \frac{e^{q_{h,g}^{\top} k_{i,h}/\sqrt{d}}}{\sum_{j \in \mathcal{S}_{t,h}} e^{q_{h,g}^{\top} k_{j,h}/\sqrt{d}}} v_{i,h}. \tag{3}$$

每个查询在合并后的索引上统一施加softmax，而非直接相加各区域独立归一化的输出 [9]。保留词元的Q/K logits采用原维计算，但缩小支持集会改变分母，并可能改变注意力输出。这些索引定义共同的逻辑支持集；KV的物理聚集与复用取决于后端和序列长度，短序列可使用带掩码的稠密路径。

D. 基于预填充观测的远区门控

可选门控利用层间差异，默认不启用：平均预填充远区注意力代理量低于ϵ的层在解码时跳过远区选择，决策在首次进入解码路径时冻结并复用至新输入清空（图2；S5）。在支持的固定配额路径上，OFF跳过远区L1/L2评分与选取，并在近区页预算不变的前提下用可用L2余量回填近区候选；移除远区支持集仍可能改变逐查询softmax分母及组内平均后的近区排名。标定按词元定义区域，可能不同于按页对齐的跳过区域；阈值不约束后续解码误差，表示准备、序列全长评分缓冲及归一化仍然保留（S5）。门控的质量与总成本影响需与默认非门控方法分别评估。

表 I
紧凑设计的参数与执行策略。这些设置定义所提出的实现，并非历史运行配置。K包含去重保护词元。

参数	设置
最终词元上限K	1024
页长；L1页上限K_1	64；128
近区页配额n_p（远区）	8（120）
近区词元配额n_k（远区）	320（572）
近区范围L_n	中间区四分之一，页对齐
L1/L2有效坐标	32/32
前缀／近期保护	4/128
预填充；解码层	稠密；全层稀疏

IV. 实验设置

本文分别评估任务质量（Q1）、区域候选覆盖（Q2）与执行成本（Q3）。表I定义紧凑Qwen3-8B设计：稠密预填充、稀疏解码，1024词元上限包含4个前缀与128个近期词元，下文统称4/128保护设计。归档运行用比例(α, β, γ)参数化同一几何，映射为$n_p = \max(1, \mathrm{round}(\beta K_1))$、$n_k = \min(\lfloor \gamma n_p B \rfloor, K_{\mathrm{mid}})$与页对齐的$L_n = \lfloor \alpha |\mathcal{M}_t| \rfloor$；$(8, 320)$等于归档$(.25, .0625, .625)$格（S7）。归档质量运行对L2词元键施加16级量化–反量化；本文视其为主线之外的实现细节（S7）。历史五任务LongBench比较中的共享子空间臂关联到较早的实现：128/128保护，并在填零的128维L2键中存放32个有效坐标。“全维页评分”与“全维词元评分”是缺失完整执行配置的名义标签，不视为受控单阶段消融。合成选择器计时与模型级解码计时来自独立研究，均未提供紧凑设计的匹配质量与成本。配置与测量细节见S6/S7。

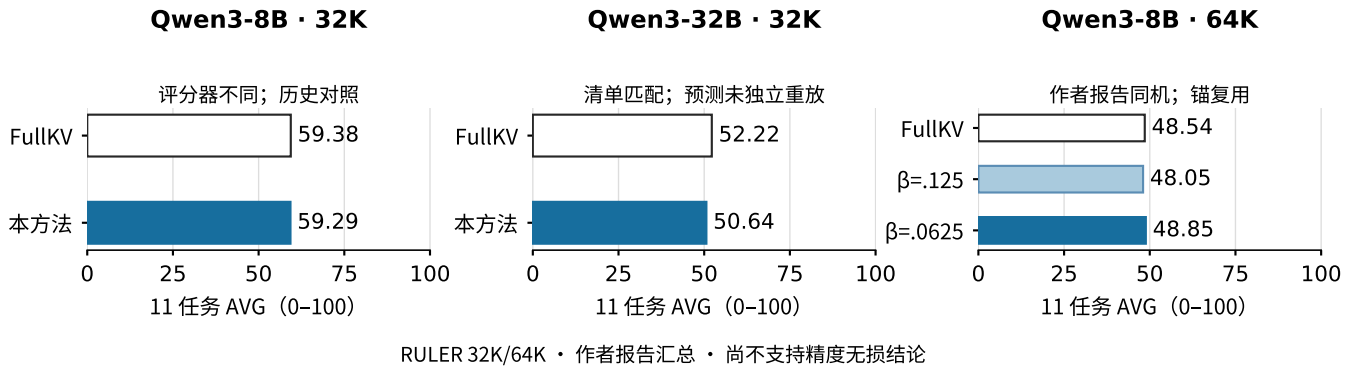


图 3. 作者报告的RULER 32K/64K结果：11任务算术AVG，每任务每臂100例。FullKV为稠密参照；方法臂报告$K = 1024$、4/128保护；32K下近区配额为(8,320)（$\beta = .0625$，8B）或(16,640)（$\beta = .125$，32B），64K的8B展示两种。两组32K比较均跨机器。8B源数据哈希匹配，但评分器不同且输入身份不完整，分差仅属历史描述，非严格配对。32B清单匹配，但预测尚未独立重放。作者报告64K稀疏两臂同机，其FullKV锚来自另一次运行。门控状态和实际评分维数未核。结果不构成非劣性或匹配质量–成本收益；逐任务得分与配置来源见补充图S8。

工作负载与对照。作者报告的质量记录覆盖五项LongBench任务（问答、摘要与代码补全）[10]，以及Qwen3-8B在32K／64K和历史128K、Qwen3-32B在32K上的11任务RULER [11]集合，另含移植的Quest/AsyncTLS/JSSA基线与Llama-3.1-8B迁移臂（32K）。LongBench的三种名义稀疏变体不构成已验证的完整双因素消融；FullKV是RULER与解码计时中的稠密参照，不设稀疏词元上限。原生方法比较要求保留并披露各方法的预填充／解码路径；统一阶段策略后的适配结果须单独报告。预算匹配须对齐含保护位置的最终去重词元上限K；实际选集大小与头间共享粒度影响KV流量，仅匹配K既不能证明质量相同，也不能建立成本匹配比较（S7）。

指标。主要质量指标为每项基准与长度比较中固定任务集合上各任务得分AVG；逐任务增减用于解释AVG，不要求每项任务均零掉分。阶段策略匹配的受控比较须匹配模型、样本、长度、评分器与阶段策略并对齐词元预算；未完成的集合不构成完整集合的AVG。图1(b)的区域保留率以选中权重和除以区域全量权重和；图1(c)则以全维参考mid-TopK权重和为分母。选择器时间（合成单层）与同步TPOT（首输出后的模型级生成间隔）均不测量计入准备、维护及输入输出工作的完整请求时延。未配对的质量与计时研究不能定义质量–时延前沿；AVG差异属于描述性比较，不构成统计非劣性证据。

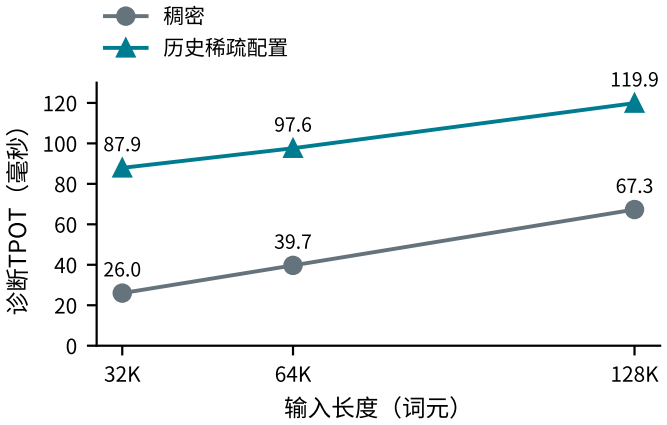


图 4. 作者报告的历史稀疏配置与稠密FullKV模型级解码TPOT，采用Qwen3-8B及动态缓存。固定输出128词元，对应127个首输出后间隔，包含设备同步与argmax。历史$(.125, .375, .625)$设置不同于当前4/128候选；这些中位数不测量完整请求E2E，也不建立匹配质量–成本比较（S6）。

V. 评估与讨论

A. Q1：缩小评分宽度能否保留任务质量?

在 HotpotQA、Qasper、MuSiQue、GovReport 和 RepoBench-P [10]上，五项任务均值在三种名义评分配置间的描述性差距不超过0.33分：共享子空间评分平均分为47.588，名义全维页评分与词元评分变体分别为47.910和47.666（补充图S4），共享子空间臂分别低0.322与0.078分。这些差值描述已记录配置，并非缩小评分宽度保持质量的证据：变体未被确认为单因素干预，共享子空间运行也采用较早的128/128保护实现。三者均为稀疏配置，稠密FullKV是另一类参照。

B. Q2：区域预算如何约束候选访问?

区域预留提高远区平均保留率，却使43/128条相关观测下降；这是候选访问诊断，非任务质量（图1(b)）。作者报告的8B 32K研究中，在$K_1 = 128$、$K = 1024$、4/128保护下，近区配额$(16,640) \to (8,320)$（归档$\beta = .125 \to .0625$）使AVG从58.30变为59.29；远区页由112增至120、远区词元预算由252升至572，同时改变。将近区页配额减半到4（归档$\beta = .03125$）在$K_1 = 128$（远区预算732）得58.07，$K_1 = 256$同配额变体得58.96，均低于所测$(8,320)$配置；CWE升3.9分、FWE降9.67分。这些稀疏臂的数据／评分器记录匹配，但预测未独立重放。

隐式耦合失效。归档诊断展示了式(2)的全部三种重分配。对生产公式做整数枚举，$K = 1024$（$B = 64$、$\beta = .125$、$\gamma = .625$、128/128保护）下首个远区归零的页上限为$K_1 = 156$，$K_1 = 155$时远区预算尚余8：容量看似随K_1增长而远区词元消失。归档任务扫描中，HotpotQA恰在远区预算为零的臂上从53.6–57.3塌缩到37.7，损伤按远区占比分级（占比.875时16.4分，.125时约1分）。在生产格$(\alpha, \beta) = (.25, .125)$，自由竞争与最优$\gamma$在保留质量诊断中相差不超过.001（.852对.8515），而$\gamma = 0$读作“无远区保留”，实际将近区词元配额压为零，保留质量降至.827。历史128K RULER臂按其报告预算推得$k_f = 0$（S6）。这些归档诊断统一了三种异常，但不是新的受控实验。

图3报告32K下相对稠密FullKV的AVG差值：8B为−0.09分（评分器不同），32B为−1.58分（清单匹配），两组均跨机。64K下，8B近区配额(8,320)/(16,640)两臂AVG为48.85/48.05，另一次运行的稠密锚为48.54。同机稀疏两臂评分器哈希相同但预测脚本不同；稠密锚评分器与输入身份不同，缺失的配对区间使因果与统计非劣结论不成立（S8）。

移植基线比较。名义预算为512时，作者报告本选择器AVG为56.00、AsyncTLS为48.33（报告值相差7.67分）。新AsyncTLS/FASA工件不在仓库快照内；最终去重词元支持、保护与阶段是否匹配仍未核实。$K = 1024$时AVG为59.29，对照JSSA的58.7（名义预算1024）、Quest的42.85与FASA的18.64；$K = 384$得15.00。Llama-3.1-8B跨机两臂在近区配额(8,320)/(16,640)下分别得83.88/86.19。移植出处、CWE的43.4分下降及缺失的配对区间见S8。

128K下，同机稀疏两臂分别得45.73（(8,320)）和46.02（(16,640)）；前者为另次运行稠密锚46.43的98.49%。历史128K RULER报告稀疏臂得分23.98，报告预算推得保留远区页时$k_f = 0$，执行未验证、22.45分损失未解释（S6）。另一组五任务LongBench比较中，仅保护词元的平均分为26.09，复用的稀疏检索参照为47.91；两者预算分别为256和1024词元，因此检索与预算同时变化。

C. Q3：紧凑评分能否降低执行成本?

模型级解码。在每个测量长度上，所报告的稀疏配置均慢于稠密FullKV（图4）。32K、64K与128K下，稀疏TPOT中位数为87.9、97.6和119.9毫秒，稠密为26.0、39.7和67.3毫秒。相对代价随长度减小，但稀疏TPOT绝对值仍增加：无解码时间收益。计时包含设备同步与argmax，配置不同于紧凑设计，汇总中位数不能定位原因，也不能预测紧凑实现的性能（S6）。

选择器局部成本。一项独立的两轮合成实验（单层、批量大小为1、单查询、64K长度QKV）给出稳态汇总：名义全维页评分1.3502毫秒，共享子空间评分1.3598毫秒，名义全维词元评分1.4634毫秒；共享子空间第一轮慢0.0237毫秒、第二轮快0.0046毫秒。原始采样序列缺失且采样协议差异尚未解决，无法可靠评估这些小幅差异（S6）。这些局部计时不能定位瓶颈，未与质量评估配对，也未测量完整请求成本。

D. 可选门控：预填充不保证解码需求

低预填充注意力并不能证明解码时可安全跳过远区选择。一条归档输入–层记录的预填充远区注意力代理量低于.05，而所报告的解码尾部五个查询均值为.1678：这是代理量跨阶段变化，并非测得的任务质量损失。门控阈值.05和.10对应五任务AVG为47.876和47.692，相对复用的47.910参考分别下降.034和.218分，每臂仍有三项任务下降，其中HotpotQA分别下降1.05和1.26分；AVG仍是主判据，不设逐任务零损门槛。小幅AVG变化或包含零的任务自助法区间均不能证明统计非劣。完整评分配置、配对预测与匹配成本缺失，门控共享子空间的质量与净节省仍未验证（S6）。

设计启示与局限。两项约束反复出现：缩小评分宽度减少单次点积的维度，但普通L2仍对完整历史评分；远区页配额允许候选进入精筛，但不保证最终远区词元容量。有用的运行点应在匹配的任务质量下减少完整请求时延，准备、维护与选择开销只计一次。所报告的历史稀疏配置解码慢于稠密注意力，选择器局部计时未建立请求级收益，紧凑设计仍缺匹配测量；历史门控汇总也缺少完整的配置身份。

VI. 结论

本文研究共享低频页／词元评分与绝对区域预算，并在选中词元上保留原维注意力计算。分析区分了评分维度缩小与执行工作减少、远区页预留与远区词元覆盖，以及显式配额与比例派生容量，其耦合表达式允许全部三种归档重分配。作者报告的11任务RULER 32K中，Qwen3-8B在近区配额(8,320)下的AVG比(16,640)高0.99分，页与词元配额同时改变；近区页配额4的两臂得58.07/58.96，均低于(8,320)。另一项Qwen3-32B稀疏配置比稠密注意力低1.58分；128K下(8,320)为另次运行稠密锚的98.49%，Llama-3.1-8B的(8,320)臂在32K跨机比较中比(16,640)低2.31分。这些描述性结果既未隔离机制，也未建立统计非劣结论；历史128K损失与较慢的稀疏解码仍是其配置的局限，紧凑4/128设计仍需匹配的质量与完整请求成本评估。

AI生成内容。通过Codex使用的OpenAI语言模型参与起草、修订、翻译、图与LaTeX代码生成、来源核对及算术复算；界面未提供可核实的模型版本标识。

References

[1] J. Tang, Y. Zhao, K. Zhu, G. Xiao, B. Kasikci, and S. Han, "Quest: Query-Aware Sparsity for Efficient Long-Context LLM Inference," in ICML, 2024. https://arxiv.org/abs/2406.10774.

[2] L. Ribar, I. Chelombiev, L. Hudlass-Galley, C. Blake, C. Luschi, and D. Orr, "SparQ Attention: Bandwidth-Efficient LLM Inference," in ICML, 2024, pp. 42558–42583. https://proceedings.mlr.press/v235/ribar24a.html.

[3] Y. Xu et al., "HISA: Efficient Hierarchical Indexing for Fine-Grained Sparse Attention," in COLM, 2026. https://arxiv.org/abs/2603.28458v4.

[4] Hu et al., "AsyncTLS: Efficient Generative LLM Inference with Asynchronous Two-level Sparse Attention," arXiv:2604.07815v1, Apr. 9, 2026. https://arxiv.org/abs/2604.07815v1.

[5] Z. Liu, Z. Ning, R. Li, X. Liu, Y. Song, M. Zhang, Z. He, and X. Qiu, "Faster Than Flash: Exploiting Attention Sparsity for Efficient Long-Context Decoding," in ICML, 2026, pp. 77913–77928. https://proceedings.mlr.press/v306/liu26da.html.

[6] H. Sun et al., "ShadowKV: KV Cache in Shadows for High-Throughput Long-Context LLM Inference," in ICML, 2025, pp. 57355–57373. https://proceedings.mlr.press/v267/sun25b.html.

[7] Z. Wang et al., "MILLION: MasterIng Long-Context LLM Inference Via Outlier-Immunized KV Product QuaNtization," in 2025 62nd ACM/IEEE Design Automation Conference (DAC), 2025, pp. 1–7, doi: 10.1109/DAC63849.2025.11132862.

[8] G. Liu, C. Li, J. Zhao, C. Zhang, and M. Guo, "ClusterKV: Manipulating LLM KV Cache in Semantic Space for Recallable Compression," in DAC, 2025. https://doi.org/10.1109/DAC63849.2025.11132479.

[9] G. Shen, J. Zhao, Q. Chen, J. Leng, C. Li, and M. Guo, "SALO: An Efficient Spatial Accelerator Enabling Hybrid Sparse Attention Mechanisms for Long Sequences," in DAC, 2022, pp. 571–576. https://doi.org/10.1145/3489517.3530504.

[10] Y. Bai et al., "LongBench: A Bilingual, Multitask Benchmark for Long Context Understanding," in ACL, 2024, pp. 3119–3137. https://aclanthology.org/2024.acl-long.172/.

[11] C.-P. Hsieh et al., "RULER: What's the Real Context Size of Your Long-Context Language Models?," in COLM, 2024. https://arxiv.org/abs/2404.06654.

[12] G. Xiao, Y. Tian, B. Chen, S. Han, and M. Lewis, "Efficient Streaming Language Models with Attention Sinks," in ICLR, 2024. https://arxiv.org/abs/2309.17453v4.

[13] J. Park, M. Kang, Y. Han, Y.-G. Kim, J. Shin, and L.-S. Kim, "Token-Picker: Accelerating Attention in Text Generation with Minimized Memory Transfer via Probability Estimation," in DAC, 2024, doi: 10.1145/3649329.3655953.