基于低频RoPE子空间的近远分区稀疏注意力

匿名作者

摘要—**稀疏注意力需要先决定哪些历史能够进入候选集，再在受限词元集合上计算注意力。本文研究固定最终词元预算下候选访问与选择成本的取舍。近远级联结合两项机制：页筛选与词元精筛共享32坐标RoPE评分映射，并为近远区域分别保留页配额；最终注意力仍使用原始全维查询、键和值。在Qwen3-8B的五项LongBench任务上，采用128/128保护的历史配置得分47.588，名义全维页评分和词元评分变体分别为47.910和47.666。这些描述性比较不能隔离评分维度效应，也不验证当前采用4/128保护的紧凑实现候选。独立合成实验中，共享子空间选择器的所报时间未低于名义全维页评分变体；历史同步TPOT也高于稠密注意力。因此，本文提供设计及初步评估，尚未建立质量–时延优势。现有证据明确了匹配评估需要回答的问题：区域候选访问与紧凑评分能否保留有用词元，同时使包含准备的成本低于所省去的注意力计算。**

Index Terms—**稀疏注意力，共享表示，区域检索，长上下文推理**

I. 引言

长上下文稀疏注意力用选中词元上的注意力替代全历史注意力，但选择本身也需要评分、排序与访存。因此，核心问题是在固定最终词元预算下，如何保留有用历史的访问机会，又不让检索耗尽省去的注意力成本。页到词元的级联使这一矛盾尤为明确：页筛选缩小精筛的候选范围，但有用词元所在页一旦被排除，就无法在后续恢复。

图1沿用ClusterKV的词元／页视角 [7]，以四项Qwen3-8B诊断连接设计选择。固定示例中，质量排序、均值评分与极值评分保留的页不同(a)，为比较区域评分器提供动机，但不能证明纯粹的池化效应。在可行整箱预算下，预留区域容量改变远端历史的访问机会(b)：远区平均保留率从.6759升至.7207，但128条相关观测中有43条下降。因此，区域分配是一项取舍，并非逐查询改善保证。坐标诊断(c)为紧凑评分提供动机，却未将频率与RoPE配对结构分离。历史逐层统计(d)促使我们考察选择性远区计算，但其中单查询代理并非当前门控统计，也不保证解码需求。这些观察为级联提出可检验假设，尚不证明生产选择器保真或任务质量收益。

本文考察级联中的两项关联决策。评分表示决定页和词元排序能够利用的信息，区域分配决定哪些历史能够进入精筛。缩小评分宽度不保证远端候选通过页筛选，预留远端页也不保证选择成本低。我们的设计在两级使用同一低频RoPE坐标映射，并为近远区域分配独立页配额，最后以原始全维Q/K/V在选集上计算注意力。共享映射与区域配额构成两项核心机制；预填充远区门控作为可选扩展，默认不启用。

本文给出共享映射的区域级联，并考察三个问题：（Q1）现有任务得分对紧凑评分提供了什么证据；（Q2）区域预算如何约束候选访问；（Q3）所报选择器与解码成本如何比较。评估分别讨论历史配置得分、区域诊断与计时，不将它们拼接为匹配的质量–时延结果。目前尚未建立联合优势：当前采用4/128保护的紧凑候选缺少匹配验证，合成选择器时间未低于名义全维页评分变体，历史同步稀疏TPOT也高于稠密TPOT。因此，本设计仍处于研究候选阶段。

II. 相关工作

Quest、SparQ与HISA等查询感知检索方法通过近似选择缩小注意力集合 [1], [2], [3]。AsyncTLS提供了页到词元级联稀疏选择的先例 [4]。本文关注共享低频RoPE评分视图与近远区域独立页配额，能否在固定最终词元预算下保留有用候选。这一区分将评分表示、区域分配与执行调度分别考察；其质量与包含准备的成本仍需匹配评估。

KV压缩与放置方法关注互补的存储容量和数据移动约束 [5], [6], [7]。本文保留原始键和值，改变的是词元选择。因此，紧凑评分表示不会相应缩减原始KV缓存容量。

III. 共享子空间内的近远筛选

级联沿一条数据路径执行（图2）。首先，固定坐标映射为两级提供评分表示；L1按独立配额筛选近远页，L2使用同一映射及保留页候选集对词元排序；随后将选中索引与保护位置合并，各查询以原始全维Q/K/V重算注意力。这一区分使近似评分不直接进入保留词元的最终logit，但排除候选仍属于近似。普通L2仍先计算全历史评分再施加掩码，因此L1控制候选访问，而不是省去这些点积。

A. 共享低频坐标

对 Qwen3-8B，从 128 维 RoPE 后查询与键中选择$J = \{48, \dots, 63, 112, \dots, 127\}$。这16个完整低频旋转对既不是连续后缀，也不是学习投影（图2a）。令$E_J \in \mathbb{R}^{128\times 32}$为坐标选择矩阵，评分向量为$z_q = E_J^\top q$与$z_i = E_J^\top k_i$。每层、每KV头的两个区域和两个阶段使用同一映射，查询头仍保留各自评分。较慢的位置相位变化为这一选择提供动机，但不保证检索保真度。紧凑实现使用32维评分张量，而历史质量运行在128维L2张量中保留32个有效坐标（S7）。

共享的是坐标，而非物理存储。对键矩阵$\mathbf{K}$与区域行选择算子R，有$R(\mathbf{K}E_J) = (R\mathbf{K})E_J$，即划分历史前后可以采用同一坐标映射。L1从这些坐标派生页摘要，L2派生量化–反量化词元键，两者无须共享缓冲区。原始键和值保持全维，因此该设计不减少原KV缓存容量。派生表示的准备与维护仍计入总成本；该代数恒等式本身不意味着运行时收益（S7）。

B. 区域页配额与词元配额

在解码过程中，令t表示当前词元在完整序列中从0计数的位置（包含预填充词元），于是$S = t+1$表示包含当前位置、排除填充位置的有效缓存位置数。s与w分别表示受保护前缀和近期窗口的长度。保护并集与未保护中间区为：

$$\mathcal{P}_t = \{i : 0 \le i \le t,\ i < s \text{ 或 } i > t - w\}, \tag{1}$$

$$\mathcal{M}_t = \{0, \dots, t\} \setminus \mathcal{P}_t. \tag{2}$$

保护重叠仅计一次。近区是未保护中间历史的后缀，远区为其余部分；近区与受保护滑动窗口不同。近区边界由未保护历史的比例α结合最小页与页对齐规则确定；中间长度为$\max(0, S - |\mathcal{P}_t|)$。默认参数见实验设置。

图2b展示区域级联。近区采用平均键页评分，远区在共享空间采用符号感知极值。对非空区域页b定义$m_{b,j} = \min_{i\in b} z_{i,j}$与$M_{b,j} = \max_{i\in b} z_{i,j}$，Quest极值构造 [1]给出

$$U_b(z_q) = \sum_j (z_{q,j}^+ M_{b,j} + z_{q,j}^- m_{b,j}), \tag{3}$$

其中$z^+ = \max(z, 0)$、$z^- = \min(z, 0)$。它仅上界未量化共享空间点积，不自动上界原维logits或另行量化的评分。不同维极值可能来自不同词元，有限页筛选仍会漏掉重要词元；平均键评分也不继承该上界。

$K_1 = 128$、$\beta = .125$分配近区16页与远区112页。区域保留提供候选访问机会，却不保证质量：远端页会占用本可分给近端的

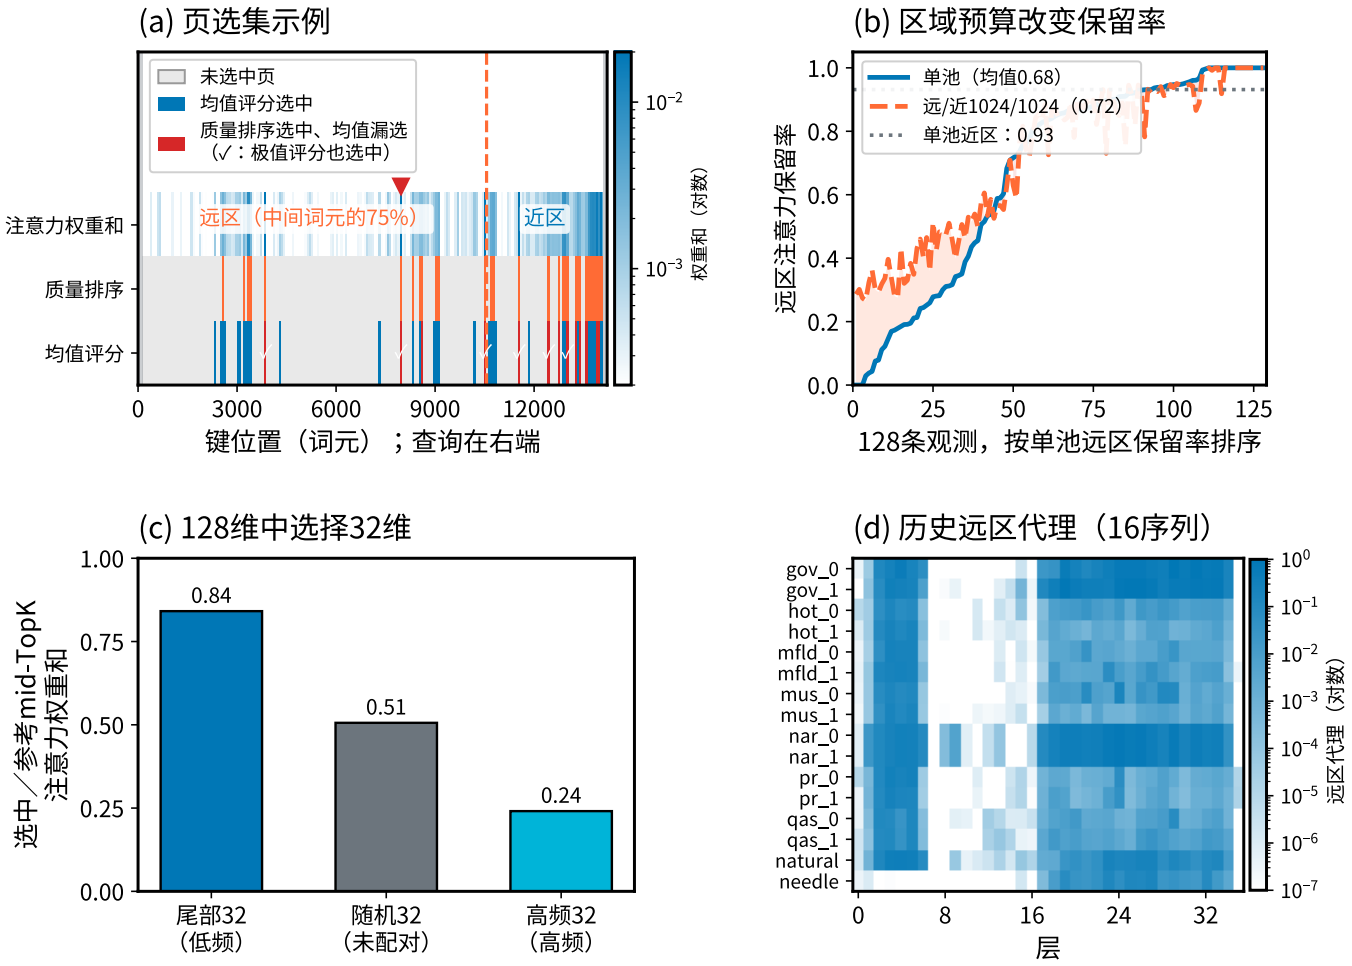


图 1. 四项设计动机诊断，模型为Qwen3-8B；(a)–(c)前缀／近期保护各128。(a) MuSiQue样本1、层24、查询14212的保存页选集；在2048上限下，质量排序、均值评分与极值评分分别使用1989/1989/2048词元，仅作示例，不是预算匹配的最优参照。红色表示质量排序选中而均值漏选的页，勾号表示极值评分也选中。(b) 四序列贡献128条相关观测，按全局远区保留率排序；比较2048全局整箱上限与远／近各1024的独立上限，不回填；红色填充为保留率下降。保留率为区域选中质量除以区域总质量，点线为全局选择的近区均值。(c) 选中质量相对全维参考mid-TopK质量；随机32不保留RoPE配对。(d) 同一16×36历史单查询代理矩阵中，24/36层的中位值低于.01，每序列有12–32个低代理值层；使用最后采样查询、组内logits先求和后softmax及旧远区$[64, t-2048)$，不同于当前门控（S6）。这些选择和统计不构成任务质量或解码安全结果。

容量。L1丢弃某页后，后续词元配额不能恢复其词元；因此区域L1与先全局筛页再分区属于不同策略。

对每个KV头h，设计上的区域候选集由保留页中的有效词元构成。下述示例假定这些候选足以填满配额。在支持的预算范围$K \geq |\mathcal{P}_t|$内，中间配额为$K_{\text{mid}} = K - |\mathcal{P}_t|$。在源码推导的历史长度充足示例中，每头总配额$K = 1024$扣除不重叠保护后，中间名义配额剩892（补充图S2）。在候选充足的标准配置下，$\gamma = .625$作用于近区页容量，产生$16 \cdot 64 \cdot .625 = 640$个近区与252个远区槽位。当前选定配置保护4个前缀和128个近期词元。4个前缀不足一整页，远区选择可能再次选中至多4个保护位置；252属于名义配额，并非保证得到252个非保护远区词元。候选不足及零值并列行为详见补充注S7。

C. GQA聚合与原维注意力

在分组查询注意力（GQA）中，32个查询头与8个KV头对应每个KV组4个查询头。L1对组内查询的页分数取平均再做区域TopK。普通L2对每个查询计算全历史低维分数，施加共享L1掩码，并在KV组内对各查询独立归一化后的概率取平均。在该Qwen3实现中，L2 logits在逐查询softmax前仍使用原始头维度对应的$1/\sqrt{128}$缩放，包括采用32个坐标评分的情形。这种概率聚合不同于先平均logits再做softmax。因此，共享坐标仍保留查询各自的分布；而全历史评分意味着，缩小页候选集本身并不会减少L2点积工作量。

组内唯一选集$\mathcal{S}_{t,h}$包含保护与区域选中词元索引，受总配额约束。组内各查询g使用相同词元索引，但以头维度$d = 128$独立重算原维注意力：

$$o_{h,g} = \sum_{i \in \mathcal{S}_{t,h}} \frac{e^{q_{h,g}^{\top} k_{i,h}/\sqrt{d}}}{\sum_{j \in \mathcal{S}_{t,h}} e^{q_{h,g}^{\top} k_{j,h}/\sqrt{d}}} v_{i,h}. \tag{4}$$

先合并词元索引再softmax，避免直接相加各区域独立归一化输出 [8]。保留词元使用原KV logit，但缩减分母仍会改变注意力输出。共享词元索引定义相同的原维注意力集合。物理聚集与复用取决于注意力后端和序列长度；所检查的实现还包含短序列稠密回退路径。实际16级表示是浮点量化反量化，不是打包四位存储或INT4算术。

D. 基于预填充观测的远区门控

可选远区门控（图2）考察预填充观测能否识别可省略重复远区筛选的层。对每个输入、每层，预填充平均远区注意力权

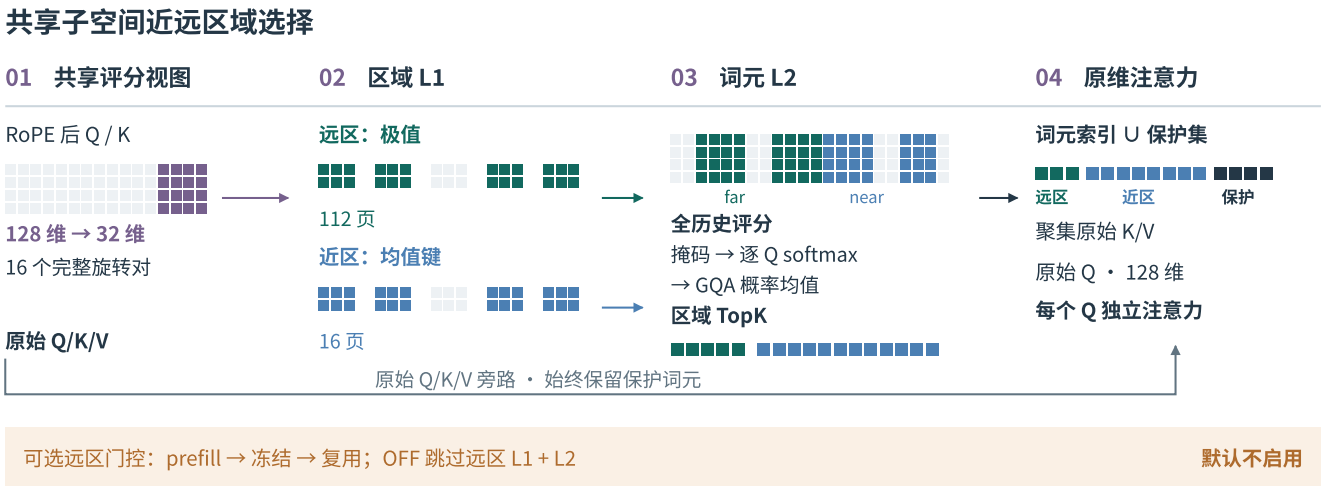


图 2. 共享子空间筛选与原始Q/K/V旁路。L1保留区域页；L2对全历史评分施加掩码，逐查询在共享候选集上归一化，再对KV组内概率取均值并精选区域词元。可选门控为OFF时，跳过远区评分，并将可用L2余量回填近区候选。图中配额为候选充足时的示例。

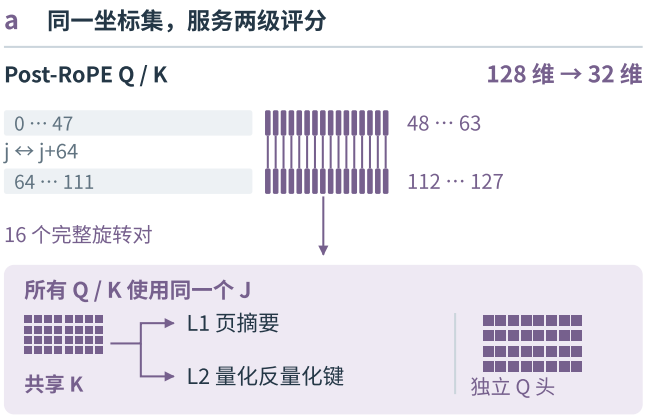


图 2a. 16个完整split-half RoPE旋转对构成32坐标评分视图。每层、每KV头基于相同坐标生成L1页摘要与量化–反量化的L2键，查询视图各自保留。原始Q/K/V绕过这些派生视图（图2）。

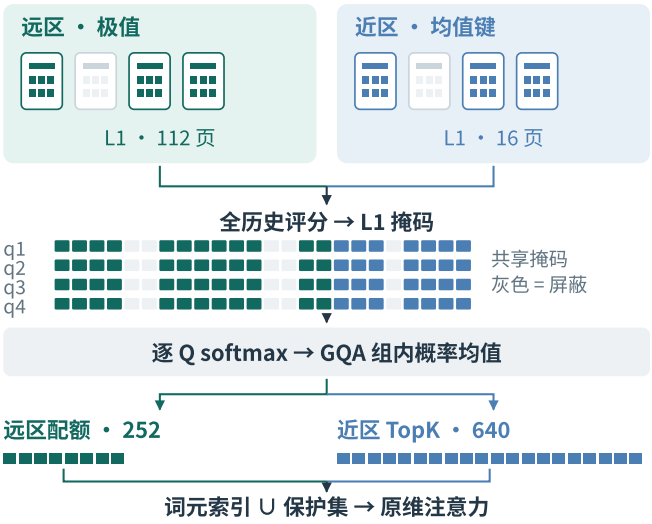


图 2b. 区域筛选与全历史L2评分。彩色单元表示合法候选，并非实测分数。候选容量充足时，当前4/128前缀／近期配置采用远／近区112/16页及名义252/640个区域槽位，另有132个保护词元，总上限$K = 1024$。不足整页的前缀可能重复占用至多4个远区槽位。近区不包含受保护的近期窗口。

重总和低于ϵ时设为OFF，否则继续远区选择；决策在解码入口冻结并复用。该功能默认不启用。在支持的固定数值配额实现上，OFF跳过远区两级评分与选取，并将可用L2余量回填近区候选，近区页预算保持不变。表示准备、序列全长评分缓冲及归一化仍然保留。

图2c展示门控决策与回填。本文实现了单序列门控扩展，其观测边界与状态转换见补充注S5。阈值约束的是预填充统计量，而非后续注意力误差。因此，门控是一种近似策略，其质量和总成本影响需要与默认非门控方法分别评估。

IV. 实验设置

本文区分设计配置与产生现有测量的配置。表I给出紧凑Qwen3-8B候选：稠密预填充、稀疏解码，最终去重词元上限1024，其中包含4个前缀与128个近期词元。五任务质量记录则采用128/128保护，在填零的128维L2键中使用32个有效坐标。合成选择器与模型级计时又分别来自独立实验。下文按各自范围报告结果；这些实验均未建立紧凑候选的匹配质量–成本结果。详细配置与来源见S6/S7。

工作负载与对照。质量证据包括五项LongBench任务，以及历史11任务RULER [10] 128K比较。LongBench得分比较三种名义稀疏评分配置；稠密FullKV在RULER与解码计时中作为单独参照。这些记录尚未构成页评分和词元评分的完整双因素消融。稀疏比较须对齐含保护的最终去重词元上限K、模型、输入与阶段策略。不同方法的内部页预算不必相同，但实际词元数与头共享粒度会影响候选访问和KV流量（S7）。

指标与解释。本文分别报告任务得分均值、合成选择器时间和同步模型级TPOT。完整请求成本还包含准备、维护及输入输出工作，归档TPOT诊断不是这一指标。本文不以未配对实验估计质量–时延前沿。五项工作负载间的任务级变化仅作描述，不构成文档配对的非劣证据。建立此类结论需要匹配运行和事前规定

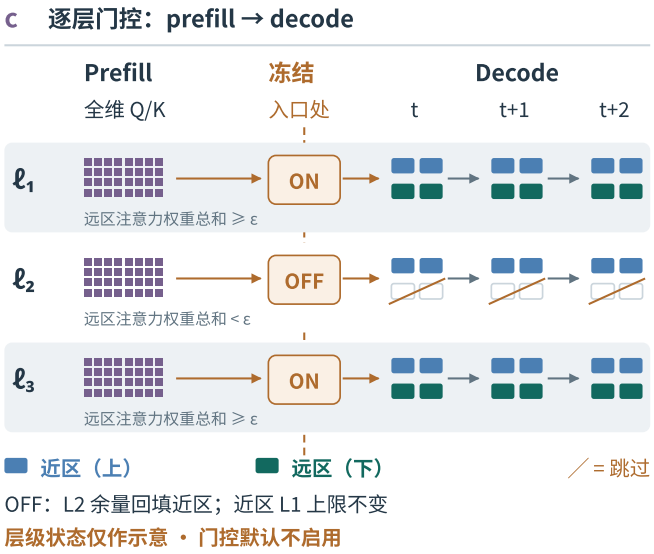


图 2c. 可选远区控制，默认不启用。全维因果预填充远区注意力权重总和在末尾至多256个查询行和全部查询头上取均值，为每个输入、每层确定决策；解码入口冻结，新输入清空。OFF跳过远区L1/L2，在近区页集合不变的前提下回填近区L2。层级状态仅作示意，每对小格分别表示L1/L2。该统计量不约束解码误差。

表 I
当前选定候选设置：M为配置参数，不表示已完成测量；C为源码行为。K包含去重保护词元。

参数	设置／证据
最终词元上限K	1024（M）
页长；L1页上限K_1	64；128（M）
α, β, γ	.25、.125、.625（M）
L1/L2有效坐标	32/32（C）
前缀／近期保护	4/128（M）
预填充；解码层	稠密（M）；全层稀疏（C）
L2评分范围	完整历史评分后施加掩码（C）

的可接受损失界限；所需对照集中于S7。

V. 评估与讨论

A. Q1：历史评分配置的得分能说明什么?

描述性质量比较。在HotpotQA、Qasper、MuSiQue、GovReport和RepoBench-P五项任务 [9]上，平均得分为47.588（共享子空间配置）、47.910（名义全维页评分变体）与47.666（名义全维词元评分变体）。后两者相对共享子空间配置分别高0.322与0.078分，名义全维词元评分变体比名义全维页评分变体低0.244分。两种名义变体运行尚未核实为仅改变页评分或词元评分维度的受控配置。因此，这些得分差值仅作描述，不能隔离任一级的作用（补充图S4及补充注S7）。归档共享子空间配置得分不能直接验证当前紧凑实现。这些配置均不等于稠密FullKV。

B. Q2：区域预算如何约束候选访问?

图1的区域诊断为预留容量提供动机，但现有任务得分不能隔离其收益。当前紧凑候选缺少匹配的稠密FullKV比较。图4保留历史128K得分。将报告的$\beta = .375$、$K_1 = 128$、页长64、$\gamma = .625$及128/128保护代入已检查的配额公式，在768个中间词元预算下推得名义远区词元配额为0。因此，预留远区页本身不保证最终远区词元配额非零。这项代码／报告配置推论不验证实际执行路径，也不隔离得分差的原因。

仅保留保护词元的配置得分26.09，对照参考为47.91，同时使用的词元数由1024变为256，因此该差值混合了检索策略与预算效应。

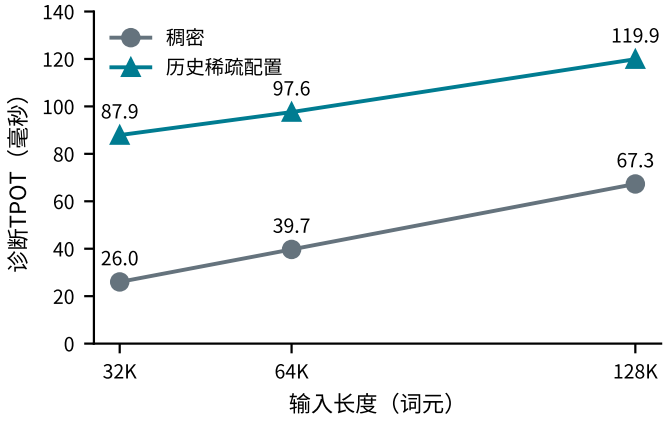


图 3. 作者报告的历史稀疏配置与稠密FullKV模型级解码TPOT，采用Qwen3-8B及动态缓存。固定输出128词元，对应127个首输出后间隔，包含设备同步与argmax。历史(.125, .375, .625)设置不同于当前4/128候选。这些中位数不测量完整请求E2E，也不建立匹配质量–成本比较；来源限制见补充注S6。

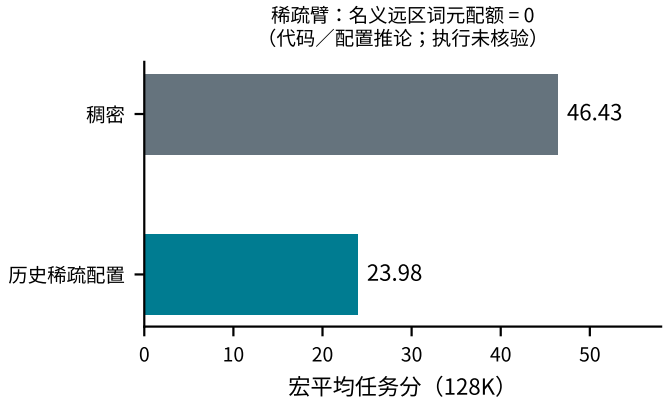


图 4. 作者报告的RULER 128K得分：11任务，每任务每臂100例。历史稀疏配置比稠密FullKV低22.45分，宏平均任务分之比为51.6%。报告的$\beta = .375$、$K_1 = 128$及128/128保护按已检查公式推得名义远区词元配额为0（中间预算768；补充注S6）。这是代码／报告配置推论，不是执行验证或因果归因。该历史设置不验证当前4/128候选，也不支持样本配对推断。

C. Q3：所报选择与解码成本如何比较?

模型级解码诊断。图3以各输入长度的稠密注意力为参照，比较作者报告的历史稀疏配置动态缓存TPOT。32K、64K、128K下，稀疏中位数为87.9、97.6、119.9毫秒，稠密为26.0、39.7、67.3毫秒，报告中位数的稀疏／稠密比值依次为3.38、2.46、1.78。在这三个报告长度上，比值减小，但稀疏TPOT仍上升且始终高于稠密TPOT。这项同步诊断不含分词、输入传输及文本输出，并非完整请求时延。汇总中位数不能识别因果瓶颈；它们不是当前紧凑4/128候选的匹配质量–成本测量。重复记录与执行路径的限制详见S6。

选择器局部成本。独立合成实验采用单层、批量大小为1、单查询、64K长度QKV，两轮稳态汇总为：名义全维页评分变体1.3502毫秒，共享子空间配置1.3598毫秒，名义全维词元评分

变体1.4634毫秒。在此设置下，共享子空间选择器的所报时间未低于名义全维页评分变体。这一排序不能定位瓶颈阶段，且尚未解决的采样协议差异使小幅计时差异无法得到可靠解释（补充注S6）。这些算子计时未与LongBench质量实验配对，也未测量完整请求成本。

D. 可选门控：预填充不保证解码需求

预填充统计量也不能约束后续远区需求：一条预填充远区注意力权重总和低于.05的记录，在解码阶段达到.1678。相对所报告的47.910参考分数，门控阈值.05和.10对应的均值分别下降.034和.218分，每个配置的五项任务均有三项下降，其中HotpotQA分别下降1.05和1.26分。较大的逐任务损失表明，小幅均值变化可能掩盖任务敏感性。这些门控汇总未明确完整的评分配置，因此其结果不能归属于门控共享子空间方法（补充注S6）。

讨论。现有证据区分了三个不能混同的命题：共享坐标定义更小的评分表示，区域配额保留候选访问机会，而二者均不等于有利的质量–成本折中。描述性质量差值不能识别阶段效应，区域比较不能隔离分配作用，计时记录也未建立匹配的质量–成本收益。可选门控进一步引入近似，其任务敏感性已在历史汇总中显现。因此，在主张非劣性、区域分配收益或完整请求加速之前，仍须对紧凑候选完成匹配评估。

VI. 结论

本文给出近远区域级联，将共享低频RoPE评分映射与区域页配额结合，并保留原维最终注意力。其核心取舍是固定最终词元预算下的候选访问与选择成本。现有Qwen3证据描述了历史配置，却尚未验证紧凑候选的联合质量与成本：合成选择器时间未低于名义全维页评分变体，报告的同步稀疏TPOT高于稠密，预填充统计也不能保证解码行为。该设计仍是研究候选，其价值取决于匹配且计入准备成本的评估。

Content Generated by AI

通过Codex使用的OpenAI语言模型参与全文起草和修订、中英文翻译、图与LaTeX代码生成，并辅助来源核对及算术复算。界面未提供可核实的底层模型版本标识。

References

[1] J. Tang, Y. Zhao, K. Zhu, G. Xiao, B. Kasikci, and S. Han, "Quest: Query-Aware Sparsity for Efficient Long-Context LLM Inference," in ICML, 2024. https://arxiv.org/abs/2406.10774.

[2] L. Ribar, I. Chelombiev, L. Hudlass-Galley, C. Blake, C. Luschi, and D. Orr, "SparQ Attention: Bandwidth-Efficient LLM Inference," in ICML, 2024, pp. 42558–42583. https://proceedings.mlr.press/v235/ribar24a.html.

[3] Y. Xu et al., "HISA: Efficient Hierarchical Indexing for Fine-Grained Sparse Attention," in COLM, 2026. https://arxiv.org/abs/2603.28458.

[4] Hu et al., "AsyncTLS: Efficient Generative LLM Inference with Asynchronous Two-level Sparse Attention," arXiv:2604.07815v1, Apr. 9, 2026. https://arxiv.org/abs/2604.07815v1.

[5] H. Sun et al., "ShadowKV: KV Cache in Shadows for High-Throughput Long-Context LLM Inference," in ICML, 2025, pp. 57355–57373. https://proceedings.mlr.press/v267/sun25b.html.

[6] Z. Wang et al., "MILLION: MasterIng Long-Context LLM Inference Via Outlier-Immunized KV Product QuaNtization," in 2025 62nd ACM/IEEE Design Automation Conference (DAC), 2025, pp. 1–7, doi: 10.1109/DAC63849.2025.11132862.

[7] G. Liu, C. Li, J. Zhao, C. Zhang, and M. Guo, "ClusterKV: Manipulating LLM KV Cache in Semantic Space for Recallable Compression," in DAC, 2025. https://doi.org/10.1109/DAC63849.2025.11132479.

[8] G. Shen, J. Zhao, Q. Chen, J. Leng, C. Li, and M. Guo, "SALO: An Efficient Spatial Accelerator Enabling Hybrid Sparse Attention Mechanisms for Long Sequences," in DAC, 2022, pp. 571–576. https://doi.org/10.1145/3489517.3530504.

[9] Y. Bai et al., "LongBench: A Bilingual, Multitask Benchmark for Long Context Understanding," in ACL, 2024, pp. 3119–3137. https://aclanthology.org/2024.acl-long.172/.

[10] C.-P. Hsieh et al., "RULER: What' s the Real Context Size of Your Long-Context Language Models?," in COLM, 2024. https://arxiv.org/abs/2404.06654.

[11] G. Xiao, Y. Tian, B. Chen, S. Han, and M. Lewis, "Efficient Streaming Language Models with Attention Sinks," in ICLR, 2024. https://arxiv.org/abs/2309.17453v4.