基于低频RoPE子空间的近远分区稀疏注意力

匿名作者

摘要—稀疏注意力需要以低选择成本保留有用候选。本文研究近远页到词元级联，共享32个低频RoPE评分坐标，选中词元用原维注意力，预算全部以绝对量给出：保护前缀与近期窗口长度、近区范围、显式近区页与词元配额，远区容量按差值确定。比例耦合的参数化会静默重分配远区容量：一个表达式把远区词元预算连到三个旋钮，归档诊断展示了全部三种失效，包括一个精确整数阈值。绝对配额使两侧容量显式且构造上非负。作者报告的11任务RULER 32K AVG在Qwen3-8B两种近区配额(16,640)与(8,320)下分别为58.30与59.29；一项Qwen3-32B比较中稀疏为50.64、稠密为52.22。这些描述性比较既未隔离机制，也未建立统计非劣结论，独立历史计时显示稀疏解码更慢。要确认紧凑4/128保护设计的收益，仍需匹配的质量与含准备开销的完整请求成本评估。

Index Terms—稀疏注意力，共享表示，区域检索，长上下文推理

I. 引言

在稠密长上下文解码中，每个新词元都对不断增长的缓存键和值进行注意力计算。稀疏注意力将最终计算限制在入选词元上，但选择这些词元仍需要评分、排序与访存。设计目标是在固定预算内保留与任务相关的词元，并使选择成本低于省去的注意力计算成本；候选选择与注意力集合大小都是核心设计问题。

AsyncTLS等级联使用低成本页摘要筛选候选页，再进行词元精筛 [4]。均值池化与符号感知极值都不按页内注意力权重总和排序，本文的选择器也采用这两类摘要。沿用ClusterKV的词元／页分析视角 [8]，图1(a)中的单个Qwen3查询显示：按注意力权重总和排序的参考页漏选更少时，漏失的参考页权重反而更多。由于区域分配与实际词元数不同，这一诊断不是受控比较，但促使我们考察评分与预算如何共同影响候选进入后续筛选的机会。

在四条序列的128条相关观测中，两种全局选择器呈现不同的区域漏失质量构成（图1(b)）。以每条查询的质量排序参考集总质量归一化后，block-avg的近区／远区平均漏失份额为.084／.170，符号感知极值为.079／.042。极值摘要在两区的平均漏失均较低；这些诊断不能证明区域分工或近区等价。在固定2048词元上限下，所测23种near-avg／far-extrema配额拆分中，最佳平均漏失为.135，全局极值为.121。这一有界诊断扫描既未建立混合方案优势，也未建立任务质量收益。

本文研究一种将共享评分视图与绝对区域预算结合的两级选择器。两级共用一组固定的32个坐标，即16个完整的低频RoPE旋转对；近区页与近区词元获得显式整数配额，远区容量按总上限差值确定。图1(c)的三个32坐标子集中，低频配对平均保留全维参考mid-TopK权重和的.84，随机坐标.51，高频配对.24；随机子集未保留RoPE配对。入选词元使用原始全维Q/K/V完成一次最终注意力计算。紧凑坐标缩短评分点积的维度，但普通词元评分仍在掩码前遍历完整历史，因此减少候选页本身不会省去这部分工作。本文还给出由图1(d)中历史层间差异提供动机的预填充远区门控扩展；该门控默认关闭，需要单独评估。

本文的贡献是给出绝对预算的两级共享坐标选择器、比例参数化中隐式预算耦合的统一分析，并分别评估任务质量、区域覆盖和执行成本。在归档比例界面下，一个由页上限、近区份额与填充比组成的表达式决定远区词元预算，因此上调三者之一都可能将其压至零。在完整11任务RULER32K集合上，已报告的Qwen3-8B AVG在近区配额(8,320)下比(16,640)高0.99点，配额同时改变。另一项Qwen3-32B的11任务RULER32K比较中，稀疏臂比稠密注意力低1.58点。这些描述性比较不能隔离任一机制的作用，归档稀疏配置在所有已测长度上的解码也均慢于稠密注意力。要证明紧凑4/128保护设计的质量–时延收益，需要匹配的任务质量与完整请求测量，包括准备、维护与选择。

II. 相关工作

Quest以符号感知页极值为远区页评分提供构造保证，SparQ从查询选定的键坐标近似注意力，HISA则按层级剪枝注意力集合 [1], [2], [3]；SparQ保护近期词元窗口，HISA将首尾块强制纳入粗筛候选集。AsyncTLS已结合页到词元级联、坐标选择、量化、逐查询归一化后分组查询注意力（GQA）概率聚合，以及使用原始KV的最终注意力 [4]，这些组成部分属于已有先例。本文不提出新级联，而是研究将这些已有组成部分与两级共享的完整低频RoPE旋转对、显式绝对近远预算结合，并区分页级候选资格与最终词元容量。

选择器自身读取什么同样重要。Token-Picker从部分键比特块构造保守概率估计，对被剪枝词元停止后续键比特块和value的传输 [13]；本文的选择器则在页与词元预算约束下用固定坐标子集对候选排序，并保留原维KV。本文的bf16配置储存浮点评分键；AsyncTLS使用打包INT4词元级索引，FFD扫描2-bit键缩略表示 [4], [5]。紧凑坐标与区域配额用于控制评分宽度和候选访问。KV压缩与放置方法关注互补的存储和数据移动约束 [6], [7], [8]；较小的评分视图不减少原始KV容量，也不能据此证明完整请求时延收益。

III. 共享子空间内的近远筛选

为同时控制选择成本与候选访问，级联采用两项显式机制：共享评分视图与绝对区域预算。同一32坐标映射用于L1页筛选和L2词元精筛，将低维筛选与原维注意力分开（图2）。级联仅在解码阶段执行；预填充保持稠密。L1为近区和远区分配独立页配额，使一个区域的页面不争用另一区域的配额。在关闭门控与候选收集的参考路径中，L2先对全历史评分，再施加保留页掩码并选择区域词元；选中词元索引与保护位置合并去重后，使用原始Q、K、V计算注意力，重算保留词元的logits并不能恢复被遗漏的词元。现有归档评测不构成对较新候选评分路径的验证。

A. 共享低频坐标

每层、每KV头的两个区域和两个筛选阶段采用相同的坐标映射，各查询头仍独立评分。对Qwen3-8B，从128维RoPE后查询与键中选择$J = \{48, \dots, 63, 112, \dots, 127\}$。这些索引保留16个完整的低频split-half RoPE旋转对（补充图S1）。令$E_J \in \mathbb{R}^{128\times 32}$为坐标选择矩阵，评分向量为$z_q = E_J^\top q$与$z_i = E_J^\top k_i$。所保留旋转对的位置旋转较慢，为这一选择提供动机，但不保证保留重要词元。紧凑实现使用32维评分张量，而历史质量运行在128维L2张量中保留32个有效坐标（S7）。

L1将选定的键坐标聚合为页摘要，用于粗粒度排序；L2在同一坐标视图中用逐词元分数精筛。两种评分视图分别存储。原始键和值仍保持全维。紧凑实现将每次评分点积缩窄至四分之一，但辅助视图的准备与维护增加工作，并未压缩原始KV缓存（S7）。

B. 绝对预算与区域资格

在解码过程中，令t表示当前词元在完整序列中从0计数的位置（包含预填充词元）。s与w分别表示受保护前缀和近期窗口的长度，保护集$\mathcal{P}_t = \{i : 0 \le i \le t,\ i < s \text{ 或 } i > t - w\}$，未保护中

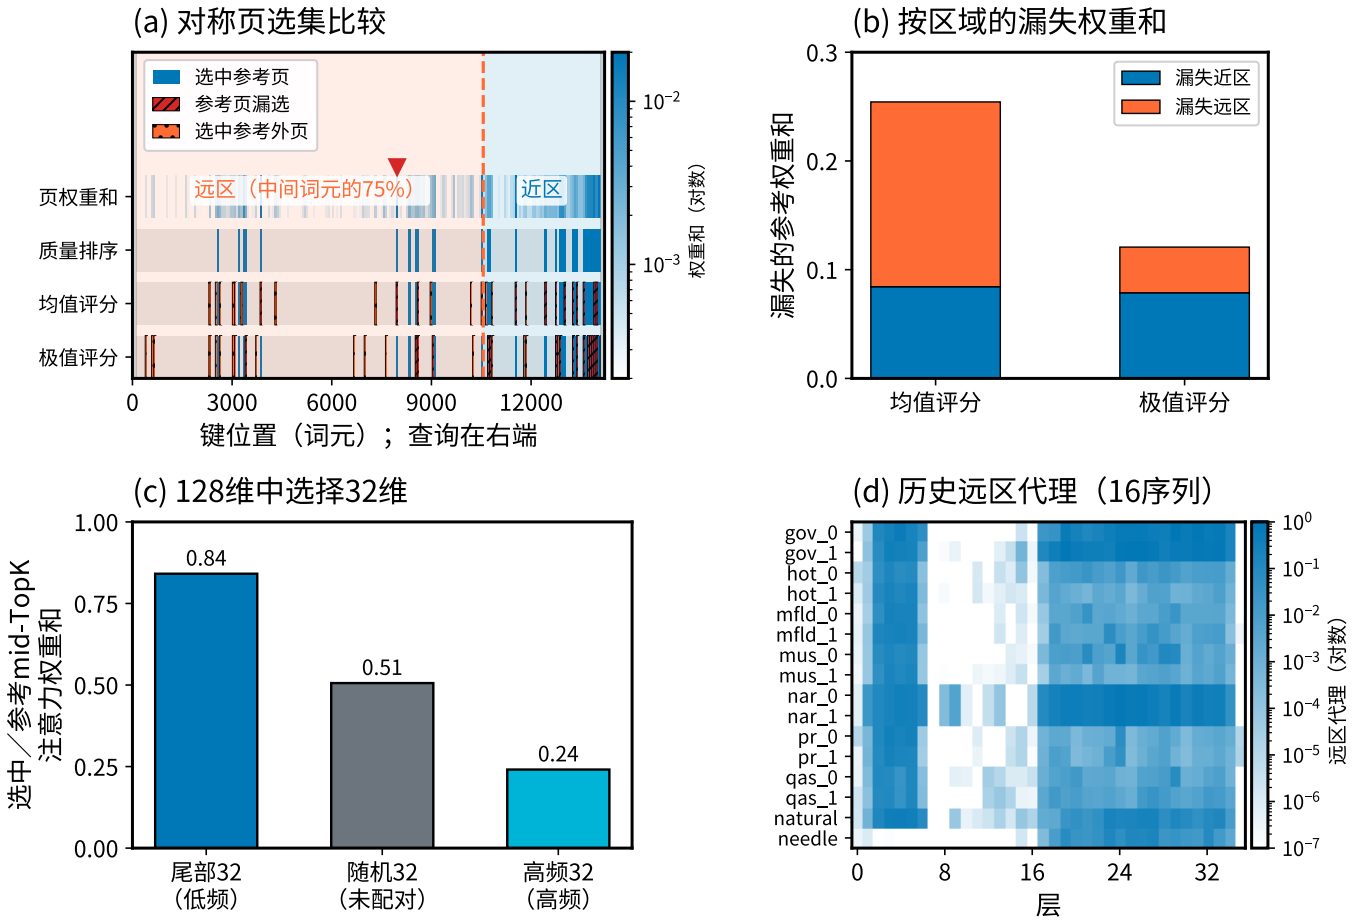


图 1. 四项设计动机诊断，模型为Qwen3-8B；(a)–(c)前缀／近期保护各128。(a) MuSiQue样本1、层24、查询14212。顶行是逐页注意力权重和，不是选集；下三行为注意力权重排序参考、均值与极值选集，均32页，在2048上限下实际使用1989/1989/2048词元。均值／极值分别漏选13／17个参考页，其中包含参考页注意力权重总和的59.65%／26.46%。蓝色为选中参考页，红色斜线为参考漏页，橙色点纹为参考外入选页。整页注意力权重排序只是比较参考，并非最优oracle、精确词元TopK或DSA；均值与极值共享32坐标及头聚合，参考采用全维注意力权重。实际区域分配和词元数不同，漏页不能证明近远分工或任务质量优劣。(b) 区域漏失参考质量的平均份额：先将每条查询在各区漏失的参考质量除以该查询的质量排序参考集总质量，再对四条序列的128条相关观测求均值。极值摘要在两区的漏失均较低，不能据此证明区域分工。(c) 选中权重和相对全维参考mid-TopK权重和；随机32不保留RoPE配对。(d) 单张16×36历史单查询代理矩阵中，24/36层的中位值低于.01，每序列有12–32个低代理值层；使用最后采样查询、组内logits先求和后softmax及旧远区$[64, t-2048)$，不同于当前门控（S6）。这些选择和统计不构成任务质量或解码安全结果。

间区$\mathcal{M}_t = \{0, \dots, t\} \setminus \mathcal{P}_t$；保护重叠仅计一次。近区是$\mathcal{M}_t$的显式页对齐后缀，长度$L_n$；远区为其余部分。近区不包含受保护的近期窗口。

级联分别为近区与远区历史设置页上限和词元配额（补充图S2）。近区页采用查询与平均键的点积汇总页级相关性；远区页采用符号感知极值来上界共享空间词元分数，这一区域分工属于评分启发式。页摘要覆盖完整物理页，包括保护位置（S7）。在分区路径中，若前缀结束或保护滑窗起点位于页内，该边界页会绕过L1排名：先从竞争池移除，再额外并入候选，不占区域页配额。页内未保护词元仍须参与L2竞争；只有保护词元强制进入最终支持集。近远分界按页对齐，不额外触发保送。对这样的非空页b，定义$m_{b,j} = \min_{i \in b} z_{i,j}$与$M_{b,j} = \max_{i \in b} z_{i,j}$。Quest极值构造 [1]给出

$$U_b(z_q) = \sum_j (z_{q,j}^{+} M_{b,j} + z_{q,j}^{-} m_{b,j}), \tag{1}$$

其中$z^{+} = \max(z, 0)$、$z^{-} = \min(z, 0)$。对页b中所表示的每个共享空间键z_i，都有$z_q^{\top} z_i \le U_b(z_q)$，因为每个带符号坐标项均由所选极值上界。这不构成对原维logits的相应保证。由于各坐标极值可能来自不同词元，U_b可能高估页内所有词元的分数，因此只保留评分最高的页仍可能漏掉重要词元。平均键页评分不提供这一逐词元上界。

对总上限$K \ge |\mathcal{P}_t|$，定义中间词元预算$K_{\text{mid}} = K - |\mathcal{P}_t|$。界面给出绝对量：近区页配额$n_p$、近区词元配额$n_k$（$0 \le n_k \le K_{\text{mid}}$），远区容量按差值确定，即远区页$K_1 - n_p$、远区词元$K_{\text{mid}} - n_k$。各配额均为显式值；不显式改动某一侧的参数，该侧容量就不会改变。当正概率候选足以填满配额时，L2无法恢复被L1排除页中的未保护词元。候选不足与掩码后零值并列需单独处理，详见S7。

比例耦合的界面隐藏了这一差值。归档参数化按$n_p = \max(1, \text{round}(\beta K_1))$与$n_k = \min(\lfloor \gamma n_p B \rfloor, K_{\text{mid}})$（半整数取偶）派生配额，因此远区词元预算化为

$$k_f = \max(0,\ K_{\text{mid}} - \min(\gamma n_p B,\ K_{\text{mid}})). \tag{2}$$

K_1、β与γ三个旋钮由此通过同一表达式重分配远区容量，而$k_f = 0$时远区页仍被接纳：页资格与词元容量是两个独立约束。归档诊断展示了全部三种重分配，包括上调K_1使远区词元归零的精确整数阈值（Q2、S6）。显式配额在构造上免疫：n_k以K_{mid}为界，远区容量是陈述值而非派生值。

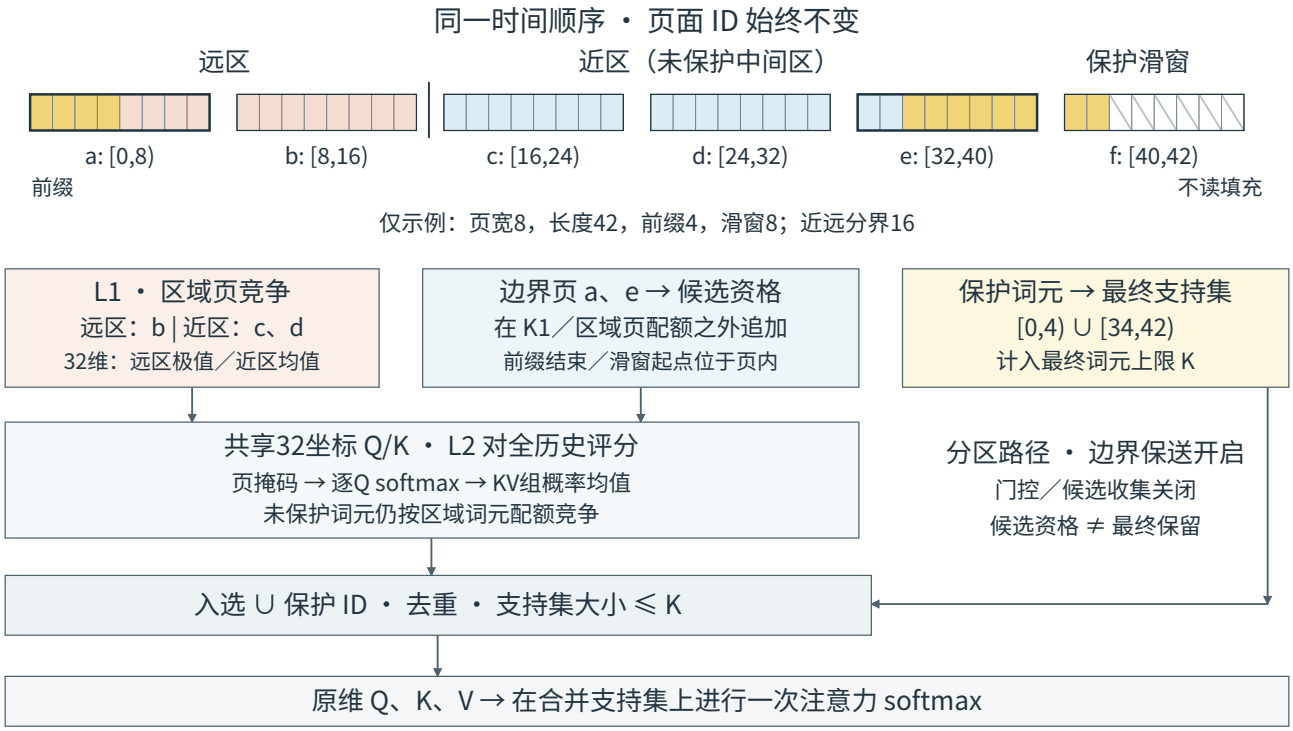


图 2. 共享子空间分区参考架构：边界页保送开启，门控与候选收集关闭。共享坐标表示用于区域L1页评分和普通全历史L2评分。同一时间顺序的页面划分近远；非对齐保护边界页在L1配额之外并入页掩码，只有保护词元绕过最终选择。页掩码限制候选资格；逐查询softmax及KV组概率均值后进行区域词元选择。保护位置与索引合并去重后满足K。近区不含保护滑窗。索引定义原维K/V支持集，物理聚集或带掩码稠密计算由后端决定；阵列均为示意。

当历史足够长、前缀与近期保护不重叠且合法候选充足时，选定紧凑配置（$K = 1024$、$s = 4$、$w = 128$）为每个KV头留下892个中间词元槽位。近区配额$(n_p, n_k) = (8, 320)$留下572个远区槽位，$(16, 640)$备选留下252个（补充图S2）。4个前缀不足一整页，远区选择可能再次选中至多4个保护位置，因此远区覆盖属于名义值。

C. GQA聚合与原维注意力

GQA将32个查询头按每个KV组4个分到8个KV头。L1对组内查询的页分数取平均再做区域TopK。普通L2先为每个查询计算全历史词元logits，施加共同的保留页掩码，并在该支持集上归一化；随后在KV组内对概率取均值，再进行区域词元TopK。在该Qwen3实现中，L2 logits在逐查询softmax前仍使用原始头维度对应的$1/\sqrt{128}$缩放，包括采用32个坐标评分的情形。由于先逐查询softmax再做组内平均，该规则通常不同于对组内平均logits施加softmax。更小的L1候选页集合缩小的是候选资格范围，而非普通L2沿全历史的词元点积数量。

对KV组h，令$\mathcal{S}_{t,h}$为保护位置与区域选中词元索引的去重并集，并满足$|\mathcal{S}_{t,h}| \le K$。组内各查询$g$使用相同词元索引，但以头维度$d = 128$独立重算原维注意力：

$$o_{h,g} = \sum_{i \in \mathcal{S}_{t,h}} \frac{e^{q_{h,g}^{\top} k_{i,h}/\sqrt{d}}}{\sum_{j \in \mathcal{S}_{t,h}} e^{q_{h,g}^{\top} k_{j,h}/\sqrt{d}}} v_{i,h}. \tag{3}$$

每个查询在合并后的索引上统一施加softmax，而非直接相加各区域独立归一化的输出 [9]。保留词元的Q/K logits采用原维计算，但缩小支持集会改变分母，并可能改变注意力输出。这些索引定义共同的逻辑支持集；KV的物理聚集与复用取决于后端和序列长度，短序列可使用带掩码的稠密路径。

D. 基于预填充观测的远区门控

可选门控默认关闭，以预填充末尾查询标定各层：按查询头对全维分数沿因果可见键施加softmax，累加远区概率，再对查询与头取均值。低于ϵ时记录待生效的跳过决策，在首次稀疏解码时冻结。在支持的固定配额路径中，触发后移除远区竞争，保留前缀／滑窗词元，并在近区页预算不变时补充近区L2预算（补充图S3；S5）。边界页保送仍可能让前缀边缘页进入候选评分，因此不能笼统声称省去全部远区点积。普通L2先对全历史评分再掩码。最终注意力的聚集后端对聚集后的键评分；稠密回退仍先对全历史评分再掩码。按词元定义的标定区域与页对齐跳过区域可能不同；ϵ不约束解码误差。移除远区支持集可能改变归一化及组内平均后的近区排名。表示准备、序列全长缓冲和归一化仍保留；门控质量与完整请求成本需单独评估（S5）。

IV. 实验设置

本文分别评估任务质量（Q1）、区域候选覆盖（Q2）与执行成本（Q3）。表I定义紧凑Qwen3-8B设计：稠密预填充、稀疏解码，1024词元上限包含4个前缀与128个近期词元，下文统称4/128保护设计。归档运行用比例(α, β, γ)参数化同一几何，映射为$n_p = \max(1, \mathrm{round}(\beta K_1))$、$n_k = \min(\lfloor \gamma n_p B \rfloor, K_{\mathrm{mid}})$与页对齐的$L_n = \lfloor \alpha |\mathcal{M}_t| \rfloor$；$(8, 320)$等于归档$(.25, .0625, .625)$格（S7）。归档质量运行对L2词元键施加16级量化–反量化；本文视其为主线之外的实现细节（S7）。历史五任务LongBench比较中的共享子空间臂关联到较早的实现：128/128保护，并在填零的128维L2键中存放32个有效坐标。“全维页评分”与“全维词元评分”是缺失完整执行配置的名义标签，不视为受控单阶段消融。合成选择器计时与模型级解码计时来自独立研究，均未提供紧凑设计的匹配质量与成本。配置与测量细节见S6/S7。

工作负载与对照。作者报告的质量记录覆盖五项LongBench任务（问答、摘要与代码补全） [10]，以及Qwen3-8B在32K／

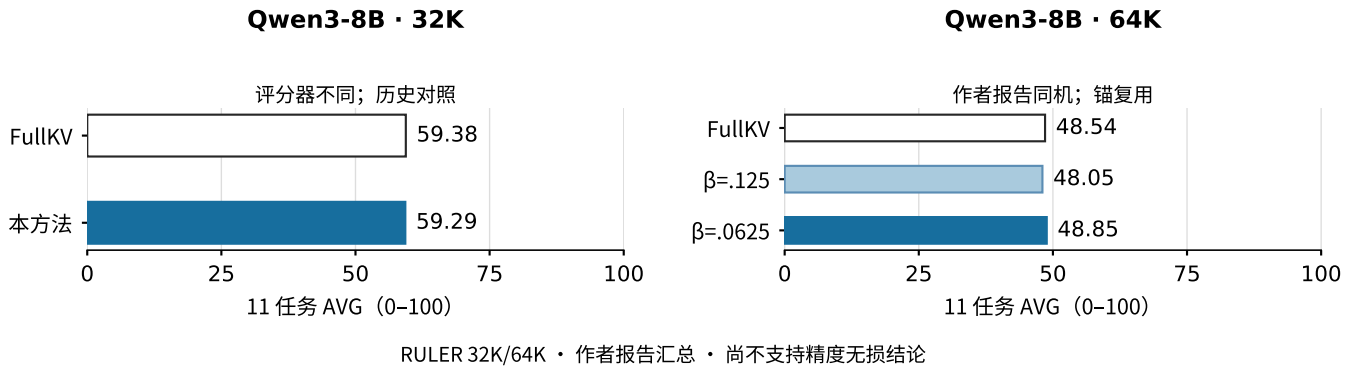


图 3. 作者报告的Qwen3-8B RULER 32K/64K结果：11任务算术AVG，每任务每臂100例。FullKV为稠密参照；稀疏臂报告$K = 1024$、4/128保护。32K面板展示近区配额(8,320)，64K展示(8,320)与(16,640)。32K比较跨机器且评分器不同；64K稀疏两臂报告同机，FullKV锚来自另次运行。门控状态和实际评分维数未核。描述性得分不构成非劣性或匹配质量–成本收益（S8）。

表 I
紧凑设计的参数与执行策略。这些设置定义所提出的实现，并非历史运行配置。K包含去重保护词元。

参数	设置
最终词元上限K	1024
页长；L1页上限K_1	64；128
近区页配额n_p（远区）	8（120）
近区词元配额n_k（远区）	320（572）
近区范围L_n	中间区四分之一，页对齐
L1/L2有效坐标	32/32
前缀／近期保护	4/128
预填充；解码层	稠密；全层稀疏

64K和历史128K、Qwen3-32B在32K上的11任务RULER [11]集合，另含移植的Quest/AsyncTLS/JSSA基线与Llama-3.1-8B迁移臂（32K）。LongBench的三种名义稀疏变体不构成已验证的完整双因素消融；FullKV是RULER与解码计时中的稠密参照，不设稀疏词元上限。原生方法比较要求保留并披露各方法的预填充／解码路径；统一阶段策略后的适配结果须单独报告。预算匹配须对齐含保护位置的最终去重词元上限K；实际选集大小与头间共享粒度影响KV流量，仅匹配K既不能证明质量相同，也不能建立成本匹配比较（S7）。

指标。主要质量指标为每项基准与长度比较中固定任务集合上各任务得分AVG；逐任务增减用于解释AVG，不要求每项任务均零掉分。阶段策略匹配的受控比较须匹配模型、样本、长度、评分器与阶段策略并对齐词元预算；未完成的集合不构成完整集合的AVG。图1(b)先以每条查询的参考集总质量归一化区域漏失质量，再对相关观测取均值；图1(c)则以全维参考mid-TopK权重和为分母。选择器时间（合成单层）与同步TPOT（首输出后的模型级生成间隔）均不测量计入准备、维护及输入输出工作的完整请求时延。未配对的质量与计时研究不能定义质量–时延前沿；AVG差异属于描述性比较，不构成统计非劣性证据。

V. 评估与讨论

A. Q1：缩小评分宽度能否保留任务质量?

在 HotpotQA、Qasper、MuSiQue、GovReport 和 RepoBench-P [10] 上，五项任务均值在三种名义评分配置间的差距不超过0.33分：共享子空间评分平均分为47.588，名义全维页评分与词元评分变体分别为47.910和47.666（补充图S4），共享子空间臂分别比两变体低0.322与0.078分。这些差值描述已记录配置，并非缩小评分宽度保持质量的证据：变体

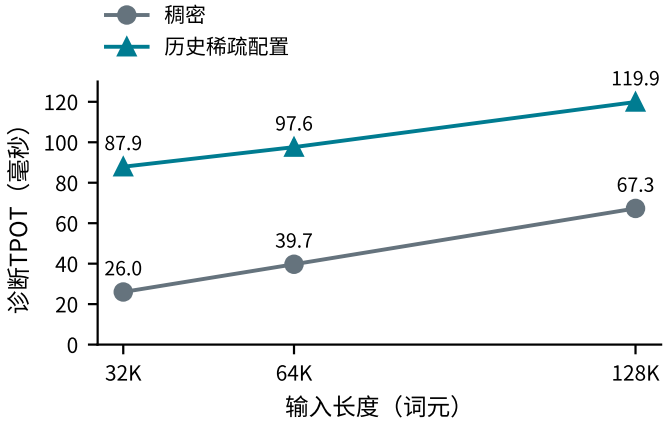


图 4. 作者报告的历史稀疏配置与稠密FullKV模型级解码TPOT，采用Qwen3-8B及动态缓存。固定输出128词元，对应127个首输出后间隔，包含设备同步与argmax。历史$(.125, .375, .625)$设置不同于当前4/128候选；这些中位数不测量完整请求E2E，也不建立匹配质量–成本比较（S6）。

未被确认为单因素干预，共享子空间运行也采用较早的128/128保护实现。三者均为稀疏配置，稠密FullKV是另一类参照。

B. Q2：区域预算如何约束候选访问?

图1(b)展示全局选择器的区域漏失构成，并非区域配额收益；固定总上限的混合扫描同样保留负例（.135对.121）。作者报告的8B 32K研究中，在$K_1 = 128$、$K = 1024$、4/128保护下，近区配额$(16,640) \to (8,320)$（归档$\beta = .125 \to .0625$）使AVG从58.30变为59.29；远区页由112增至120、远区词元预算由252升至572，同时改变。归档$\beta = .03125$下，$K_1 = 128$得58.07，近区页为4、远区词元预算为732；$K_1 = 256$得58.96，近区配额$(8,320)$与59.29分臂相同，但远区页由120扩至248。两臂均低于59.29；相对59.29分臂，$K_1 = 256$臂的CWE升3.9分、FWE降9.67分。这些稀疏臂的数据／评分器记录匹配，但预测未独立重放。

隐式耦合失效。归档诊断展示了式(2)的全部三种重分配。对归档公式做整数枚举，$K = 1024$（$B = 64$、$\beta = .125$、$\gamma = .625$、128/128保护）下首个远区归零的页上限为$K_1 = 156$，$K_1 = 155$时远区预算尚余8：容量看似随K_1增长而远区词元消失。归档任务扫描中，HotpotQA恰在远区预算为零的臂上从53.6–57.3塌缩到37.7，损伤按远区占

比分级（占比.875时16.4分，.125时约1分）。在归档网格点$(\alpha,\beta)=(.25,.125)$，自由竞争与最优$\gamma$在保留质量诊断中相差不超过.001（.852对.8515），而$\gamma=0$读作“无远区保留”，实际将近区词元配额压为零，保留质量降至.827。历史128K RULER臂按其报告预算推得$k_f=0$（S6）。这些归档诊断统一了三种异常，但不是新的受控实验。

作者报告的32K相对稠密FullKV的AVG差值为：8B为−0.09分，32B为−1.58分；两组均跨机，8B的评分协议也不同。64K下，8B近区配额(8,320)/(16,640)两臂AVG为48.85/48.05，另一次运行的稠密锚为48.54。稀疏两臂同机且评分器相同，但预测协议不同；稠密对照也采用不同评分器。这些描述性比较不能建立因果或统计非劣结论（S8）。

移植基线比较。名义预算为512时，作者报告本选择器AVG为56.00、AsyncTLS为48.33（报告值相差7.67分）。最终去重词元预算、保护策略与执行阶段尚未匹配（S8）。$K=1024$时AVG为59.29，对照JSSA的58.7（名义预算1024）、Quest的42.85与FASA的18.64；$K=384$得15.00。Llama-3.1-8B跨机两臂在近区配额(8,320)/(16,640)下分别得83.88/86.19。移植出处、CWE的43.4分下降及缺失的配对区间见S8。

128K下，同机稀疏两臂分别得45.73（(8,320)）和46.02（(16,640)）；前者为另次运行稠密锚46.43的98.49%。历史128K RULER报告稀疏臂得分23.98，报告预算推得保留远区页时$k_f=0$，执行未验证、22.45分损失未解释（S6）。另一组五任务LongBench比较中，仅保护词元的平均分为26.09，复用的稀疏检索参照为47.91；两者预算分别为256和1024词元，因此检索与预算同时变化。

C. Q3：紧凑评分能否降低执行成本?

模型级解码。在每个测量长度上，所报告的稀疏配置均慢于稠密FullKV（图4）。32K、64K与128K下，稀疏TPOT中位数为87.9、97.6和119.9毫秒，稠密为26.0、39.7和67.3毫秒。相对代价随长度减小，但稀疏TPOT绝对值仍增加：无解码时间收益。计时包含设备同步与argmax，配置不同于紧凑设计，汇总中位数不能定位原因，也不能预测紧凑实现的性能（S6）。

选择器局部成本。一项独立的两轮合成实验（单层、批量大小为1、单查询、64K长度QKV）给出稳态汇总：名义全维页评分1.3502毫秒，共享子空间评分1.3598毫秒，名义全维词元评分1.4634毫秒；共享子空间第一轮慢0.0237毫秒、第二轮快0.0046毫秒。原始采样序列缺失且采样协议差异尚未解决，无法可靠评估这些小幅差异（S6）。这些局部计时不能定位瓶颈，未与质量评估配对，也未测量完整请求成本。

D. 可选门控：预填充不保证解码需求

低预填充注意力并不能证明解码时可安全跳过远区选择。一条归档输入–层记录的预填充远区注意力代理量低于.05，而所报告的解码尾部五个查询均值为.1678：这是代理量跨阶段变化，并非测得的任务质量损失。门控阈值.05和.10对应五任务AVG为47.876和47.692，相对复用的47.910参考分别下降.034和.218分，每臂仍有三项任务下降，其中HotpotQA分别下降1.05和1.26分；AVG仍是主判据，不设逐任务零损门槛。小幅AVG变化或包含零的任务自助法区间均不能证明统计非劣。完整评分配置、配对预测与匹配成本缺失，门控共享子空间的质量与净节省仍未验证（S6）。

设计启示与局限。两项约束反复出现：缩小评分宽度减少单次点积的维度，但普通L2仍对完整历史评分；远区页配额允许候选进入精筛，但不保证最终远区词元容量。有用的运行点应在匹配的任务质量下减少完整请求时延，准备、维护与选择开销只计一次。所报告的历史稀疏配置解码慢于稠密注意力，选择器局部计时未建立请求级收益，紧凑设计仍缺匹配测量；历史门控汇总也缺少完整的配置身份。

VI. 结论

本文研究共享低频页／词元评分与绝对区域预算，并在选中词元上保留原维注意力计算。分析区分了评分维度缩小与执行工作减少、远区页预留与远区词元覆盖，以及显式配额与比例派生容量，其耦合表达式允许全部三种归档重分配。作者报告的11任务RULER 32K中，Qwen3-8B在近区配额(8,320)下的AVG比(16,640)高0.99分，页与词元配额同时改变。在$\beta=.03125$时，$K_1=128/256$两臂得58.07/58.96（近区页配额为4/8），均低于59.29。另一项Qwen3-32B稀疏配置比稠密注意力低1.58分；128K下(8,320)为另次运行稠密锚的98.49%，Llama-3.1-8B的(8,320)臂在32K跨机比较中比(16,640)低2.31分。这些描述性结果既未隔离机制，也未建立统计非劣结论；历史128K损失与较慢的稀疏解码仍是其配置的局限，紧凑4/128设计仍需匹配的质量与完整请求成本评估。

AI生成内容。通过Codex使用的OpenAI语言模型参与起草、修订、翻译、图与LaTeX代码生成、来源核对及算术复算；界面未提供可核实的模型版本标识。

References

[1] J. Tang, Y. Zhao, K. Zhu, G. Xiao, B. Kasikci, and S. Han, "Quest: Query-Aware Sparsity for Efficient Long-Context LLM Inference," in ICML, 2024. https://arxiv.org/abs/2406.10774.

[2] L. Ribar, I. Chelombiev, L. Hudlass-Galley, C. Blake, C. Luschi, and D. Orr, "SparQ Attention: Bandwidth-Efficient LLM Inference," in ICML, 2024, pp. 42558–42583. https://proceedings.mlr.press/v235/ribar24a.html.

[3] Y. Xu et al., "HISA: Efficient Hierarchical Indexing for Fine-Grained Sparse Attention," in COLM, 2026. https://arxiv.org/abs/2603.28458v4.

[4] Hu et al., "AsyncTLS: Efficient Generative LLM Inference with Asynchronous Two-level Sparse Attention," arXiv:2604.07815v1, Apr. 9, 2026. https://arxiv.org/abs/2604.07815v1.

[5] Z. Liu, Z. Ning, R. Li, X. Liu, Y. Song, M. Zhang, Z. He, and X. Qiu, "Faster Than Flash: Exploiting Attention Sparsity for Efficient Long-Context Decoding," in ICML, 2026, pp. 77913–77928. https://proceedings.mlr.press/v306/liu26da.html.

[6] H. Sun et al., "ShadowKV: KV Cache in Shadows for High-Throughput Long-Context LLM Inference," in ICML, 2025, pp. 57355–57373. https://proceedings.mlr.press/v267/sun25b.html.

[7] Z. Wang et al., "MILLION: MasterIng Long-Context LLM Inference Via Outlier-Immunized KV Product QuaNtization," in 2025 62nd ACM/IEEE Design Automation Conference (DAC), 2025, pp. 1–7, doi: 10.1109/DAC63849.2025.11132862.

[8] G. Liu, C. Li, J. Zhao, C. Zhang, and M. Guo, "ClusterKV: Manipulating LLM KV Cache in Semantic Space for Recallable Compression," in DAC, 2025. https://doi.org/10.1109/DAC63849.2025.11132479.

[9] G. Shen, J. Zhao, Q. Chen, J. Leng, C. Li, and M. Guo, "SALO: An Efficient Spatial Accelerator Enabling Hybrid Sparse Attention Mechanisms for Long Sequences," in DAC, 2022, pp. 571–576. https://doi.org/10.1145/3489517.3530504.

[10] Y. Bai et al., "LongBench: A Bilingual, Multitask Benchmark for Long Context Understanding," in ACL, 2024, pp. 3119–3137. https://aclanthology.org/2024.acl-long.172/.

[11] C.-P. Hsieh et al., "RULER: What's the Real Context Size of Your Long-Context Language Models?," in COLM, 2024. https://arxiv.org/abs/2404.06654.

[12] G. Xiao, Y. Tian, B. Chen, S. Han, and M. Lewis, "Efficient Streaming Language Models with Attention Sinks," in ICLR, 2024. https://arxiv.org/abs/2309.17453v4.

[13] J. Park, M. Kang, Y. Han, Y.-G. Kim, J. Shin, and L.-S. Kim, "Token-Picker: Accelerating Attention in Text Generation with Minimized Memory Transfer via Probability Estimation," in DAC, 2024, doi: 10.1145/3649329.3655953.