LoDA-SA：低频距离感知稀疏注意力

匿名作者

摘要—稀疏注意力需要以低选择成本保留有用候选。本文提出LoDA-SA（低频距离感知稀疏注意力）：近远页到词元级联共享32个低频RoPE评分坐标，选中词元用原维注意力，预算全部以绝对量给出：保护前缀与近期窗口长度、近区范围n_l、近区页预算n_b与按差值$K_1 - n_b$确定的远区页，以及单一自由竞争词元池；非对齐保护边界页在页配额之外并入候选。比例耦合的参数化会静默重分配远区容量：一个表达式把远区词元预算连到三个旋钮，归档诊断展示了全部三种失效，包括一个精确整数阈值。绝对接口使页容量显式，并完全移除区域词元配额。一份归档五任务LongBench摘要报告86个配置及一个对照：32近区页、4096近区范围的免配额选择得48.26，对照为47.46，而同一几何下的数值词元配额臂得48.67。紧凑设计的单轮实测在RULER 32K/64K/128K得59.02、47.80与46.82，对另次运行的稠密锚59.38、48.54与46.43，差距处于历史批次级差异的量级；历史比例接口臂在128K以零远区词元得23.98。这些单轮比较既未隔离机制，也未建立统计非劣结论，graph重放使32K以上解码TPOT低于稠密。要确认紧凑4/128保护设计的收益，仍需匹配的质量与含准备开销的完整请求成本评估。

Index Terms—稀疏注意力，共享表示，区域检索，长上下文推理

I. 引言

长上下文解码需要在有限注意力预算下保留对有用历史的访问。不同距离的词元竞争同一预算，而全局排名本身不为某个位置区域预留候选入口。因此，距离可以用来组织选择，但不意味着重要性随距离单调下降，也不意味着近处词元总是更重要。选择器需要先明确哪些区域能够提供候选，再以足够低的成本排序，使限制最终注意力支持集具有意义。

词元级选择追踪细粒度相关性，但要为逐词元索引付费；页级摘要削减了这份成本，却模糊了注意力在页内的集中位置 [4]。沿用ClusterKV的词元／页分析视角 [8]，图1(a)用单个Qwen3查询展示两类摘要以各自的方式失效：均值键池化稀释集中的远端尖峰，漏掉承载86.5%参考质量的8个参考页；min–max极值漏页更多（9页）但漏质量少得多（4.7%）、漏失集中在近端，其松弛界反而引入参考外入选页。两种机制还各自携带一套评分视图，级联因此重算本可由同一共享集服务的坐标与摘要。由于区域分配与实际词元数不同，这一诊断不是受控比较，但促使我们考察评分与预算如何共同影响候选进入后续筛选的机会。

这种互补失效是系统性的，并非单查询假象：四条序列的128条相关观测中，avg漏失以远区为主的查询占65%，minmax漏失以近区为主的占61%，近／远平均漏失份额avg为.084／.170、minmax为.079／.042（S6）。互补性既不能证明区域分工，也不能证明近区等价；固定2048词元上限下所测23种near-avg／far-extrema拆分中最佳平均漏失为.135，全局极值为.121——这一有界扫描既未建立混合方案优势，也未建立任务质量收益。

本文研究一种将共享评分视图与绝对区域预算结合的两级选择器。两级共用一组固定的32个坐标，即16个完整的低频RoPE旋转对；近区页预算n_b与近区范围n_l为显式绝对值，远区页按差值$K_1 - n_b$确定，非对齐保护边界页在配额之外并入候选，L2在单一自由竞争池中精筛词元。图1(b)的三个32坐标子集中，低频配对平均保留全维参考mid-TopK权重和的.84，随机坐标.51，高频配对.24；随机子集未保留RoPE配对。入选词元使用原始全维Q/K/V完成一次最终注意力计算。紧凑坐标缩短评分点积的维度，但普通词元评分仍在掩码前遍历完整历史，因此减少候选页本身不会省去这部分工作。本文还给出由图1(c)中历史层间差异提供动机的预填充远区门控扩展；该门控默认关闭，需要单独评估。

本文的贡献是给出LoDA-SA——绝对预算的两级共享坐标选择器、比例参数化中隐式预算耦合的统一分析、区分区域几何与词元分配选择的描述性网格比较，并分别评估任务质量、区域覆盖和执行成本。在归档比例界面下，一个由页上限、近区份额与填充比组成的表达式决定远区词元预算，因此上调三者之一都可能将其压至零；归档近区配额(16,640)变为(8,320)时已报告的Qwen3-8B RULER 32K AVG移动0.99点，两侧配额同时改变。网格各格为单轮运行，无graph稀疏解码在所有已测长度上均慢于稠密注意力。要证明紧凑4/128保护设计的质量–时延收益，需要匹配的任务质量与完整请求测量，包括准备、维护与选择。

II. 相关工作

Quest提供符号感知页极值界，SparQ从查询选择键坐标，HISA按层级剪枝注意力集合 [1], [2], [3]。AsyncTLS明确在粗粒度选块时沿用Quest，在细粒度选词元时采用Double Sparsity，并结合量化、逐查询归一化与GQA概率聚合及原始KV注意力 [4]；更早的Twilight采用先选择再剪枝架构 [14]。LoDA-SA沿用这一广义层级选择范式，研究显式距离区域页准入、两级共享完整低频RoPE对与统一L2竞争的组合。这里陈述的是算法思想关系，不是已核实的直接代码继承。

选择器自身读取什么同样重要。Token-Picker从部分键比特块构造保守概率估计，对被剪枝词元停止后续键比特块和value的传输 [13]；本文的选择器则在页预算约束下用固定坐标子集对候选排序，并保留原维KV。本文的两级选择均保持bf16。AsyncTLS词元键为INT4，FFD扫描2-bit键，HISA官方实现以FP8池化块摘要 [4], [5], [3]；LoDA-SA期望通过紧凑评分与结构化候选准入降低选择开销；普通L2仍对全历史评分，因此仅凭页级收窄不能证明这一节省。KV压缩与放置方法关注互补的存储和数据移动约束 [6], [7], [8]；较小的评分视图不减少原始KV容量，也不能据此证明完整请求时延收益。

III. LoDA-SA：共享子空间中的距离感知选择

LoDA-SA区分三项决策：哪些距离区域能够提供候选页、如何用同一共享紧凑视图评分，以及合并候选中的哪些词元进入最终注意力。图1直接支撑前两项：互补的近远漏失驱动区域准入（a），频段对照驱动共享视图（b）；面板(c)则为可选远区门控提供动机（III-F节）。距离策略用n_l指定近区范围、n_b指定近区页预算，远区获得$K_1 - n_b$页。实现先准备共享32坐标表示，再执行区域L1选择（图2）；选择仅在解码阶段执行，预填充保持稠密，门控保持关闭，归档运行不验证当前LoDA-SA。

A. 区域预算从两个距离带准入候选页

在解码过程中，令t表示当前词元在完整序列中从0计数的位置（包含预填充词元）。s与w分别表示受保护前缀和近期窗口的长度，保护集$\mathcal{P}_t = \{i : 0 \le i \le t,\ i < s \text{ 或 } i > t - w\}$，未保护中间区$\mathcal{M}_t = \{0, \dots, t\} \setminus \mathcal{P}_t$；保护重叠仅计一次。请求的近区长度为$n_l$个词元。实现取至少一页的长度$L = \max(B, n_l)$，再将近远切点向下对齐至页边界：近区结束于保护滑窗起点，远区为其余中间历史。

近远两区选中页与保护边界保送页共同构成L2候选池。当前不设置近远区域词元配额；最终区域份额由分数竞争决定，而非词元配额。当正概率候选充足时，L2不能恢复被L1排除页中的未保护词元；候选不足与掩码后零值并列的例外见S7。

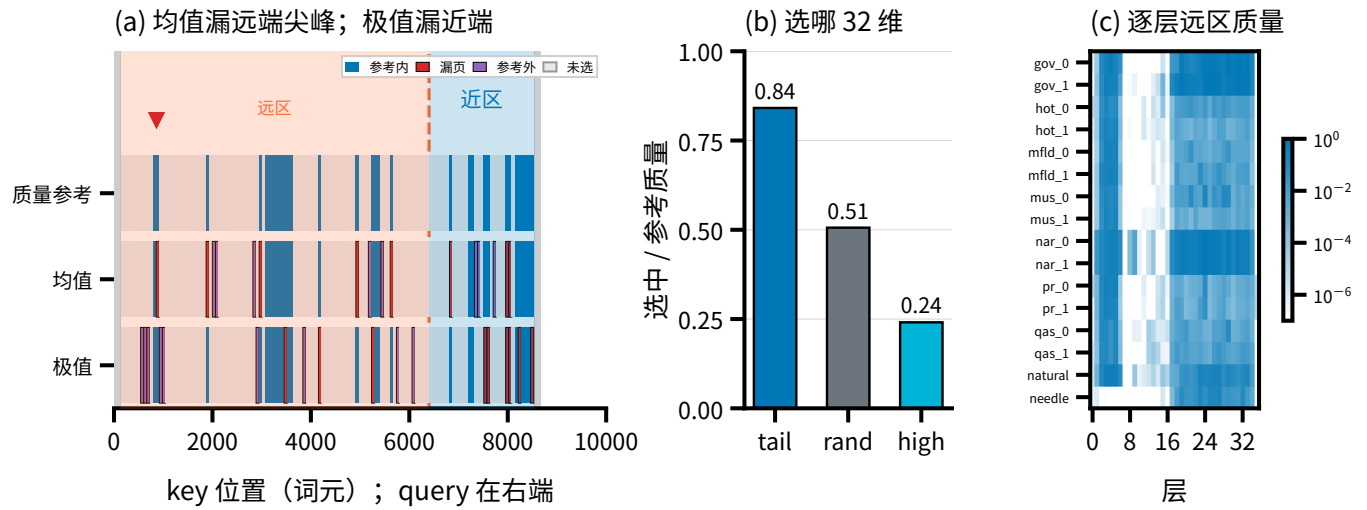


图 1. LoDA-SA的设计动机诊断，每个面板对应一项设计决策；模型为Qwen3-8B，(a)(b)前缀／近期保护各128。(a) HotpotQA样本0、层24、查询8672，互补极端例（远区份额为128条观测第87百分位）：条带依次为质量排序参考、均值与极值选集，在2048上限下实际使用2017/2017/2048词元。均值漏选8个参考页、含参考质量的86.5%，其中3/4在远端；极值漏选9页但仅4.7%，4/5在近端，并救回均值漏页中的6页（含全部5个远区漏页）；标记的尖峰页单词元承载页质量99.85%，均值稀释落选、极值上界保留。四条序列128条相关观测的区域平均漏失份额（近／远：avg为.084／.170，minmax为.079／.042），avg漏失远区为主的查询占65%，minmax近区为主的占61%（S6）。蓝色为选中参考页，红色为参考漏页，紫色为参考外入选页，区域洗色标示近／远。整页注意力权重排序只是比较参考，并非最优oracle、精确词元TopK或DSA；实际区域分配和词元数不同，漏页不能证明近远分工或任务质量优劣。(b) 选中权重和相对全维参考mid-TopK权重和：尾部32坐标保留.84，随机32为.51，高频32为.24；随机32不保留RoPE配对。(c) 单张16×36历史单查询代理矩阵中，24/36层的中位值低于.01，每序列有12–32个低代理值层；使用最后采样查询、组内logits先求和后softmax及旧远区$[64, t-2048)$，不同于所讨论的历史可选门控统计（S6）。这些选择和统计不构成任务质量或解码安全结果。

B. 同一32坐标视图服务两级评分

每层、每KV头的两个区域和两个筛选阶段采用相同的坐标映射，各查询头仍独立评分。对Qwen3-8B的尾部坐标配置，从128维RoPE后查询与键中选择$J = \{48, \dots, 63, 112, \dots, 127\}$。这些索引保留16个完整的低频split-half RoPE旋转对（补充图S1）；该陈述不泛指全维、静态配对、投影或MLA配置。令$E_J \in \mathbb{R}^{128\times 32}$为坐标选择矩阵，评分向量为$z_q = E_J^\top q$与$z_i = E_J^\top k_i$。所保留旋转对的位置旋转较慢，为这一选择提供动机，但不保证保留重要词元。紧凑实现使用32维评分张量（历史宽度128形式见S7）。

L1将选定的键坐标聚合为页摘要，用于粗粒度排序；L2在同一坐标视图中用逐词元分数精筛。两种评分视图分别存储。原始键和值仍保持全维。紧凑实现将每次评分点积缩窄至四分之一，但辅助视图的准备与维护增加工作，并未压缩原始KV缓存（S7）。

C. 符号感知界与边界保送

级联设置区域页上限与一个共享词元预算（补充图S2）。近区页采用查询与平均键的点积汇总页级相关性；远区页采用符号感知极值来上界共享空间词元分数，这一区域分工属于评分启发式。页摘要覆盖完整物理页，包括保护位置（S7）。在分区路径中，若前缀结束或保护滑窗起点位于页内，该边界页绕过L1排名，在配额之外并入候选；页内未保护词元仍须参与L2竞争，只有保护词元强制进入最终支持集。对这样的非空页b，定义$m_{b,j} = \min_{i\in b} z_{i,j}$与$M_{b,j} = \max_{i\in b} z_{i,j}$。Quest极值构造 [1] 给出

$$U_b(z_q) = \sum_j (z_{q,j}^+ M_{b,j} + z_{q,j}^- m_{b,j}), \tag{1}$$

其中$z^+ = \max(z, 0)$、$z^- = \min(z, 0)$。对页b中所表示的每个共享空间键z_i，都有$z_q^\top z_i \le U_b(z_q)$，因为每个带符号坐标项均由所选极值上界。这不构成对原维logits的相应保证。由于各坐标极值可能来自不同词元，U_b可能高估页内所有词元的分数，因此只保留评分最高的页仍可能漏掉重要词元。平均键页评分不提供这一逐词元上界。

D. 绝对预算暴露比例耦合的隐式重分配

对总上限$K \ge |\mathcal{P}_t|$且保护不重叠，中间词元预算$K_{\text{mid}} = K - |\mathcal{P}_t|$填入单一池：L2施加保留页掩码后，对组内均值概率做一次TopK，不区分区域地保留至多K_{mid}个词元。界面给出绝对量：近区页预算n_b、按差值确定的远区页$K_1 - n_b$（页配额按可用页数截断）、近区范围n_l。远区页预算仍共同取决于K_1与n_b；显式参数不意味着区域容量彼此独立。

比例耦合的界面隐藏了这一差值。归档参数化按$n_b = \max(1, \text{round}(\beta K_1))$与$n_k = \min(\lfloor \gamma n_b B \rfloor, K_{\text{mid}})$（半整数取偶）派生配额，因此远区词元预算化为

$$k_f = \max(0,\ K_{\text{mid}} - \min(\lfloor \gamma n_b B \rfloor,\ K_{\text{mid}})). \tag{2}$$

K_1、β与γ三个旋钮由此通过同一表达式重分配远区容量，而$k_f = 0$时远区页仍被接纳：页资格与词元容量是两个独立约束。归档诊断展示了全部三种重分配，包括上调K_1使远区词元归零的精确整数阈值（Q2、S6）。当前接口移除了预定的区域词元配额，但不保证区域访问：$n_b = K_1$会使远区页配额为零，统一L2即使接纳远区页也可能不选中远区词元。

历史充足且候选充足时，一个示意性的紧凑配置（$K = 1024$、$s = 4$、$w = 128$、$n_b = 32$、$n_l = 4096$）为每个KV头留下892个中间词元槽位，L1接纳32近区页与96远区页（补充图S2）；4个前缀不足一整页，选择可能再次选中至多4个保护位置，因此保留覆盖属于名义值。

E. 原维空间一次合并softmax

GQA将32个查询头按每个KV组4个分到8个KV头。L1对组内查询的页分数取平均再做区域TopK。普通L2先为每个查询计算全历史词元logits，施加共同的保留页掩码，并在该支持集上归一化；随后在KV组内对概率取均值，再对合并中间候选进行一次TopK。在该Qwen3实现中，L2 logits在逐查询softmax前仍

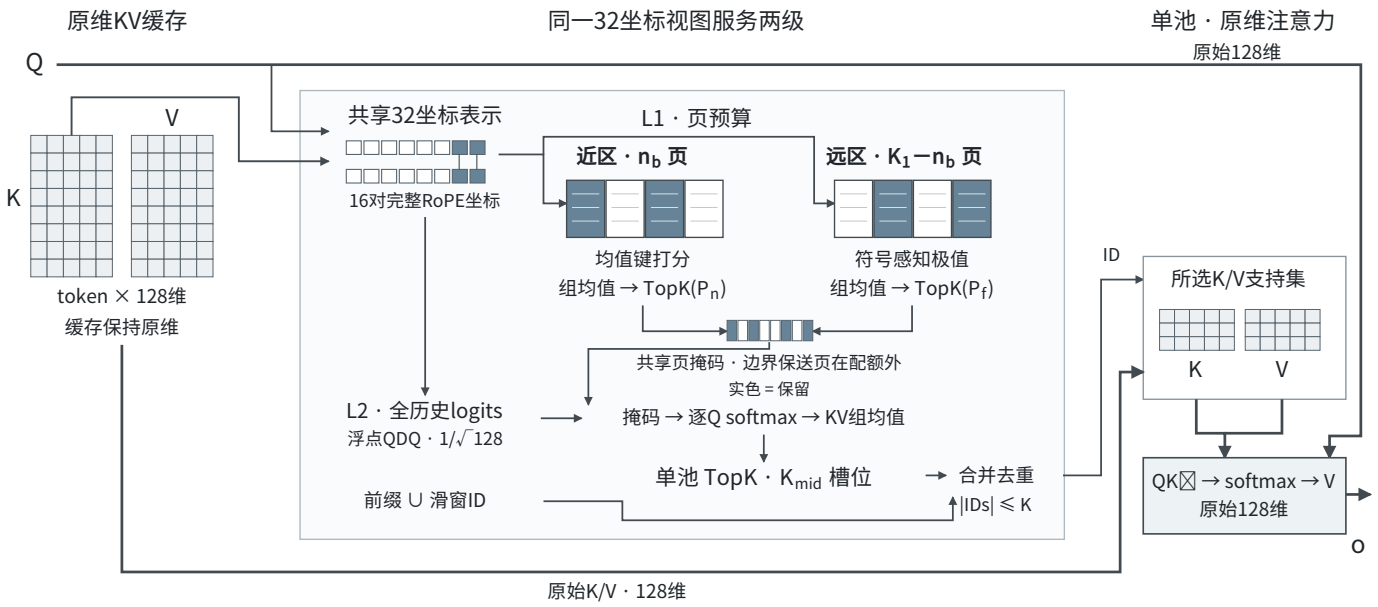


图 2. LoDA-SA参考架构：边界页保送开启，门控关闭。同一共享坐标视图用于区域L1页评分和普通全历史L2评分；各lane标注绝对预算（近区n_b页、远区K_1-n_b页、单池K_{mid}槽位）。非对齐保护边界页在L1配额之外并入页掩码，只有保护词元绕过最终选择。逐查询softmax及KV组概率均值后进行一次合并中间候选的TopK；保护位置与索引合并去重后满足K。索引定义原维K/V支持集，物理聚集由后端决定。可选远区门控（预填充标定、解码冻结）默认不启用；阵列均为示意。

使用原始头维度对应的$1/\sqrt{128}$缩放，包括采用32个坐标评分的情形。由于先逐查询softmax再做组内平均，该规则通常不同于对组内平均logits施加softmax。

对KV组h，令$\mathcal{S}_{t,h}$为保护位置与统一竞争入选词元索引的去重并集，并满足$|\mathcal{S}_{t,h}| \le K$。组内各查询$g$使用相同词元索引，但以头维度$d = 128$独立重算原维注意力：

$$o_{h,g} = \sum_{i \in \mathcal{S}_{t,h}} \frac{e^{q_{h,g}^\top k_{i,h}/\sqrt{d}}}{\sum_{j \in \mathcal{S}_{t,h}} e^{q_{h,g}^\top k_{j,h}/\sqrt{d}}} v_{i,h}. \tag{3}$$

每个查询在合并后的索引上统一施加softmax，而非直接相加各区域独立归一化的输出 [9]。保留词元的Q/K logits采用原维计算，但缩小支持集会改变分母，并可能改变注意力输出。这些索引定义共同的逻辑支持集；KV的物理聚集与复用取决于后端和序列长度，短序列可使用带掩码的稠密路径。

F. 可选远区门控保持关闭

当前n_l/n_b设计关闭远区门控。历史扩展在逐头因果softmax后，以末尾预填充查询的远区质量标定层决策，并在稀疏解码时冻结；其数值词元配额回填分支不是当前统一L2规则（S5）。在统一分支中，移除远区页竞争并不保证最终远区词元全部消失：前缀边界页仍可能进入合并竞争，因此本文不宣称完整跳过远区，也不将历史门控结果移用于当前设计。标定阈值不约束解码误差，质量与完整请求成本均需另行评估。

IV. 实验设置

本文分别评估任务质量（Q1）、区域候选覆盖（Q2）与执行成本（Q3）。表I定义紧凑Qwen3-8B设计：稠密预填充、稀疏解码，1024词元上限包含4个前缀与128个近期词元，下文统称4/128保护设计。Q2网格提供历史描述性比较，并以最优免配额格$(n_b, n_l) = (32, 4096)$启发紧凑工作点，属描述性选择。当前设计以自由竞争填充K_{mid}；这一设计选择不证明删除数值词元配额能够保持质量。归档运行保留比例定义的几何与数值词元配额；$(8, 320)$表示近区页数与近区词元数，而非(n_l, n_b)。这些质量运行对L2词元键施加16级量化–反量化（主线外实现细节），共享子空间臂还关联较早的128/128保护与填零128维L2键（S7）。“全维页评分”与“全维词元评分”是缺失完整执行配置的名义标签，不视为受控单阶段消融。

表 I
紧凑设计的参数与执行策略，与Q2实测运行一致。K包含去重保护词元。

参数	设置
最终词元上限K	1024
页长；L1页上限K_1	64；128
近区页预算n_b（远区）	32（96）
近区范围n_l	4096词元，页对齐
L2词元选择	单池自由竞争
L1/L2有效坐标	32/32
前缀／近期保护	4/128
预填充；解码层	稠密；全层稀疏

工作负载与对照。作者报告的质量记录覆盖五项LongBench任务（问答、摘要与代码补全） [10]，以及Qwen3-8B在32K／64K／128K上的11任务RULER [11]集合，另含移植的Quest/AsyncTLS/JSSA/FASA基线。FullKV是RULER与解码计时中的稠密参照，不设稀疏词元上限。原生方法比较要求保留并披露各方法的预填充／解码路径；统一阶段策略后的适配结果须单独报告。预算匹配须对齐含保护位置的最终去重词元上限K；实际选集大小与头间共享粒度影响KV流量，仅匹配K既不能证明质量相同，也不能建立成本匹配比较（S7）。

指标。主要质量指标为每项基准与长度比较中固定任务集合上各任务得分AVG；逐任务增减用于解释AVG，不要求每项任务均零掉分。阶段策略匹配的受控比较须匹配模型、样本、长度、评分器与阶段策略并对齐词元预算；未完成的集合不构成完整集合的AVG。区域漏失份额先以每条查询的参考集总质量归一化

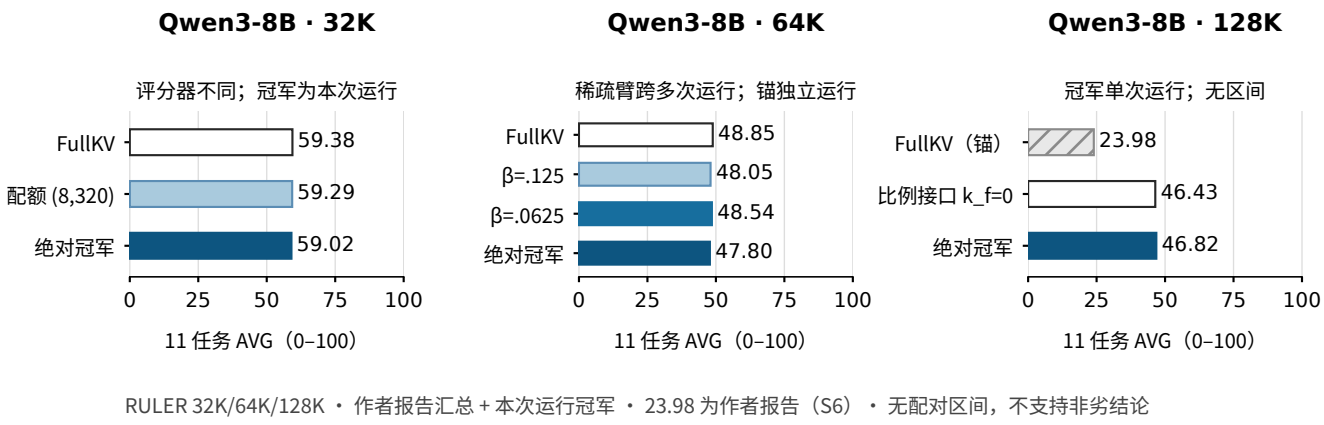


图 3. RULER AVG（Qwen3-8B）：11任务算术平均，每任务每臂100例。归档稀疏臂报告$K = 1024$、4/128保护与比例派生词元配额，早于自由竞争配置；32K近区配额(8,320)（$\beta = .0625$），64K展示(8,320)与(16,640)。实测臂按表I紧凑设计每长度运行一轮（自由竞争，批8/2/2，YaRN关闭/2.0/4.0）。稠密锚均另次运行；32K跨机器且评分器不同。斜纹128K柱为推得$k_f = 0$的历史比例接口，得23.98，实测绝对接口得46.82。单轮无配对区间，全部比较属描述性（S8）。

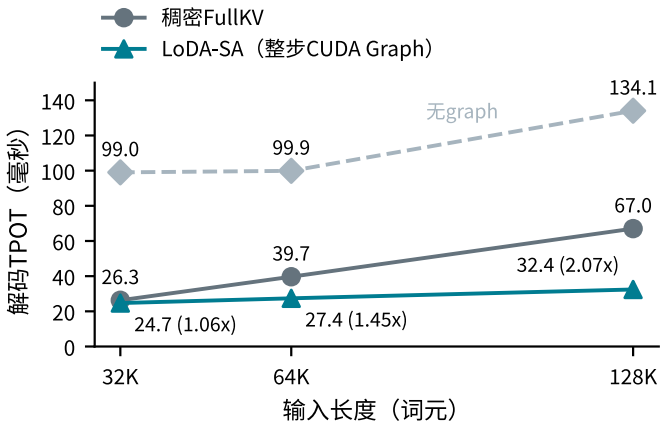


图 4. 实测模型级解码TPOT，Qwen3-8B，表I几何：稠密FullKV（原生解码）对比整步CUDA Graph重放的LoDA-SA；虚线臂关闭graph。127个首输出后间隔包含设备同步与argmax（6/4/1次运行均值）；graph重放与eager词元逐位一致。该间隔不测量含准备的完整请求时延，也不建立匹配质量–成本比较（S6）。

区域漏失质量，再对相关观测取均值（S6）；图1(b)则以全维参考mid-TopK权重和为分母。选择器时间（合成单层）与同步TPOT（首输出后的模型级生成间隔）均不测量计入准备、维护及输入输出工作的完整请求时延。未配对的质量与计时研究不能定义质量–时延前沿；AVG差异属于描述性比较，不构成统计非劣性证据。

V. 评估与讨论

A. Q1：缩小评分宽度能否保留任务质量?

在 HotpotQA、Qasper、MuSiQue、GovReport 和 RepoBench-P [10] 上，五项任务均值在三种名义评分配置间的差距不超过0.33分：共享子空间评分平均分为47.588，名义全维页评分与词元评分变体分别为47.910和47.666（补充图S4），共享子空间臂分别比两变体低0.322与0.078分。这些差值描述已记录配置，并非缩小评分宽度保持质量的证据：变体未被确认为单因素干预。三者均为稀疏配置，稠密FullKV是另一类参照。

B. Q2：区域预算如何约束候选访问?

描述性网格比较。一份归档Qwen3-8B摘要报告了五任务LongBench上的86个近区页、近区范围与词元配额配置及一个无分区对照，每个配置运行一轮。$(n_b, n_l) = (32, 4096)$下免配额选择的已报告AVG5为48.264，免配额最佳配置为48.300，对照为47.462；这些均为描述性点估计。近区页边际均值从46.37（n_b=4）升至48.21（n_b=32），在64处走平（48.11）；最佳格聚集在$n_b B \approx n_l/2$附近，与归档近区质量集中（前一半页承载中位.93）相符，但单轮边际不支持因果隔离。69次数值词元配额与免配额比较覆盖17种不同的(n_b, n_l)设置，同一几何下数值配额减去免配额的AVG5平均差为+0.040点，其中42次为正。在$(n_b, n_l) = (32, 4096)$处，数值词元配额448臂为48.668，免配额臂为48.264，相差+0.404点。该归档JSON摘要中的三个配对区间对应排名前三的数值词元配额配置之间的两两比较，未与免配额选择比较；区间含零既不证明等价，也不证明词元配额不存在效应。这些摘要不能隔离近区页预算或近区范围的质量贡献，也不能验证当前紧凑统一L2配置；仍需匹配配置与输入身份、配对预测及完整请求成本（S6）。

归档RULER 32K臂在近区配额$(16,640) \to (8,320)$（归档$\beta = .125 \to .0625$）下从58.30升至59.29，远区页由112增至120、远区词元预算由252升至572，同时改变；归档近区页4和近区页8的两臂分别得58.07（$K_1 = 128$、远区词元预算732）与58.96（$K_1 = 256$、近区配额同为$(8,320)$但远区页扩至248），均低于59.29，其中$K_1 = 256$臂相对59.29分臂CWE升3.9分、FWE降9.67分。这些归档比例接口臂不是选定配置；记录匹配，预测未重放。

隐式耦合失效。归档诊断展示了式(2)的全部三种重分配。对归档公式做整数枚举，$K = 1024$（$B = 64$、$\beta = .125$、$\gamma = .625$、128/128保护）下首个远区归零的页上限为$K_1 = 156$，$K_1 = 155$时远区预算尚余8：容量看似随K_1增长而远区词元消失。归档任务扫描中，HotpotQA恰在远区预算为零的臂上从53.6–57.3塌缩到37.7，损伤按远区占比分级（占比.875时16.4分，.125时约1分）。在归档网格点$(\alpha, \beta) = (.25, .125)$，自由竞争与最优$\gamma$在保留质量诊断中相差不超过.001（.852对.8515），而$\gamma = 0$读作“无远区保留”，实际将近区词元配额压为零，保留质量降至.827。历史128K RULER臂按其报告预算推得$k_f = 0$（S6）。这些归档诊断统一了三种异常，但不是新的受控实验。

作者报告的Qwen3-8B 32K相对稠密FullKV的AVG差值为−0.09分，比较跨机且评分协议不同。64K下，8B近区配额(8,320)/(16,640)两臂AVG为48.85/48.05，另一次运行的稠密锚为48.54。稀疏两臂同机且评分器相同，但预测协议不同；稠密对照也采用不同评分器。这些描述性比较不能建立因果或统计非劣结论（S8）。

移植基线比较。在Qwen3-8B RULER32K上，作者报告历史数值词元配额选择器臂在名义$K = 512$时AVG为56.00，名义预算512的AsyncTLS移植版为48.33，相差7.67分。历史选择器臂在$K = 1024$和$K = 384$时分别得到59.29和15.00；另行报告的JSSA、Quest和FASA移植版分别为58.7、42.85和18.64。最终去重词元预算、保护策略与执行阶段尚未核实匹配；这些历史选择器臂也不能验证当前合池L2配置。移植出处、历史CWE的43.4分下降及缺失的配对区间见S8。

128K下，同机稀疏两臂分别得45.73（(8,320)）和46.02（(16,640)）；前者为另次运行稠密锚46.43的98.49%。历史128K RULER报告稀疏臂得分23.98，报告预算推得保留远区页时$k_f = 0$，执行未验证、22.45分损失未解释（S6）。另一组五任务LongBench比较中，仅保护词元的平均分为26.09，复用的稀疏检索参照为47.91；两者预算分别为256和1024词元，因此检索与预算同时变化。

紧凑设计实测运行。表I配置（自由竞争；批大小8/2/2，YaRN关闭/2.0/4.0）在RULER 32K/64K/128K各运行一轮，得59.02、47.80与46.82（11任务×100例），对另次运行的稠密锚59.38、48.54与46.43：差距−0.36、−0.74与+0.39，处于历史批次级差异的量级（同机64K稀疏两臂相差0.80，跨机32K比较相差0.09）。稠密锚跨代际、机器与评分器，单轮运行无配对区间，因此这些比较既不建立非劣性，也不建立退化。128K处实测绝对接口得46.82，而推得$k_f = 0$的历史比例臂得23.98；无匹配协议，该差距仍属描述性。

C. Q3：紧凑评分能否降低执行成本?

模型级解码。整步CUDA Graph重放下，紧凑配置在32K/ 64K/ 128K解码TPOT为24.7/27.4/32.4毫秒，稠密为26.3/39.7/67.0毫秒：1.06/1.45/2.07倍，随长度单调增长，32K近打平（图4）。关闭graph后稀疏臂回到99–134毫秒：增益来自重放而非选择。计时包含设备同步与argmax，不测量含准备的完整请求时延（S6）。

选择器局部成本。一项独立的两轮合成实验（单层、批量大小为1、单查询、64K长度QKV）报告稳态汇总：名义全维页评分1.3502毫秒，共享子空间评分1.3598毫秒，名义全维词元评分1.4634毫秒。共享子空间减去页评分的两轮时间差分别为+0.0237和−0.0046毫秒，未建立共享子空间的一致计时优势。原始计时序列缺失且采样协议差异尚未解决，无法可靠评估这些时间差的不确定性；这些汇总既不证明等价，也不能定位瓶颈，且未与质量运行配对（S6）。

D. 可选门控：预填充不保证解码需求

低预填充注意力并不能证明解码时可安全跳过远区选择。一条归档输入–层记录的预填充远区注意力代理量低于.05，而所报告的解码尾部五个查询均值为.1678：这是代理量跨阶段变化，并非测得的任务质量损失。门控阈值.05和.10对应五任务AVG为47.876和47.692，相对复用的47.910参考分别下降.034和.218分（每臂仍有三项任务下降，其中HotpotQA分别下降1.05和1.26分）；AVG仍是主判据，不设逐任务零损门槛。小幅AVG变化或包含零的任务自助法区间均不能证明统计非劣。完整评分配置、配对预测与匹配成本缺失，门控共享子空间的质量与净节省仍未验证（S6）。

设计启示与局限。两项约束反复出现：缩小评分宽度减少单次点积的维度，但普通L2仍对完整历史评分；页级资格不保证最终入选，由单池按组均值概率决定。有用的运行点应在匹配的任务质量下削减计入准备开销的完整请求时延。紧凑设计仍缺匹配测量；历史门控汇总也缺少完整的配置身份。

VI. 结论

本文研究LoDA-SA：共享低频页／词元评分、显式区域页预算、单一合并词元竞争及原维注意力。页候选资格不保证最终区域覆盖。归档网格报告免配额AVG5为48.264，对照47.462，但同一几何下的数值配额臂得48.668；这些观测既不能隔离质量贡献，也不能验证当前紧凑设计。紧凑设计的单轮实测（32K/64K/128K得59.02/47.80/46.82）处于另次运行稠密锚的历史批次级差距之内，并以46.82取代128K比例接口的23.98损失，但不支持非劣性结论。graph重放TPOT随长度低于稠密，无graph解码仍更慢，完整请求成本未测量；要建立收益，仍需匹配质量。

AI生成内容。通过Codex使用的OpenAI语言模型参与起草、修订、翻译、图与LaTeX代码生成、来源核对及算术复算；界面未提供可核实的模型版本标识。

References

[1] J. Tang, Y. Zhao, K. Zhu, G. Xiao, B. Kasikci, and S. Han, "Quest: Query-Aware Sparsity for Efficient Long-Context LLM Inference," in ICML, 2024. https://arxiv.org/abs/2406.10774.

[2] L. Ribar, I. Chelombiev, L. Hudlass-Galley, C. Blake, C. Luschi, and D. Orr, "SparQ Attention: Bandwidth-Efficient LLM Inference," in ICML, 2024, pp. 42558–42583. https://proceedings.mlr.press/v235/ribar24a.html.

[3] Y. Xu et al., "HISA: Efficient Hierarchical Indexing for Fine-Grained Sparse Attention," in COLM, 2026. https://arxiv.org/abs/2603.28458v4.

[4] Hu et al., "AsyncTLS: Efficient Generative LLM Inference with Asynchronous Two-level Sparse Attention," arXiv:2604.07815v1, Apr. 9, 2026. https://arxiv.org/abs/2604.07815v1.

[5] Z. Liu, Z. Ning, R. Li, X. Liu, Y. Song, M. Zhang, Z. He, and X. Qiu, "Faster Than Flash: Exploiting Attention Sparsity for Efficient Long-Context Decoding," in ICML, 2026, pp. 77913–77928. https://proceedings.mlr.press/v306/liu26da.html.

[6] H. Sun et al., "ShadowKV: KV Cache in Shadows for High-Throughput Long-Context LLM Inference," in ICML, 2025, pp. 57355–57373. https://proceedings.mlr.press/v267/sun25b.html.

[7] Z. Wang et al., "MILLION: MasterIng Long-Context LLM Inference Via Outlier-Immunized KV Product QuaNtization," in 2025 62nd ACM/IEEE Design Automation Conference (DAC), 2025, pp. 1–7, doi: 10.1109/DAC63849.2025.11132862.

[8] G. Liu, C. Li, J. Zhao, C. Zhang, and M. Guo, "ClusterKV: Manipulating LLM KV Cache in Semantic Space for Recallable Compression," in DAC, 2025. https://doi.org/10.1109/DAC63849.2025.11132479.

[9] G. Shen, J. Zhao, Q. Chen, J. Leng, C. Li, and M. Guo, "SALO: An Efficient Spatial Accelerator Enabling Hybrid Sparse Attention Mechanisms for Long Sequences," in DAC, 2022, pp. 571–576. https://doi.org/10.1145/3489517.3530504.

[10] Y. Bai et al., "LongBench: A Bilingual, Multitask Benchmark for Long Context Understanding," in ACL, 2024, pp. 3119–3137. https://aclanthology.org/2024.acl-long.172/.

[11] C.-P. Hsieh et al., "RULER: What's the Real Context Size of Your Long-Context Language Models?," in COLM, 2024. https://arxiv.org/abs/2404.06654.

[12] G. Xiao, Y. Tian, B. Chen, S. Han, and M. Lewis, "Efficient Streaming Language Models with Attention Sinks," in ICLR, 2024. https://arxiv.org/abs/2309.17453v4.

[13] J. Park, M. Kang, Y. Han, Y.-G. Kim, J. Shin, and L.-S. Kim, "Token-Picker: Accelerating Attention in Text Generation with Minimized Memory Transfer via Probability Estimation," in DAC, 2024, doi: 10.1145/3649329.3655953.

[14] C. Lin et al., "Twilight: Adaptive Attention Sparsity with Hierarchical Top-p Pruning," arXiv:2502.02770v1, Feb. 4, 2025. https://arxiv.org/abs/2502.02770v1.