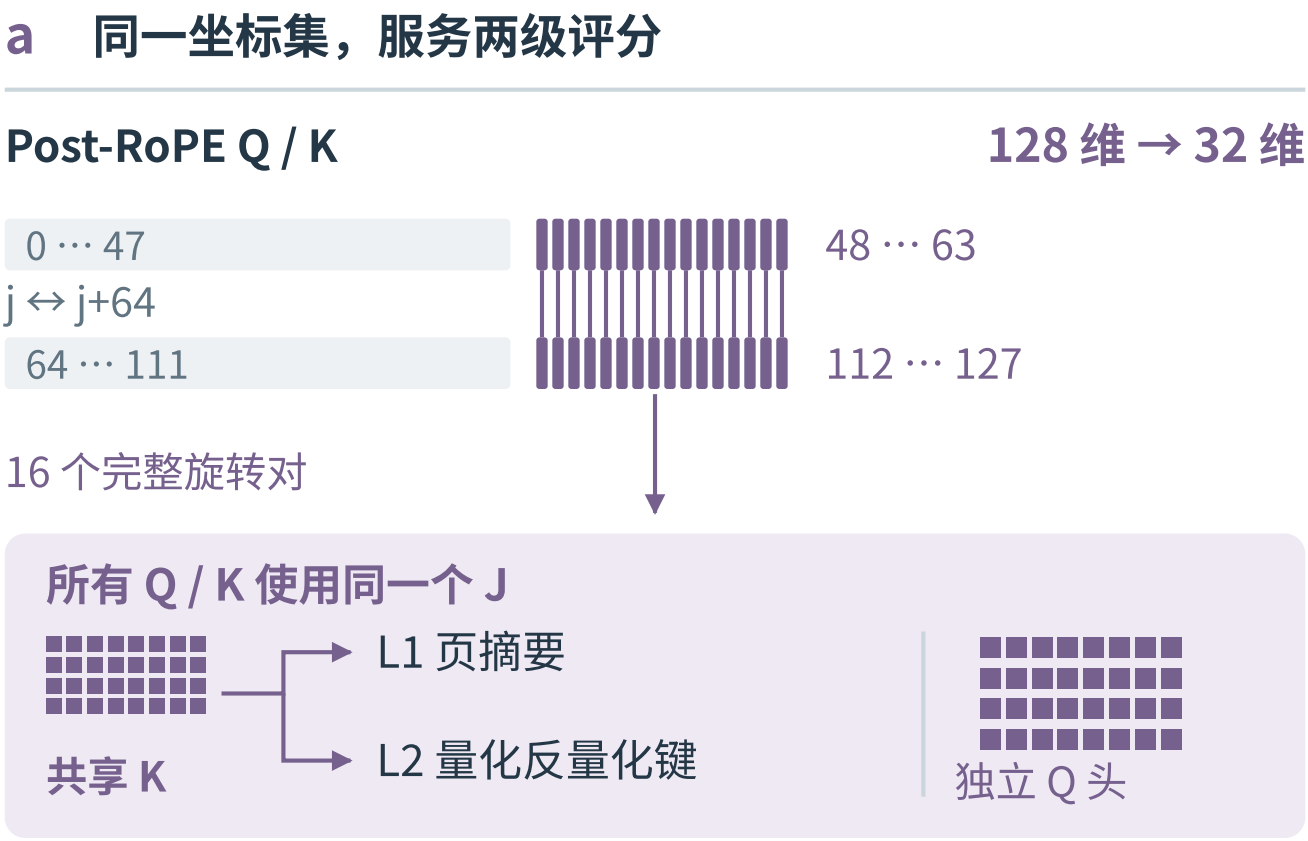
LoDA-SA：机制补充与历史证据

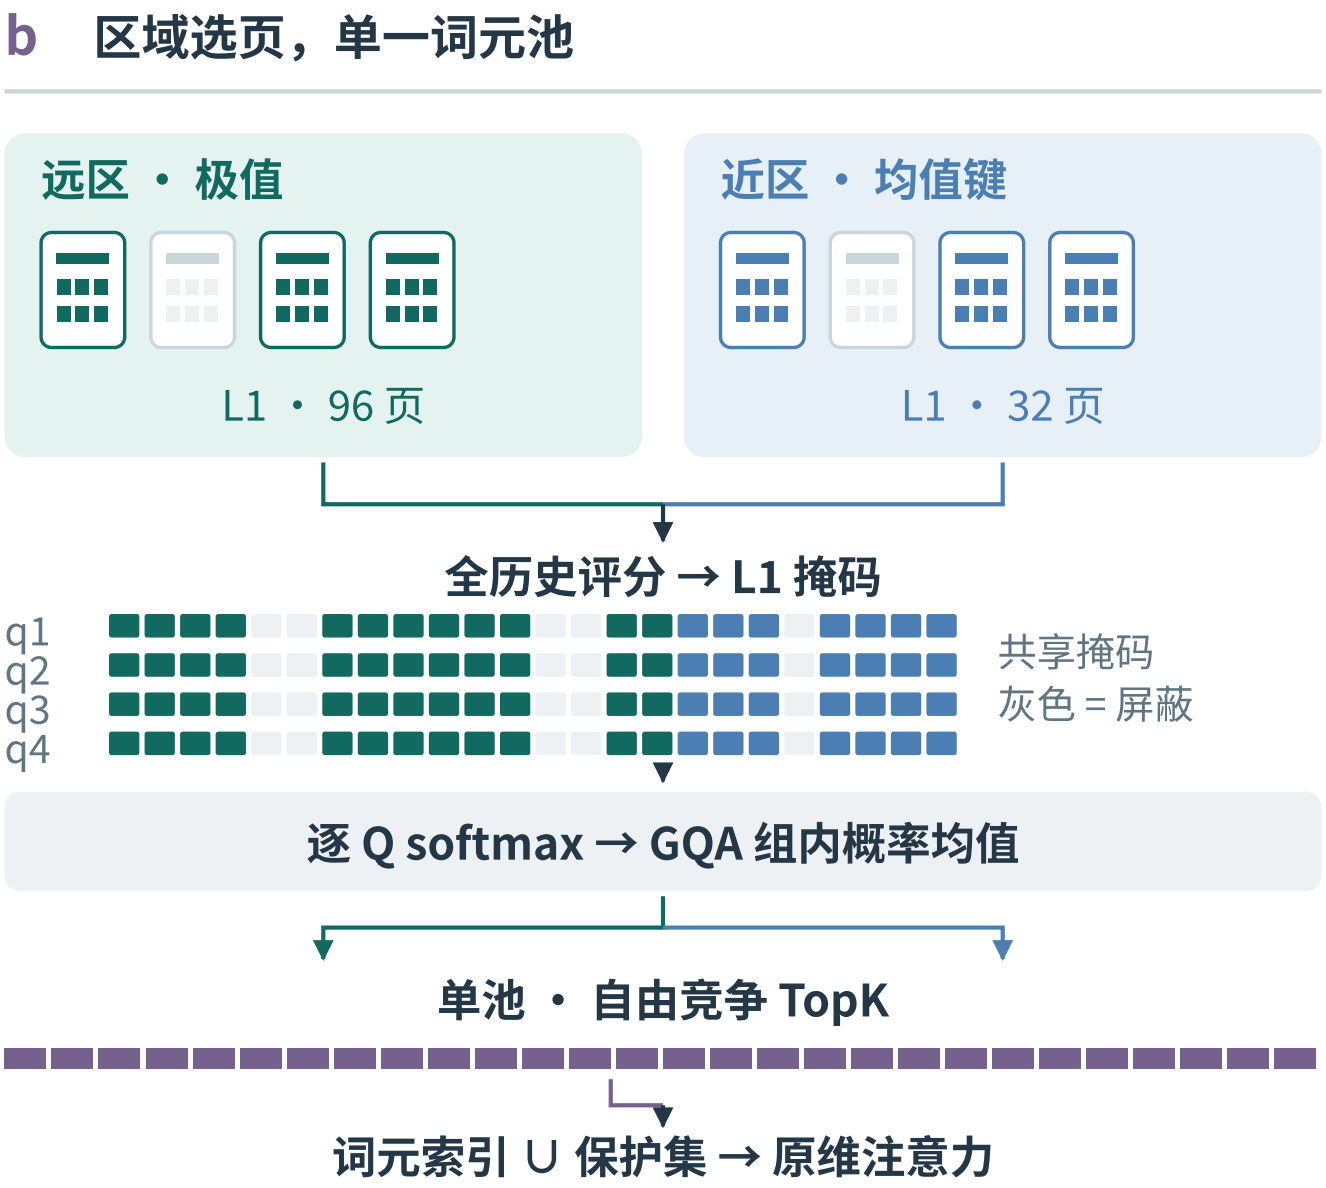
机制补充图 S1: 低频子空间选取

本补充给出子空间选取与当前统一L2流程，并单独保留历史数值词元配额门控。



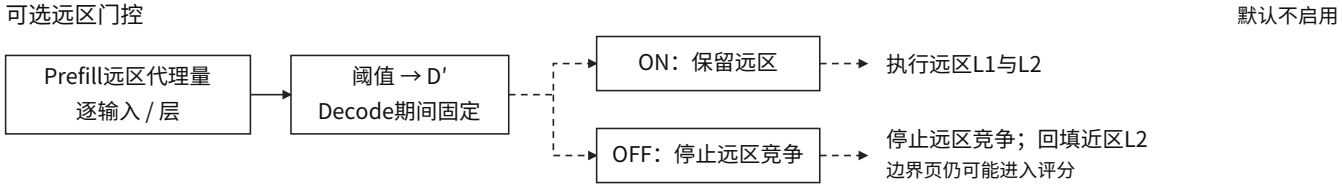
以历史QDQ变体示意低频子空间选取。16个完整旋转对同时供近远区域和L1/L2使用。该变体的量化反量化表示为浮点，不是packed INT4；主文bf16配置不以QDQ为必要条件；所选词元索引定义原始128维KV的支持集，物理访问方式取决于后端。

机制补充图 S2: 区域页配额与单池词元



区域筛选与保护预算。候选充足时，128页配额为保护设置4/128、$(n_b, n_l) = (32, 4096)$的示意配置分配近区32／远区96页；总1024上限包含132保护与892槽位的单一自由竞争池。前缀不足整页，可能重复选中至多4个保护位置，减少非保护覆盖。图块数量仅示意。逐查询头归一化后才在KV组内平均。实测解码运行的L1页上限减半为K_1=64（近区32／远区32页）；本图保留实测RULER质量臂的$K_1 = 128$布局。

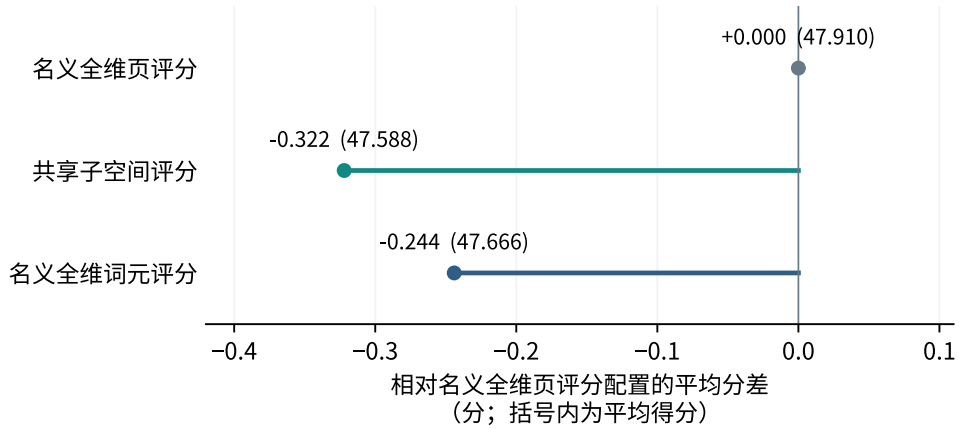
机制补充图 S3: 历史数值词元配额门控



虚线：控制流。Prefill统计不约束Decode误差。

历史数值词元配额门控的状态转换及条件执行；本图不是当前统一L2算法。预填充暂存决定，首次解码路径调用冻结。在有效长度、远区非空的固定数值配额实现上，OFF移除远区竞争和最终未保护远区词元选取；边界保送仍可能让前缀边缘页进入评分，只把L2余量回填近区配额，此替代示例的L1近区仍16页。全域准备、S宽缓冲及softmax成本保留。图中的控制路径仅作示意，并非实测层级结果。门控默认不启用，共享子空间配置的匹配质量／成本尚未验证。

补充图 S4：描述性配置比较



五任务均值为47.910（名义全维页评分变体）、47.588（共享子空间配置）与47.666（名义全维词元评分变体）。相对共享子空间配置的0.322、0.078分差值仅作描述。名义全维页评分变体缺实验元数据，名义全维词元评分变体的L2模式标记未能对应到实现该模式的代码版本，因此这些标签不能建立受控阶段干预或已完成的三个配置消融。补充注S7列出配置证据。这些均不是稠密FullKV，也不建立文档配对非劣性或匹配质量–成本结论。

补充注 S5：Gate观测与执行范围

当前n_l/n_b设计关闭门控。下文描述历史数值词元配额扩展，不是已验证的统一L2门控；统一分支中，移除普通远区页竞争后，前缀边界候选仍可能产生远区入选词元。

功能未启用时仍执行普通远区选择；图中OFF仅指启用功能后标定得到的逐层跳过决定。可选远区门控在每层预填充观测后暂存门控决策，在首次解码路径调用时冻结，后续复用直到新输入清空（补充图S3）。该调用可能仍在消费问题词元，不能据此假定已经看完整问题。标定使用末尾至多256行可用Q、原维评分及逐Q头softmax，对平均远区注意力权重总和做严格阈值比较；该阈值只用于预填充观测的判定，并不约束后续解码的远区注意力权重总和或任务误差。

标定区域几何。历史充足时，令S_c为标定长度、$m_c = S_c - s - w$。统计量先对$[s, s + \lfloor(1-\alpha)m_c\rfloor)$内的注意力求和，再对查询行与查询头取均值。受支持的解码跳过路径则采用历史页对齐边界Bb_n，其中$L = \max(B, \lfloor\alpha(S - s - w)\rfloor)$、$b_n = \max(\lfloor s/B\rfloor, \lfloor(S - w - L)/B\rfloor)$，其中未保护跳过区间从$s$开始。即使两阶段长度相同，这两个区间也未必一致。$B = 64$、$s = 4$、$w = 128$、$\alpha = .25$时，在$S_c = S = 8192$处，两者右端点分别为6049和6016；长度为1065时则为703和704。因此，该统计量属于远区贡献代理，既非被移除支持集的精确注意力权重总和，也不是其保守上界。前缀位置仍受保护。

在支持的固定数值配额实现（批量大小为1、有效长度已知且远区非空）中，OFF移除远区竞争和最终未保护远区词元选取；边界保送仍可能让前缀边缘页进入评分，仅将剩余L2配额回填合法近区词元，不扩大近区的L1页预算。启用远区、关闭远区并回填近区配额、关闭远区且不回填配额是不同干预。移除远区可能改变逐Q softmax分母及组平均近区排序，因此回填不是保持近区选集不变的单纯省算。准备、量化、复制与浮点转换和S宽缓冲／softmax均计入成本。该实现不支持组合动态与静态层跳过；批内状态隔离、运行时状态转换和分布变化触发的回退尚未验证。运行时自适应调整α, β, γ不属于本文评估的配置。

历史门控是共享子空间方法的候选扩展。现有门控任务汇总缺生成源码SHA、完整子空间配置与配对预测，不能用于验证该配置。上述实现细节限定机制适用范围，并非实测速度或质量收益。

补充注 S6：历史诊断的适用范围

以下保留主文限制所依据的详细数值。这些是作者归档诊断，不是新实验，也不是共享子空间方法的匹配验证。归档记录携带比例身份；按$n_b = \max(1, \mathrm{round}(\beta K_1))$与$n_k = \min(\lfloor \gamma n_b B \rfloor, K_{\mathrm{mid}})$映射为绝对配额，$K_1 = 128$下$\beta = .0625$等于近区配额(8,320)，$\beta = .125$等于(16,640)。

动机性诊断。图1使用归档Qwen3-8B观测，评分与选择规则如下。(a)保留E140b中固定HotpotQA0/L24/q8672的页数组与保存选集（2026-10-23图修订；更早的固定MuSiQue1/L24/q14212数组与已退役的顶部注意力质量条带保留在仓库历史）：注意力权重排序和均值评分各用2017词元，极值评分用2048词元；固定示例为128条观测中按页数与漏失质量双口径同时极端的3条之一（远区份额第87百分位），非中位样本。均值与极值均使用相同32个低频坐标，并在32个查询头间平均评分；注意力权重参考则来自全维注意力概率。两种评分的全局选集具有不同区域分配及实际词元数，因此该例不能证明近远评分分工或预算匹配的最优性。132个中间页中三个集合各含32页；相对注意力权重排序，均值漏8页、极值漏9页，含共同漏选2页。仅均值漏选6页，仅极值漏选7页；各自参考外入选为8和9页。灰色表示既未选入也不是参考漏页。这些集合差异不是错误或任务质量损失，整页参考也没有最优oracle保证。位置832页的一个词元承载该页保存权重和的99.85%，只说明此查询，不代表总体机制。(a)的区域统计（2026-10-23图修订：堆叠柱内嵌面板随面板数缩减退役，数字保留在此文本引用）按绝对区间$[q - d_{hi}, q - d_{lo} + 1)$和真实区域边界重算归属，每条查询的区域漏失质量先除以该查询参考集总质量，再对这些份额求均值：均值池化漏失近区.0843、远区.1699，极值漏失近区.0787、远区.0420（128条相关观测均值）。漏失页数均值为均值池化近／远3.98/3.89页、极值5.27/3.77页，页数准则与权重准则对两评分器的排序不同。另一组近区预算扫描（近区用均值、远区用极值，总上限2048，近区预算128–1536步长64）从未胜过全局极值选择：最优拆分在近区预算1408处漏失.1345，全局极值为.1208，因此预算划分不由该平面决定。早先的配额臂面板（全局2048对比远／近1024/1024）已退役，其逐查询记录保留在仓库历史中。这些是四条源序列的相关查询／层观测，不是独立文档。(b)保留八个cell的坐标比值和未配对随机选择，不能隔离频率或代表生产评分。(c)只使用历史far-profile的16×36矩阵：24层中位值低于.01，每序列12–32个低代理值层。其生产者使用最后一个采样查询、先在GQA组内求和logits再softmax，far定义为$[64, t - 2048)$。该历史代理不是S5的历史可选门控统计；低值层数不等于可安全跳过层数。不使用另一份10条profile的skip摘要。随附数值输入包含逐查询选集及来源哈希。

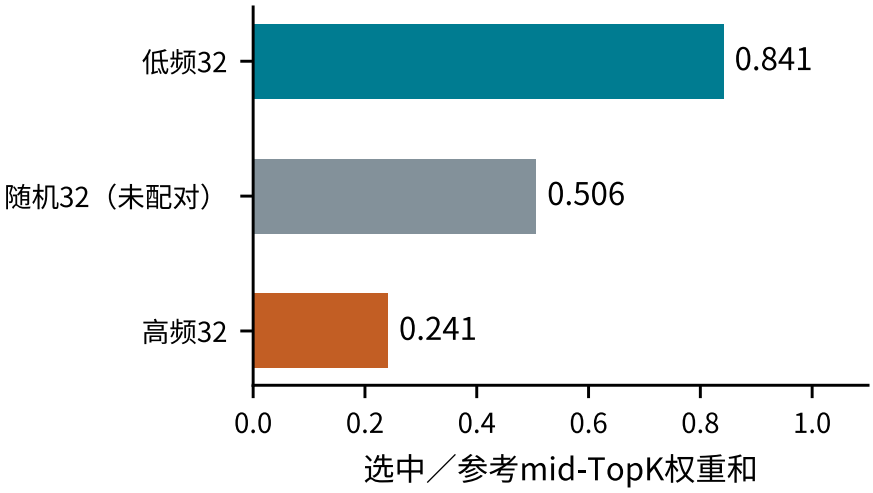


Figure 1: 归档坐标辅助诊断：选中注意力权重总和除以全维参考mid-TopK权重总和，中间上限768，128/128保护另计。诊断采用页均值选择器，不同于生产近区均值／远区极值评分。Random32未配对；未进行配对随机质量或输出误差检验。

计时来源。 主文解码TPOT图采用E152v4正式记录的干净臂（主机pc40）：Qwen3-8B bf16、NVIDIA H20-3e、Torch 2.8.0+cu128、贪心解码固定输出128词元、ABBA交错且每臂两进程、逐同步设备计时并包含贪心argmax。稠密臂在动态缓存上运行原生稠密解码路径，不使用CUDA Graph（每长度6次实测重复）；稀疏臂在静态缓存上按表I几何做整步CUDA Graph重放（4次重复），另有一条每长度1次的无graph eager参考，报99.025/99.893/134.063毫秒。graph臂生成词元与eager参考在三个长度逐位一致。本机共居污染复刻臂（稠密基线从26抬升至39毫秒）通过同一逐位门但不计入报告均值；预热运行均已排除。更早的E152v2记录对归档$(.125, .375, .625)$动态缓存配置报中位数87.9/97.6/119.9毫秒（无graph重放）；E152v4取代其图源地位，两份记录均支持无graph稀疏解码慢于稠密。后端路径为作者报告，未独立核验。E127的5.47倍比较旧版与优化版选择器阶段时间汇总，并非稠密FullKV。它与E152汇总均不能建立launch-bound因果归因。数据、采集器和绘图脚本哈希见`sources/evidence_bindings.json`。

选择器局部计时与汇总。归档性能记录对后续实现进行两轮GPU交换测量。其关联源码具有紧凑共享子空间L2

实现，区别于补充注S7的早期LongBench实现；源码检查本身不能核实计时执行路径。每轮值分别为全维页评分变体的1.3635／1.337毫秒、共享子空间配置的1.3872／1.3324毫秒、全维词元评分变体的1.4794／1.4473毫秒。记录给出的两轮中位汇总分别为1.3502、1.3598、1.4634毫秒。每组两个报告值的中点中位数为1.35025、1.35980、1.46335毫秒；这些是算术复算，并非新增测量。原件未提供逐阶段中位数或原始序列，因此不能确认此前“五阶段中位数之和”的描述。合成单层、批量大小为1、单查询、64K的范围不同于完整层或请求，也未与质量实验配对。记录称60步、40次预热及20个稳态样本，但此前检查的测量程序对应100总步及60个稳态样本；矛盾仍未解决。所报共享子空间配置时间高于全维页评分变体，既未确立统计显著性，也未建立完整系统加速。

区域与门控诊断。历史仅保留保护词元的均值26.09，含中间检索47.91，但预算也从1024降到256，无法隔离区域策略贡献。门控标定包含16输入、每个36层；保存远区注意力权重总和字段$<.05$的输入–层记录在预填充／解码分别30／22条，交集13。在预填充选中的输入–层记录之间，所存解码代理量的均值为0.0582、最大值为0.1678；每条解码代理量据报告是尾部五个查询的平均值，并非逐词元最大值。这些跨阶段变化不能证明任务精度保持或请求收益。

词元配额诊断。归档E130/E98汇总报告所选词元保留的全维因果注意力权重总和（包含保护词元），而非任务精度；先在每条trace内取均值，再对16条trace等权平均（14条LongBench、两条构造输入）。在$(\alpha,\beta)=(.25,.125)$处，L1选页后的词元自由竞争得0.852，最佳已测γ（.875）为0.8519，近区词元配额为零的$\gamma=0$为0.827。其他网格的有效样本支持不同，比较其汇总均值前须对齐样本。所检查分析器使用近区均值／远区极值页评分，2048个中间词元槽另加128/1024个sink／近期保护词元；该协议不同于当前紧凑配置，历史执行尚未独立重放。另行E109配额计算也不将远区配额为零视为坍塌的充分条件。这些诊断既不能隔离区域词元配额的保护效果，也不能排除调参收益；当前配置的自由竞争任务质量及完整请求成本仍未核验。

归档绝对配额网格（E155d）。已提交摘要报告Qwen3-8B五任务LongBench上的86个配置及一个无分区对照，每个配置运行一轮。最高数值配额配置$(n_b,n_k,n_l)=(32,448,4096)$得48.668，免配额$(32,4096)$得48.264，免配额最佳$(64,8192)$得48.300，对照得47.462。$n_b=4,8,16,32,64$的边际均值依次为46.371、47.344、47.965、48.212和48.106，对应不均衡的12、20、24、18和12个配置；这些汇总比较不能隔离因果轴。69次数值配额减免配额比较覆盖17种几何，均值$+0.040$点，42次为正；$(32,4096)$处配额448比免配额高0.404点。该JSON中的三个区间比较前三名数值配额臂，未比较免配额选择。后续任务记录另报配额448减off为$+0.405$、区间$[+.099,+.786]$，off减对照为$+.803$、区间$[-.194,+1.839]$，配额448减对照为$+1.209$、区间$[+.177,+2.265]$；这些后续区间在此缺少独立原始数据重放及已确认的文档簇重采样协议，也不建立当前方法验证。另报的前半数页质量中位.933实际由包含远区的全部已存中间页计算，而非已核近区子集，不能解释近区半覆盖规律。当前统一L2仍是一项设计选择，需要匹配输入与配置身份、质量及完整请求成本；网格摘要和后续区间报告是不同证据来源。

后续作者汇总在$\epsilon=.05/.10$时五任务均值47.876／47.692，对复用47.910锚分别下降0.034／0.218分。每个配置的3项任务下降，HotpotQA下降1.05／1.26分。作者五任务bootstrap区间$[-.584,.452]/[-.806,.400]$仅为描述，跨零不证明等价。现有作业记录尚不能建立共享子空间配置的匹配比较（补充注S5）；三政策质量及完整成本仍未匹配验证。

共享子空间配置尚缺匹配的稠密FullKV质量参照、全维评分稀疏对照及包含准备成本的请求比较。历史全维页评分与尾部32坐标词元评分实验不能替代这些对照。作者报告的RULER汇总（文献见主文）标识了名义128K、YaRN因子4的Qwen3-8B及$\alpha=.125$、$\beta=.375$、$\gamma=.625$稀疏配置。对其11项任务得分重算非加权均值，FullKV为46.43，稀疏配置为23.98，差值为-22.45分，稀疏／FullKV得分比为51.6%。这是负面的汇总结果，不构成当前n_l/n_b与统一L2配置的已核验匹配验证：所检查的仓库快照缺少原始预测；配对输入身份、评分器执行及当前紧凑执行的对应关系均未独立核验。对未覆盖配额的常规固定配额路径，已检查公式给出$K_{2,\mathrm{mid}}=1024-128-128=768$，而$\mathrm{round}(128\cdot.375)\cdot64\cdot.625=1920$，故名义远区词元配额为$\max(0,768-\min(1920,768))=0$。这是已检查代码与报告配置的联合推论，实际执行路径未独立验证，也不能据此认定得分差的唯一原因。后续64K文件仅含汇总得分与manifest，并非原始预测；其回执摘要缺少α、β及sink保护等字段，不能闭合完整运行配置身份。本比较不加入64K得分。这些汇总不能分离YaRN或远端候选不足的因果效应。历史静态逐层策略未达到预设提升阈值，已有配额与门控诊断又同时改变了多种策略或尺度；这些负结果限制了结论范围，但未直接检验当前共享子空间配置与预填充远区门控。原始得分及来源详见实验记录。

补充注 S7：预算与配置身份

当前前缀／近期配置。当前设计采用4个前缀词元、128词元近期窗口、稠密预填充与稀疏解码，示意性且未验证的紧凑点为近区32页、近区范围4096、中间自由竞争单池，实现默认值仍为128/128。E149汇总报告4/128保护，但页数与词元配额标签不一致；完整预测及协调一致的执行身份尚不可用。历史充足且保护不重叠时，保护词元为132，当前设计的中间名义配额$1024-132=892$填入单一池（归档配额下为640/252近远）。4个前缀仅占64词元页的一部分，区域选择可能再次选中至多4个前缀保护位置，因此892个槽位不保证892个不同的非保护词元。源码接口要求显式近区长度和页数同时指定`tli_near_tokens=off`；零或省略不选择此分支，这是兼容开关而非可调词元预算。StreamingLLM为少量sink保护提供动机，但其LongBench对照也表明保留较大语义前缀可能有益；它并未证明4词元对Qwen3最优，也未验证128词元近期窗口。固定K时，相比128/128，该变化释放124个检索槽位，不能隔离减

少sink词元本身的影响。归档五任务表示得分及历史计时、保护诊断保留各自设置，不改标为4/128结果。

整数边界与摘要覆盖范围。对当前显式n_l/n_b分区路径、有效长度$S = t + 1$（含当前位置、排除填充位置的有效缓存位置数）、页长B及不重叠的前缀／近期保护，令$M = \max(0, S - s - w)$、$L = \max(B, n_l)$，并取

$$b_n = \max(\lfloor s/B \rfloor, \lfloor (S - w - L)/B \rfloor) .$$

历史充足时，移除边界保送页前的远区L1几何页区间为$[\lfloor s/B \rfloor, b_n)$，近区为$[b_n, b_w)$，其中$b_w = \max(b_n, \lceil S/B \rceil - \max(1, \lfloor w/B \rfloor))$。统一L2使用区间$[B\lfloor s/B \rfloor, S - w)$及合并页掩码。因此，取整和页对齐后的实际近区长度可以不同于n_l。摘要先按物理页计算，再进行区域选择，并不按未保护交集重新汇总。部分前缀页的极值因此包含保护前缀键；S非页对齐时，最后一个近区摘要页还可能包含近期窗口键，但合并L2仍截止于$S - w$。这些规则描述当前显式几何路径，不适用于聚类、配额覆盖或短历史分支。

保留候选不足。在当前统一选择路径中，L1选页掩码在softmax前施加于L2词元logit；共享选集随后在各KV组内平均概率。合并TopK按区间宽度裁剪请求数量，而非按正得分位置数裁剪。裁剪后的数量超过正得分位置数时，剩余槽位由零值并列位置补足，其中可能包含未入选页中的缓存词元。最终掩码记录这些索引，不再与L1掩码取交集。因此，补充图S2的候选层级假定正得分候选充足且保护区域不重叠；部分前缀页的重复选取是另一问题。这一源码层面的可能性既不能证明所报告运行中实际发生过此类选择，也不能确定其任务质量影响。

公平比较。比较须匹配模型、输入ID、生成上限与任务评分程序；等K稀疏比较将保护词元计入最终去重上限。保留并报告各方法的原生阶段、层及保护策略；策略匹配的适配器属于单独的受控比较。内部页配额可以不同，但构造、评分、排序和访存均计入完整请求成本。报告实际词元数与选集共享粒度，计时比较还须匹配硬件与精度。

共享子空间配置 LongBench设置。五份实验元数据明确页长64、L1上限128页、最终上限1024词元、压缩比4、尾部低频坐标、$\alpha = .25$、$\beta = .125$、$\gamma = .625$、近区平均／远区 极值页评分及16级量化–反量化数值，并明确共享KV头选集、稠密预填充、静态跳层关闭。五份运行记录均绑定实现提交标识`35b39bd8e43cf478bb4f0ab64a8457f08d87c864`。对这些非投影运行，该源码为L1抽取32个坐标，但将量化–反量化值散写到填零的128维L2键中，并用全维查询评分。因此，页评分和词元评分各32个坐标指有效坐标数，并非两级的物理收缩宽度。后续非投影共享子空间配置路径为L2抽取32维Q/K；归档质量得分不能直接验证该实现。这些源码路径不构成运行核验或有限精度排序等价的证据。该源码还给出前缀保护$2 \times 64 = 128$、近期保护128，以及Qwen3各层稀疏解码。这些源码推断字段不能核实未记录的修改工作树或执行轨迹。历史长度充足时的标准配置分配近区/远区各16/112页、中间各640/128词元，并加入256保护词元。8192个候选槽位不等于最终使用8192个注意力词元，也不约束L2评分量：普通L2仍完整历史评分后施加掩码。逐步实际计数未记录。

保存的输入上限为31500；各任务样本数／最大生成词元数为：Qasper 200/128、HotpotQA 200/32、MuSiQue 200/32、GovReport 200/512、RepoBench-P 500/64。上限不等于实际输入长度。这些保存的运行配置不能建立完整模型／分词器版本、运行精度、硬件身份与评分器版本，匹配比较须另行绑定。非劣检验仍需文档簇身份、匹配稠密运行以及事前规定的任务质量容差。

名义全维页评分变体。五份历史预测无实验元数据或执行记录。文件名与结果判定记录可定位页长64、L1上限128、最终上限1024、压缩比4及相同名义α, β, γ。有效输入上限、完整实现版本、保护、阶段和完整评分设置未核实，不能用当前默认值补齐。

名义全维词元评分变体。五份实验元数据含上述预算设置及full L2标记。四份执行记录缺实现提交标识；MuSiQue记录为`60027fba3672f33744917c4f59960d0f131f8ab0`，但该代码树没有实现记录中的L2模式字段。因此，该提交不能确定实际执行的代码。保留名义标签和得分，不能确认实际执行了全维L2评分。

Quest对照方法。官方评测采用多词元稠密预填充、逐词元稀疏处理、前两层采用稠密注意力及逐Q头选页。其1024词元预算与16词元页长，在内部不同于本文128个64词元页。受控比较对齐最终去重K与阶段／层策略，页配额和头共享差异单列。论文原生配置与受控适配器不得混合为一个结果。本文不声称已完成匹配Quest或FullKV的质量–请求成本比较。

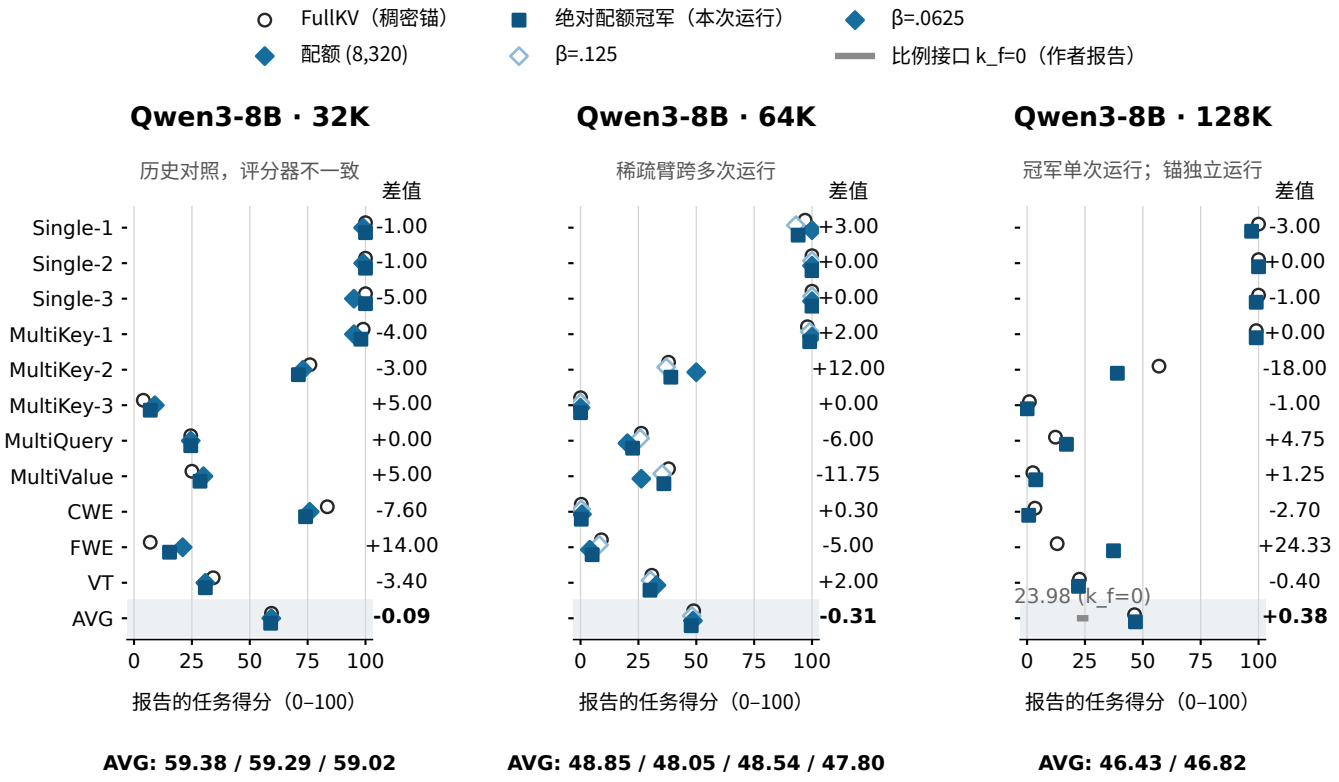
其他实验组。64K合成选择器计时为单层、批量大小为1、单查询汇总，采样协议仍存在矛盾（S6），未与LongBench请求绑定。门控汇总记录阈值但未明确完整实现与子空间配置。仅保留保护词元的配置使用256词元，对照使用1024。缺少的身份、未知门控与配额回填设置及未测完整成本均保持未知，不以当前默认值推断。

机制归因所需对照（本文尚未完成）。固定索引回放将在相同回放输入与解码步数下比较表示复用与重建，并计入初始准备和逐步维护成本。每个回放步都须在两臂间对齐坐标映射、摘要、量化规则、选中词元索引及最终注意力计算。单独的L1分配对照将仅在区域分配与全局分配之间切换，固定页长、K_1、表示、保护、统一L2及其总预算，以及最终上限K。两臂将对全部历史使用同一页评分函数，并同时报告候选不足及实际页数和词元数。在该分配对照中固定K_1，不要求不同方法采用相同页上限。历史门控／回填对照与当前统一L2设计分开；未来门控研究须先定义并验证预期支持集语义。

上述内容是后续匹配检验的要求，不是主文已报告的实验。

表示维护与成本记账。追加键、移动区域边界及改变坐标映射时，派生视图、逻辑词元索引与区域归属须保持一致；共享映射恒等式并未规定增量维护算法。量化–反量化键使用16级浮点数值，不是打包INT4算术。完整请求计时包含表示准备、维护、标定、选择、KV聚集、注意力与同步，重叠工作计一次。TTFT截止首个返回词元，TPOT为后续返回间隔均值。这些定义是匹配评估要求，不表示历史研究已测得完整请求成本。

补充图S8：RULER 32K–128K逐任务得分



RULER 32K/64K/128K · 11 任务 × 每任务 100 例 · 作者报告汇总 + 本次冠军 · 23.98 作者报告（S6） · 无配对区间，不支持非劣结论

历史数值词元配额记录加每长度一条实测紧凑设计臂：作者报告的11任务得分，每任务每臂100例，Qwen3-8B覆盖32K、64K与128K。主指标AVG为完整11任务得分的算术平均；逐任务结果解释差异，不另设逐项零损门槛。差值为历史稀疏配额臂减稠密FullKV的分数点，无配对置信区间。32K历史稀疏臂使用$\beta = .0625$。64K面板比较$\beta = .0625$与$\beta = .125$两种稀疏分配及复用的稠密FullKV锚。稀疏臂的报告标签共同包含页长64、$K_1 = 128$、$K = 1024$、$\alpha = .25$、$\gamma = .625$、前缀4／近期128及压缩比4。门控状态、实际L1/L2维数与实际选集未独立核验，不能标为已验的共享子空间加门控结果。

32K比较跨机器。任务ID、答案哈希、长度与源数据哈希在清单层面相符，但评分器不同，输入身份分别为native与legacy-partial。其−0.09分AVG差异仅为未匹配历史汇总的算术差。两面板均不证明统计非劣或匹配质量–成本收益。

64K下，作者报告$\beta = .0625$（E147h）与.125（E146c）稀疏两臂同机；E119稠密锚来自独立运行。三臂清单中的输入ID、答案哈希、长度及源数据哈希相符。稀疏两臂评分器哈希相同，但生产脚本与有效配置哈希不同；稠密锚输入身份为legacy-partial，评分器也不同，YaRN设置仅为操作者声明。三者AVG依次为48.85、48.05和48.54：稀疏两臂差+0.80，相对稠密分别为+0.31与−0.49。三臂在MultiKey-3上均为零、CWE均低于1分。这些描述性汇总没有报告配对区间，预测也未重放，不能隔离β变化的作用。

来源：32K为E147c稀疏与E116e历史FullKV（8B）；64K为E147h／E146c稀疏两臂与E119 FullKV锚。版本`51b4679c52feebc5327775c660db41550b1c8782`。可编辑图目录保存精确JSON／manifest快照、Git blob来源、得分／差值CSV及复现脚本。这是汇总算术复核加下述单轮实测，不是新增配对实验。

紧凑设计实测运行（新增单轮）。每长度一轮，执行减半前的表I配置串`tli_64_128_1024_c4_Aa0_b0_g1_sk4_sw128_np32_ntoff_nl4096`：页长64、K_1=128、K=1024、sink 4、窗口128、近区页32、自由竞争（`ntoff`）、近区范围4096。Q3的解码生产运行将L1页上限减半为K_1=64；上述质量运行早于该减半。32K/64K/128K批大小为8/2/2，YaRN为关闭/2.0/4.0；回执绑定预测SHA-256、生产脚本、种子42及逐格生成身份（11/11任务有回执，无缺格）。AVG为59.02、47.80与46.82，对另次运行稠密锚59.38、48.54与46.43（差距−0.36/ − 0.74/ + 0.39；128K推得$k_f = 0$的历史比例臂为23.98）。逐任务：NIAH-single-1/2/3三长度为100/100/100、94/100/100与97/100/99；MultiKey-3在32K为7.0、64K/128K为0；CWE为74.1/0.3/0.7，MultiValue为28.5/36.0/3.75；FWE为15.33/5.0/37.33。单轮无配对区间；稠密锚跨代际、机器与评分器，不能推出非劣性。结果JSON与回执仅存于

本地未跟踪exp/目录：t6_ruler_q8b_L32768/65536/131072_champ.json及逐长度回执JSON；128K稠密锚为e119_ruler128k_formal_fullkv.json。23.98比例接口汇总无逐任务JSON，取自作者报告的S6记录。

移植基线比较臂（新记录，未入图）。移植的32K基线：JSSA 58.7（预算1024、rank 32；basis 校准 8× ∼32K 短于 vendor 默认 8×131072，已披露）、AsyncTLS 48.33（名义词元预算512；官方代码未开源故为论文协议语义复现；作者称其为排序索引重跑，取代50.09；排序效果尚未独立核实）、Quest 42.85（原生配置）与 FASA 18.64（预算1024、阈值0.8、k16）。报告的更长上下文得分为：AsyncTLS 64K 得33.88、128K 得37.47（均为排序索引重跑，取代乱序版记录）；FASA 64K/128K分别得1.72/1.40。同一批移植的 eager-torch 时延记录（单张H20、合成needle提示、生成128词元）给出32/64/128K解码TPOT：稠密 26.05/39.62/66.94 毫秒，JSSA 33.30/39.68/61.69（128K 低于稠密），FASA 75.64/133.00/265.91，AsyncTLS 105.29/123.42/160.25，Quest 177.04/317.38/621.37。这些 eager 实现表征方法语义而非官方 kernel 成本，既未与任务质量运行配对，也未与主文历史解码计时对接。同机 K2 预算行：$K = 512$ 得 56.00，CWE 32.5（$K = 1024$ 为 75.9，降 43.4 分），两个 NIAH 任务各降 1 分、FWE 升 1.33；$K = 384$ 崩塌至 15.00，这两个测试点不能确定预算下界。β 曲线第三点 $K_1 = 128$、$\beta = .03125$（远区页124、远区词元732）得 58.07；$\beta = .0625$ 位于原始0.125步长网格点之间，相对.125臂将近区页减半（16→8）、远区词元配额由252升至572。同机 128K 对得 45.73（$\beta = .0625$）对 46.02（$\beta = .125$），46.43 FullKV 锚来自另一次运行（$\beta = .0625$比值98.49%）。这些得分为作者报告，非第三方重放，均无配对区间。新AsyncTLS/FASA结果JSON、manifest与receipt仅存于本地未跟踪的exp/目录；下列来源标识不构成仓库工件可得性。

来源：jssa_r32k_formal、
e119_ruler32768_formal_asynctls_vendor_fix、
e119_ruler32k_formal_quest_vendor、
e119_ruler32768_formal_fasa_vendor_10182330、
e119_ruler65536_formal_asynctls_vendor_64k、
e119_ruler65536/131072_formal_fasa_vendor、
e147j_k2512/k2384_r32k_formal、
e147d_r32k_formal、
e147h_r128k_formal。

历史跨模型记录（不属主文范围）。作者报告的Qwen3-32B RULER32K AVG为稀疏50.64、稠密52.22（−1.58）。跨机Llama-3.1-8B两臂在历史近区页／词元配额(8,320)和(16,640)下分别报告83.88与86.19。这些描述性记录缺少匹配执行与配对不确定性，不扩大当前Qwen3-8B主文范围，也不验证其n_l/n_b统一L2配置。