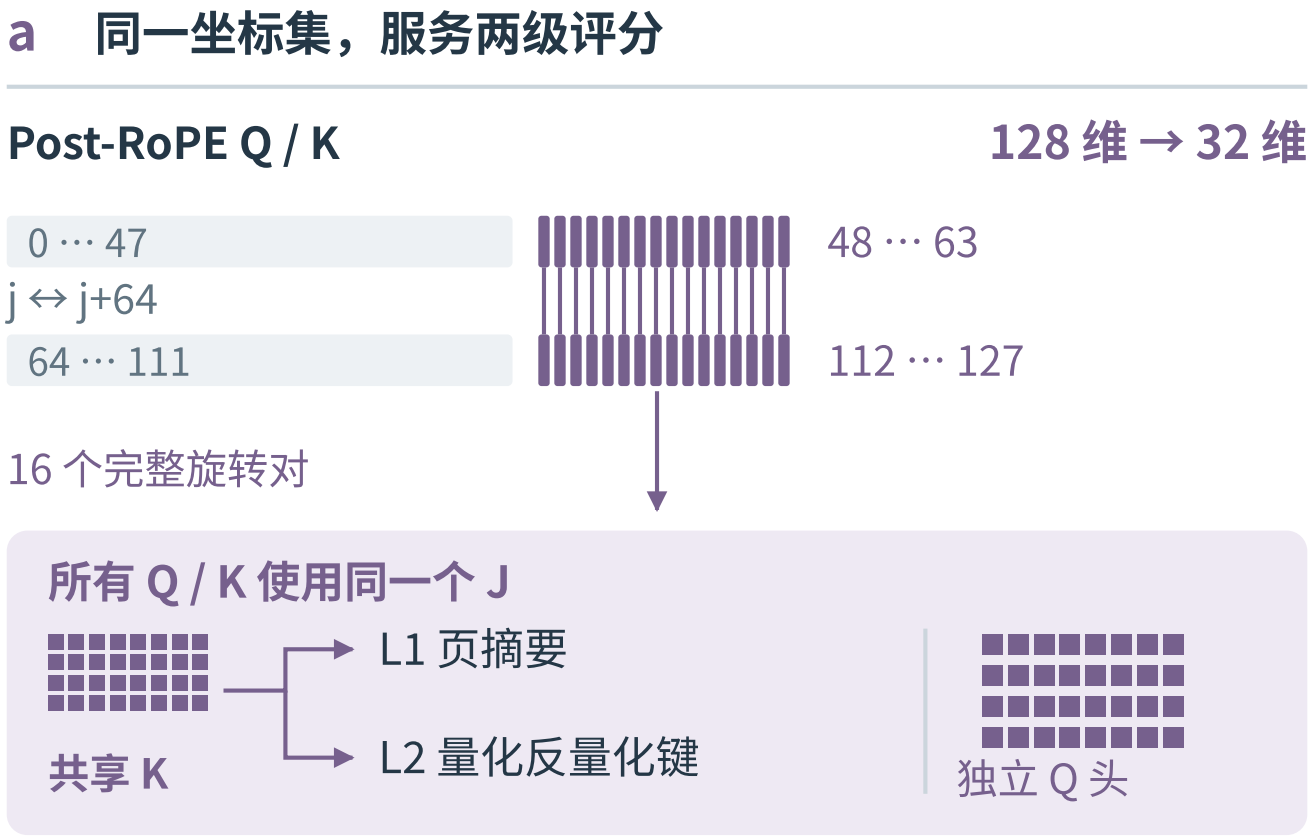
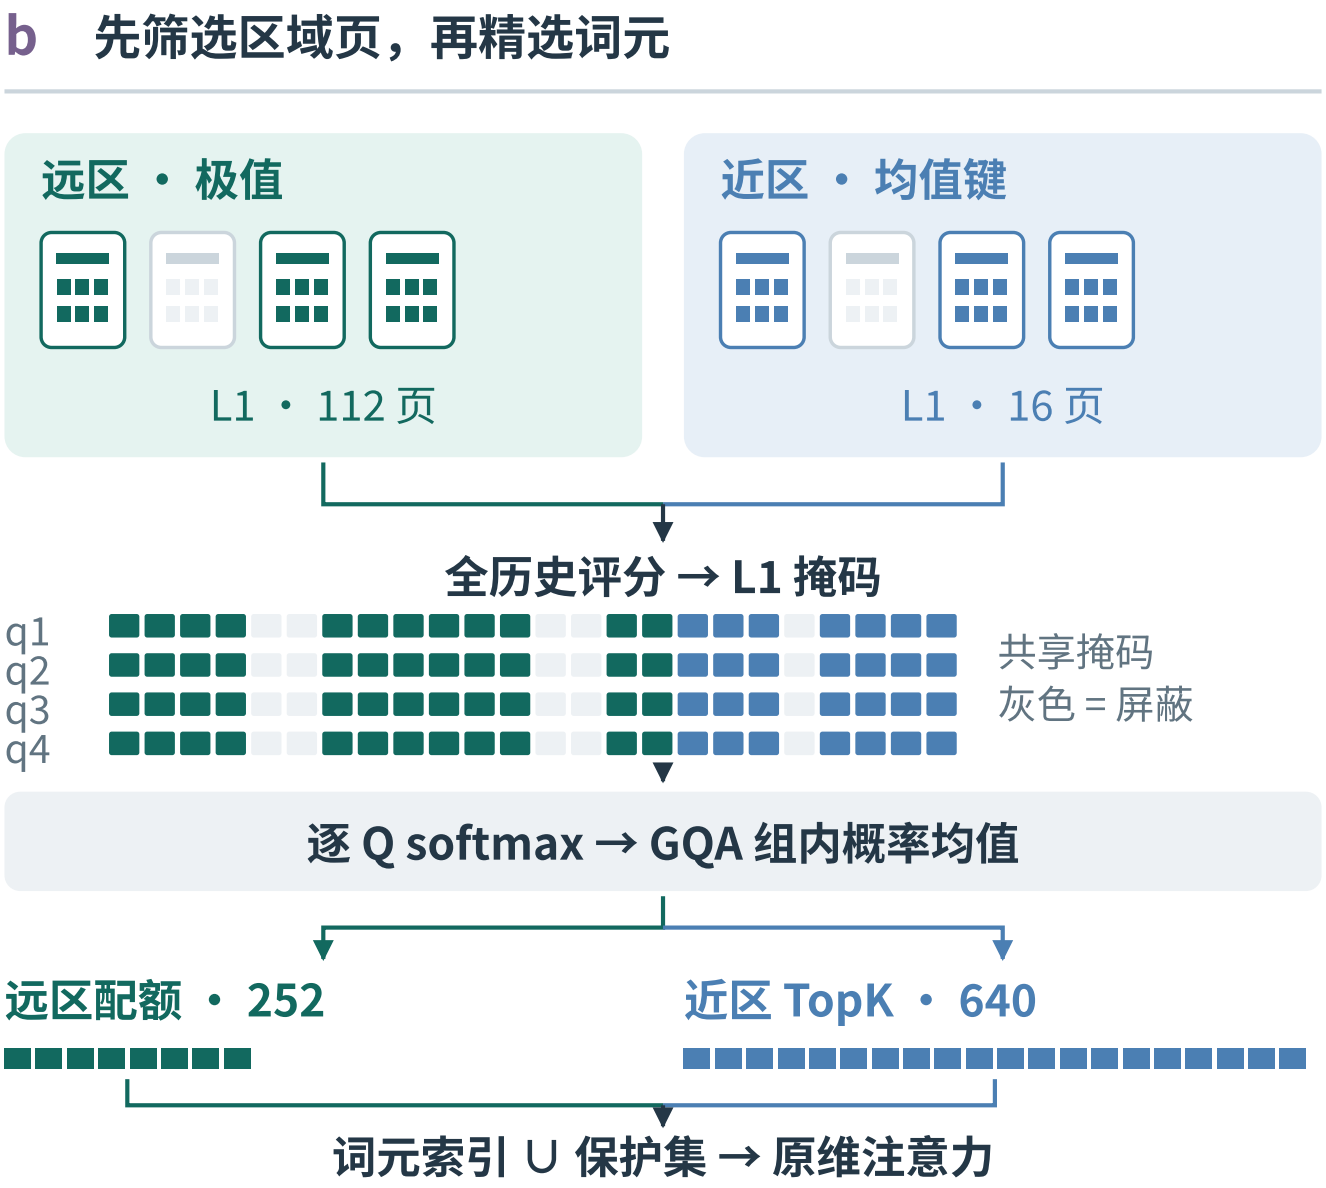
机制补充图 S1: 低频子空间选取

本补充给出子空间选取、区域配额与门控状态转换的详细流程，适用条件与主文一致。



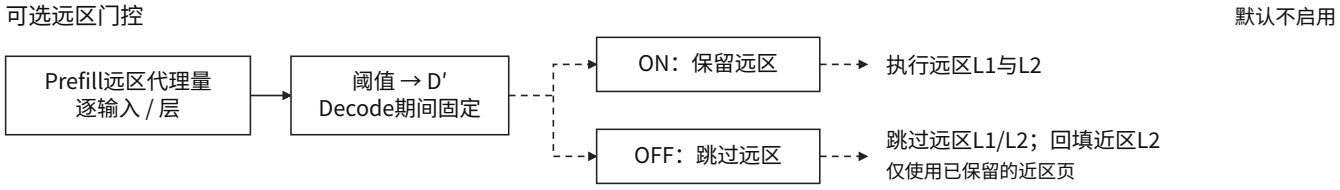
当前紧凑实现的低频子空间选取。16个完整旋转对同时供近远区域和L1/L2使用。实际量化反量化表示为浮点，不是packed INT4；所选词元索引定义原始128维KV的支持集，物理访问方式取决于后端。

机制补充图 S2: 区域页配额与词元配额



区域筛选与保护预算。候选充足时，128页配额分成近区16／远区112页；当前4/128配置的总1024上限包含132保护与名义640／252近远槽位。前缀不足整页，可能重复选中至多4个保护位置，减少非保护远区覆盖。图块数量仅示意。逐查询头归一化后才在KV组内平均。

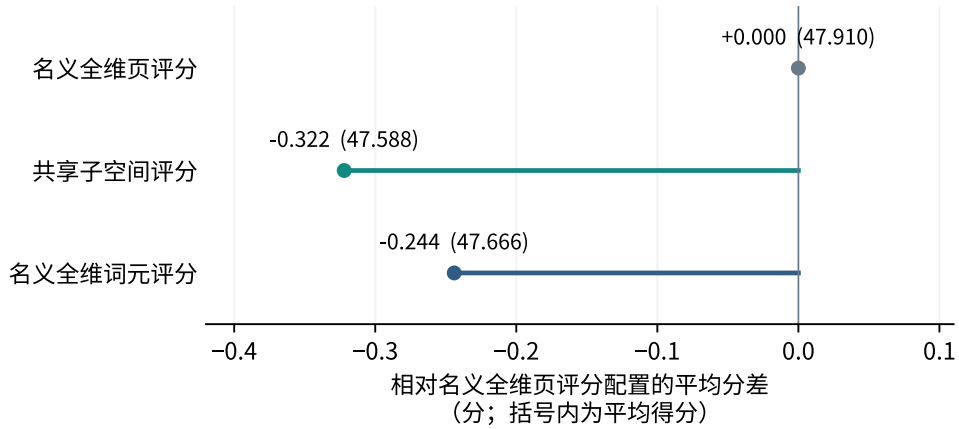
机制补充图 S3: 从预填充观测到解码复用的门控状态转换



虚线：控制流。Prefill统计不约束Decode误差。

逐层门控状态转换及条件执行。预填充暂存决定，首次解码路径调用冻结。在有效长度、远区非空的固定数值配额实现上，OFF跳过远区 L1/L2点积与选取，只把L2余量回填近区，L1 近区仍16页。全域准备、S宽缓冲及softmax成本保留。图中的控制路径仅作示意，并非实测层级结果。门控默认不启用，共享子空间配置的匹配质量／成本尚未验证。

补充图 S4：描述性配置比较



五任务均值为47.910（名义全维页评分变体）、47.588（共享子空间配置）与47.666（名义全维词元评分变体）。相对共享子空间配置的0.322、0.078分差值仅作描述。名义全维页评分变体缺实验元数据，名义全维词元评分变体的L2模式标记未能对应到实现该模式的代码版本，因此这些标签不能建立受控阶段干预或已完成的三个配置消融。补充注S7列出配置证据。这些均不是稠密FullKV，也不建立文档配对非劣性或匹配质量–成本结论。

补充注 S5：Gate观测与执行范围

功能未启用时仍执行普通远区选择；图中OFF仅指启用功能后标定得到的逐层跳过决定。可选远区门控在每层预填充观测后暂存门控决策，在首次解码路径调用时冻结，后续复用直到新输入清空（补充图S3）。该调用可能仍在消费问题词元，不能据此假定已经看完整问题。标定使用末尾至多256行可用Q、原维评分及逐Q头softmax，对平均远区注意力权重总和做严格阈值比较；该阈值只用于预填充观测的判定，并不约束后续解码的远区注意力权重总和或任务误差。

标定区域几何。历史充足时，令S_c为标定长度、$m_c = S_c - s - w$。统计量先对$[s, s + \lfloor(1-\alpha)m_c\rfloor)$内的注意力求和，再对查询行与查询头取均值。受支持的解码跳过路径则采用S7定义的页对齐远区边界Bb_n，其中未保护跳过区间从s开始。即使两阶段长度相同，这两个区间也未必一致。$B = 64$、$s = 4$、$w = 128$、$\alpha = .25$时，在$S_c = S = 8192$处，两者右端点分别为6049和6016；长度为1065时则为703和704。因此，该统计量属于远区贡献代理，既非被移除支持集的精确注意力权重总和，也不是其保守上界。前缀位置仍受保护。

在支持的固定数值配额实现（批量大小为1、有效长度已知且远区非空）中，OFF跳过远区 L1/L2点积与选取，仅将剩余L2配额回填合法近区词元，不扩大近区的L1页预算。启用远区、关闭远区并回填近区配额、关闭远区且不回填配额是不同干预。移除远区可能改变逐Q softmax分母及组平均近区排序，因此回填不是保持近区选集不变的单纯省算。准备、量化、复制与浮点转换和S宽缓冲／softmax均计入成本。该实现不支持组合动态与静态层跳过，也不支持将动态门控用于Llama；批内状态隔离、运行时状态转换和分布变化触发的回退尚未验证。运行时自适应调整α, β, γ不属于本文评估的配置。

主文门控是共享子空间方法的候选扩展。现有门控任务汇总缺生成源码SHA、完整子空间配置与配对预测，不能用于验证该配置。上述实现细节限定机制适用范围，并非实测速度或质量收益。

补充注 S6：历史诊断的适用范围

以下保留主文限制所依据的详细数值。这些是作者归档诊断，不是新实验，也不是共享子空间方法的匹配验证。

动机性诊断。图1使用归档Qwen3-8B观测，评分与选择规则如下。(a)保留E140b中固定MuSiQue1/L24/q14212的页数组与保存选集：注意力权重排序和均值评分各用1989词元，极值评分用2048词元；均值与极值均使用相同32个低频坐标，并在32个查询头间平均评分；注意力权重参考则来自全维注意力概率。两种评分的全局选集具有不同区域分配及实际词元数，因此该例不能证明近远评分分工或预算匹配的最优性。顶行逐页汇总注意力，不是TopK或DSA选集；下三行对称展示注意力权重排序、均值与极值选集，两种评分器使用相同漏选／参考外入选编码。219页中三个集合各含32页；相对注意力权重排序，均值漏13页、极值漏17页，含共同漏选7页。仅均值漏选6页，仅极值漏选10页；各自参考外入选为13和17页。灰色表示既未选入也不是参考漏页。这些集合差异不是错误或任务质量损失，整页参考也没有最优oracle保证。位置7936页的一个词元承载该页保存权重和的99.84%，只说明此查询，不代表总体机制。(b)按绝对区间$[q-d_{hi}, q-d_{lo}+1)$和真实区域边界重算归属；整箱有效词元数放得下才接纳，并列按绝对位置排序。全局上限2048；另一策略分别以1024/1024限制远／近区，不回填。128条全局计数与分区总数均不超过2048。远区平均保留率为.67591615与.72070552，43条配对差值为负；全局近区保留率为.93149427。这些是四条源序列的相关查询／层观测，不是独立文档。(c)保留八个cell的坐标比值和未配对随机选择，不能隔离频率或代表生产评分。(d)只使用历史far-profile的16×36矩阵：24层中位值低于.01，每序列12–32个低代理值层。其生产者使用最后一个采样查询、先在GQA组内求和logits再softmax，far定义为$[64, t-2048)$。该历史代理不是S5的当前门控统计；低值层数不等于可安全跳过层数。不使用另一份10条profile的skip摘要。随附数值输入包含逐查询选集及来源哈希。

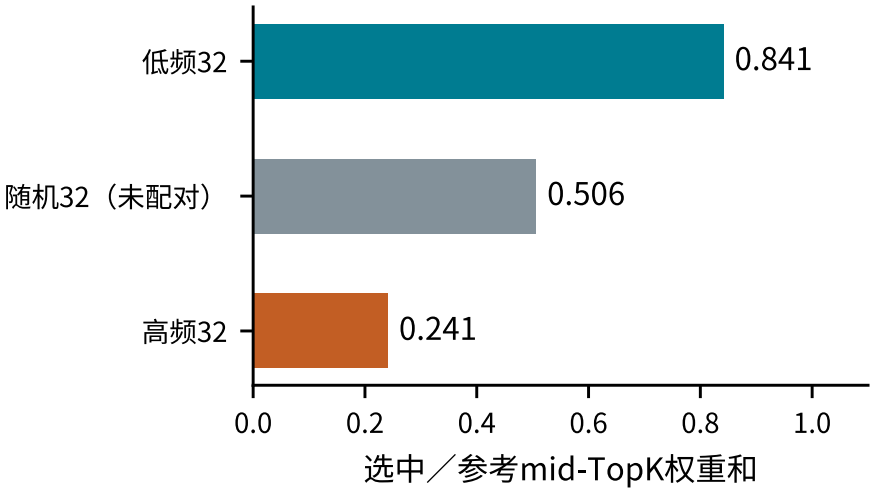


Figure 1: 归档坐标辅助诊断：选中注意力权重总和除以全维参考mid-TopK权重总和，中间上限768，128/128保护另计。诊断采用页均值选择器，不同于生产近区均值／远区极值评分。Random32未配对；未进行配对随机质量或输出误差检验。

计时来源。主文解码TPOT图采用历史稀疏配置$(\alpha,\beta,\gamma)=(.125,.375,.625)$、名义$K_1=128$与$K=1024$，保护配置未显式绑定。来源报告Qwen3-8B bf16、NVIDIA H20、Transformers 4.56.2及Torch 2.8.0。最小派生绘图输入保留这些字段及原仓库文件SHA-256，省略宿主地址和私有路径；其哈希与原文件不同。E152v2提供作者报告中位数，而非逐次重复原件。作者审计列出每长度每动态臂三条记录、每记录三次测量；所写交错次序不足以将各臂统一标为ABBA×3。当前采集器将后端路径标为未验证。82.0毫秒StaticCache点属于不同修复与重复身份，故不纳入；StaticCache构建发生在请求计时之前。E127的5.47倍比较旧TLI与优化TLI阶段时间汇总，并非稠密FullKV。它与E152汇总均不能建立launch-bound因果归因。数据、采集器和绘图脚本哈希见`sources/evidence_bindings.json`。

选择器局部计时与汇总。归档性能记录对后续实现进行两轮GPU交换测量。其关联源码具有紧凑共享子空间L2实现，区别于补充注S7的早期LongBench实现；源码检查本身不能核实计时执行路径。每轮值分别为全维页评分变体的1.3635／1.337毫秒、共享子空间配置的1.3872／1.3324毫秒、全维词元评分变体的1.4794／1.4473毫秒。记录给出的两轮中位汇总分别为1.3502、1.3598、1.4634毫秒。每组两个报告值的中点中位数为1.35025、1.35980、1.46335毫秒；这些是算术复算，并非新增测量。原件未提供逐阶段中位数或原始序列，因此不能确认此前“五阶段中位数之和”的描述。合成单层、批量大小为1、单查询、64K的范围不同于完整层或请求，也未与质量实验配对。记录称60步、40次预热及20个稳态样本，但此前检查的测量程序对应100总步及60个稳态样本；矛盾仍未解决。所报共享子空间配置时间高于全维页评分变体，既未确立统计显著性，也未建立完整系统加速。

区域与门控诊断。历史仅保留保护词元的均值26.09，含中间检索47.91，但预算也从1024降到256，无法隔离区

域策略贡献。门控标定包含16输入、每个36层；保存远区注意力权重总和字段$<.05$的输入–层记录在预填充／解码分别30／22条，交集13。在预填充选中的输入–层记录之间，所存解码代理量的均值为0.0582、最大值为0.1678；每条解码代理量据报告是尾部五个查询的平均值，并非逐词元最大值。这些跨阶段变化不能证明任务精度保持或请求收益。

后续作者汇总在$\epsilon = .05/.10$时五任务均值47.876／47.692，对复用47.910锚分别下降0.034／0.218分。每个配置的3项任务下降，HotpotQA下降1.05／1.26分。作者五任务bootstrap区间$[-.584, .452]/[-.806, .400]$仅为描述，跨零不证明等价。现有作业记录尚不能建立共享子空间配置的匹配比较（补充注S5）；三政策质量及完整成本仍未匹配验证。

共享子空间配置尚缺匹配的稠密FullKV质量参照、全维评分稀疏对照及包含准备成本的请求比较。历史全维页评分与尾部32坐标词元评分实验不能替代这些对照。作者报告的RULER汇总（主文文献[10]）标识了名义128K、YaRN因子4的Qwen3-8B及$\alpha = .125$、$\beta = .375$、$\gamma = .625$稀疏配置。对其11项任务得分重算非加权均值，FullKV为46.43，稀疏配置为23.98，差值为-22.45分，稀疏／FullKV得分比为51.6%。这是负面的汇总结果，不构成当前紧凑配置（$\alpha = .25$、$\beta = .125$、$\gamma = .625$）的已核验匹配验证：所检查的仓库快照缺少原始预测；配对输入身份、评分器执行及当前紧凑执行的对应关系均未独立核验。对未覆盖配额的常规固定配额路径，已检查公式给出$K_{2,\text{mid}} = 1024 - 128 - 128 = 768$，而$\text{round}(128 \cdot .375) \cdot 64 \cdot .625 = 1920$，故名义远区词元配额为$\max(0, 768 - \min(1920, 768)) = 0$。这是已检查代码与报告配置的联合推论，实际执行路径未独立验证，也不能据此认定得分差的唯一原因。后续64K文件仅含汇总得分与manifest，并非原始预测；其回执摘要缺少α、β及sink保护等字段，不能闭合完整运行配置身份。本比较不加入64K得分。这些汇总不能分离YaRN或远端候选不足的因果效应。历史静态逐层策略未达到预设提升阈值，已有配额与门控诊断又同时改变了多种策略或尺度；这些负结果限制了结论范围，但未直接检验当前共享子空间配置与预填充远区门控。原始得分及来源详见实验记录。

补充注 S7：预算与配置身份

当前前缀／近期配置。当前选定候选采用4个前缀词元、128词元近期窗口、稠密预填充与稀疏解码，实现默认值仍为128/128。作者汇总评估配置（E149）显式选择4/128，但完整预测及执行身份记录尚不可用。历史充足且保护不重叠时，保护词元为132，中间名义配额为$1024 - 132 = 892$，近区仍为640、远区为252。4个前缀仅占64词元页的一部分，区域选择可能再次选中至多4个前缀保护位置，因此远区配额不保证252个不同的非保护词元。StreamingLLM为少量sink保护提供动机，但其LongBench对照也表明保留较大语义前缀可能有益；它并未证明4词元对Qwen3最优，也未验证128词元近期窗口。固定K时，相比128/128，该变化释放124个检索槽位，不能隔离减少sink词元本身的影响。归档五任务表示得分及历史计时、保护诊断保留各自设置，不改标为4/128结果。

整数边界与摘要覆盖范围。对普通分区路径（$\alpha, \beta > 0$）、有效长度$S = t + 1$（含当前位置、排除填充位置的有效缓存位置数）、页长B及不重叠的前缀／近期保护，令$M = \max(0, S - s - w)$、$L = \max(B, \lfloor \alpha M \rfloor)$，并取

$$b_n = \max(\lfloor s/B \rfloor, \lfloor (S - w - L)/B \rfloor) .$$

历史充足时，远区L1页索引为$[\lfloor s/B \rfloor, b_n)$，近区为$[b_n, b_w)$，其中$b_w = \max(b_n, \lceil S/B \rceil - \max(1, \lfloor w/B \rfloor))$。L2使用远区词元区间$[B\lfloor s/B \rfloor, Bb_n)$与近区区间$[Bb_n, S - w)$。因此，取整和页对齐后的实际近区长度可以不同于$\alpha M$。摘要先按物理页计算，再进行区域选择，并不按未保护交集重新汇总。部分前缀页的极值因此包含保护前缀键；S非页对齐时，最后一个近区摘要页还可能包含近期窗口键，但近区L2仍截止于$S - w$。这些规则描述普通固定配额路径，不适用于聚类、配额覆盖或短历史分支。

保留候选不足。在普通固定配额路径中，L1选页掩码在softmax前施加于L2词元logit；共享选集随后在各KV组内平均概率。区域TopK按区间宽度裁剪请求数量，而非按正得分位置数裁剪。裁剪后的数量超过正得分位置数时，剩余槽位由零值并列位置补足，其中可能包含未入选页中的缓存词元。最终掩码记录这些索引，不再与L1掩码取交集。因此，补充图S2的候选层级假定正得分候选充足且保护区域不重叠；部分前缀页的重复选取是另一问题。这一源码层面的可能性既不能证明所报告运行中实际发生过此类选择，也不能确定其任务质量影响。

公平比较。比较须匹配模型、输入ID、生成上限与任务评分程序；等K稀疏比较将保护词元计入最终去重上限。保留并报告各方法的原生阶段、层及保护策略；策略匹配的适配器属于单独的受控比较。内部页配额可以不同，但构造、评分、排序和访存均计入完整请求成本。报告实际词元数与选集共享粒度，计时比较还须匹配硬件与精度。

共享子空间配置 LongBench设置。五份实验元数据明确页长64、L1上限128页、最终上限1024词元、压缩比4、尾部低频坐标、$\alpha = .25$、$\beta = .125$、$\gamma = .625$、近区平均／远区 极值页评分及16级量化–反量化数值，并明确共享KV头选集、稠密预填充、静态跳层关闭。五份运行记录均绑定实现提交标识`35b39bd8e43cf478bb4f0ab64a8457f08d87c864`。对这些非投影运行，该源码为L1抽取32个坐标，但将量化–反量化值散写到填零的128维L2键中，并用全维查询评分。因此，页评分和词元评分各32个坐标指有效坐标数，并非两级的物理收缩宽度。后续非投影共享子空间配置路径为L2抽取32维Q/K；归档质量得分不能直接验证该实现。这些源码路径不构成运行核验或有限精度排序等价的证据。该源码还给出前缀保护$2 \times 64 = 128$、近期保护128，以及Qwen3各层稀疏解码。这些源码推断字段不能核实未记录的修改工作树或执行轨迹。历史长度充足时的标准配置分配近区/远区各16/112页、中间各640/128词元，并

加入256保护词元。8192个候选槽位不等于最终使用8192个注意力词元，也不约束L2评分量：普通L2仍完整历史评分后施加掩码。逐步实际计数未记录。

保存的输入上限为31500；各任务样本数／最大生成词元数为：Qasper 200/128、HotpotQA 200/32、MuSiQue 200/32、GovReport 200/512、RepoBench-P 500/64。上限不等于实际输入长度。这些保存的运行配置不能建立完整模型／分词器版本、运行精度、硬件身份与评分器版本，匹配比较须另行绑定。非劣检验仍需文档簇身份、匹配稠密运行以及事前规定的任务质量容差。

名义全维页评分变体。五份历史预测无实验元数据或执行记录。文件名与结果判定记录可定位页长64、L1上限128、最终上限1024、压缩比4及相同名义α, β, γ。有效输入上限、完整实现版本、保护、阶段和完整评分设置未核实，不能用当前默认值补齐。

名义全维词元评分变体。五份实验元数据含上述预算设置及full L2标记。四份执行记录缺实现提交标识；MuSiQue记录为`60027fba3672f33744917c4f59960d0f131f8ab0`，但该代码树没有实现记录中的L2模式字段。因此，该提交不能确定实际执行的代码。保留名义标签和得分，不能确认实际执行了全维L2评分。

Quest对照方法。官方评测采用多词元稠密预填充、逐词元稀疏处理、前两层采用稠密注意力及逐Q头选页。其1024词元预算与16词元页长，在内部不同于本文128个64词元页。受控比较对齐最终去重K与阶段／层策略，页配额和头共享差异单列。论文原生配置与受控适配器不得混合为一个结果。本文不声称已完成匹配Quest或FullKV的质量–请求成本比较。

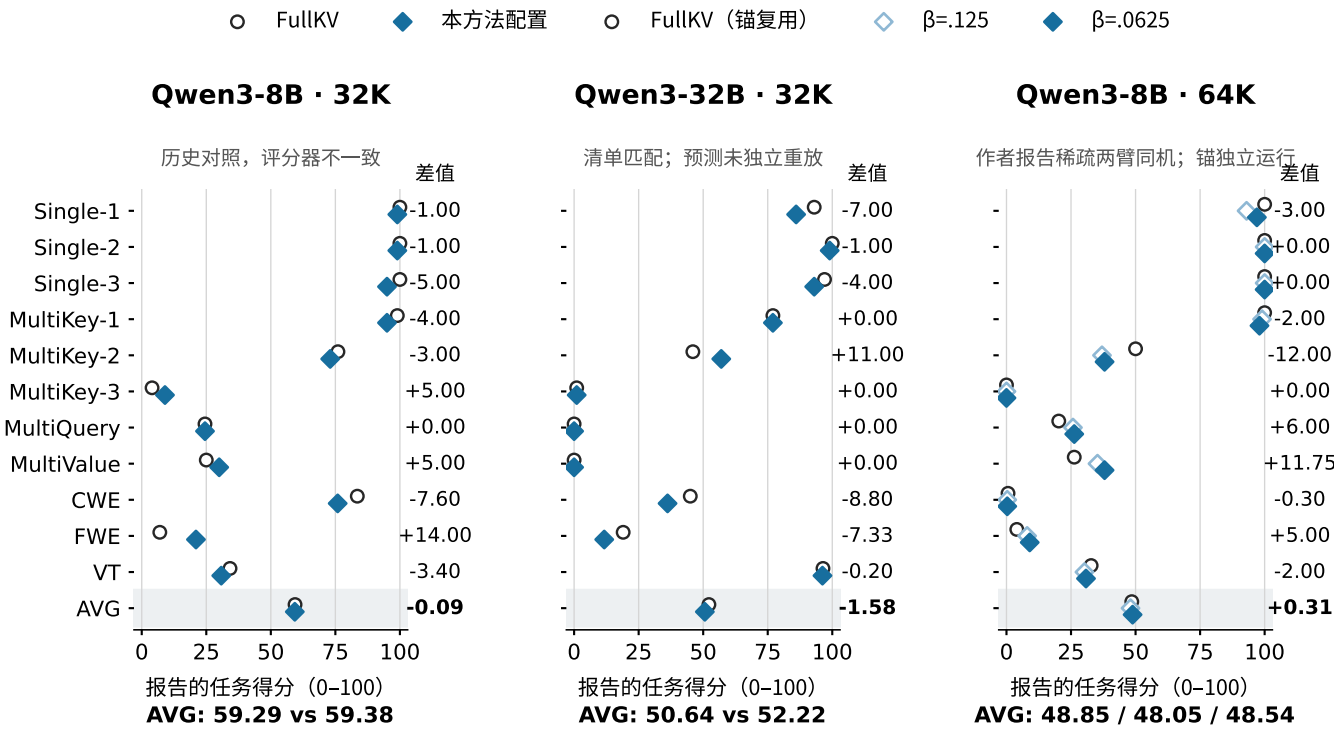
其他实验组。64K合成选择器计时为单层、批量大小为1、单查询汇总，采样协议仍存在矛盾（S6），未与LongBench请求绑定。门控汇总记录阈值但未明确完整实现与子空间配置。仅保留保护词元的配置使用256词元，对照使用1024。缺少的身份、未知门控与配额回填设置及未测完整成本均保持未知，不以当前默认值推断。

机制归因所需对照（本文尚未完成）。固定索引回放将在相同回放输入与解码步数下比较表示复用与重建，并计入初始准备和逐步维护成本。每个回放步都须在两臂间对齐坐标映射、摘要、量化规则、选中词元索引及最终注意力计算。单独的L1分配对照将仅在区域分配与全局分配之间切换，固定页长、K_1、表示、保护、L2精筛及其词元配额，以及最终上限K。两臂将对全部历史使用同一页评分函数，并同时报告候选不足及实际页数和词元数。在该分配对照中固定K_1，不要求不同方法采用相同页上限。门控对照将比较启用远区、关闭远区并回填近区L2配额，以及关闭远区且不回填，保持近区L1页上限不变；移除远区支持也可能改变近区排序。

上述内容是后续匹配检验的要求，不是主文已报告的实验。

表示维护与成本记账。追加键、移动区域边界及改变坐标映射时，派生视图、逻辑词元索引与区域归属须保持一致；共享映射恒等式并未规定增量维护算法。量化–反量化键使用16级浮点数值，不是打包INT4算术。完整请求计时包含表示准备、维护、标定、选择、KV聚集、注意力与同步，重叠工作计一次。TTFT截止首个返回词元，TPOT为后续返回间隔均值。这些定义是匹配评估要求，不表示历史研究已测得完整请求成本。

补充图S8：RULER 32K／64K逐任务得分



RULER 32K/64K · 11 个任务，每任务每组 100 例 · 作者报告的汇总结果
差值＝稀疏−FullKV（64K取β=.0625）；无配对区间或非劣结论。

作者报告的11任务得分，每任务每臂100例，覆盖32K（Qwen3-8B、Qwen3-32B）与64K（Qwen3-8B）。主指标AVG为完整11任务得分的算术平均；逐任务结果解释差异，不另设逐项零损门槛。差值为本方法减稠密FullKV的分数点，无配对置信区间。32K两方法臂使用不同分配：Qwen3-8B的$\beta = .0625$，Qwen3-32B为.125。64K面板比较$\beta = .0625$与$\beta = .125$两种稀疏分配及复用的稠密FullKV锚。稀疏臂的报告标签共同包含页长64、$K_1 = 128$、$K = 1024$、$\alpha = .25$、$\gamma = .625$、前缀4／近期128及压缩比4。门控状态、实际L1/L2维数与实际选集未独立核验，不能标为已验的共享子空间加门控结果。

两组32K比较均跨机器。8B的任务ID、答案哈希、长度与源数据哈希在清单层面相符，但评分器不同，输入身份分别为native与legacy-partial。其−0.09分AVG差异仅为未匹配历史汇总的算术差。32B的源数据哈希、评分器、生产脚本与模型配置记录相符，但原始预测配对及跨机重放尚未核验。−1.58分AVG差异包括MK2提高11分、CWE下降8.80分、FWE下降7.33分；两臂MQ/MV均零不能定因。两面板均不证明统计非劣、同一配置的跨模型规模验证或匹配质量–成本收益。

64K下，作者报告$\beta = .0625$（E147h）与.125（E146c）稀疏两臂同机；E119稠密锚来自独立运行。三臂清单中的输入ID、答案哈希、长度及源数据哈希相符。稀疏两臂评分器哈希相同，但生产脚本与有效配置哈希不同；稠密锚输入身份为legacy-partial，评分器也不同，YaRN设置仅为操作者声明。三者AVG依次为48.85、48.05和48.54：稀疏两臂差+0.80，相对稠密分别为+0.31与−0.49。三臂在MultiKey-3上均为零、CWE均低于1分。这些描述性汇总没有报告配对区间，预测也未重放，不能隔离β变化的作用。

来源：8B为E147c稀疏与E116e历史FullKV；32B为E143a稀疏与FullKV，固定仓库版本`b5a97b314119006dc7e1624bf60268ff2501e44d`；64K为E147h／E146c稀疏两臂与E119 FullKV锚，版本`51b4679c52feebc5327775c660db41550b1c8782`。可编辑图目录保存11份精确JSON／manifest快照、Git blob来源、48行得分／差值CSV及复现脚本。这是汇总算术复核，不是新增实验；128K历史损失仍保留在主文及S6。