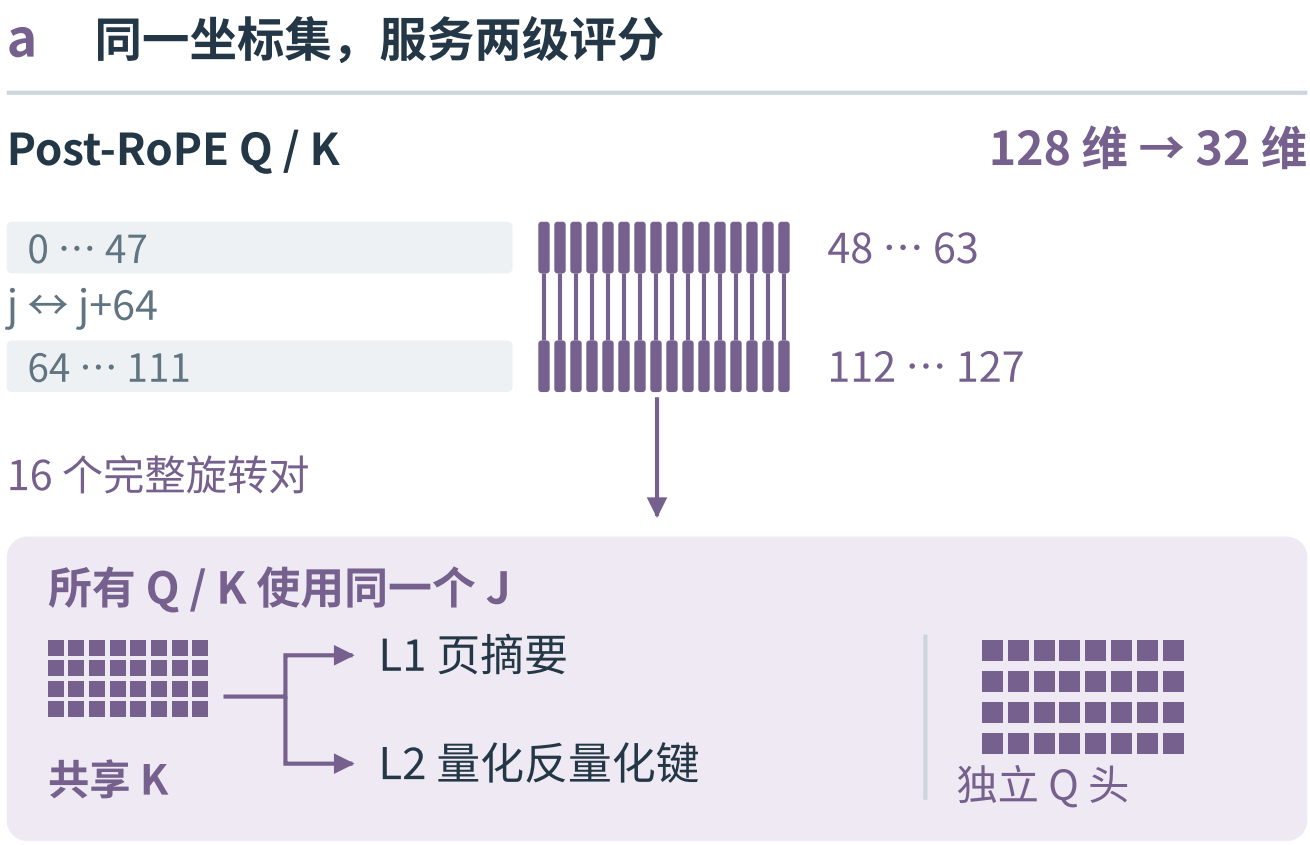
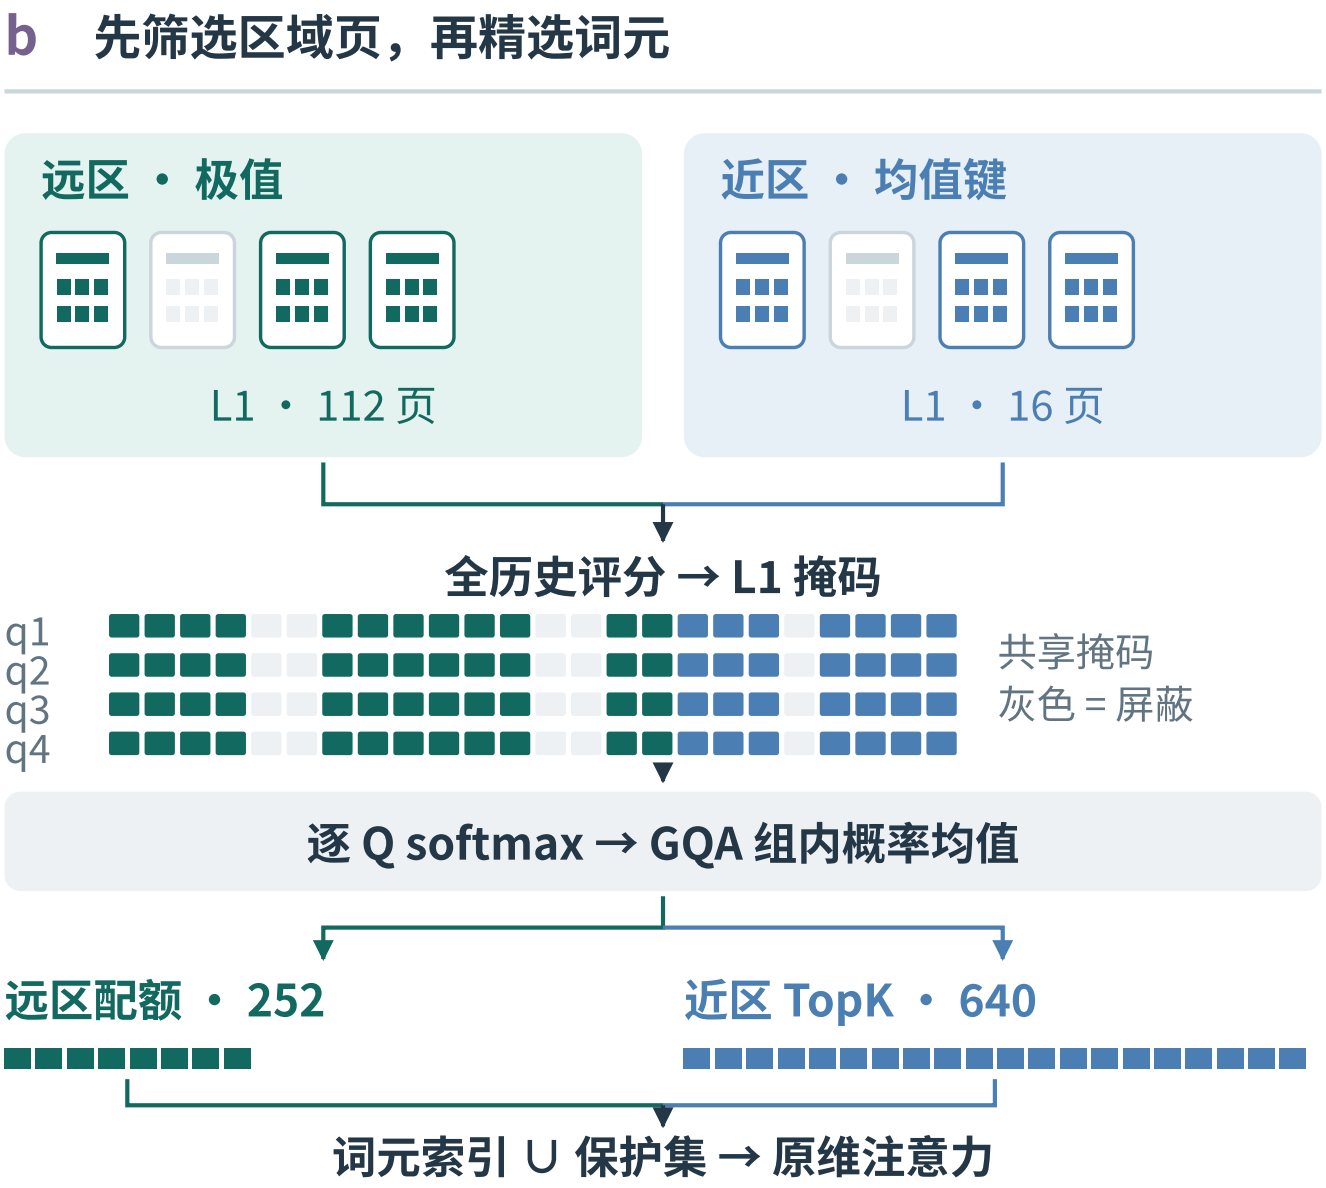
机制补充图 S1: 低频子空间选取

本补充给出子空间选取、区域配额与门控状态转换的详细流程，适用条件与主文一致。



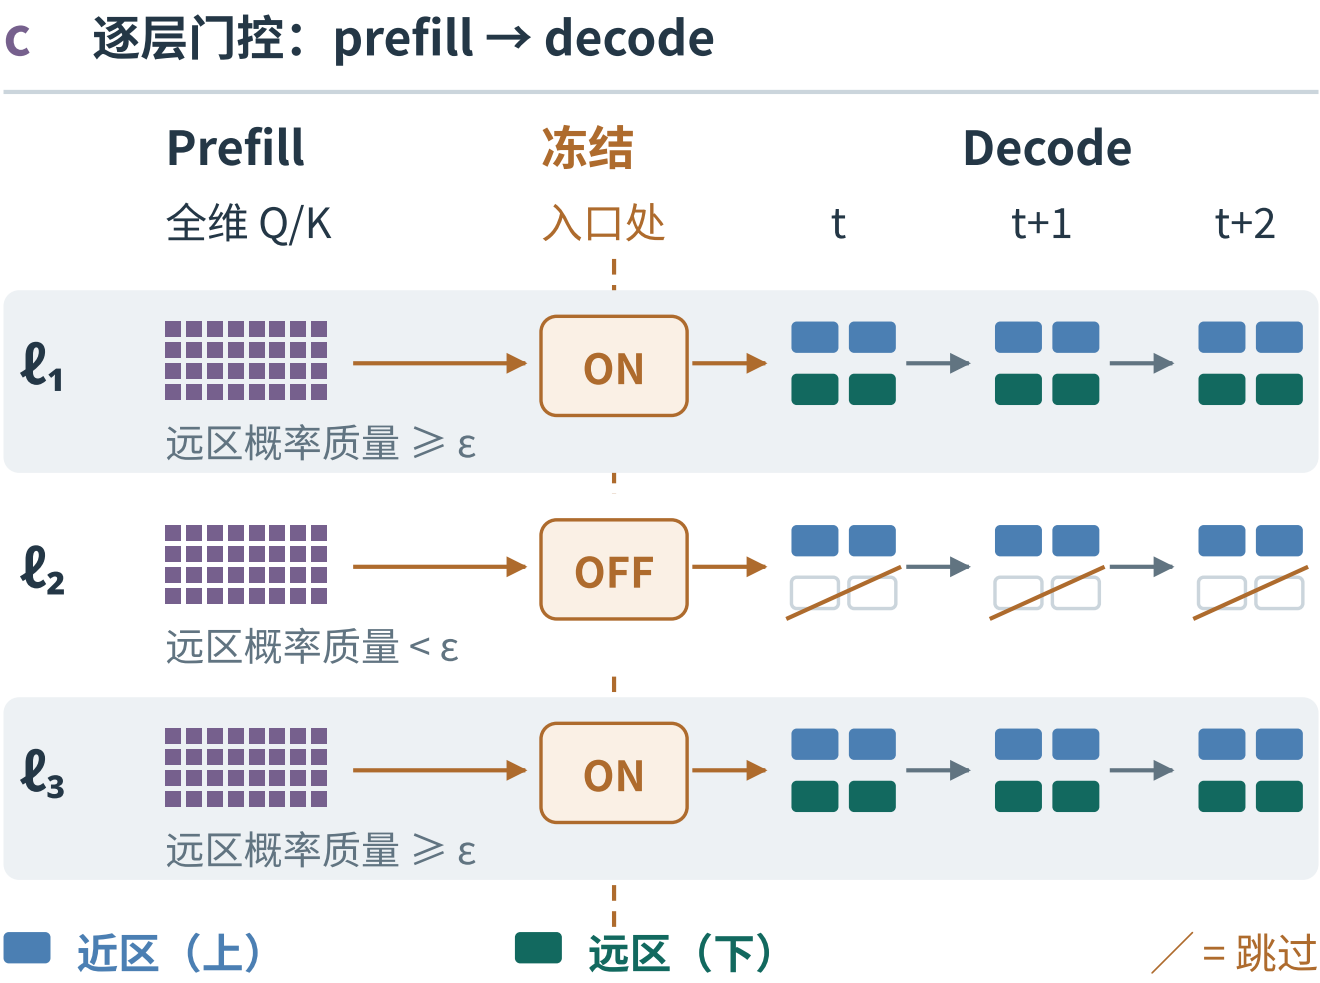
当前紧凑实现的低频子空间选取。16个完整旋转对同时供近远区域和L1/L2使用。实际量化反量化表示为浮点，不是packed INT4；所选词元索引读取原始128维KV。

机制补充图 S2: 区域页配额与词元配额



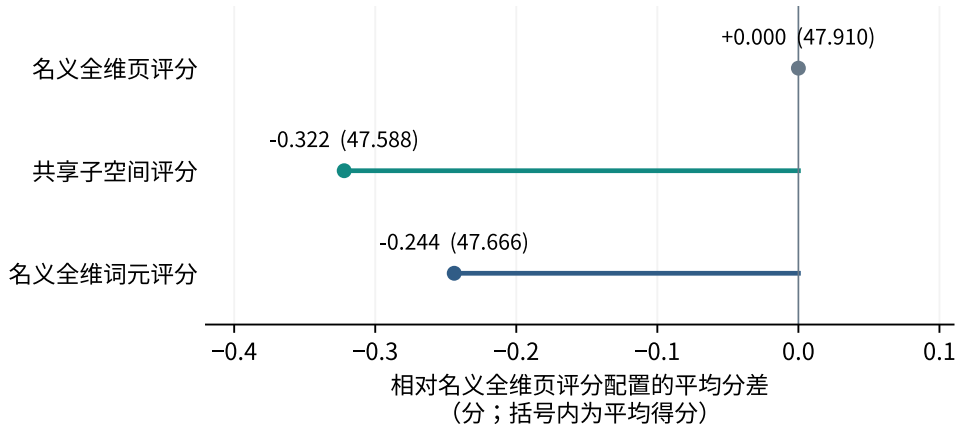
区域筛选与保护预算。候选充足时，128页配额分成近区16／远区112页；当前4/128配置的总1024上限包含132保护与名义640／252近远槽位。前缀不足整页，可能重复选中至多4个保护位置，减少非保护远区覆盖。图块数量仅示意。逐查询头归一化后才在KV组内平均。

机制补充图 S3: 从预填充观测到解码复用的门控状态转换



逐层门控状态转换及条件执行。预填充暂存决定，首次解码路径调用冻结。在有效长度、远区非空的固定数值配额实现上，OFF跳过远区 L1/L2点积与选取，只把L2余量回填近区，L1 近区仍16页。全域准备、S宽缓冲及softmax成本保留。图中的层级状态与重复解码步骤仅作示意，并非实测层级结果。门控默认不启用，共享子空间配置的匹配质量／成本尚未验证。

补充图 S4：描述性配置比较



五任务均值为47.910（名义全维页评分变体）、47.588（共享子空间配置）与47.666（名义全维词元评分变体）。相对共享子空间配置的0.322、0.078分差值仅作描述。名义全维页评分变体缺实验元数据，名义全维词元评分变体的L2模式标记未能对应到实现该模式的代码版本，因此这些标签不能建立受控阶段干预或已完成的三个配置消融。补充注S7列出配置证据。这些均不是稠密FullKV，也不建立文档配对非劣性或匹配质量–成本结论。

补充注 S5：Gate观测与执行范围

功能未启用时仍执行普通远区选择；图中OFF仅指启用功能后标定得到的逐层跳过决定。可选远区门控在每层预填充观测后暂存门控决策，在首次解码路径调用时冻结，后续复用直到新输入清空（补充图S3）。该调用可能仍在消费问题词元，不能据此假定已经看完整问题。标定使用末尾至多256行可用Q、原维评分及逐Q头softmax，对平均远区注意力质量做严格阈值比较；该阈值只用于预填充观测的判定，并不约束后续解码的远区注意力概率质量或任务误差。

在支持的固定数值配额实现（批量大小为1、有效长度已知且远区非空）中，OFF跳过远区 L1/L2点积与选取，仅将剩余L2配额回填合法近区词元，不扩大近区的L1页预算。启用远区、关闭远区并回填近区配额、关闭远区且不回填配额是不同干预。移除远区会改变逐Q softmax分母及组平均近区排序，因此回填不是保持近区选集不变的单纯省算。准备、量化、复制与浮点转换和S宽缓冲／softmax均计入成本。该实现不支持组合动态与静态层跳过，也不支持将动态门控用于Llama；批内状态隔离、运行时状态转换和分布变化触发的回退尚未验证。运行时自适应调整α, β, γ不属于本文评估的配置。

主文门控是共享子空间方法的候选扩展。现有门控任务汇总缺生成源码SHA、完整子空间配置与配对预测，不能用于验证该配置。上述实现细节限定机制适用范围，并非实测速度或质量收益。

补充注 S6：历史诊断的适用范围

以下保留主文限制所依据的详细数值。这些是作者归档诊断，不是新实验，也不是共享子空间方法的匹配验证。

动机性诊断。存档坐标比较采用共同的诊断选择器，随机坐标对照不保持完整旋转对。因此，该比较不能将频率效应与坐标配对结构分离，也不测量实际区域评分器的表现。整箱区域选择启发式可能超出其名义词元预算，不构成等预算的词元级最优参考。这些诊断用于提出受控评估问题，不能证明区域配额带来的质量收益。另一份预填充逐层统计所用的聚合方式也不同于本文门控的逐查询头概率平均，其层级模式并非主文门控示意图的实测结果。

选择器局部计时与汇总。归档性能记录对后续实现进行两轮GPU交换测量。其关联源码具有紧凑共享子空间L2实现，区别于补充注S7的早期LongBench实现；源码检查本身不能核实计时执行路径。每轮值分别为全维页评分变体的1.3635／1.337毫秒、共享子空间配置的1.3872／1.3324毫秒、全维词元评分变体的1.4794／1.4473毫秒。记录给出的两轮中位汇总分别为1.3502、1.3598、1.4634毫秒。每组两个报告值的中点中位数为1.35025、1.35980、1.46335毫秒；这些是算术复算，并非新增测量。原件未提供逐阶段中位数或原始序列，因此不能确认此前“五阶段中位数之和”的描述。合成单层、批量大小为1、单查询、64K的范围不同于完整层或请求，也未与质量实验配对。记录称60步、40次预热及20个稳态样本，但此前检查的测量程序对应100总步及60个稳态样本；矛盾仍未解决。所报共享子空间配置时间高于全维页评分变体，既未确立统计显著性，也未建立完整系统加速。

区域与门控诊断。历史仅保留保护词元的均值26.09，含中间检索47.91，但预算也从1024降到256，无法隔离区域策略贡献。门控标定包含16输入、每个36层；保存远区概率质量字段$<.05$的输入–层记录在预填充／解码分别30／22条，交集13。预填充选中记录的解码 远区注意力质量均值0.0582、最大0.1678，表明跨阶段变化，不能证明任务精度保持或请求收益。

后续作者汇总在$\epsilon = .05/.10$时五任务均值47.876／47.692，对复用47.910锚分别下降0.034／0.218分。每个配置的3项任务下降，HotpotQA下降1.05／1.26分。作者五任务bootstrap区间$[-.584, .452]/[-.806, .400]$仅为描述，跨零不证明等价。现有作业记录尚不能建立共享子空间配置的匹配比较（补充注S5）；三政策质量及完整成本仍未匹配验证。

共享子空间配置尚缺匹配的稠密FullKV质量参照、全维评分稀疏对照及包含准备成本的请求比较。历史全维页评分与尾部32坐标词元评分实验不能替代这些对照。作者报告的RULER汇总（主文文献[10]）标识了名义128K、YaRN因子4的Qwen3-8B及$\alpha = .125$、$\beta = .375$、$\gamma = .625$稀疏配置。对其11项任务得分重算非加权均值，FullKV为46.43，稀疏配置为23.98，差值为-22.45分，稀疏／FullKV得分比为51.6%。这是负面的汇总结果，不构成当前紧凑配置（$\alpha = .25$、$\beta = .125$、$\gamma = .625$）的已核验匹配验证：所检查的仓库快照缺少原始预测；配对输入身份、评分器执行及当前紧凑执行的对应关系均未独立核验。这些汇总不能分离YaRN或远端候选不足的因果效应。历史静态逐层策略未达到预设提升阈值，已有配额与门控诊断又同时改变了多种策略或尺度；这些负结果限制了结论范围，但未直接检验当前共享子空间配置与预填充远区门控。原始得分及来源详见实验记录。

补充注 S7：预算与配置身份

当前前缀／近期配置。当前选定候选采用4个前缀词元、128词元近期窗口、稠密预填充与稀疏解码，实现默认值仍为128/128。作者汇总评估配置（E149）显式选择4/128，但完整预测及执行身份记录尚不可用。历史充足且保护不重叠时，保护词元为132，中间名义配额为$1024 - 132 = 892$，近区仍为640、远区为252。4个前缀仅占64词元页的一部分，区域选择可能再次选中至多4个前缀保护位置，因此远区配额不保证252个不同的非保护词元。StreamingLLM为少量sink保护提供动机，但其LongBench对照也表明保留较大语义前缀可能有益；它并未证明4词元对Qwen3最优，也未验证128词元近期窗口。固定K时，相比128/128，该变化释放124个检索槽位，不能隔离减少sink词元本身的影响。归档五任务表示得分及历史计时、保护诊断保留各自设置，不改标为4/128结果。

保留候选不足。图2b的容量充足示例假定各区域有足够正概率候选，保护区域不重叠；前缀不足整页导致的重复选取另行计入。实现中，L1掩码位置在softmax后概率为零。区域TopK按区域宽度裁剪请求数量，而不是按正概率候选数裁剪。当候选不足时，零概率的掩码位置可能通过并列入选。因此页候选资格是设计上的支持集，并非对所有短输入或退化情况都成立的无填充保证。候选不足时，需要显式检查实际选中数与零值并列行为。

公平比较。稀疏对手的预算以最终去重注意力选集K对齐，保护词元包含其中。L1候选页属于内部设计，不要求与对手相同；其构造、评分、排序和访存均计入成本。模型、输入ID、生成上限、预填充/解码处理、稠密层策略及任务评分程序应匹配。原生实现与受控适配器结果分别报告。名义K之外，还需报告页取整后的实际词元数与选集共享粒度。

共享子空间配置 LongBench设置。五份实验元数据明确页长64、L1上限128页、最终上限1024词元、压缩比4、尾部低频坐标、$\alpha = .25$、$\beta = .125$、$\gamma = .625$、近区平均／远区 极值页评分及16级量化–反量化数值，并明确共享KV头选集、稠密预填充、静态跳层关闭。五份运行记录均绑定实现提交标识`35b39bd8e43cf478bb4f0ab64a8457f08d87c864`。对这些非投影运行，该源码为L1抽取32个坐标，但将量化–反量化值散写到填零的128维L2键中，并用全维查询评分。因此，页评分和词元评分各32个坐标指有效坐标数，并非两级的物理收缩宽度。后续非投影共享子空间配置路径为L2抽取32维Q/K；归档质量得分不能直接验证该实现。这些源码路径不构成运行核验或有限精度排序等价的证据。该源码还给出前缀保护$2 \times 64 = 128$、近期保护128，以及Qwen3各层稀疏解码。这些源码推断字段不能核实未记录的修改工作树或执行轨迹。历史长度充足时的标准配置分配近区/远区各16/112页、中间各640/128词元，并加入256保护词元。8192个候选槽位不等于最终使用8192个注意力词元，也不约束L2评分量：普通L2仍完整历史评分后施加掩码。逐步实际计数未记录。

保存的输入上限为31500；各任务样本数／最大生成词元数为：Qasper 200/128、HotpotQA 200/32、MuSiQue 200/32、GovReport 200/512、RepoBench-P 500/64。上限不等于实际输入长度。这些保存的运行配置不能建立完整模型／分词器版本、运行精度、硬件身份与评分器版本，匹配比较须另行绑定。非劣检验仍需文档簇身份、匹配稠密运行以及事前规定的任务质量容差。

名义全维页评分变体。五份历史预测无实验元数据或执行记录。文件名与结果判定记录可定位页长64、L1上限128、最终上限1024、压缩比4及相同名义α, β, γ。有效输入上限、完整实现版本、保护、阶段和完整评分设置未核实，不能用当前默认值补齐。

名义全维词元评分变体。五份实验元数据含上述预算设置及full L2标记。四份执行记录缺实现提交标识；MuSiQue记录为`60027fba3672f33744917c4f59960d0f131f8ab0`，但该代码树没有实现记录中的L2模式字段。因此，该提交不能确定实际执行的代码。保留名义标签和得分，不能确认实际执行了全维L2评分。

Quest对照方法。官方评测采用多词元稠密预填充、逐词元稀疏处理、前两层采用稠密注意力及逐Q头选页。其1024词元预算与16词元页长，在内部不同于本文128个64词元页。受控比较对齐最终去重K与阶段／层策略，页配额和头共享差异单列。论文原生配置与受控适配器不得混合为一个结果。本文不声称已完成匹配Quest或FullKV的质量–请求成本比较。

其他实验组。64K合成选择器计时为单层、批量大小为1、单查询汇总，采样协议仍存在矛盾（S6），未与LongBench请求绑定。门控汇总记录阈值但未明确完整实现与子空间配置。仅保留保护词元的配置使用256词元，对照使用1024。缺少的身份、未知门控与配额回填设置及未测完整成本均保持未知，不以当前默认值推断。