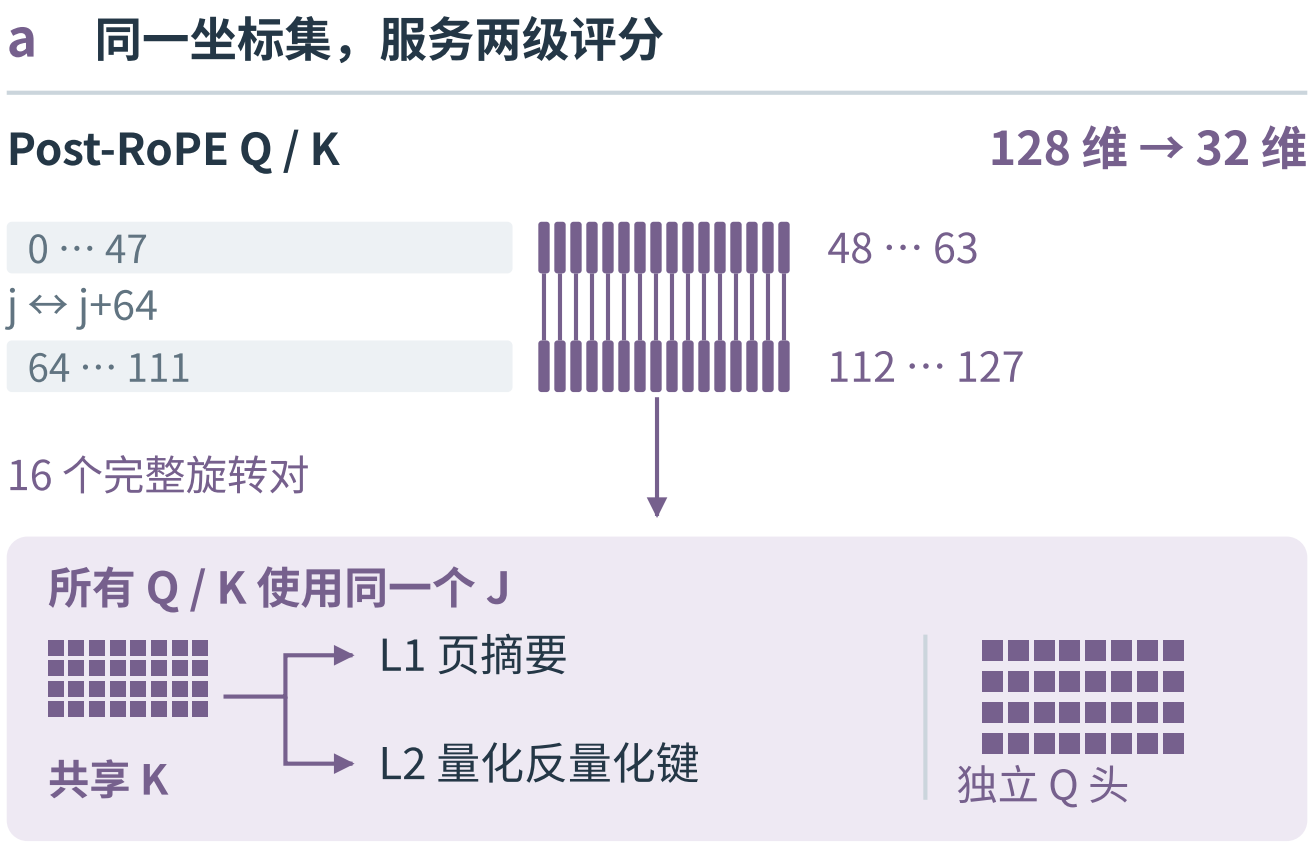
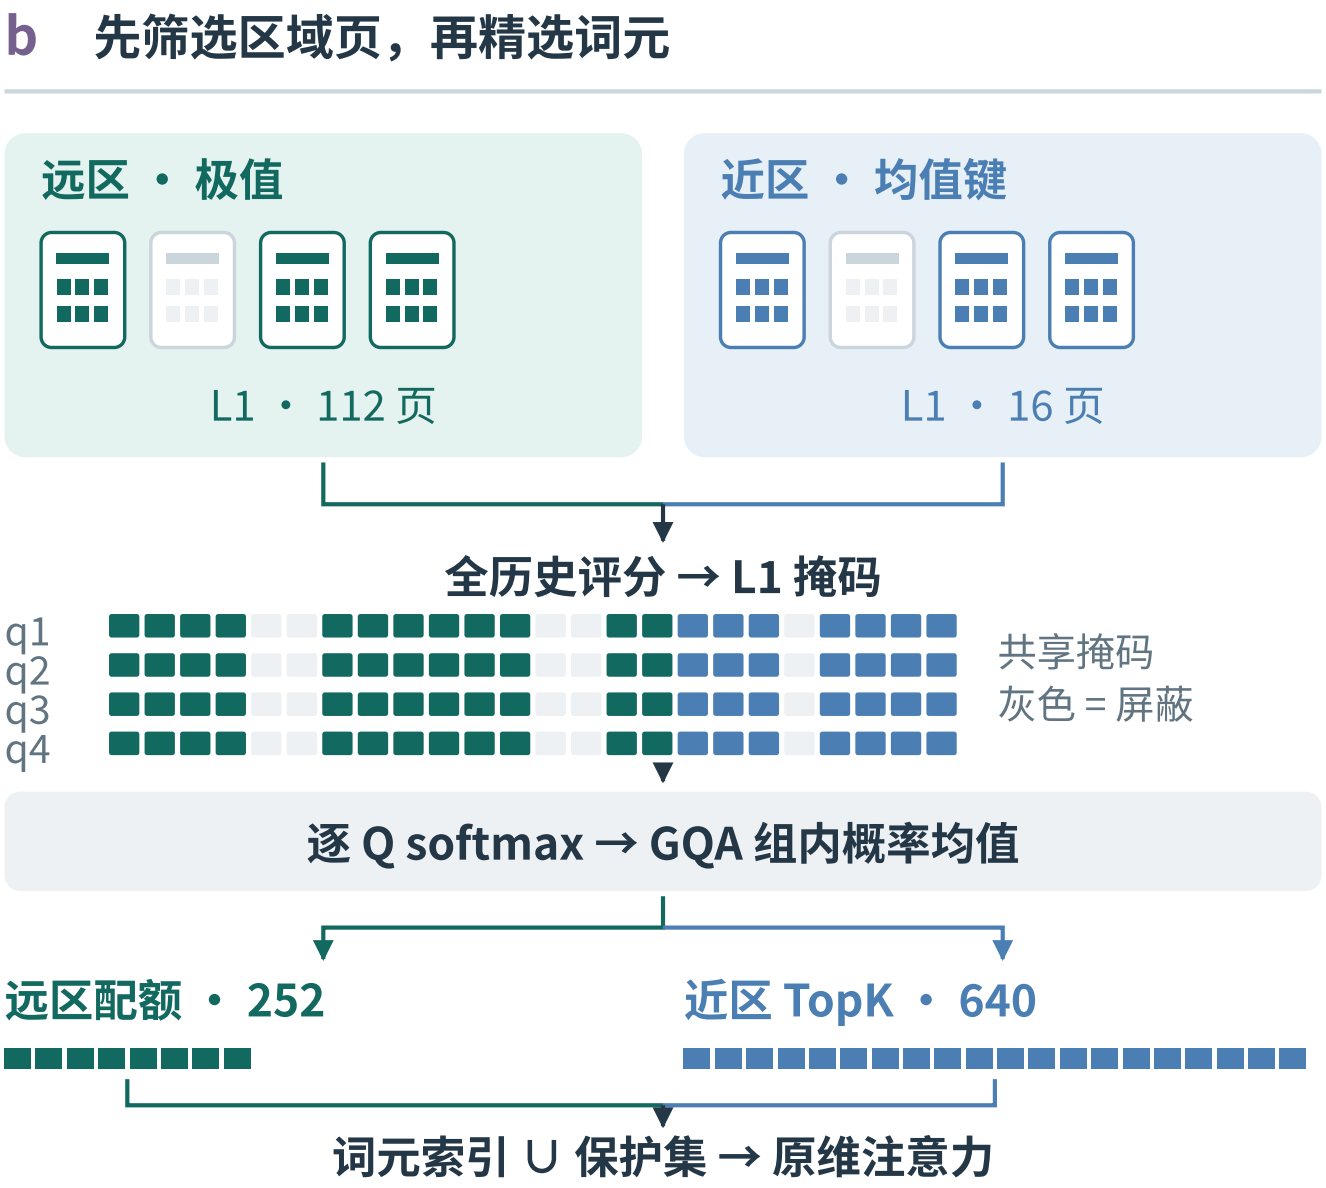
机制补充图 S1: 低频子空间选取

本补充给出子空间选取、区域配额与门控状态转换的详细流程，适用条件与主文一致。



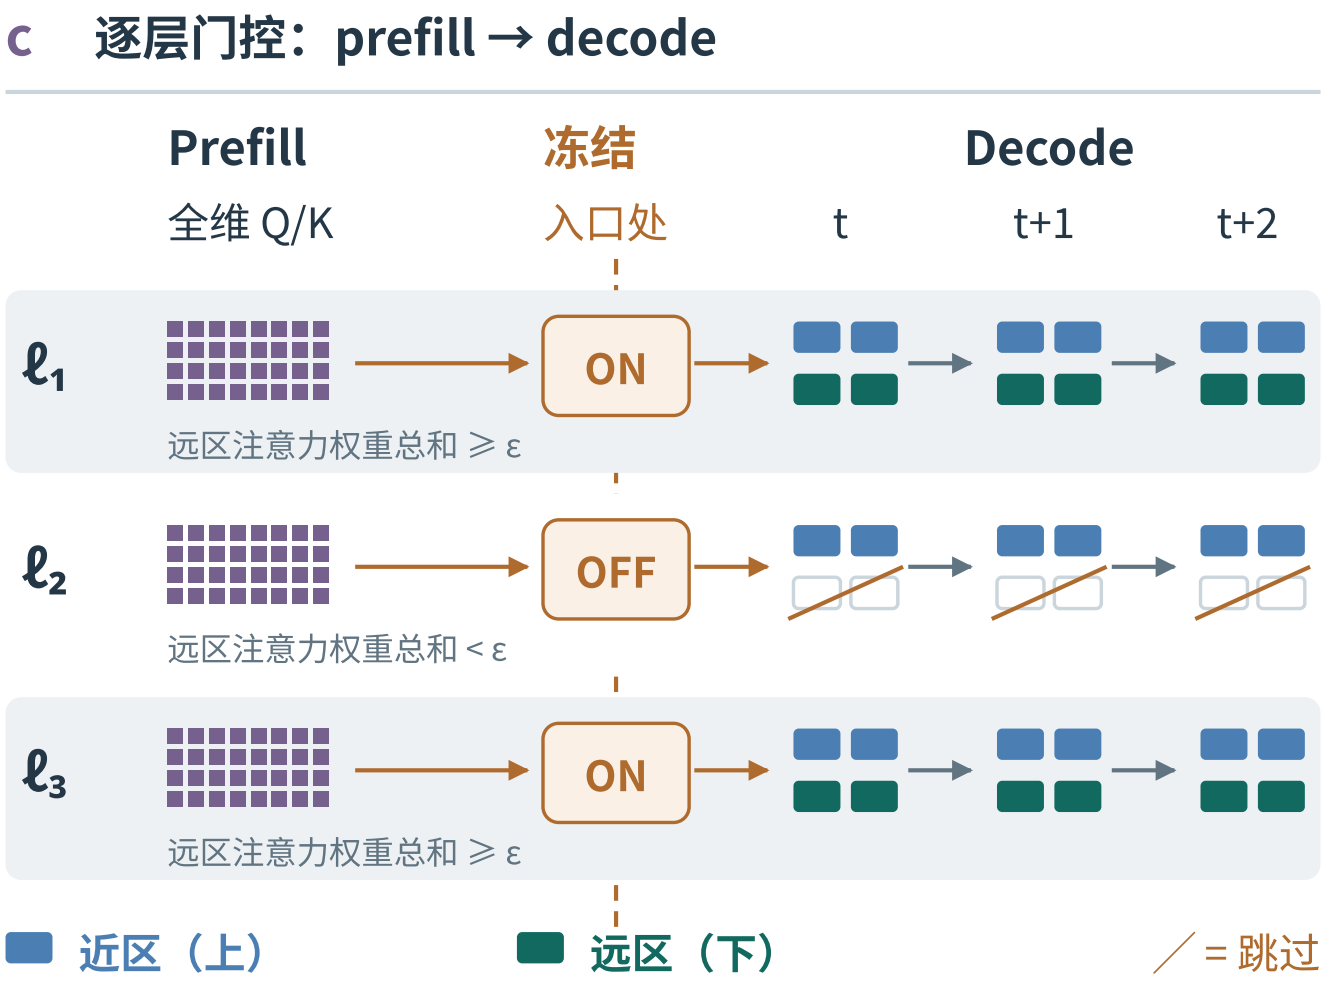
当前紧凑实现的低频子空间选取。16个完整旋转对同时供近远区域和L1/L2使用。实际量化反量化表示为浮点，不是packed INT4；所选词元索引读取原始128维KV。

机制补充图 S2: 区域页配额与词元配额



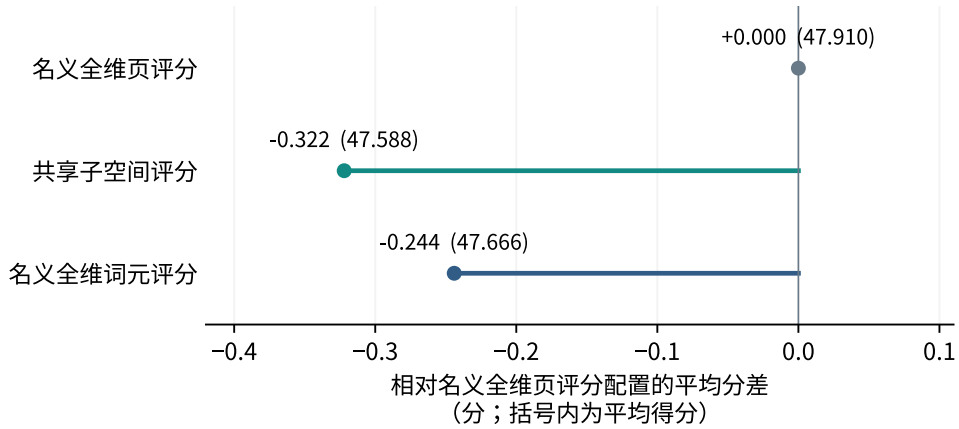
区域筛选与保护预算。候选充足时，128页配额分成近区16／远区112页；当前4/128配置的总1024上限包含132保护与名义640／252近远槽位。前缀不足整页，可能重复选中至多4个保护位置，减少非保护远区覆盖。图块数量仅示意。逐查询头归一化后才在KV组内平均。

机制补充图 S3: 从预填充观测到解码复用的门控状态转换



逐层门控状态转换及条件执行。预填充暂存决定，首次解码路径调用冻结。在有效长度、远区非空的固定数值配额实现上，OFF跳过远区 L1/L2点积与选取，只把L2余量回填近区，L1 近区仍16页。全域准备、S宽缓冲及softmax成本保留。图中的层级状态与重复解码步骤仅作示意，并非实测层级结果。门控默认不启用，共享子空间配置的匹配质量／成本尚未验证。

补充图 S4：描述性配置比较



五任务均值为47.910（名义全维页评分变体）、47.588（共享子空间配置）与47.666（名义全维词元评分变体）。相对共享子空间配置的0.322、0.078分差值仅作描述。名义全维页评分变体缺实验元数据，名义全维词元评分变体的L2模式标记未能对应到实现该模式的代码版本，因此这些标签不能建立受控阶段干预或已完成的三个配置消融。补充注S7列出配置证据。这些均不是稠密FullKV，也不建立文档配对非劣性或匹配质量–成本结论。

补充注 S5：Gate观测与执行范围

功能未启用时仍执行普通远区选择；图中OFF仅指启用功能后标定得到的逐层跳过决定。可选远区门控在每层预填充观测后暂存门控决策，在首次解码路径调用时冻结，后续复用直到新输入清空（补充图S3）。该调用可能仍在消费问题词元，不能据此假定已经看完整问题。标定使用末尾至多256行可用Q、原维评分及逐Q头softmax，对平均远区注意力权重总和做严格阈值比较；该阈值只用于预填充观测的判定，并不约束后续解码的远区注意力权重总和或任务误差。

在支持的固定数值配额实现（批量大小为1、有效长度已知且远区非空）中，OFF跳过远区 L1/L2点积与选取，仅将剩余L2配额回填合法近区词元，不扩大近区的L1页预算。启用远区、关闭远区并回填近区配额、关闭远区且不回填配额是不同干预。移除远区会改变逐Q softmax分母及组平均近区排序，因此回填不是保持近区选集不变的单纯省算。准备、量化、复制与浮点转换和S宽缓冲／softmax均计入成本。该实现不支持组合动态与静态层跳过，也不支持将动态门控用于Llama；批内状态隔离、运行时状态转换和分布变化触发的回退尚未验证。运行时自适应调整α, β, γ不属于本文评估的配置。

主文门控是共享子空间方法的候选扩展。现有门控任务汇总缺生成源码SHA、完整子空间配置与配对预测，不能用于验证该配置。上述实现细节限定机制适用范围，并非实测速度或质量收益。

补充注 S6：历史诊断的适用范围

以下保留主文限制所依据的详细数值。这些是作者归档诊断，不是新实验，也不是共享子空间方法的匹配验证。

动机性诊断。主图1采用远端四面板设计。(a)保留E140b中固定MuSiQue1/L24/q14212的页数组与保存选集：质量排序和均值评分各用1989词元，极值评分用2048词元；其中混合表示和池化差异，不能作为预算匹配的最优性证据。位置7936页的一个词元承载该页保存质量的99.84%，只说明此查询，不代表总体机制。(b)按绝对区间$[q-d_{hi}, q-d_{lo}+1)$和真实区域边界重算归属；整箱有效词元数放得下才接纳，并列按绝对位置排序。全局上限2048；另一策略分别以1024/1024限制远／近区，不回填。128条全局计数与分区总数均不超过2048。远区平均保留率为.67591615与.72070552，43条配对差值为负；全局近区保留率为.93149427。这些是四条源序列的相关查询／层观测，不是独立文档。(c)保留八个cell的坐标比值和未配对随机选择，不能隔离频率或代表生产评分。(d)只使用历史far-profile的16×36矩阵：24层中位值低于.01，每序列12–32个低代理值层。其生产者使用最后一个采样查询、先在GQA组内求和logits再softmax，far定义为$[64, t-2048)$。该历史代理不是S5的当前门控统计；低值层数不等于可安全跳过层数。不使用另一份10条profile的skip摘要。包内保留最小数值输入、逐查询选集及来源哈希，不声称新增模型运行或恢复原始张量。

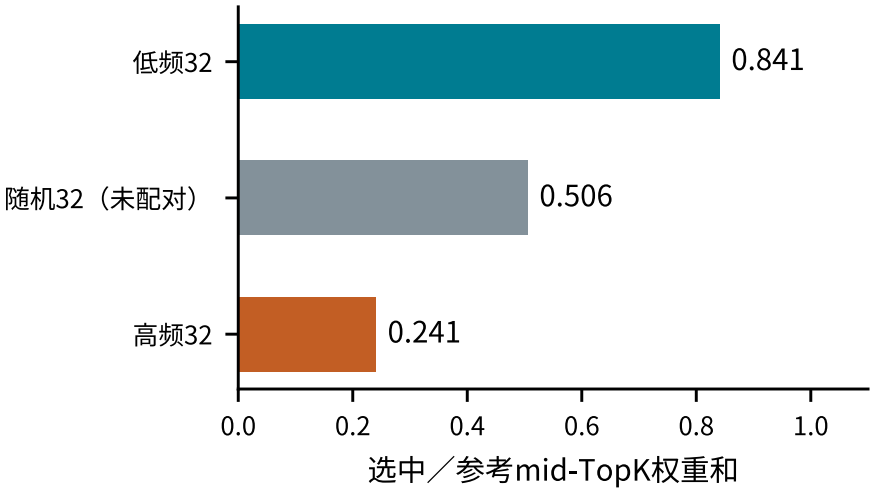


Figure 1: 归档坐标辅助诊断：选中注意力权重总和除以全维参考mid-TopK权重总和，中间上限768，128/128保护另计。诊断采用页均值选择器，不同于生产近区均值／远区极值评分。Random32未配对；未进行配对随机质量或输出误差检验。

计时来源。图3采用历史稀疏配置$(\alpha, \beta, \gamma) = (.125, .375, .625)$、名义$K_1 = 128$与$K = 1024$，保护配置未显式绑定。来源报告Qwen3-8B bf16、NVIDIA H20、Transformers 4.56.2及Torch 2.8.0。最小派生绘图输入保留这些字段及原仓库文件SHA-256，省略宿主地址和私有路径；其哈希与原文件不同。E152v2提供作者报告中位数，而非逐次重复原件。作者审计列出每长度每动态臂三条记录、每记录三次测量；所写交错次序不足以将各臂统一标为ABBA×3。当前采集器将后端路径标为未验证。82.0毫秒StaticCache点属于不同修复与重复身份，故不纳入；StaticCache构建发生在请求计时之前。E127的5.47倍比较旧TLI与优化TLI阶段时间汇总，并非稠密FullKV。它与E152汇总均不能建立launch-bound因果归因。数据、采集器和绘图脚本哈希见`sources/evidence_bindings.json`。

选择器局部计时与汇总。归档性能记录对后续实现进行两轮GPU交换测量。其关联源码具有紧凑共享子空间L2实现，区别于补充注S7的早期LongBench实现；源码检查本身不能核实计时执行路径。每轮值分别为全维页评分变体的1.3635／1.337毫秒、共享子空间配置的1.3872／1.3324毫秒、全维词元评分变体的1.4794／1.4473毫秒。记录给出的两轮中位汇总分别为1.3502、1.3598、1.4634毫秒。每组两个报告值的中点中位数为1.35025、1.35980、1.46335毫秒；这些是算术复算，并非新增测量。原件未提供逐阶段中位数或原始序列，因此不能确认此前“五阶段中位数之和”的描述。合成单层、批量大小为1、单查询、64K的范围不同于完整层或请求，也未与质量实验配对。记录称60步、40次预热及20个稳态样本，但此前检查的测量程序对应100总步及60个稳态样本；矛盾仍未解决。所报共享子空间配置时间高于全维页评分变体，既未确立统计显著性，也未建立完整系统加速。

区域与门控诊断。历史仅保留保护词元的均值26.09，含中间检索47.91，但预算也从1024降到256，无法隔离区域策略贡献。门控标定包含16输入、每个36层；保存远区注意力权重总和字段$< .05$的输入–层记录在预填充／解码分别30／22条，交集13。预填充选中记录的解码 远区注意力权重总和均值0.0582、最大0.1678，表明跨阶段变化，不能证明任务精度保持或请求收益。

后续作者汇总在$\epsilon = .05/.10$时五任务均值47.876／47.692，对复用47.910锚分别下降0.034／0.218分。每个配置的3项任务下降，HotpotQA下降1.05／1.26分。作者五任务bootstrap区间$[-.584, .452]/[-.806, .400]$仅为描述，跨零不证明等价。现有作业记录尚不能建立共享子空间配置的匹配比较（补充注S5）；三政策质量及完整成本仍未匹配验

证。

共享子空间配置尚缺匹配的稠密FullKV质量参照、全维评分稀疏对照及包含准备成本的请求比较。历史全维页评分与尾部32坐标词元评分实验不能替代这些对照。作者报告的RULER汇总（主文文献[10]）标识了名义128K、YaRN因子4的Qwen3-8B及$\alpha = .125$、$\beta = .375$、$\gamma = .625$稀疏配置。对其11项任务得分重算非加权均值，FullKV为46.43，稀疏配置为23.98，差值为−22.45分，稀疏／FullKV得分比为51.6%。这是负面的汇总结果，不构成当前紧凑配置（$\alpha = .25$、$\beta = .125$、$\gamma = .625$）的已核验匹配验证：所检查的仓库快照缺少原始预测；配对输入身份、评分器执行及当前紧凑执行的对应关系均未独立核验。对未覆盖配额的常规固定配额路径，已检查公式给出$K_{2,\text{mid}} = 1024 - 128 - 128 = 768$，而$\text{round}(128 \cdot .375) \cdot 64 \cdot .625 = 1920$，故名义远区词元配额为$\max(0, 768 - \min(1920, 768)) = 0$。这是已检查代码与报告配置的联合推论，实际执行路径未独立验证，也不能据此认定得分差的唯一原因。后续64K文件仅含汇总得分与manifest，并非原始预测；其回执摘要缺少α、β及sink保护等字段，不能闭合完整运行配置身份。本比较不加入64K得分。这些汇总不能分离YaRN或远端候选不足的因果效应。历史静态逐层策略未达到预设提升阈值，已有配额与门控诊断又同时改变了多种策略或尺度；这些负结果限制了结论范围，但未直接检验当前共享子空间配置与预填充远区门控。原始得分及来源详见实验记录。

补充注 S7：预算与配置身份

当前前缀／近期配置。当前选定候选采用4个前缀词元、128词元近期窗口、稠密预填充与稀疏解码，实现默认值仍为128/128。作者汇总评估配置（E149）显式选择4/128，但完整预测及执行身份记录尚不可用。历史充足且保护不重叠时，保护词元为132，中间名义配额为$1024 - 132 = 892$，近区仍为640、远区为252。4个前缀仅占64词元页的一部分，区域选择可能再次选中至多4个前缀保护位置，因此远区配额不保证252个不同的非保护词元。StreamingLLM为少量sink保护提供动机，但其LongBench对照也表明保留较大语义前缀可能有益；它并未证明4词元对Qwen3最优，也未验证128词元近期窗口。固定K时，相比128/128，该变化释放124个检索槽位，不能隔离减少sink词元本身的影响。归档五任务表示得分及历史计时、保护诊断保留各自设置，不改标为4/128结果。

保留候选不足。图2b的容量充足示例假定各区域有足够正概率候选，保护区域不重叠；前缀不足整页导致的重复选取另行计入。实现中，L1掩码位置在softmax后概率为零。区域TopK按区域宽度裁剪请求数量，而不是按正概率候选数裁剪。当候选不足时，零概率的掩码位置可能通过并列入选。因此页候选资格是设计上的支持集，并非对所有短输入或退化情况都成立的无填充保证。候选不足时，需要显式检查实际选中数与零值并列行为。

公平比较。稀疏对手的预算以最终去重注意力选集K对齐，保护词元包含其中。L1候选页属于内部设计，不要求与对手相同；其构造、评分、排序和访存均计入成本。模型、输入ID、生成上限、预填充/解码处理、稠密层策略及任务评分程序应匹配。原生实现与受控适配器结果分别报告。名义K之外，还需报告页取整后的实际词元数与选集共享粒度。

共享子空间配置 LongBench设置。五份实验元数据明确页长64、L1上限128页、最终上限1024词元、压缩比4、尾部低频坐标、$\alpha = .25$、$\beta = .125$、$\gamma = .625$、近区平均／远区 极值页评分及16级量化–反量化数值，并明确共享KV头选集、稠密预填充、静态跳层关闭。五份运行记录均绑定实现提交标识`35b39bd8e43cf478bb4f0ab64a8457f08d87c864`。对这些非投影运行，该源码为L1抽取32个坐标，但将量化–反量化值散写到填零的128维L2键中，并用全维查询评分。因此，页评分和词元评分各32个坐标指有效坐标数，并非两级的物理收缩宽度。后续非投影共享子空间配置路径为L2抽取32维Q/K；归档质量得分不能直接验证该实现。这些源码路径不构成运行核验或有限精度排序等价的证据。该源码还给出前缀保护$2 \times 64 = 128$、近期保护128，以及Qwen3各层稀疏解码。这些源码推断字段不能核实未记录的修改工作树或执行轨迹。历史长度充足时的标准配置分配近区/远区各16/112页、中间各640/128词元，并加入256保护词元。8192个候选槽位不等于最终使用8192个注意力词元，也不约束L2评分量：普通L2仍完整历史评分后施加掩码。逐步实际计数未记录。

保存的输入上限为31500；各任务样本数／最大生成词元数为：Qasper 200/128、HotpotQA 200/32、MuSiQue 200/32、GovReport 200/512、RepoBench-P 500/64。上限不等于实际输入长度。这些保存的运行配置不能建立完整模型／分词器版本、运行精度、硬件身份与评分器版本，匹配比较须另行绑定。非劣检验仍需文档簇身份、匹配稠密运行以及事前规定的任务质量容差。

名义全维页评分变体。五份历史预测无实验元数据或执行记录。文件名与结果判定记录可定位页长64、L1上限128、最终上限1024、压缩比4及相同名义α, β, γ。有效输入上限、完整实现版本、保护、阶段和完整评分设置未核实，不能用当前默认值补齐。

名义全维词元评分变体。五份实验元数据含上述预算设置及full L2标记。四份执行记录缺实现提交标识；MuSiQue记录为`60027fba3672f33744917c4f59960d0f131f8ab0`，但该代码树没有实现记录中的L2模式字段。因此，该提交不能确定实际执行的代码。保留名义标签和得分，不能确认实际执行了全维L2评分。

Quest对照方法。官方评测采用多词元稠密预填充、逐词元稀疏处理、前两层采用稠密注意力及逐Q头选页。其1024词元预算与16词元页长，在内部不同于本文128个64词元页。受控比较对齐最终去重K与阶段／层策略，页配额和头共享差异单列。论文原生配置与受控适配器不得混合为一个结果。本文不声称已完成匹配Quest或FullKV的质量–请求成本比较。

其他实验组。64K合成选择器计时为单层、批量大小为1、单查询汇总，采样协议仍存在矛盾（S6），未与

LongBench请求绑定。门控汇总记录阈值但未明确完整实现与子空间配置。仅保留保护词元的配置使用256词元，对照使用1024。缺少的身份、未知门控与配额回填设置及未测完整成本均保持未知，不以当前默认值推断。

机制归因所需对照（本文尚未完成）。固定词元索引回放在相同解码步数、坐标映射、摘要与量化规则、选中词元索引和最终注意力下比较复用与重建，并计入初始准备与逐步维护，以隔离复用成本。若要隔离L1区域分配的作用，区域／全局对照则固定页长、L1总上限K_1、表示、保护、L2精筛及其词元配额、最终上限K，仅改变L1区域分配。两个配置对全部历史使用同一页评分函数，候选不足反映在实际词元数中。这些机制消融固定项不要求不同稀疏方法采用相同K_1。门控仍比较启用远区、关闭远区并回填近区配额、关闭远区且不回填配额，因为移除远区也可能改变近区排序。

上述内容是后续匹配检验的要求，不是主文已报告的实验。

表示维护与成本记账。追加键、移动区域边界及改变坐标映射时，派生视图、逻辑词元索引与区域归属须保持一致；共享映射恒等式并未规定增量维护算法。量化–反量化键使用16级浮点数值，不是打包INT4算术。完整请求计时包含表示准备、维护、标定、选择、KV聚集、注意力与同步，重叠工作计一次。TTFT截止首个返回词元，TPOT为后续返回间隔均值。这些定义是匹配评估要求，不表示历史研究已测得完整请求成本。