子空间下的近远两级注意力

共享低维索引，保留原维注意力

32

维 / 16 完整旋转对

近区 / 远区

共享表示，两级选择

128

维原始 Q / K / V

方法设置

共享低频坐标与区域页配额

固定词元预算下：候选访问与选择成本

问题

均值与极值刻画不同评分目标，页注意力和另作参照。
全局 TopK 不提供区域容量保证。

方法

共享 32 个低频 RoPE 坐标； nl 定义近区范围、 nb 预留近区页；合并候选统一 L2 竞争，最终原维注意力。

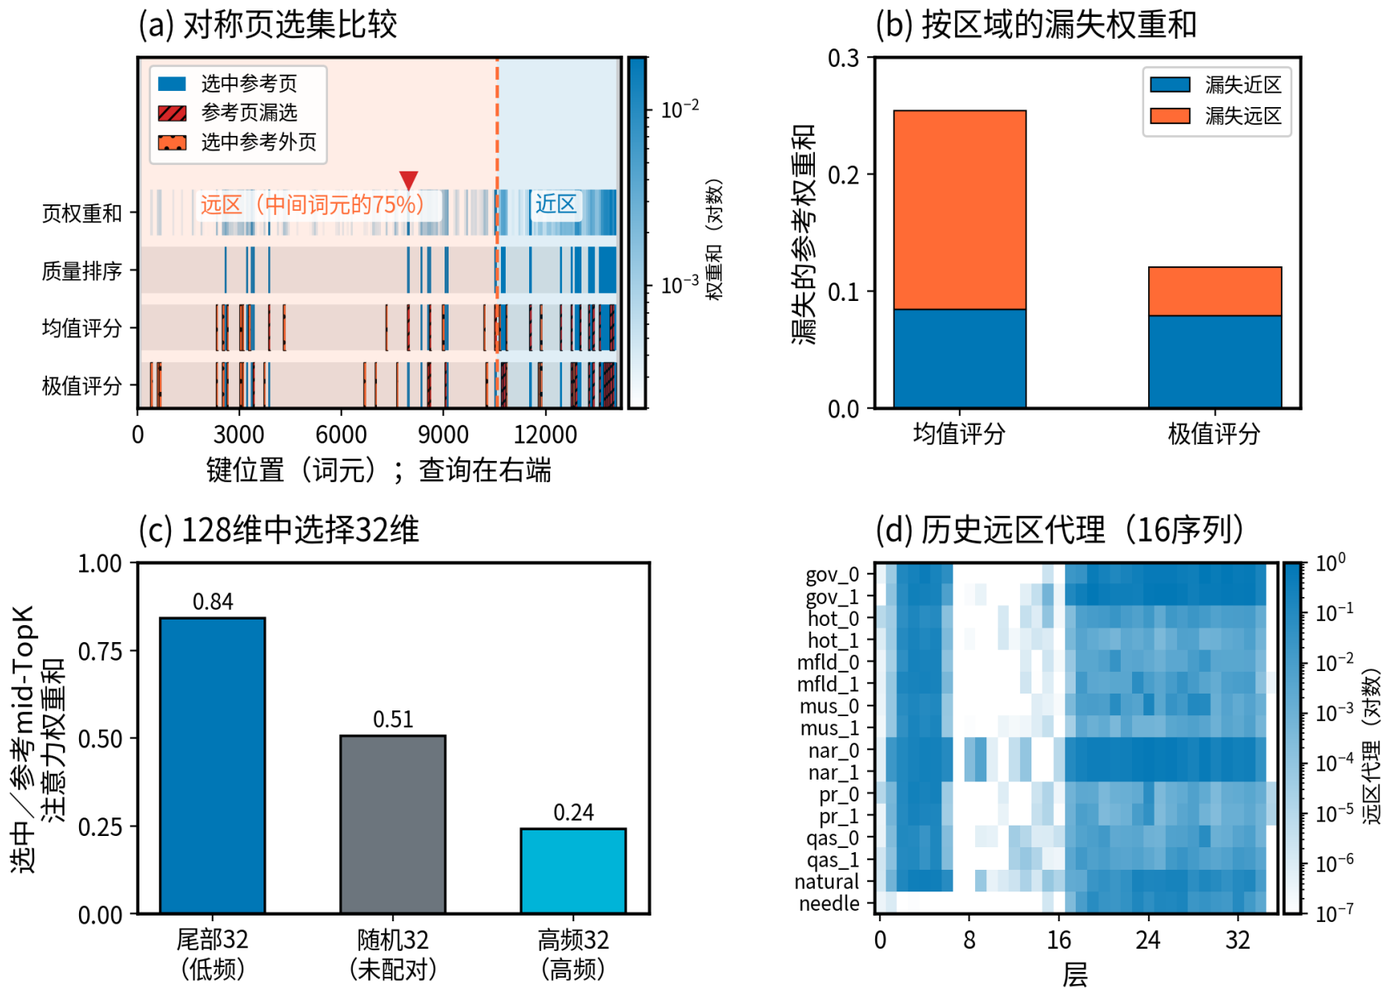
观察与边界

极值在两区的漏失均较低；混合配额诊断未胜全局极值（ .135 / .121 ）。历史稀疏解码更慢，当前设计尚缺匹配质量—成本结果。

可选远区门控

远区门控在预填充阶段逐层标定，在解码入口固定后复用，默认关闭。低预填充概率不保证后续任务质量。

四项观察：区域选集、紧凑坐标与历史层差异



(a) 均值／极值同 32 维，参考为全维；实际词元数不同； (b) 各区漏失 ÷ 每查询参考集总质量，再取均值；极值两区均较低； 23 种拆分最佳 .135 ，仍差于全局极值 .121 ； (c) 随机未配对； (d) 历史代理，非解码保证。

检索机制与本方法的设计位置

FullKV	**稠密注意力**	同输入、精度与生成协议的质量 / 成本参照
AsyncTLS	**级联、坐标选择与量化评分**	逐查询概率聚合；原维 KV 最终注意力
Quest	**页级选择**	用页内坐标极值估计候选页相关性
ClusterKV	**聚类选择**	通过聚类组织 KV ，建簇与维护构成额外成本

两项核心机制，一个可选扩展

01 共享低频 RoPE 坐标

共享坐标映射，不要求共享物理缓冲区

同层同 KV 头的 16 完整旋转对
近区 / 远区、 L1 / L2 共用坐标

02 显式近区范围与页预算

页准入不保证最终区域份额

nl 指定近区范围； nb 预留近区页
合并候选统一 L2 ； 最终原维 Q / K / V

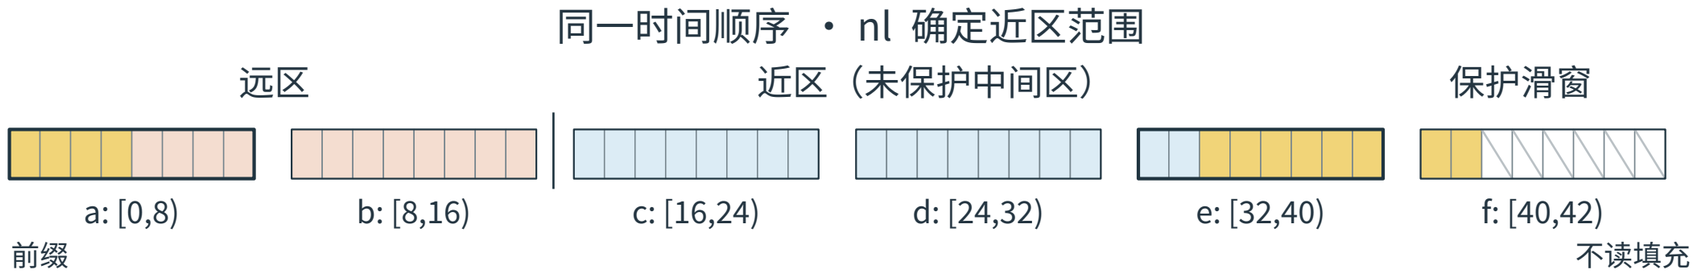
03 可选远区门控

默认关闭；低预填充概率不约束解码误差

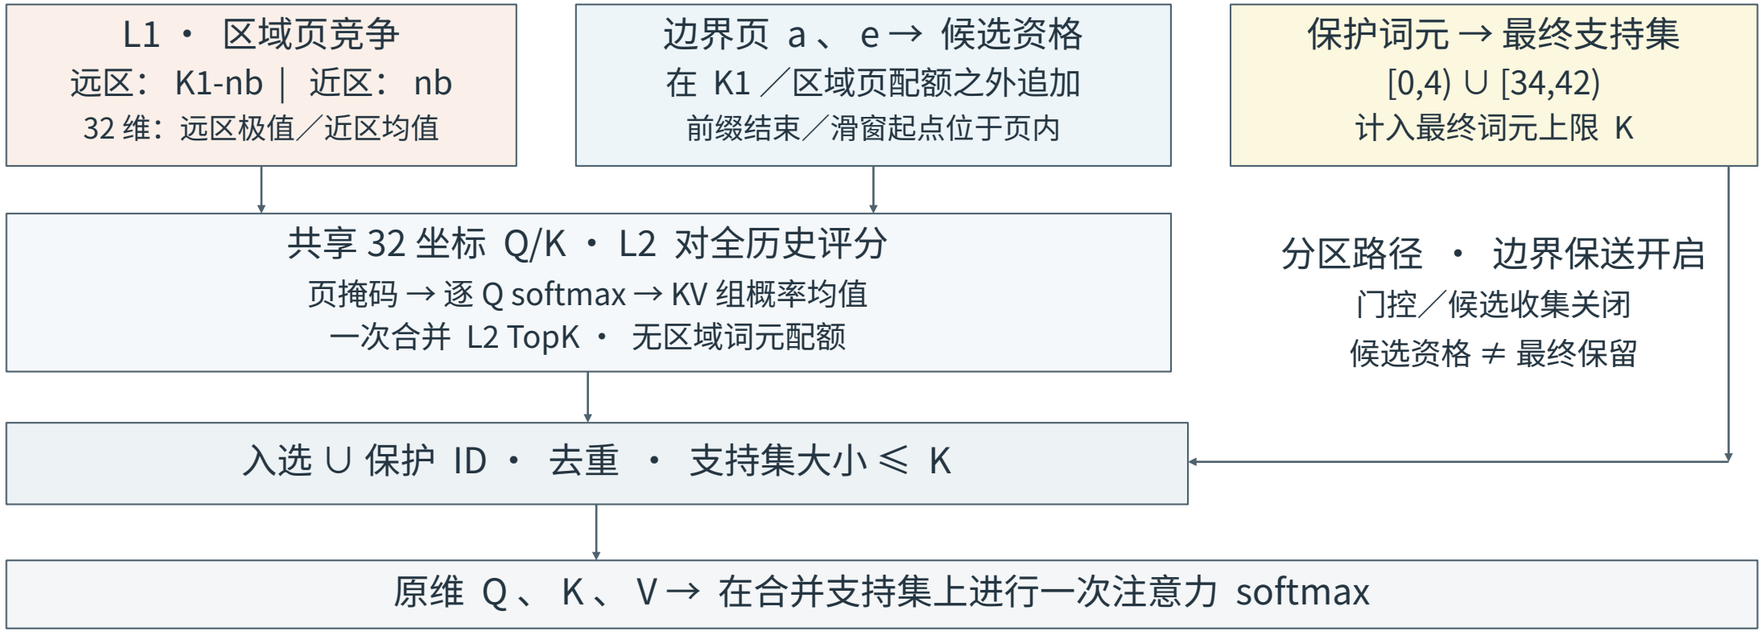
历史固定配额门控另行研究
当前统一 L2 设计关闭门控

总架构：共享索引与原维注意力

分区参考路径：边界保送开启，门控／候选收集关闭；示例数字不是默认配置；归档评测不验证新路径



仅示例：页宽 8 ，长度 42 ，前缀 4 ，滑窗 8 ；近远分界 16



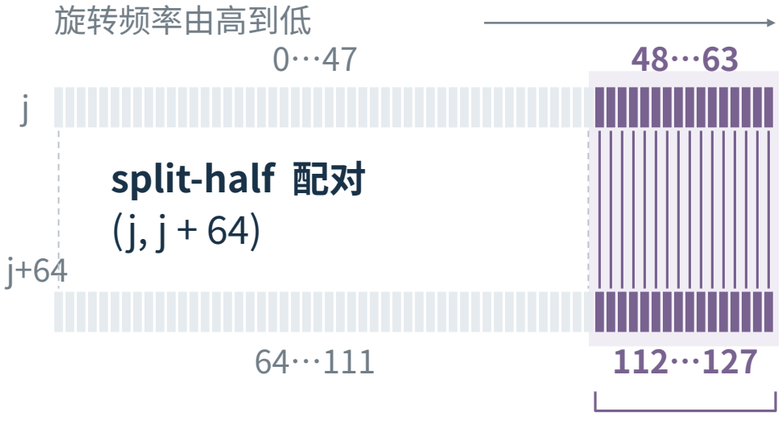
低频子空间： 16 个完整旋转对，共 32 维

16 完整旋转对，两级共用；图示 QDQ 为历史量化变体，主文 bf16 配置不以该量化为必要条件；最终为原维注意力

a 完整低频 RoPE 对

RoPE 后 • D = 128

32 个 Q 头 / 8 个 KV 头；每组 4Q + 1K



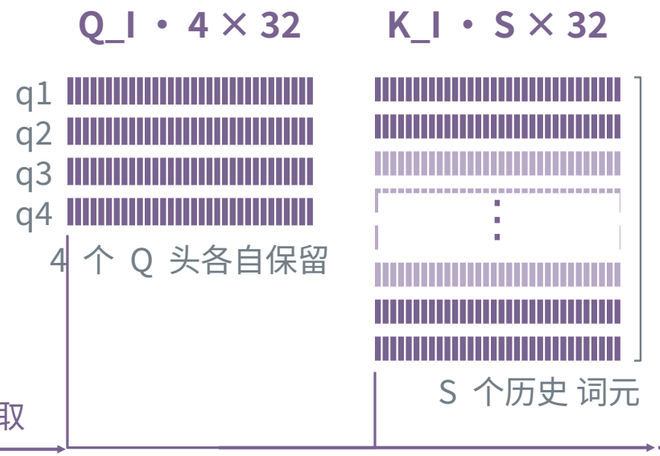
I = [48…63] ∪ [112…127]

32 坐标 = 16 个完整低频 RoPE 对

b 固定坐标选择视图

同一索引 I 作用于每个 Q / K

以下示意一个 KV 组

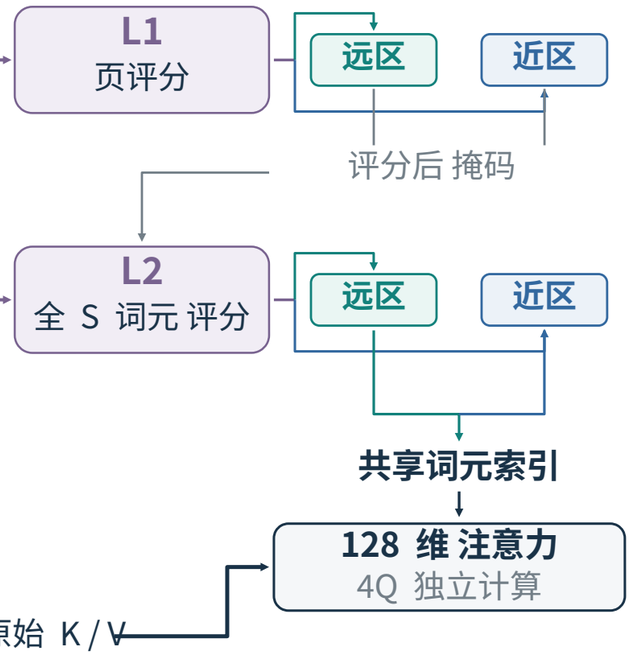


无学习投影；维度索引固定

Q 头独立 • K 视图组内共享

c 两级复用与原维计算

表示共享先于 近区 / 远区 分区





原始 Q / K / V • 128 维

绕过选择视图，按共享词元索引读取原始 K / V

nl / nb： 区域页准入，统一词元竞争

保护不重叠的长历史； 4/128 保护， K=1024 ； 无近远词元配额

1 近区范围 nl

同一时间序列按页对齐切分近远；nl 为请求的近区词元长度，至少一页。

2 页预算 nb

近区 nb 页，远区 K1 − nb 页；非对齐保护边界页另行加入。

3 统一 L2

两区与边界页的候选合并；逐查询 softmax → KV 组概率平均 → 一次 TopK 。

候选资格 ≠ 最终保护

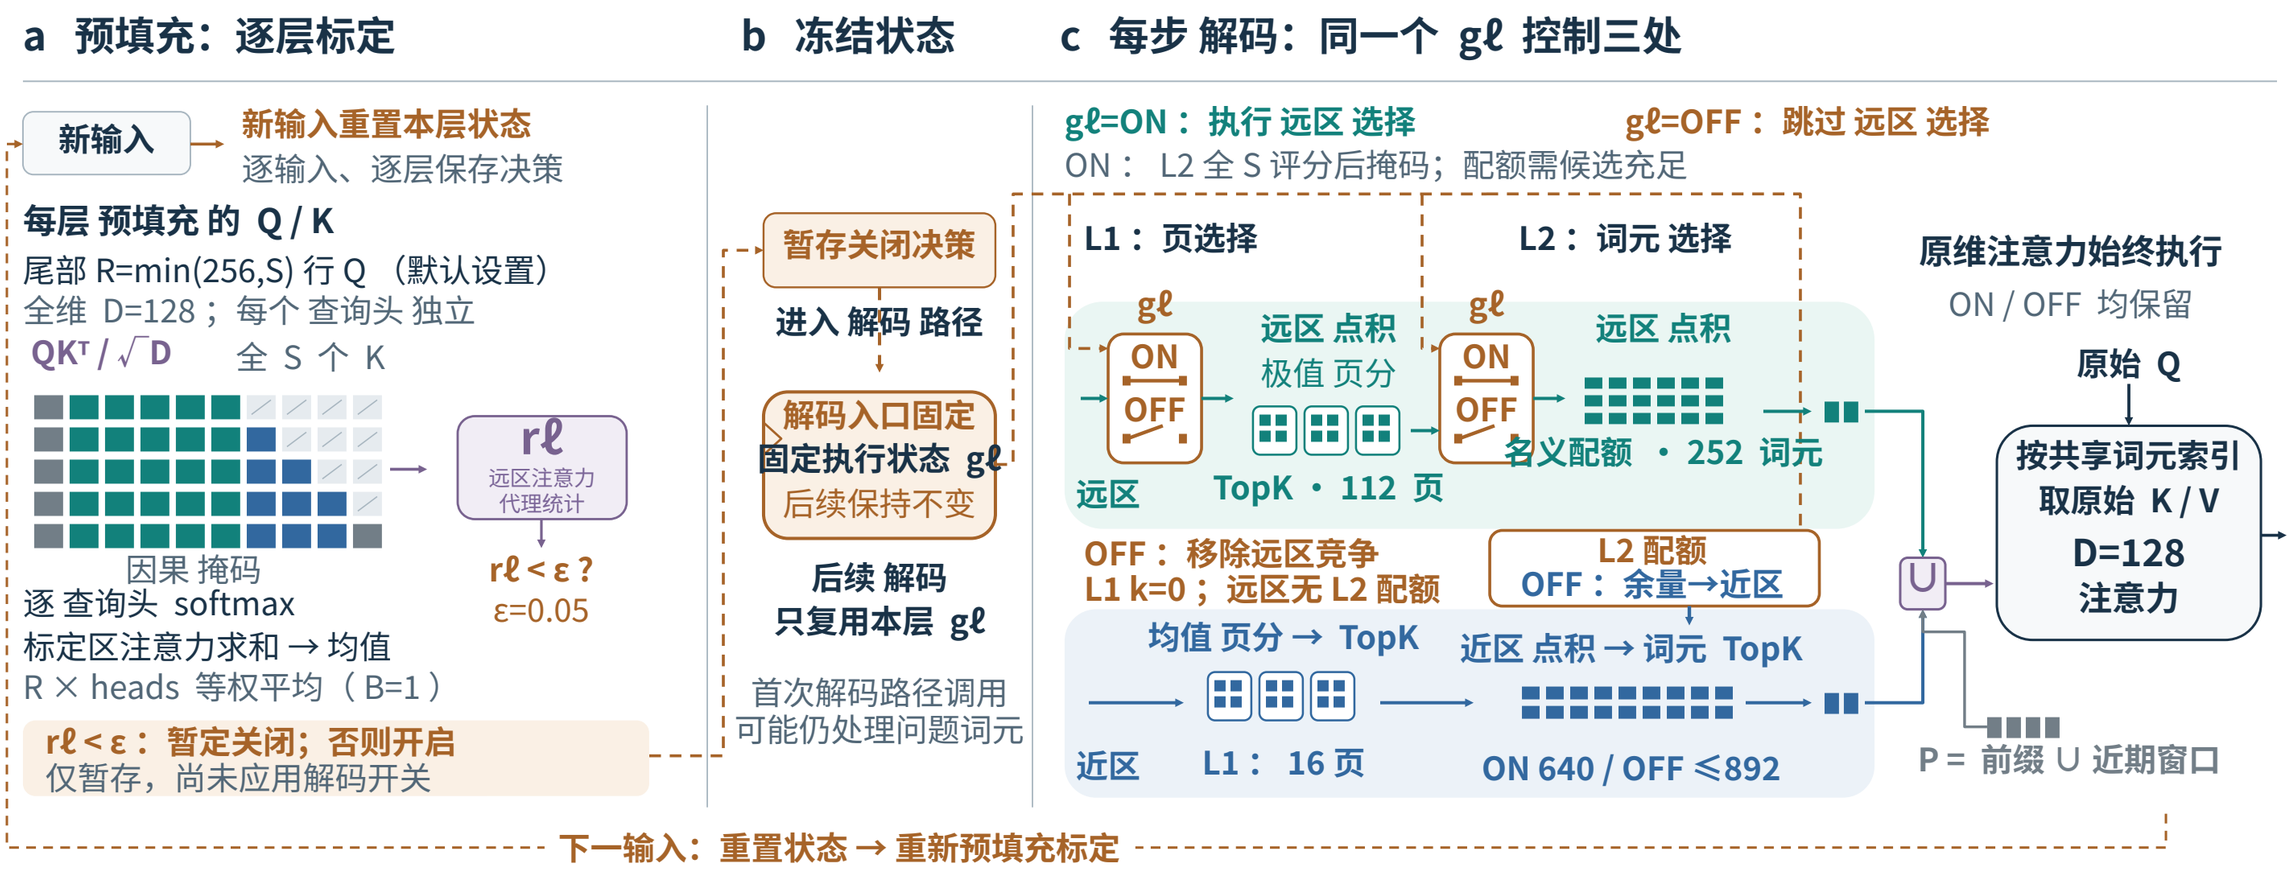
边界页内未保护词元仍须竞争；仅 sink4 与近期 128 词元强制进入最终支持集。

名义 892 个共享中间槽位

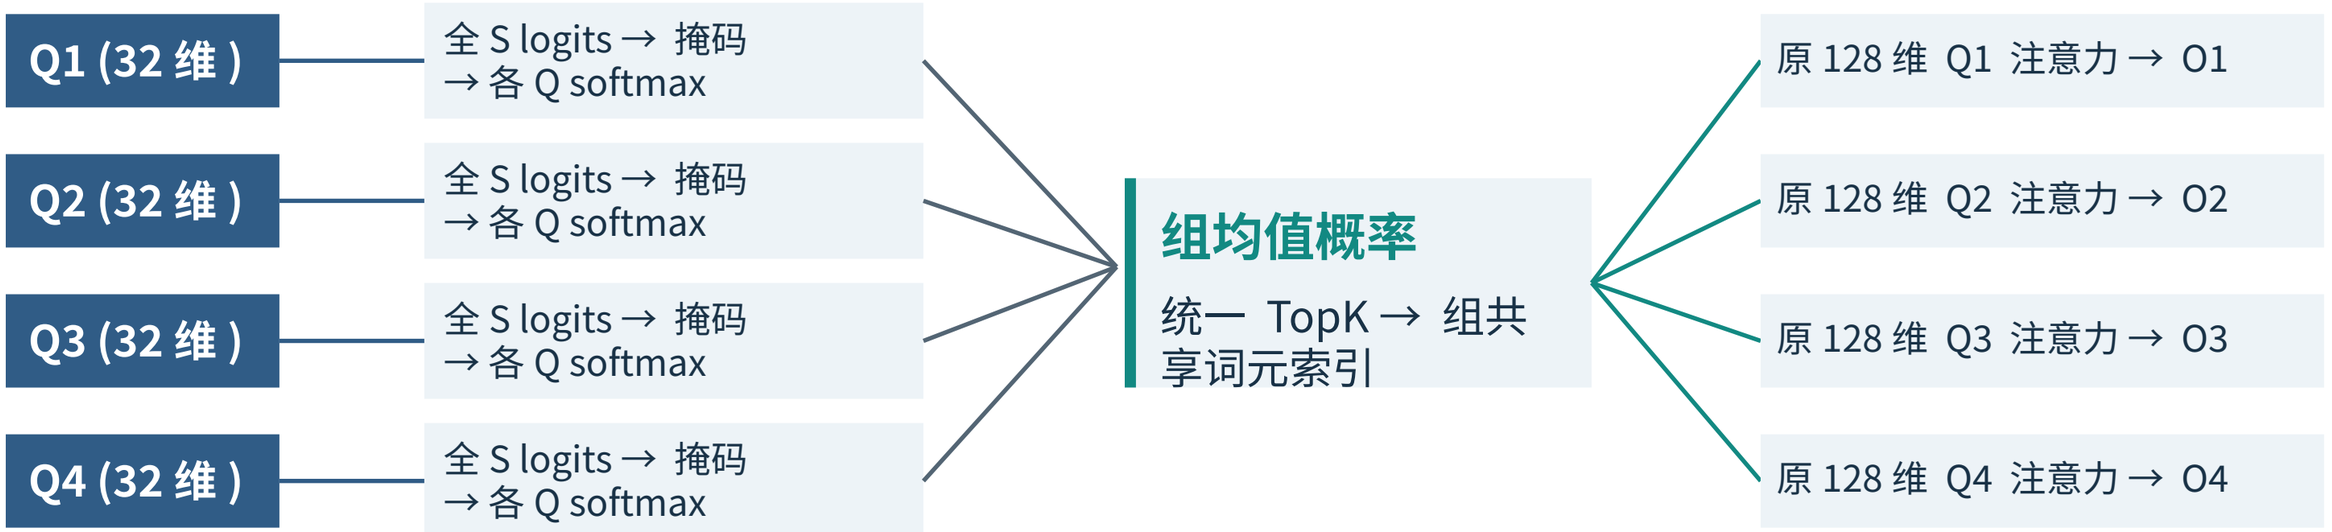
无预定近远词元份额；部分 sink 页可重复选中保护位置，去重后未保护数量可能更少。

历史数值词元配额门控：非当前统一 L2 算法

当前 nl/nb 设计关闭门控；下图回填属于历史固定词元配额分支，不移用于当前方法



GQA： 组共享选择，各查询头独立计算注意力



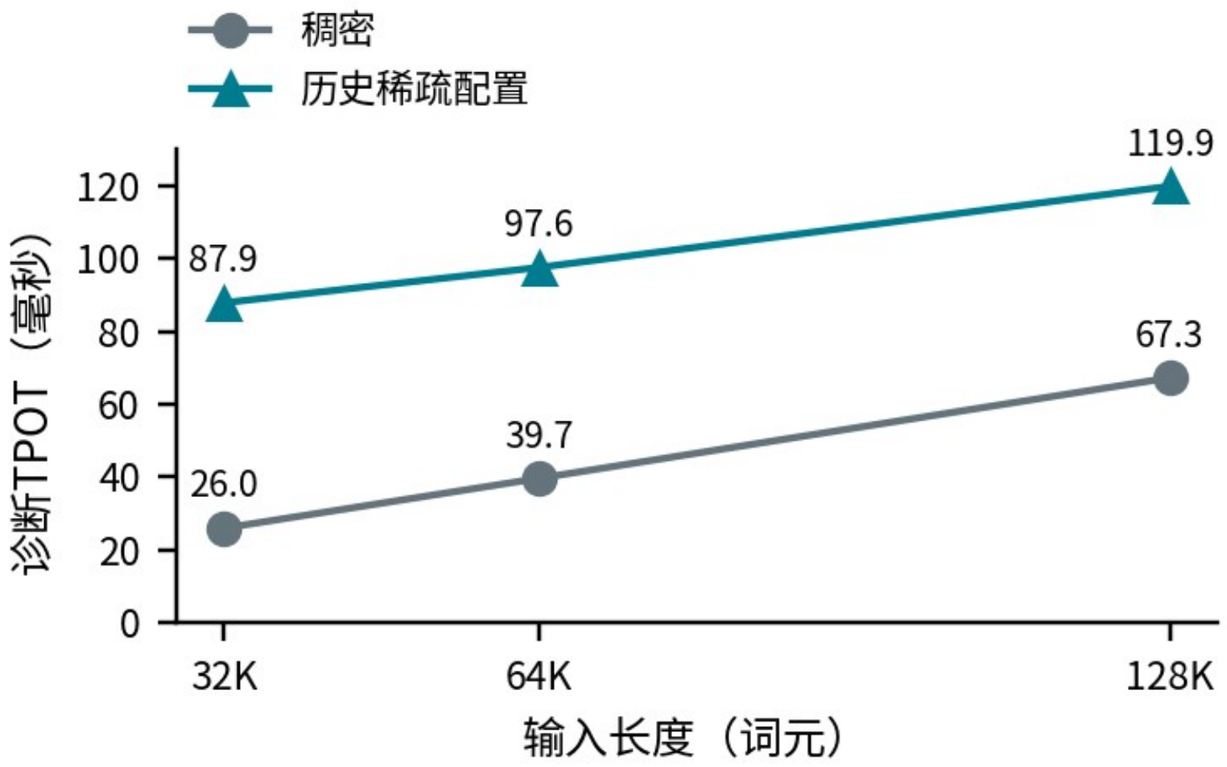
历史记录： Q1： 缩小评分宽度能否保留任务质量?

L1 表示	L2 全维	L2 低频 32
全维	**全维稀疏对照** 未测量	**名义全维页评分** 均值： 47.910
低频 32	**名义全维词元评分** 均值： 47.666	**共享子空间** 均值： 47.588

共享子空间臂
关联代码： L2 宽 128 ／有效 32
配置匹配尚未确认

尚缺匹配比较 → **共享子空间与稠密 FullKV** → **固定任务集 AVG 逐任务解释差异**

历史动态缓存：同步模型级解码计时



作者报告中位数 • 非完整请求 E2E
Qwen3-8B，固定 128 输出词元
127 个首输出后间隔，逐步同步
历史稀疏配置 α=.125 / β=.375 / γ=.625
不同于当前 nl/nb 统一 L2 设计；
运行路径未独立核验
32K/64K/128K 稀疏／稠密中位数比：
3.38 / 2.46 / 1.78
三档比值减小，但稀疏 TPOT 仍上升且高于稠密；汇总不能定位因果瓶颈。

历史记录：区域访问与门控：证据支持到哪里?

左栏共享子空间臂：关联代码 128/128 保护， L2 宽 128 ／有效 32 ；非当前 4/128 候选

低频表示

47.588

五任务均值；相对名义全维页评分
低 0.322 分，相对名义全维词元评分
低 0.078 分；配置未确认匹配，
不能隔离阶段效应。

近远检索

26.09 → 47.91

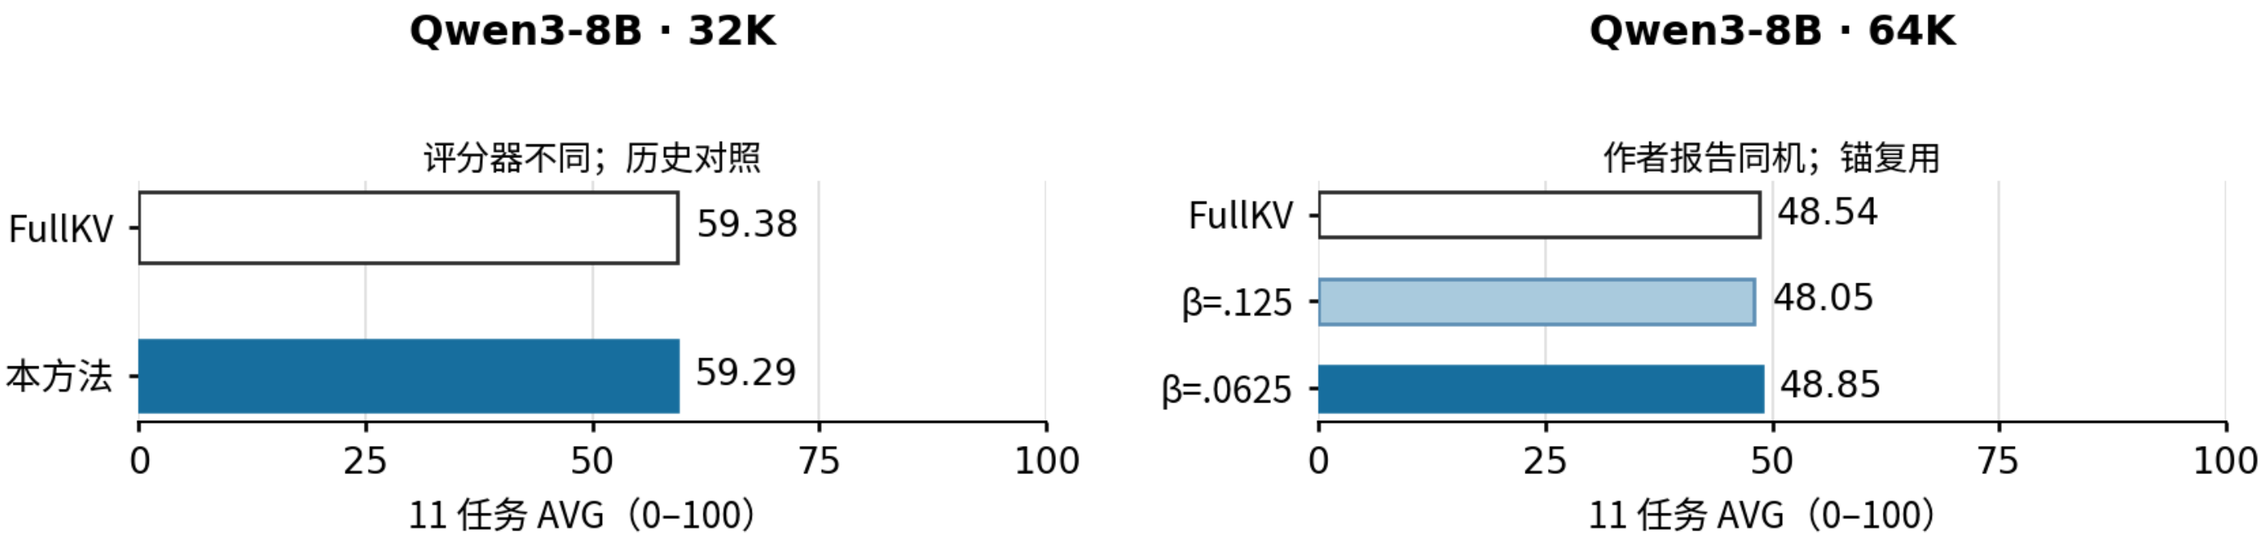
仅保护词元与中间历史检索比较，
预算 256→1024 ，
未隔离区域分配效应。

可选远区门控

47.876 / 47.692

阈值 .05/.10 ； 参考 AVG 47.910
AVG 变化 − .034 / −.218
各 3 项下降； Hotpot 降 1.05/1.26
逐任务仅诊断， AVG 为主
配置 / 配对 / 成本缺失；不证非劣

历史记录： Qwen3-8B： RULER 32K ／ 64K 与稠密 FullKV 的 AVG



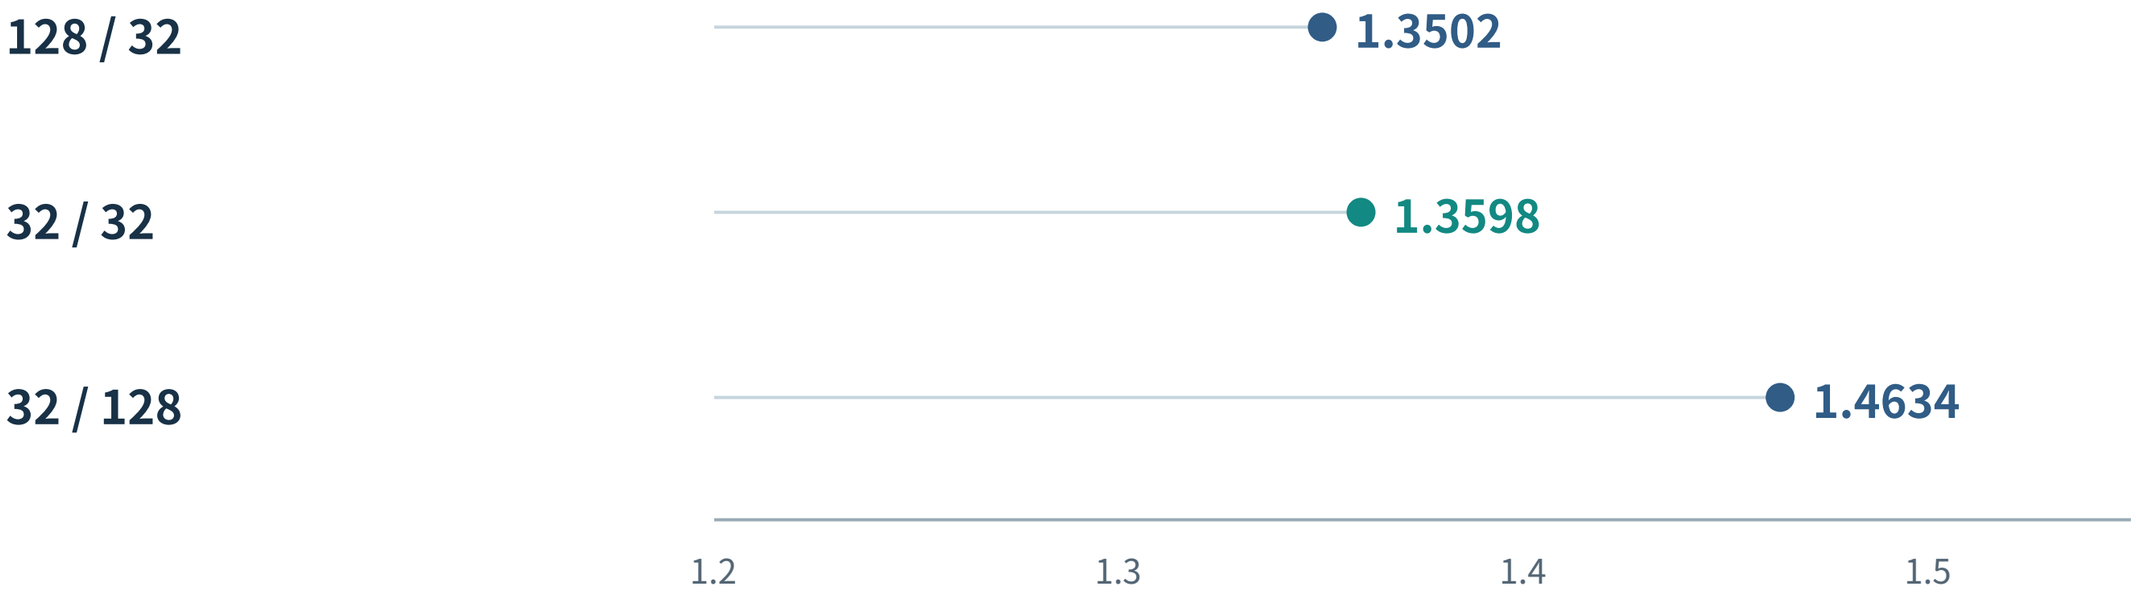
RULER 32K/64K · 作者报告汇总 · 尚不支持精度无损结论

11 任务 × 100 例／任务／臂； 32K 比较跨机器、评分器不同。
64K 稀疏两臂报告同机、评分器相同，生成脚本／有效配置不同；稠密锚另次运行、不同评分器、 legacy-partial 。
仅稀疏臂 K=1024 、 4/128 保护；门控与评分维数未核，不证非劣或匹配质量—成本收益。

保留历史负例： 128K FullKV 46.43 ／稀疏 23.98 （− 22.45 ）；旧 128/128 保护配置，不验证当前 4/128 。

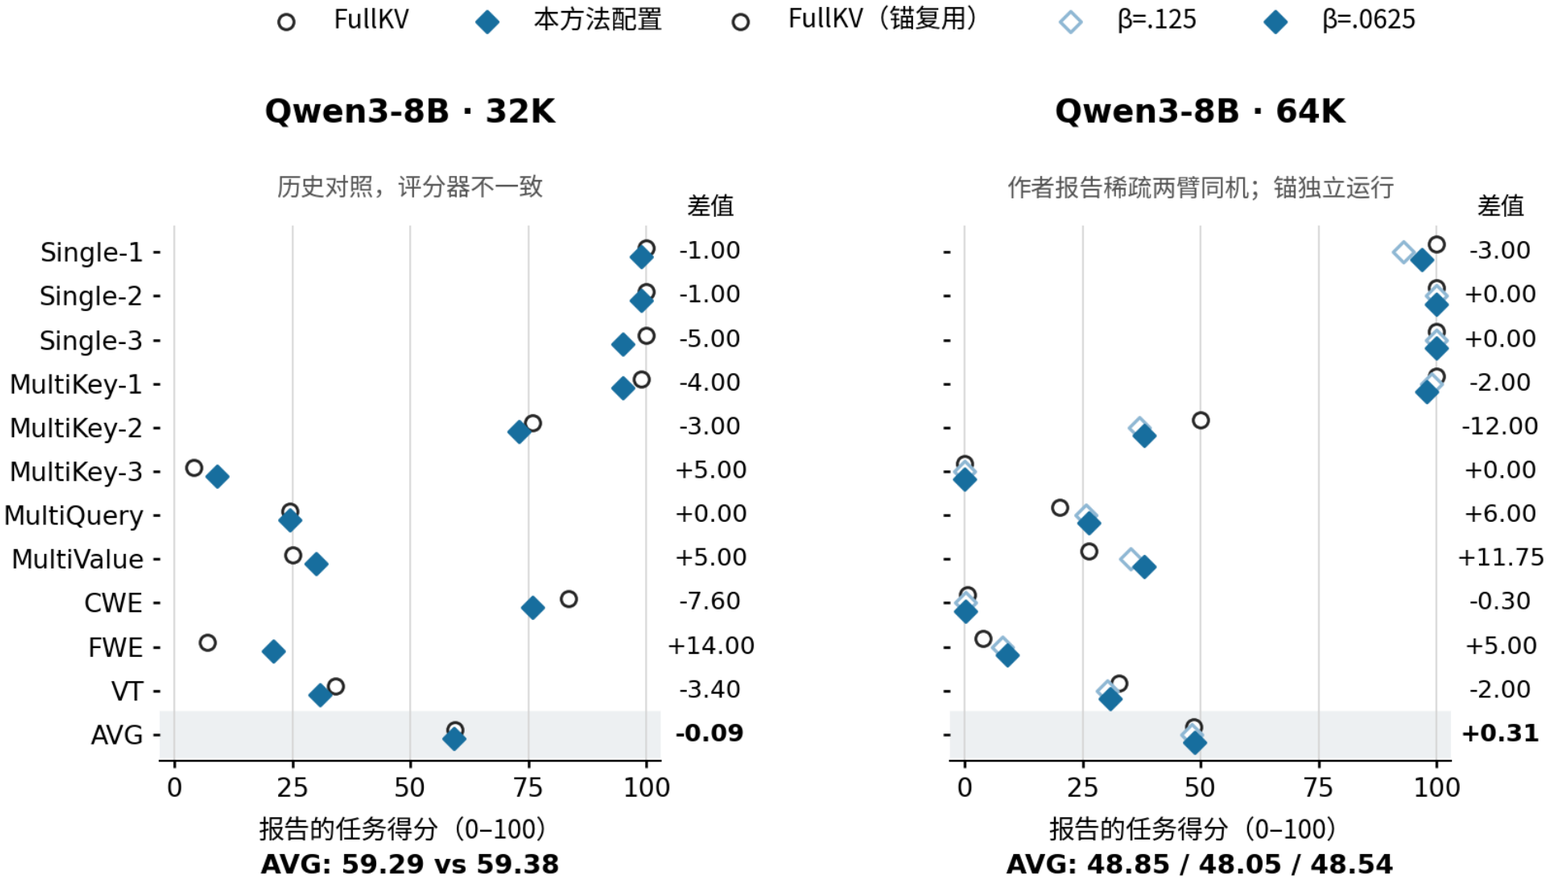
历史记录：共享子空间评分未显示一致计时优势

名义页／词元评分坐标数 • 合成 64K • 单层、批量 1 、单查询 • 两轮稳态汇总（ ms ）



相对名义页评分，两轮慢 0.0237 ／快 0.0046 ms ，汇总仍较高。原始样本缺失、协议差异未解，不能认定等价或定位瓶颈。未与质量配对，未测完整请求成本。

历史记录： 32K ／ 64K 逐任务差异解释 AVG ，不另设逐项零损门槛



RULER 32K/64K · 11 个任务，每任务每组 100 例 · 作者报告的汇总结果
差值＝稀疏－FullKV（64K取β=.0625）；无配对区间或非劣结论。

64K： 三臂 MultiKey-3 均为 0 、 CWE 均低于 1 ； 稀疏臂评分器哈希相同，生成脚本／有效配置不同。
稠密锚另次运行、不同评分器、 legacy-partial ； 预测未重放，无配对区间；门控与实际维数未核。

评分表示、区域访问与执行成本的取舍

共享低频评分表示

32 维选择 → 共享词元索引

↓

原 128 维 注意力

nb 控制候选页准入，不保证最终区域份额
nl/nb 统一 L2 仍缺匹配质量与完整请求成本

可选远区门控

预填充 标定

↓

解码 复用

门控默认关闭；历史任务存在损失
预填充统计不保证解码需求