# 子空间下的近远两级注意力

共享低维索引，保留原维注意力

**32**

维 / 16 完整旋转对

**近区 / 远区**

共享表示，两级选择

**128**

维原始 Q / K / V

---

**方法设置**

**共享低频坐标与区域页配额**

# 低频共享表示与近远分区的稀疏注意力


**问题**

页粗筛排除的历史，后续词元精筛无法恢复。

**方法**

L1 / L2 共享低频 RoPE32 视图，分区筛页与词元，
按组共享选集后用原 128 维 Q / K / V 完成注意力。

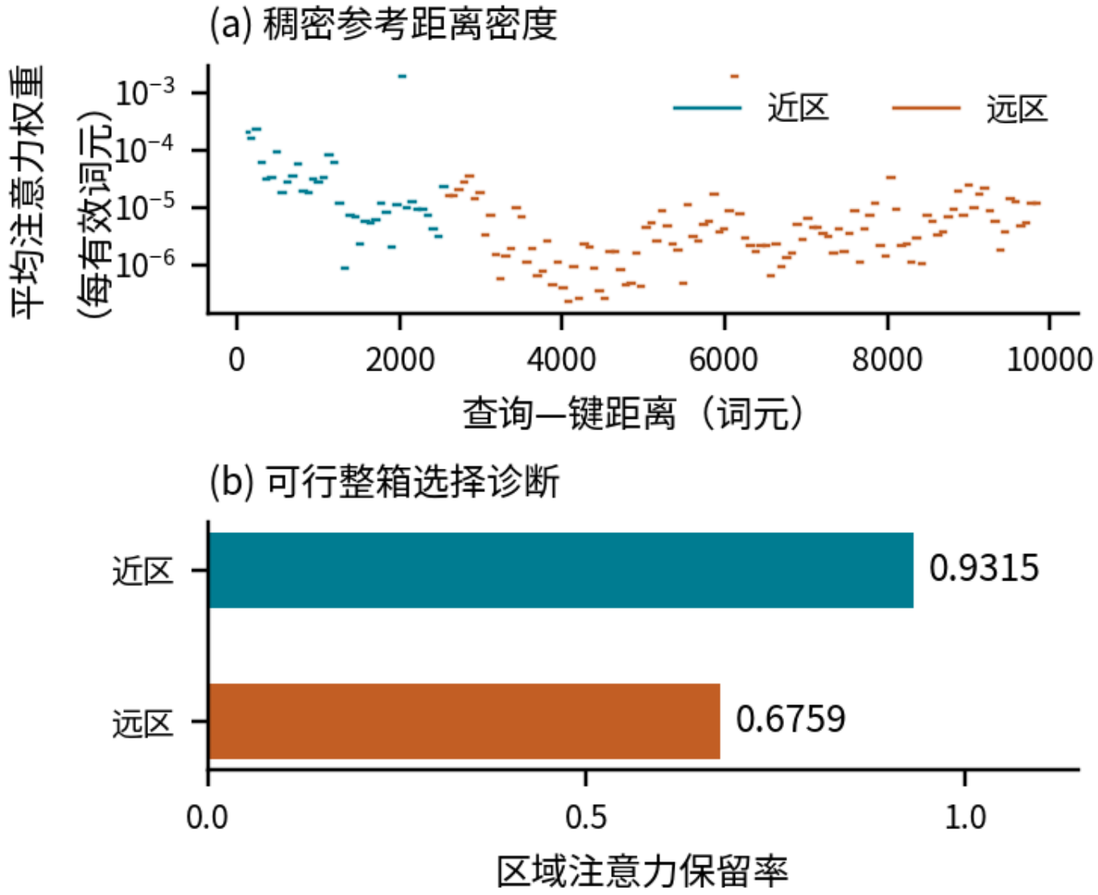
**初步结果**

Qwen3-8B 五任务均值 47.588 ，较名义全维页评分配置低 0.322 分。差值仅作描述，不能隔离阶段效应。

**可选远区门控**

远区门控在预填充阶段逐层标定，在解码入口固定后复用，默认关闭。低预填充概率不保证后续任务质量。

# 稠密参考：距离密度与整箱捕获诊断




Qwen3-8B • 归档 128/128 保护

密度： MuSiQue 样本 1 / 层 24 / q9996

每有效词元平均注意力权重

四条源序列， 128 条相关查询／层观测

注意力保留率：远 0.6759 ，近 0.9315

各区选中权重和／该区总权重

每观测同一全局整箱选集≤ 2048 中间词元；不是 K1024 方法选集、最优上界或任务质量。

# 检索机制与本方法的设计位置

| | | |
|---|---|---|
| **FullKV** | **稠密注意力** | 同输入、精度与生成协议的质量 / 成本参照 |
| **AsyncTLS** | **页到词元的级联稀疏选择** | 相关工作的级联选择先例 |
| **Quest** | **页级选择** | 用页内坐标极值估计候选页相关性 |
| **ClusterKV** | **聚类选择** | 通过聚类组织 KV ， 建簇与维护构成额外成本 |

# 共享表示、区域容量与远端控制

## 01 共享低频 RoPE 坐标

同一坐标视图服务页筛选与词元精筛

同层同 KV 头的 16 完整旋转对
近区 / 远区、 L1 / L2 共用坐标

## 02 近远两级分配

区域配额保留近端与远端候选入口

固定 α / β / γ 定义区域和配额
最终仍用原 128 维 Q / K / V

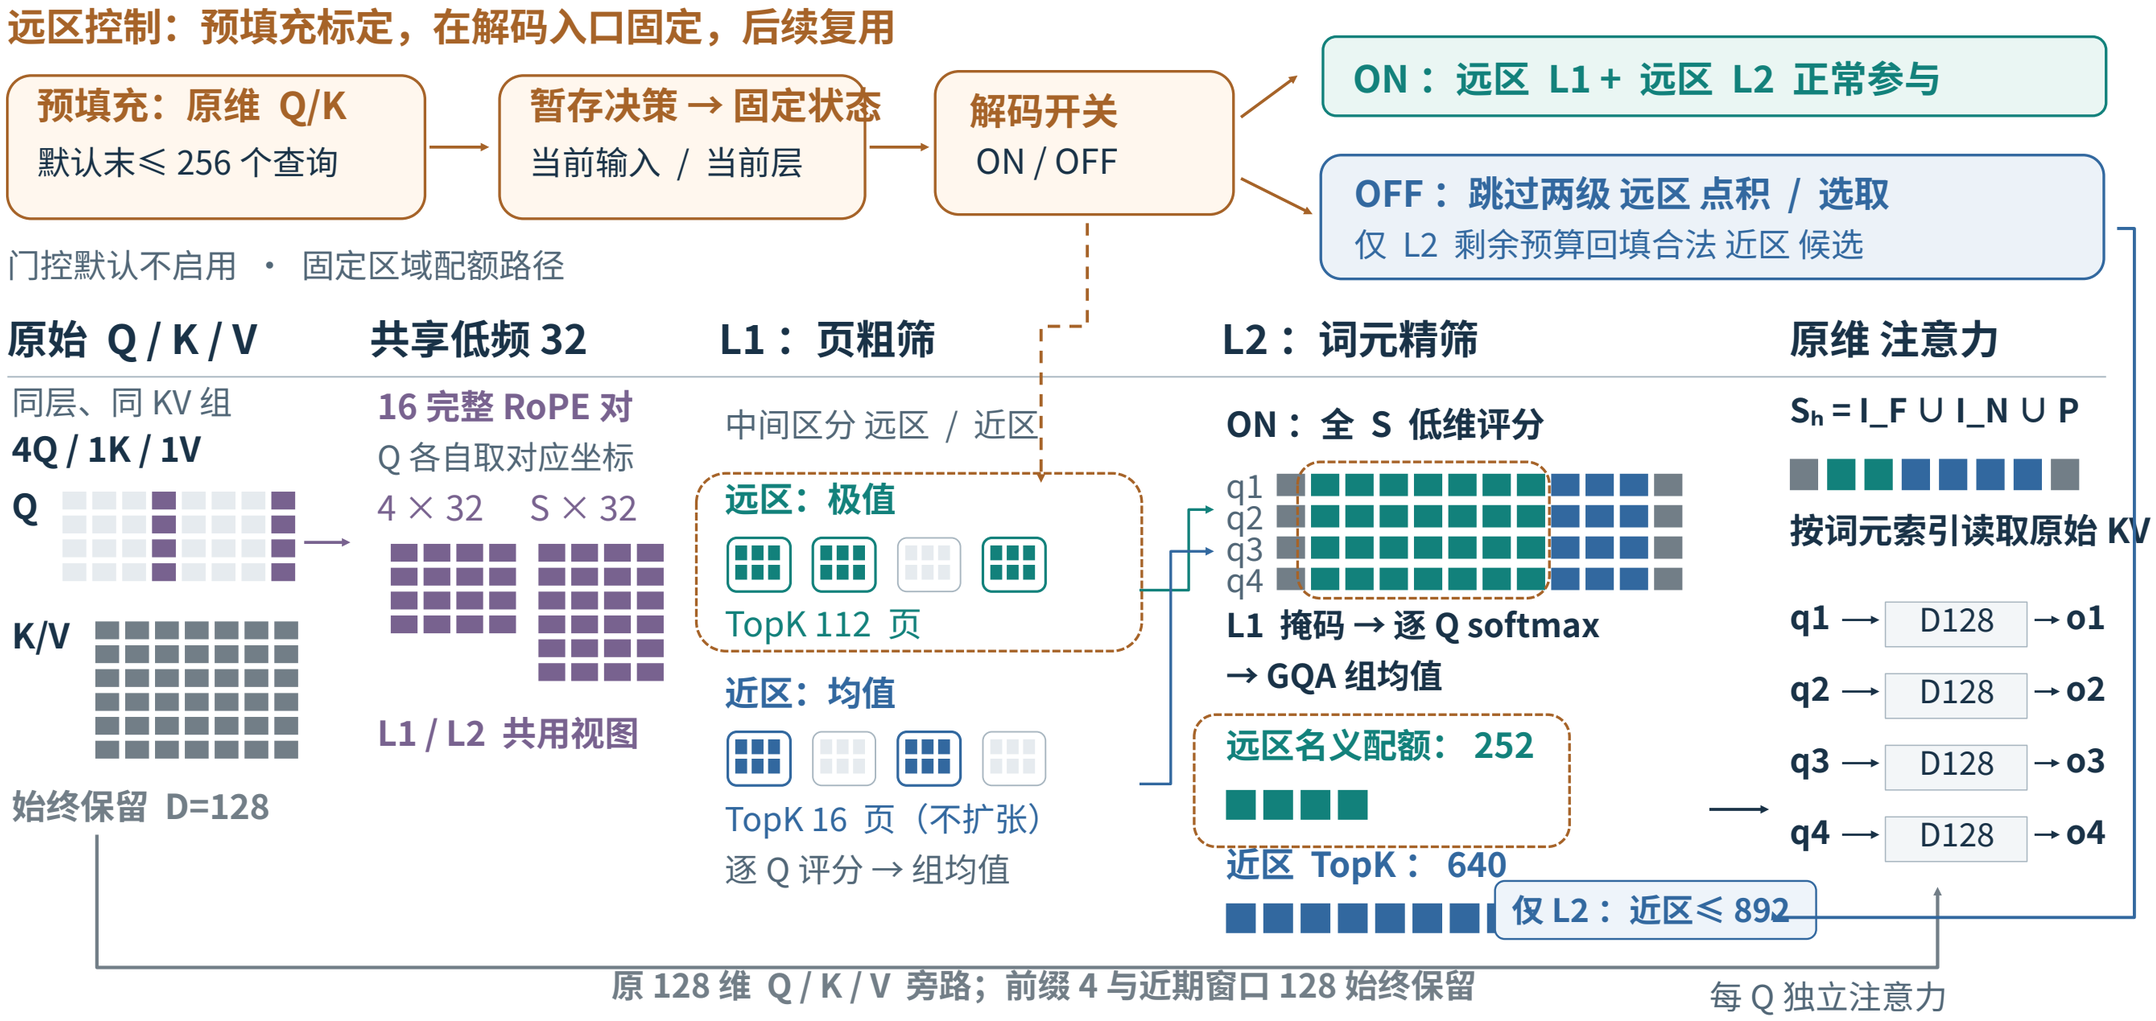
## 03 可选远区门控

默认关闭；低预填充概率不约束解码误差

预填充阶段为各输入确定逐层决策
解码复用，关闭远区时回填近区配额

# 总架构：低频索引与可选远区门控

原维 Q/K/V 始终保留；图示正常远区启用， OFF 只回填 L2 近端预算



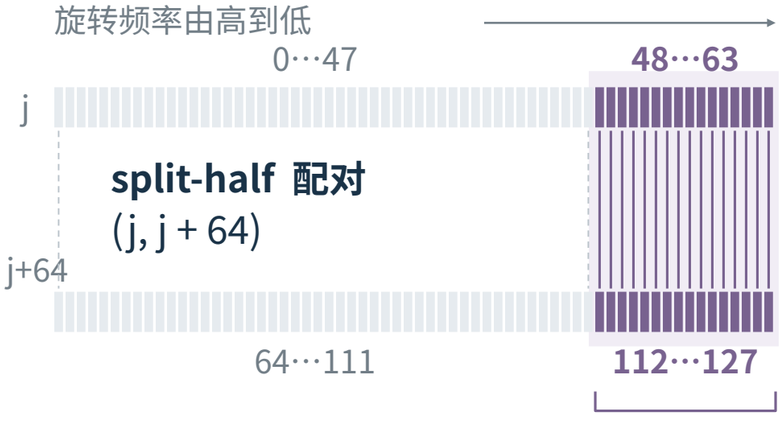
# 低频子空间： 16 个完整旋转对，共 32 维

16 完整旋转对，两级共用；浮点 16 级量化–反量化，原 128 维注意力

## a 完整低频 RoPE 对

**RoPE 后 • D = 128**

32 个 Q 头 / 8 个 KV 头；每组 4Q + 1K



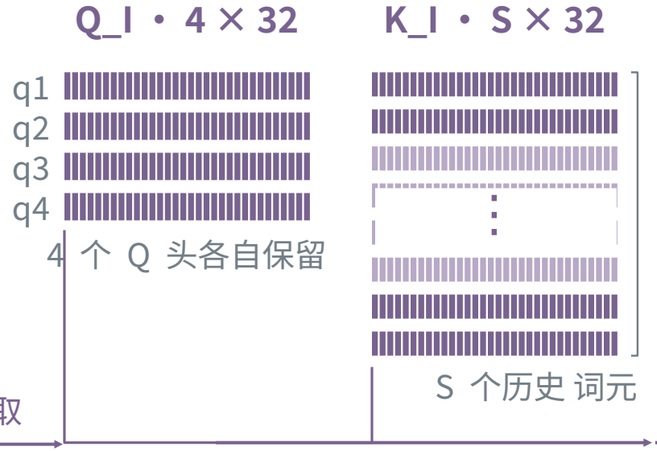

**I = [48…63] ∪ [112…127]**

32 坐标 = 16 个完整低频 RoPE 对

## b 固定坐标选择视图

**同一索引 I 作用于每个 Q / K**

以下示意一个 KV 组

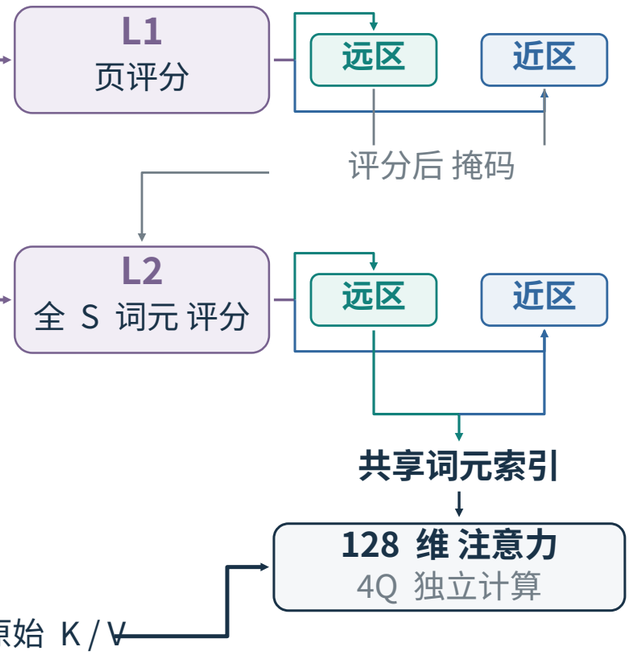



无学习投影；维度索引固定

Q 头独立 • K 视图组内共享

## c 两级复用与原维计算

**表示共享先于 近区 / 远区 分区**







**原始 Q / K / V • 128 维**

绕过选择视图，按共享词元索引读取原始 K / V

# 近远两级筛选：位置、页预算与词元预算

候选充足的 4/128 示例；远区可重复选中至多 4 个前缀词元

## a 共享 RoPE32

RoPE 后： 4Q / 1 KV 组

Q

0…63　64…127

K

[48…63] ∪ [112…127]
16 对完整 RoPE 坐标

4 × 32　S × 32

$q_1 \ldots q_4$　$K_s$

L1 / L2 复用同一 RoPE32

## b L1： 区域页筛选

按位置划分未保护中间历史

P | 远区 | 近区 | P

$|M_t| = S - |P_t|$

α=.25 定边界；页对齐，近区≥ 64

近区∩ P=∅ ； $|P_t|$=132 示例

每 Q 页分 → 组内 均值 → TopK

远区 • 极值

112 页

近区 • 均值

16 页

L1 候选页 掩码

$K_1$=128 ； β=.125 → 近区 16 / 远区 112 页

## c L2： 区域 词元 筛选

普通 L2： 32 维全 S 评分

S

q1
q2
q3
q4

[4, S]

加 L1 掩码

每 Q softmax　组内 均值

区域 词元 TopK

近区 = min(892, ⌊γ • 16 • 64⌋) = 640

远区名义配额 = 892 − 640 = 252

区域名义槽位： 892

## d 原维注意力

原始 128 维 Q / K / V 保留

K　V

P = 前缀 4 ∪ 近期窗口 128

$S_h = I_F \cup I_N \cup P$

名义 1024 = 252 + 640 + 132

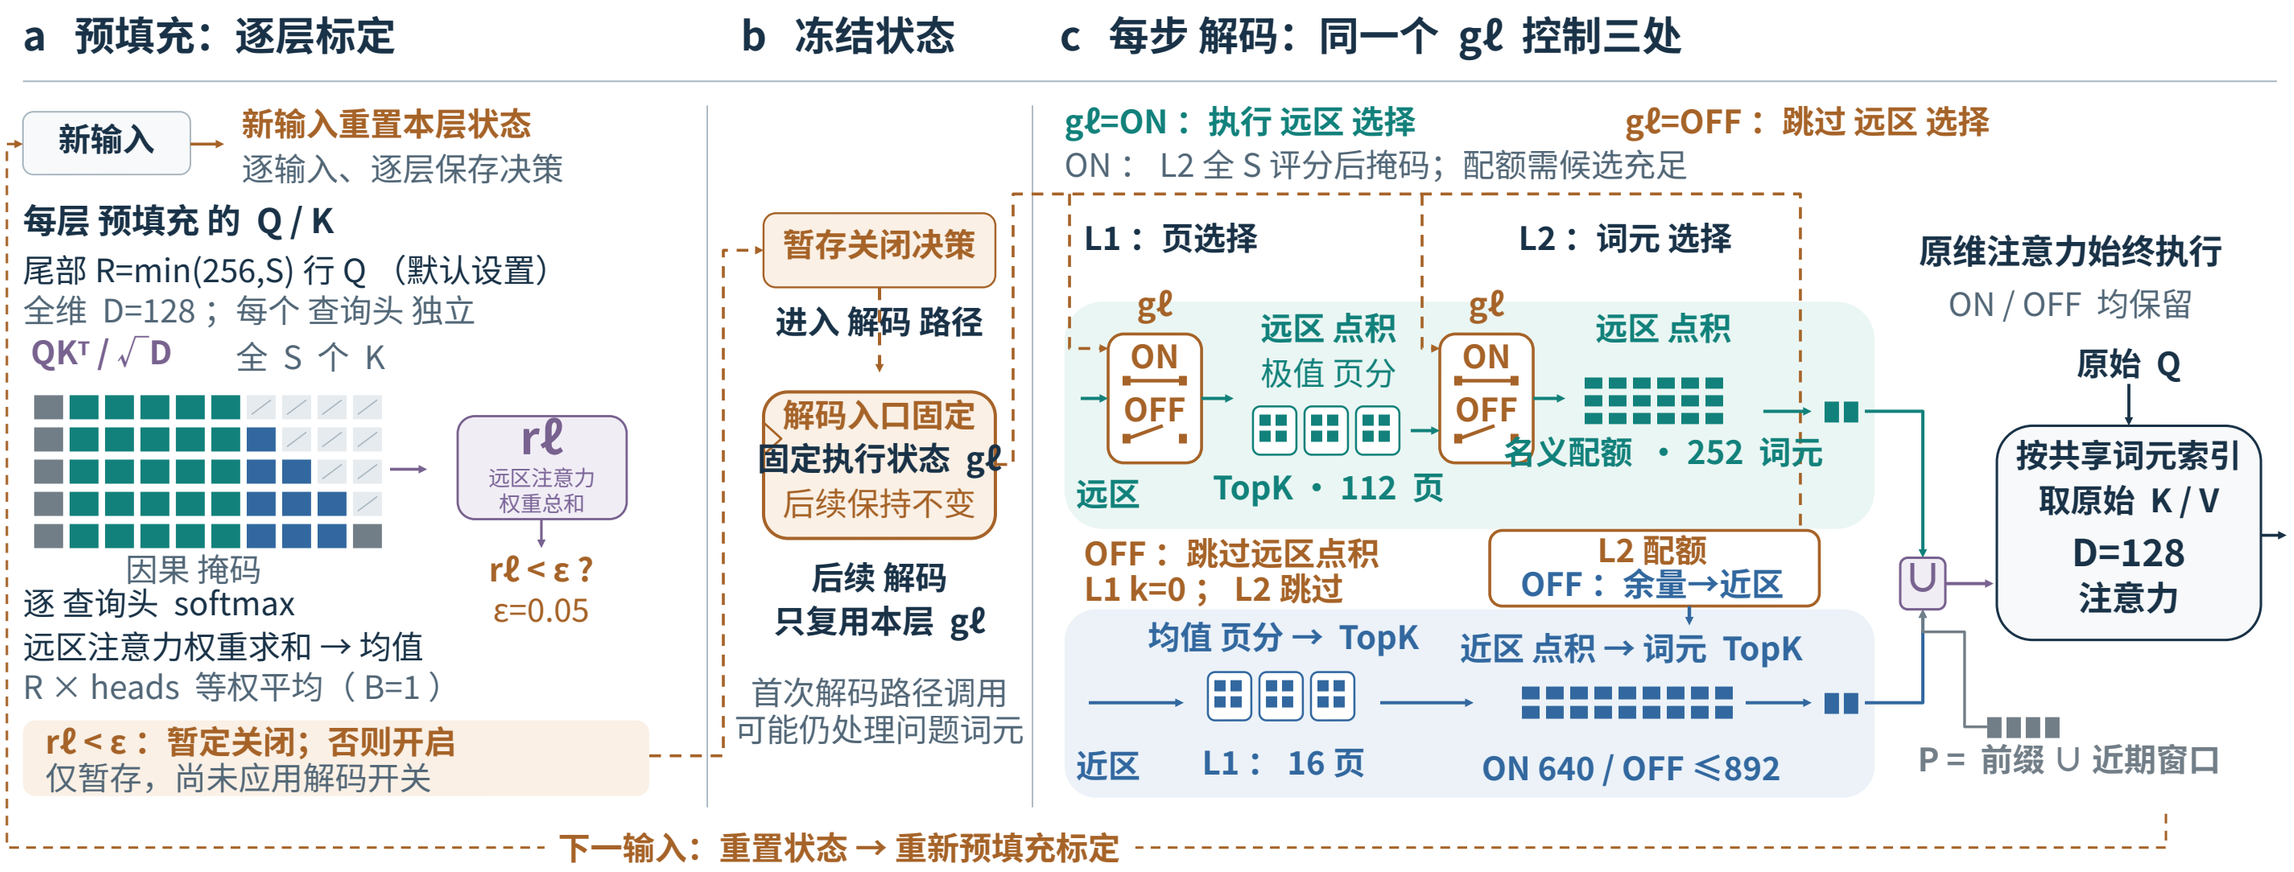
按 $S_h$ 读取原始 K / V

q1 → 128 维 注意力 → o1
q2 → 128 维 注意力 → o2
q3 → 128 维 注意力 → o3
q4 → 128 维 注意力 → o4

4Q 共享词元索引，各自计算
最终 注意力 权重

# 远区门控：从预填充观测到解码逐层复用

门控默认不启用；固定区域配额、有效历史长度路径；质量与成本尚未验证



# GQA： 组共享选择，各查询头独立计算注意力



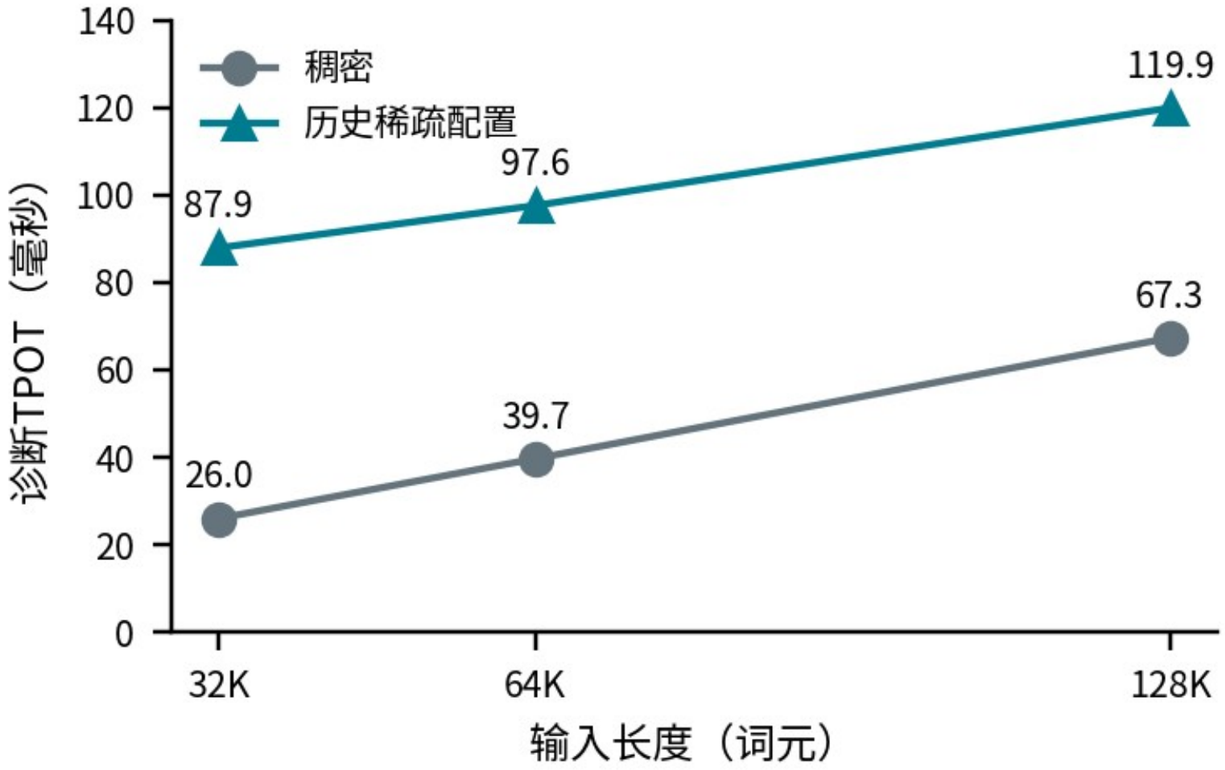
# 三种名义配置的描述性比较

| L1 表示 | L2 全维 | L2 低频 32 |
| --- | --- | --- |
| 全维 | **全维稀疏对照**<br>未测量 | **名义全维页评分**<br>均值： 47.910 |
| 低频 32 | **名义全维词元评分**<br>均值： 47.666 | **共享子空间**<br>均值： 47.588 |

归档评分实现
L2 张量宽 128 ／有效 32
配置匹配尚未确认

**尚缺匹配比较** → **共享子空间与稠密 FullKV** → **文档配对质量评估**

# 历史动态缓存：同步模型级解码计时




作者报告中位数 • 非完整请求 E2E

Qwen3-8B，固定 128 输出词元

127 个首输出后间隔，逐步同步

历史稀疏配置 α=.125 / β=.375 / γ=.625

不同于当前 4/128 候选；运行路径未独立核验

三档稀疏计时均高于稠密；汇总不能定位因果瓶颈。

# 表示、检索范围与门控的初步结果

归档 128/128 保护： L2 宽 128 、有效 32 ； 不代表当前 4/128 候选

## 低频表示

**47.588**

五任务均值；较名义全维页评分低 0.322 分。名义全维词元评分高 0.078 分；配置未确认匹配，不能隔离阶段效应。

## 近远检索

**26.09 → 47.91**

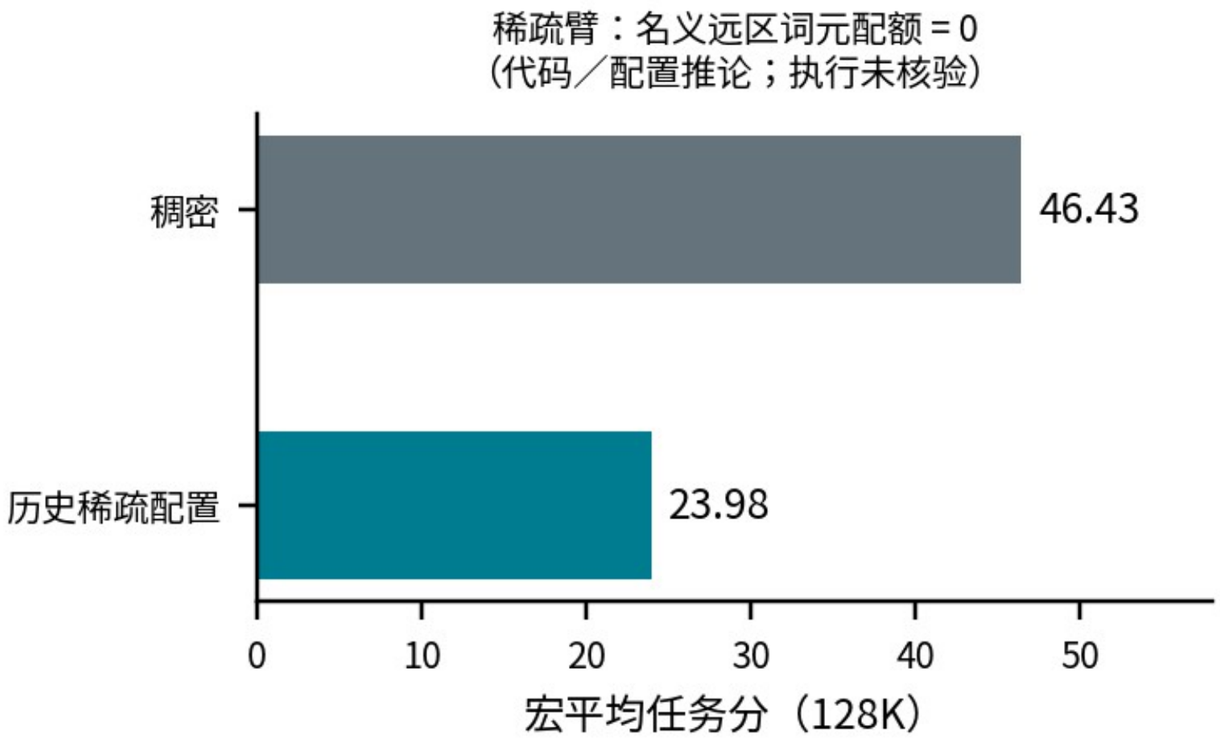
仅保护词元与中间历史检索比较，预算 256→1024 ，未隔离区域分配效应。

## 可选远区门控

**3 / 5**

阈值 0.05/0.10 各 3 项下降。HotpotQA 降 1.05/1.26 分，评分配置不完整，限于此对照。

# 保留历史 128K 质量负结果




历史 128K 得分： 46.43 / 23.98

11 任务；每任务每臂 100 例

报告 β=.375， K1=128，保护 128/128

中间预算 768；页长 64， γ=.625

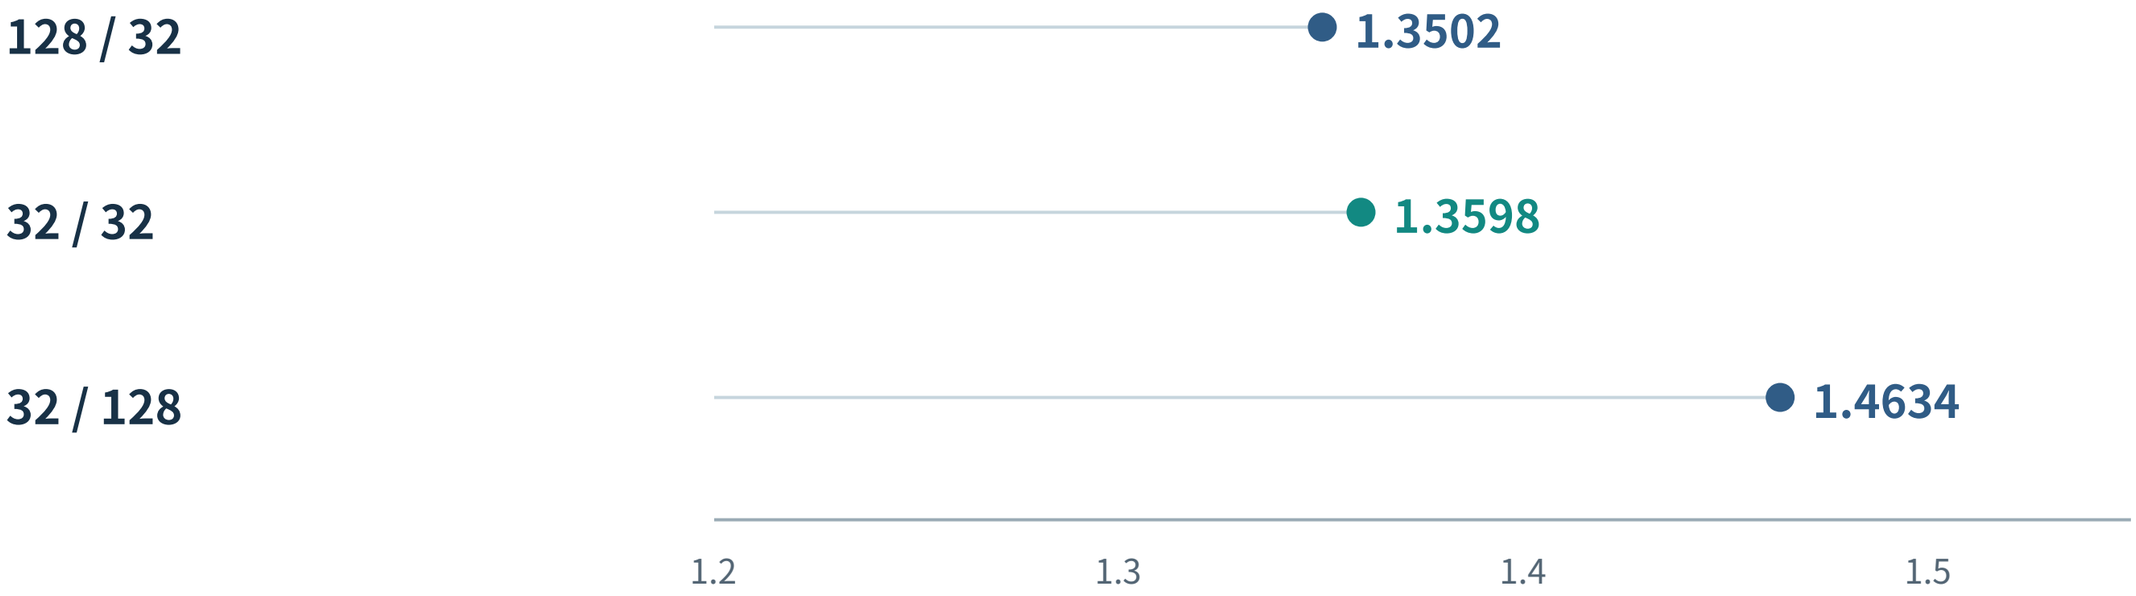
按已检公式：名义远区词元配额 =0

代码／配置推论；实际执行未核验

不能据此认定得分差的唯一原因；不验证当前 4/128 候选。

# 评分降维未降低该设置下的局部耗时

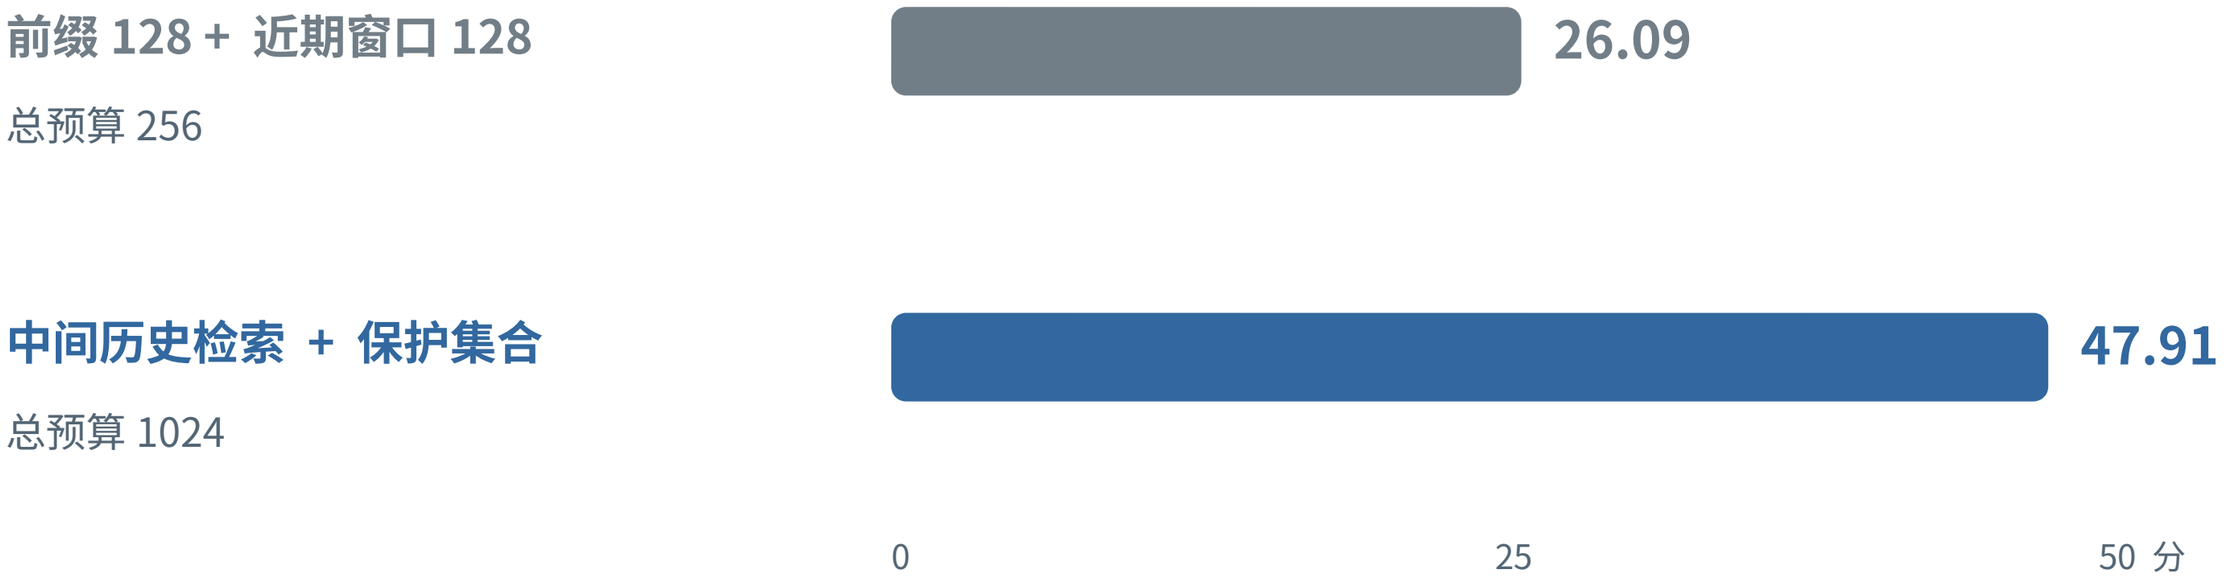
名义页／词元评分坐标数 • 合成 64K • 单层、批量 1 、单查询 • 两轮稳态汇总（ ms ）




采样协议存在未核实差异，小幅时延差值不足以定位瓶颈。

# 历史 128/128 保护：检索与词元预算的联合变化

预算 256 与 1024 的联合变化，未隔离分区贡献



# 表示质量与执行成本的取舍

**共享低频评分表示**

**32 维选择** → **共享词元索引**

↓

**原 128 维 注意力**

五任务均值 47.588
配置差值不能隔离评分阶段效应

**可选远区门控**

**预填充 标定**

↓

**解码 复用**

小幅均值变化掩盖逐任务损失
低预填充概率不能保证解码质量