子空间下的近远两级注意力

共享低维索引，保留原维注意力

32

维 / 16 完整旋转对

近区 / 远区

共享表示，两级选择

128

维原始 Q / K / V

方法设置

共享低频坐标与区域页配额

固定词元预算下：候选访问与选择成本

问题

页筛控制哪些词元获得正的精筛概率；检索本身也有成本。

方法

共享 32 坐标映射与区域页配额协同选择，
最终在选集上使用原 128 维 Q / K / V 。

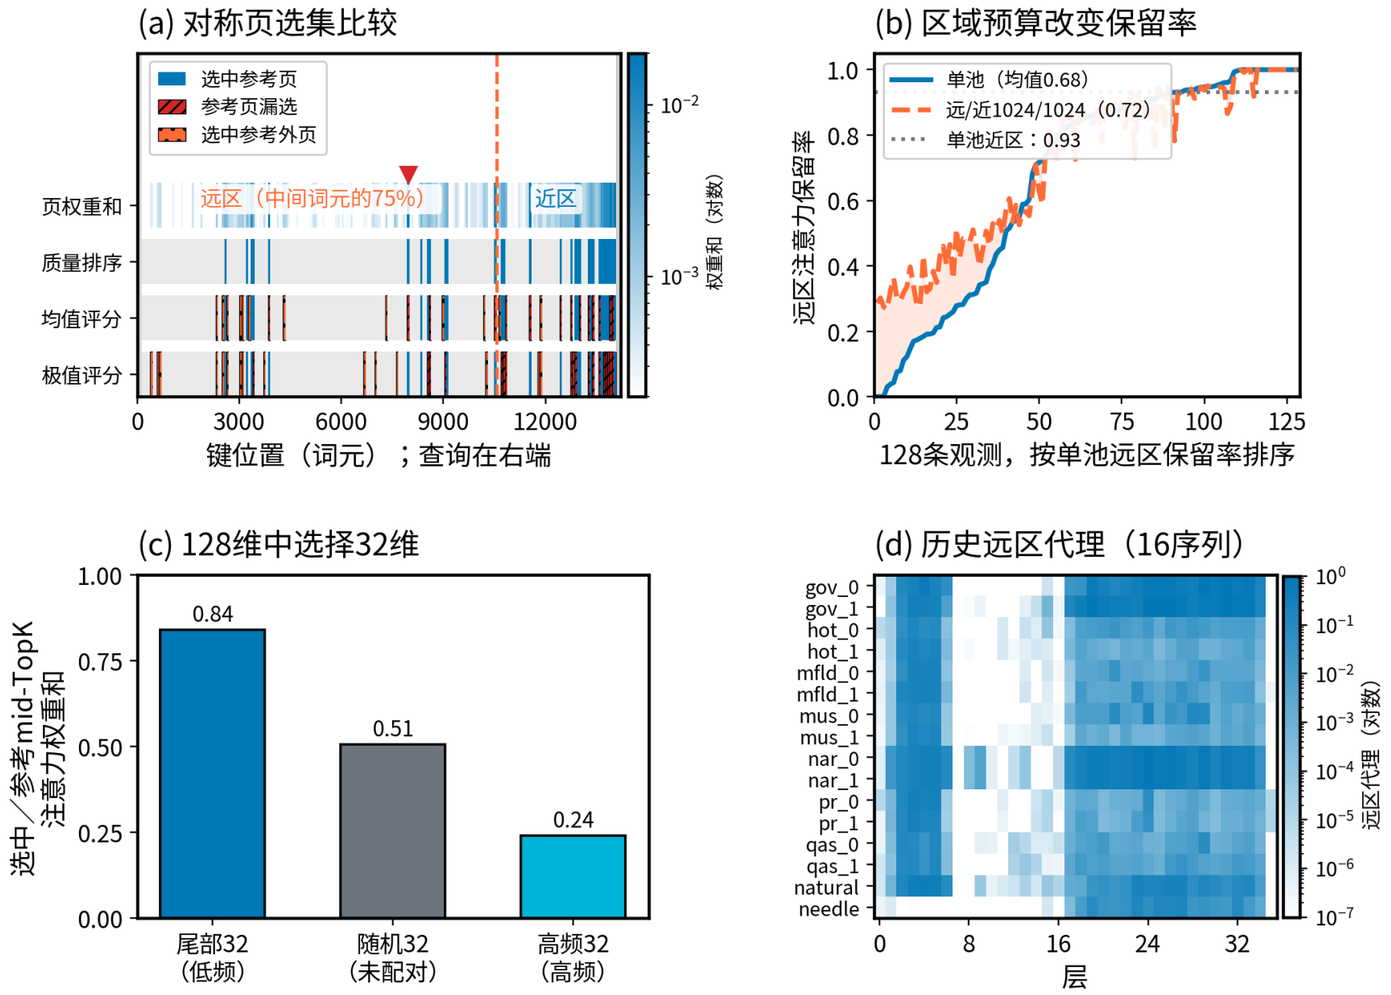
观察与边界

区域预留改变远区覆盖， 43/128 条观测下降；历史稀疏解码更慢，当前 4/128 尚缺匹配质量—成本结果。

可选远区门控

远区门控在预填充阶段逐层标定，在解码入口固定后复用，默认关闭。低预填充概率不保证后续任务质量。

四项观察：区域选集、紧凑坐标与历史层差异



(a) 页权重排序≠词元 TopK；实际 1989/1989/2048 词元，集合差异不代表质量优劣；
(b) 43/128 条下降；(c) 随机未配对；(d) 历史代理，不是当前门控或解码保证。

检索机制与本方法的设计位置

FullKV	**稠密注意力**	同输入、精度与生成协议的质量 / 成本参照
AsyncTLS	**级联、坐标选择与量化评分**	逐查询概率聚合；原维 KV 最终注意力
Quest	**页级选择**	用页内坐标极值估计候选页相关性
ClusterKV	**聚类选择**	通过聚类组织 KV ，建簇与维护构成额外成本

两项核心机制，一个可选扩展

01 共享低频 RoPE 坐标

共享坐标映射，不要求共享物理缓冲区

同层同 KV 头的 16 完整旋转对
近区 / 远区、 L1 / L2 共用坐标

02 近远两级分配

区域配额保留近端与远端候选入口

固定 α / β / γ 定义区域和配额
最终仍用原 128 维 Q / K / V

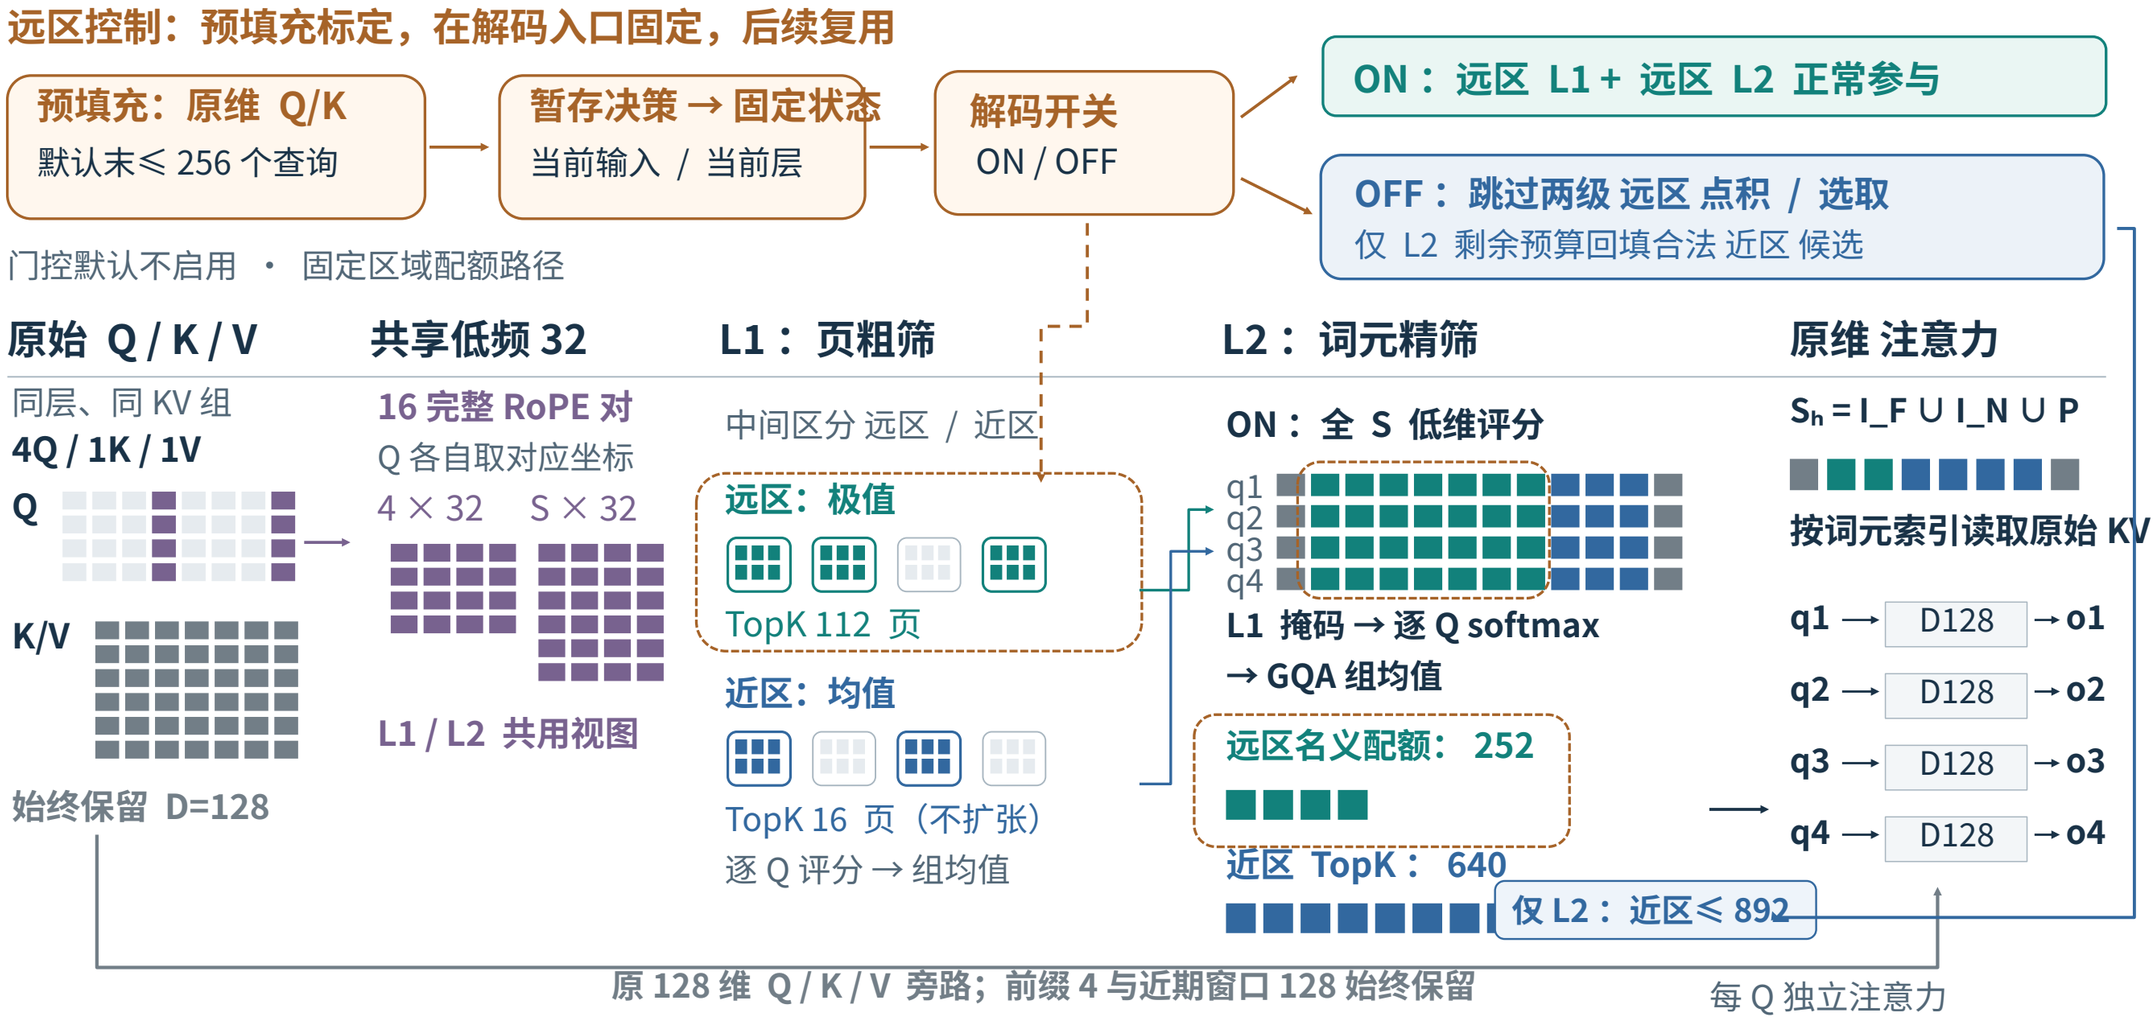
03 可选远区门控

默认关闭；低预填充概率不约束解码误差

预填充阶段为各输入确定逐层决策
解码复用，关闭远区时回填近区配额

总架构：低频索引与可选远区门控

原维 Q/K/V 始终保留；图示正常远区启用， OFF 只回填 L2 近端预算



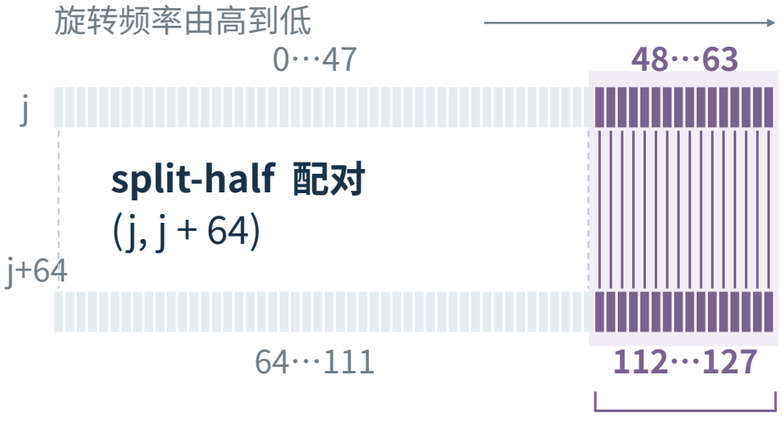
低频子空间： 16 个完整旋转对，共 32 维

16 完整旋转对，两级共用；浮点 16 级量化–反量化，原 128 维注意力

a 完整低频 RoPE 对

RoPE 后 • D = 128

32 个 Q 头 / 8 个 KV 头；每组 4Q + 1K



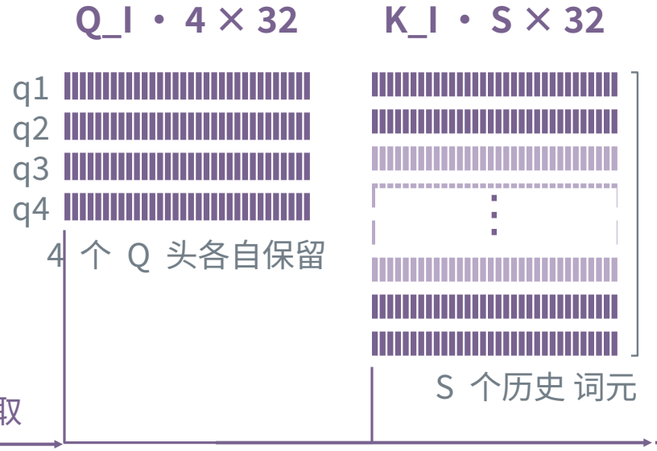
I = [48…63] ∪ [112…127]

32 坐标 = 16 个完整低频 RoPE 对

b 固定坐标选择视图

同一索引 I 作用于每个 Q / K

以下示意一个 KV 组

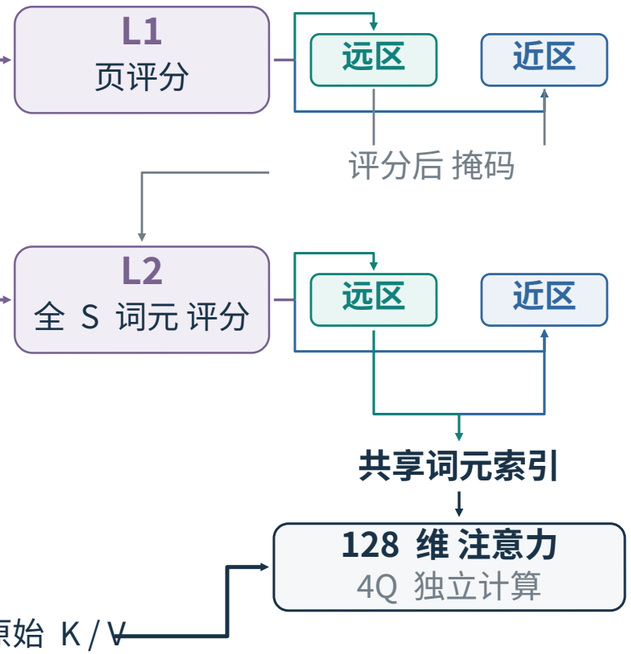


无学习投影；维度索引固定

Q 头独立 • K 视图组内共享

c 两级复用与原维计算

表示共享先于 近区 / 远区 分区





原始 Q / K / V • 128 维

绕过选择视图，按共享词元索引读取原始 K / V

近远两级筛选：位置、页预算与词元预算

候选充足的 4/128 示例；远区可重复选中至多 4 个前缀词元

a 共享 RoPE32

RoPE 后： 4Q / 1 KV 组

Q

0…63　64…127

K

[48…63] ∪ [112…127]
16 对完整 RoPE 坐标

4 × 32　S × 32

$q_1 \ldots q_4$　K_s

L1 / L2 复用同一 RoPE32

b L1： 区域页筛选

按位置划分未保护中间历史

P | 远区 | 近区 | P

$|M_t| = S - |P_t|$

α=.25 定边界；页对齐，近区≥ 64

近区∩ P=∅ ； $|P_t|$=132 示例

每 Q 页分 → 组内 均值 → TopK

远区 • 极值

112 页

近区 • 均值

16 页

L1 候选页 掩码

K_1=128 ； β=.125 → 近区 16 / 远区 112 页

c L2： 区域 词元 筛选

普通 L2： 32 维全 S 评分

S

q1
q2
q3
q4

[4, S]

加 L1 掩码

每 Q softmax　组内 均值

区域 词元 TopK

近区 = min(892, ⌊γ • 16 • 64⌋) = 640

远区名义配额 = 892 − 640 = 252

区域名义槽位： 892

d 原维注意力

原始 128 维 Q / K / V 保留

K　V

P = 前缀 4 ∪ 近期窗口 128

$S_h = I_F \cup I_N \cup P$

名义 1024 = 252 + 640 + 132

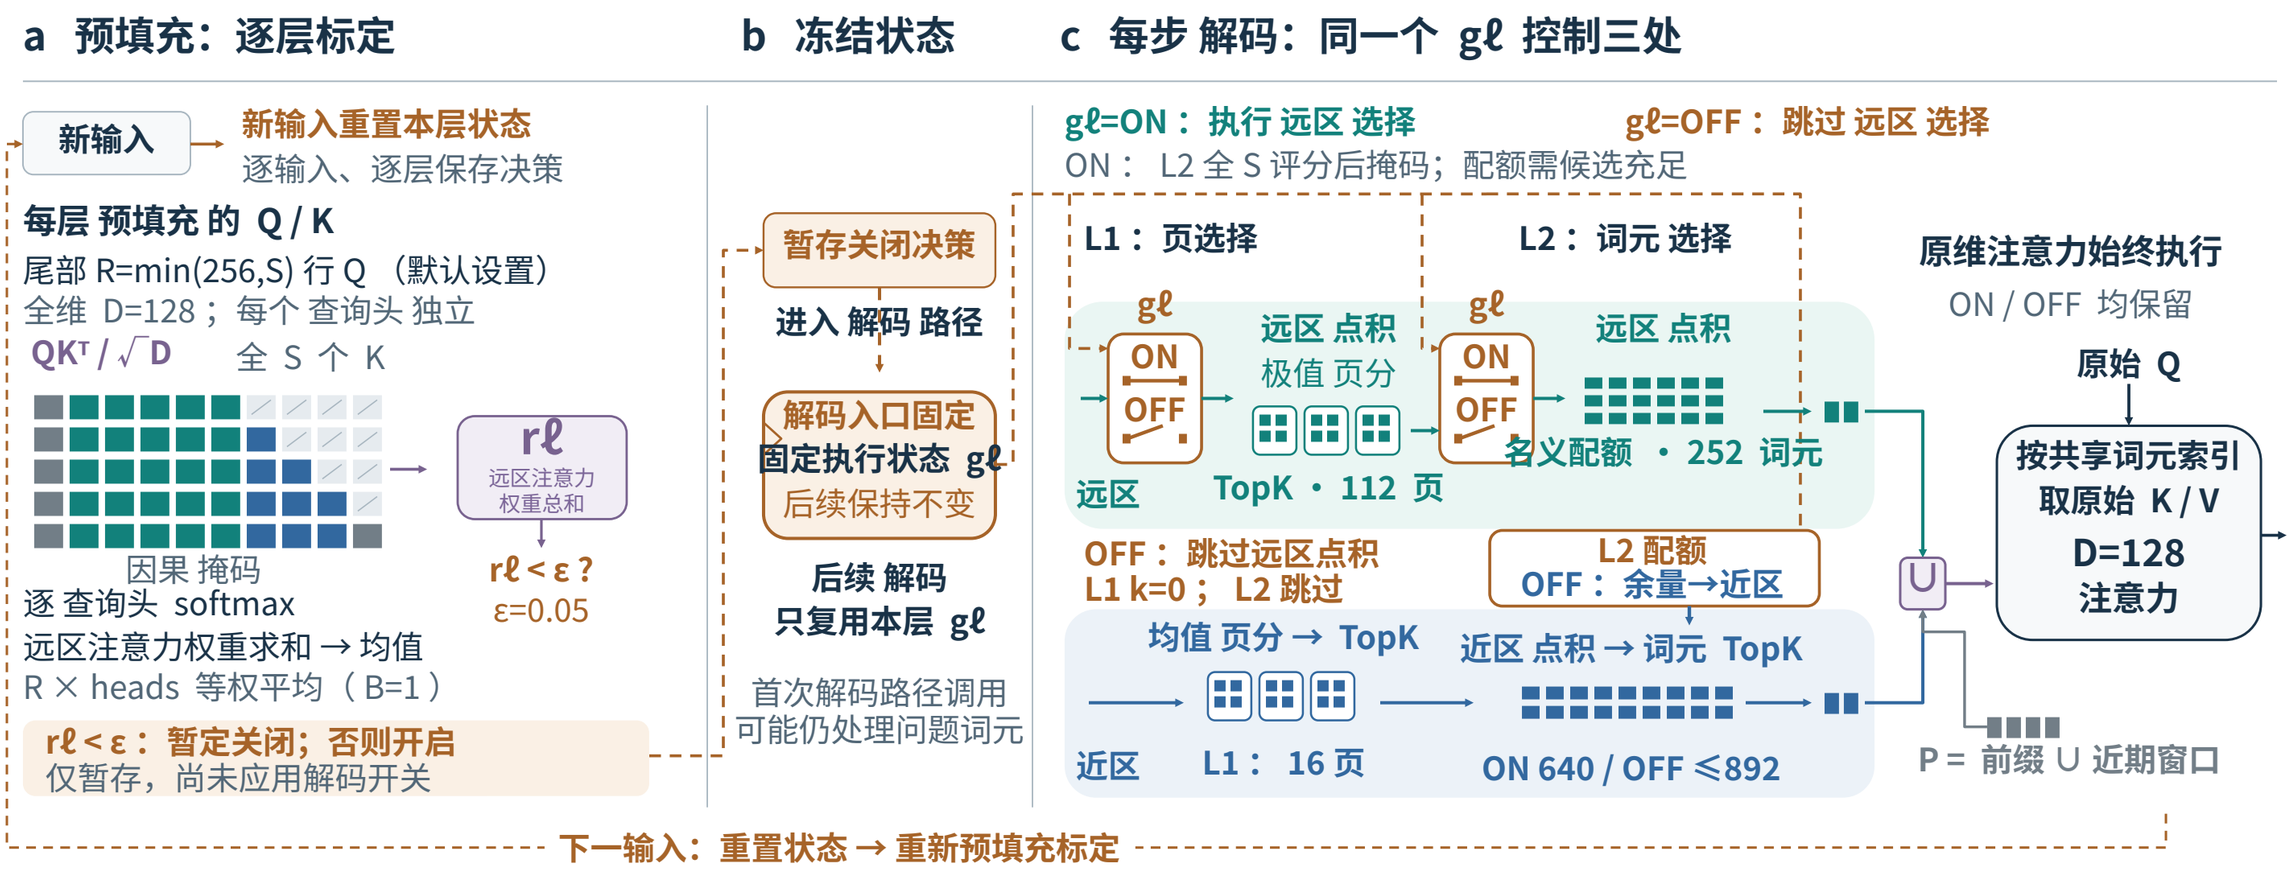
按 S_h 读取原始 K / V

q1 → 128 维 注意力 → o1
q2 → 128 维 注意力 → o2
q3 → 128 维 注意力 → o3
q4 → 128 维 注意力 → o4

4Q 共享词元索引，各自计算
最终 注意力 权重

远区门控：从预填充观测到解码逐层复用

门控默认不启用；固定区域配额、有效历史长度路径；质量与成本尚未验证



GQA： 组共享选择，各查询头独立计算注意力



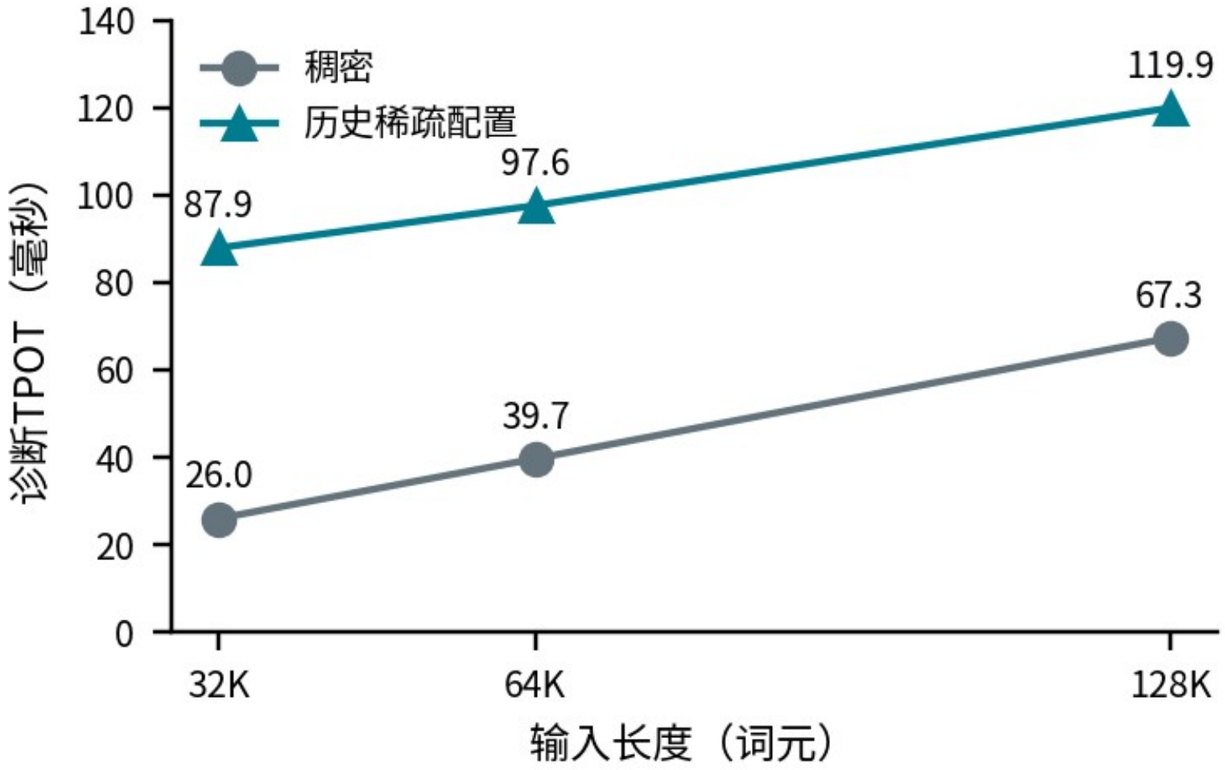
Q1： 缩小评分宽度能否保留任务质量?

L1 表示	L2 全维	L2 低频 32
全维	**全维稀疏对照** 未测量	**名义全维页评分** 均值： 47.910
低频 32	**名义全维词元评分** 均值： 47.666	**共享子空间** 均值： 47.588

归档评分实现
L2 张量宽 128 ／有效 32
配置匹配尚未确认

尚缺匹配比较 → **共享子空间与稠密 FullKV** → **文档配对质量评估**

历史动态缓存：同步模型级解码计时



作者报告中位数 • 非完整请求 E2E

Qwen3-8B，固定 128 输出词元

127 个首输出后间隔，逐步同步

历史稀疏配置 α=.125 / β=.375 / γ=.625

不同于当前 4/128 候选；运行路径未独立核验

32K/64K/128K 报告中位数之比（稀疏／稠密）： 3.38 / 2.46 / 1.78

三档比值减小，但稀疏 TPOT 仍上升且高于稠密；汇总不能定位因果瓶颈。

区域访问与门控：证据支持到哪里？

归档 128/128 保护： L2 宽 128 、有效 32 ； 不代表当前 4/128 候选

低频表示

47.588

五任务均值；相对名义全维页评分
低 0.322 分，相对名义全维词元评分
低 0.078 分；配置未确认匹配，
不能隔离阶段效应。

近远检索

26.09 → 47.91

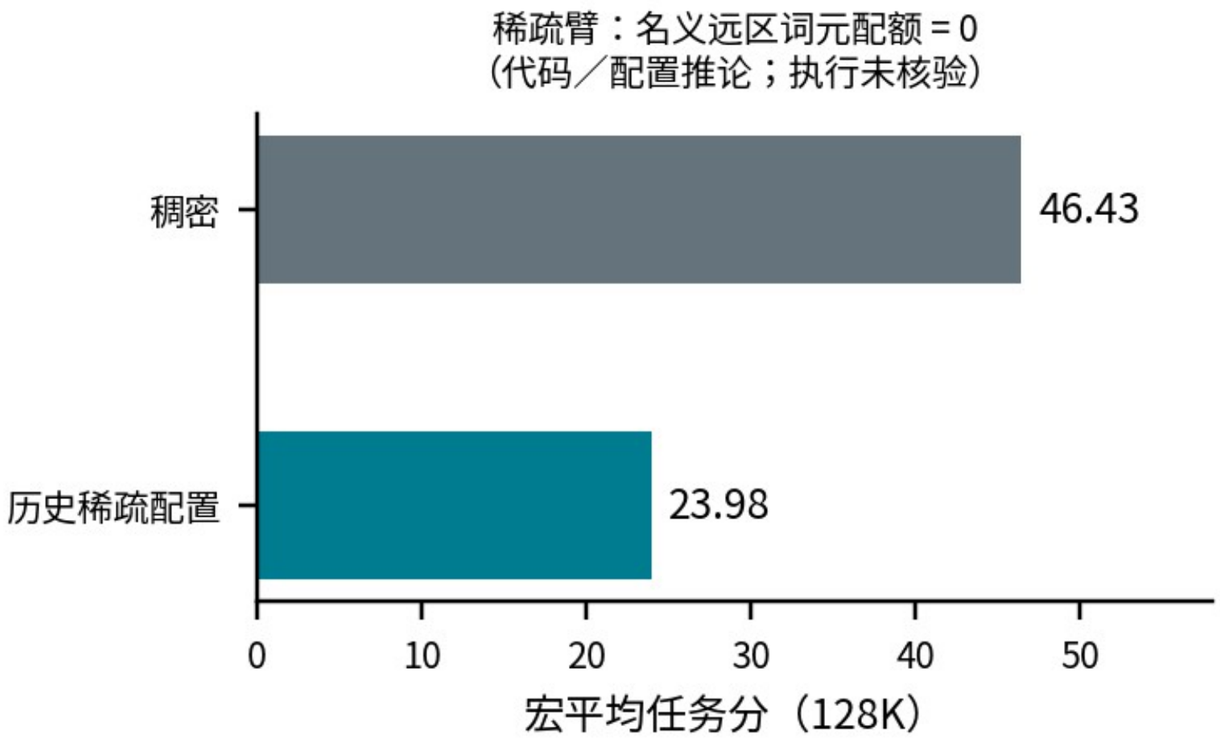
仅保护词元与中间历史检索比较，
预算 256→1024 ，
未隔离区域分配效应。

可选远区门控

3 / 5

阈值 0.05/0.10 各 3 项下降。
HotpotQA 降 1.05/1.26 分，
评分配置不完整，限于此对照。

保留历史 128K 质量负结果



历史 128K 得分： 46.43 / 23.98

11 任务；每任务每臂 100 例

报告 β=.375， K1=128，保护 128/128

中间预算 768；页长 64， γ=.625

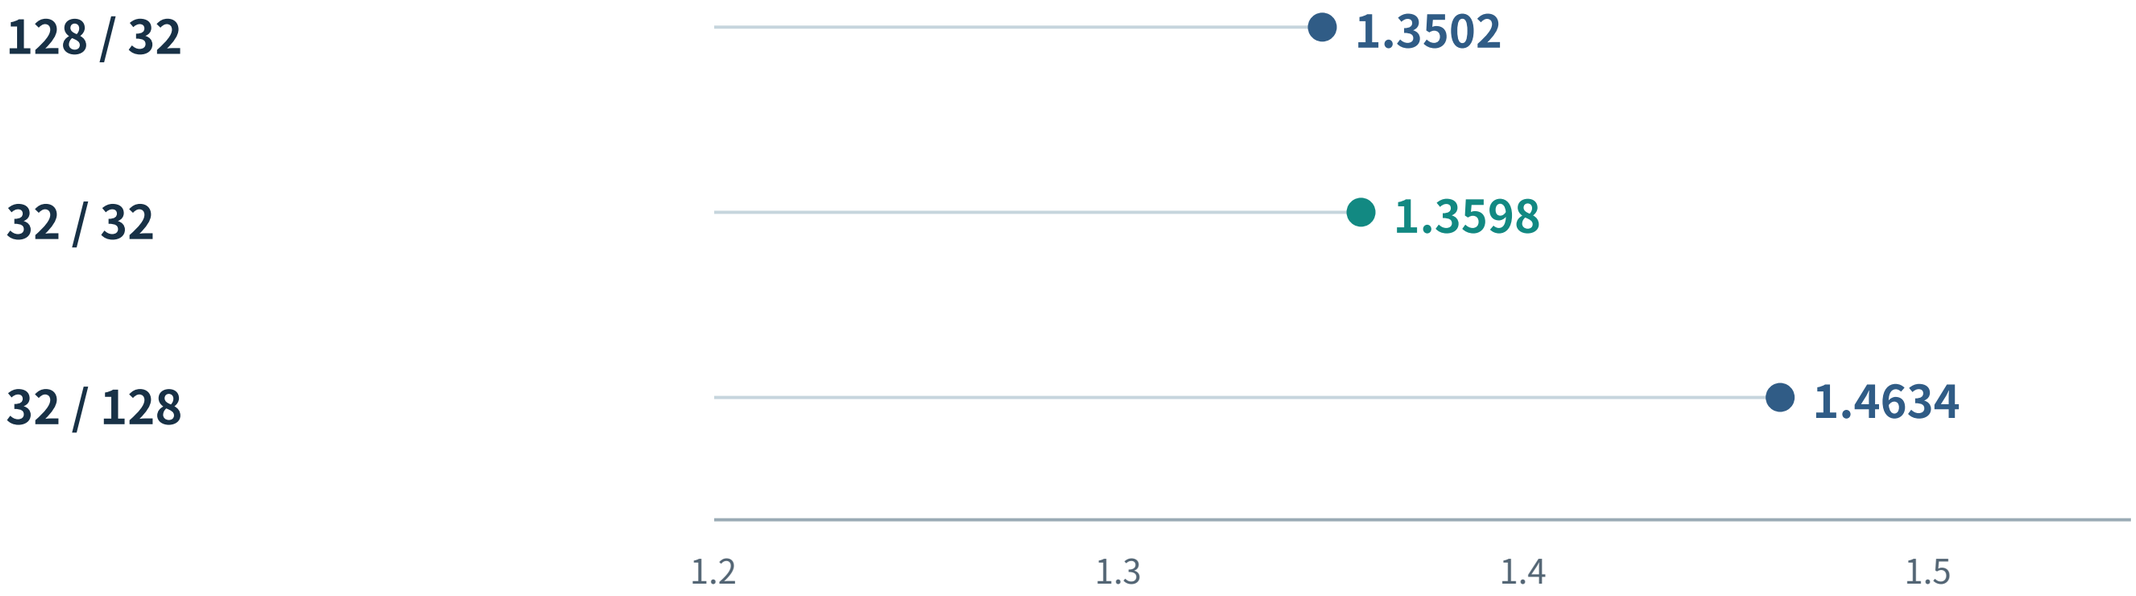
按已检公式：名义远区词元配额 =0

代码／配置推论；实际执行未核验

不能据此认定得分差的唯一原因；不验证当前 4/128 候选。

评分降维未降低该设置下的局部耗时

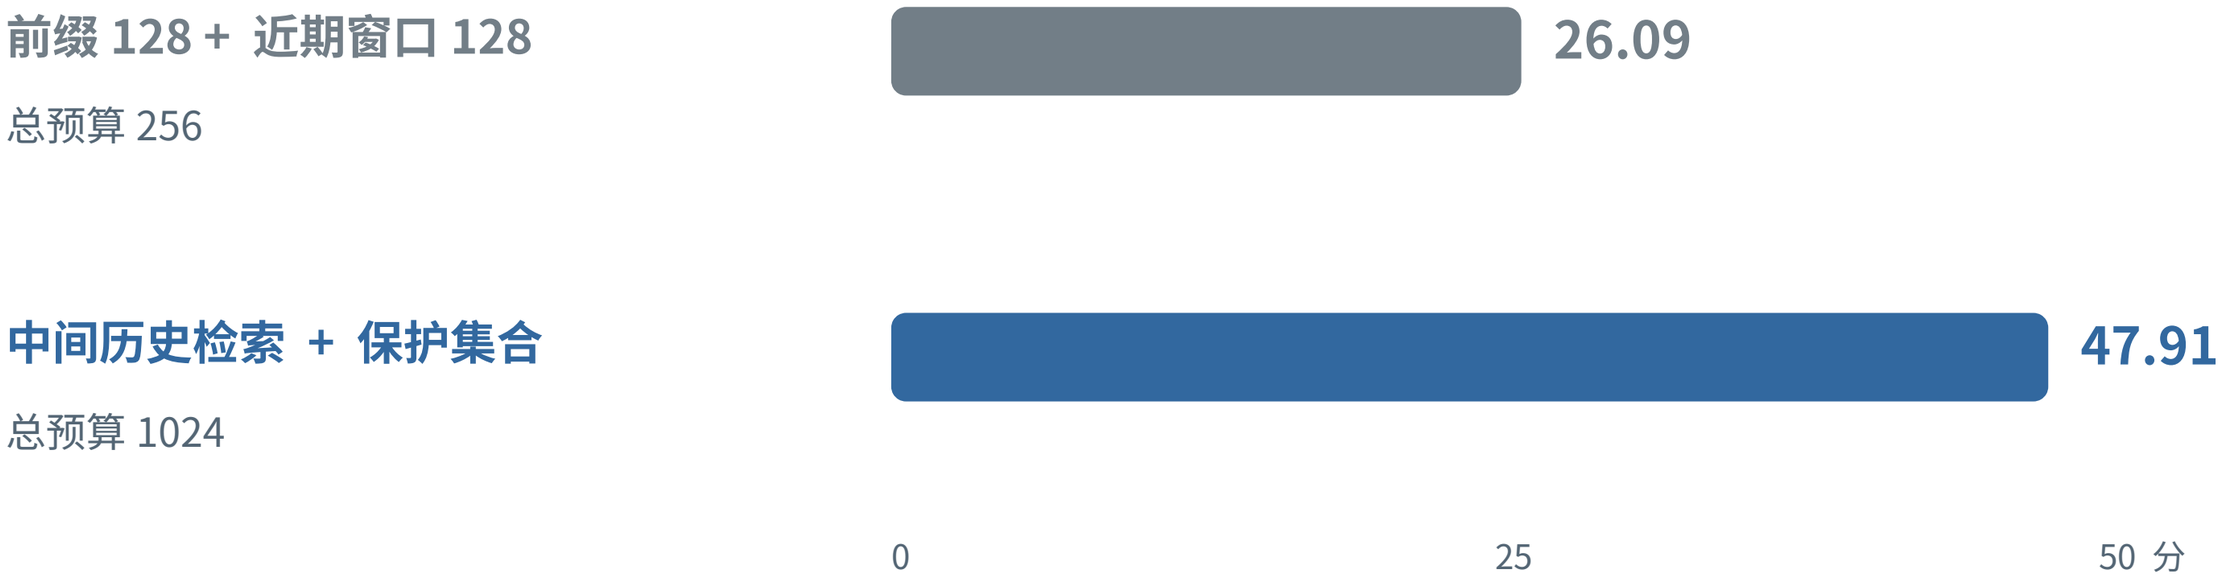
名义页／词元评分坐标数 • 合成 64K • 单层、批量 1 、单查询 • 两轮稳态汇总（ ms ）



采样协议存在未核实差异，小幅时延差值不足以定位瓶颈。

历史 128/128 保护：检索与词元预算的联合变化

预算 256 与 1024 的联合变化，未隔离分区贡献



评分表示、区域访问与执行成本的取舍

共享低频评分表示

32 维选择 → 共享词元索引

↓

原 128 维 注意力

保留远区页，不保证留有远区词元配额
当前 4/128 尚缺匹配质量—成本验证

可选远区门控

预填充 标定

↓

解码 复用

门控默认关闭；历史任务存在损失
预填充统计不保证解码需求