子空间下的近远两级注意力

共享低维索引，保留原维注意力

32

维 / 16 完整旋转对

近区 / 远区

共享表示，两级选择

128

维原始 Q / K / V

方法设置

共享低频坐标与区域页配额

低频共享表示与近远分区的稀疏注意力

问题

页粗筛排除的历史，后续词元精筛无法恢复。

方法

L1 / L2 共享低频 RoPE32 视图，分区筛页与词元，
按组共享选集后用原 128 维 Q / K / V 完成注意力。

初步结果

Qwen3-8B 五任务均值 47.588 ，较名义全维页评分配置低 0.322 分。差值仅作描述，不能隔离阶段效应。

可选远区门控

远区门控在预填充阶段逐层标定，在解码入口固定后复用，默认关闭。低预填充概率不保证后续任务质量。

两级筛选的质量与成本



Qwen3-8B： 稠密注意力距离密度

尚未测量

64- 词元距离箱：概率质量／有效词元数
128/128 保护去重单列；逐头 softmax 后组内平均

近／远区：词元与页的集中程度

尚未测量

覆盖区域 90% 质量的最小词元／ 64 词元页比例
同时报告区域概率质量；含不完整页；不代表选择器召回率

检索机制与本方法的设计位置

FullKV	**稠密注意力**	同输入、精度与生成协议的质量 / 成本参照
AsyncTLS	**组共享的两级候选选择**	全维页评分、校准精筛通道与异步执行
Quest	**页级选择**	用页内坐标极值估计候选页相关性
ClusterKV	**聚类选择**	通过聚类组织 KV ， 建簇与维护构成额外成本

共享表示、区域容量与远端控制

01 共享低频 RoPE 坐标

同一坐标视图服务页筛选与词元精筛

同层同 KV 头的 16 完整旋转对
近区 / 远区、 L1 / L2 共用坐标

02 近远两级分配

区域配额保留近端与远端候选入口

固定 α / β / γ 定义区域和配额
最终仍用原 128 维 Q / K / V

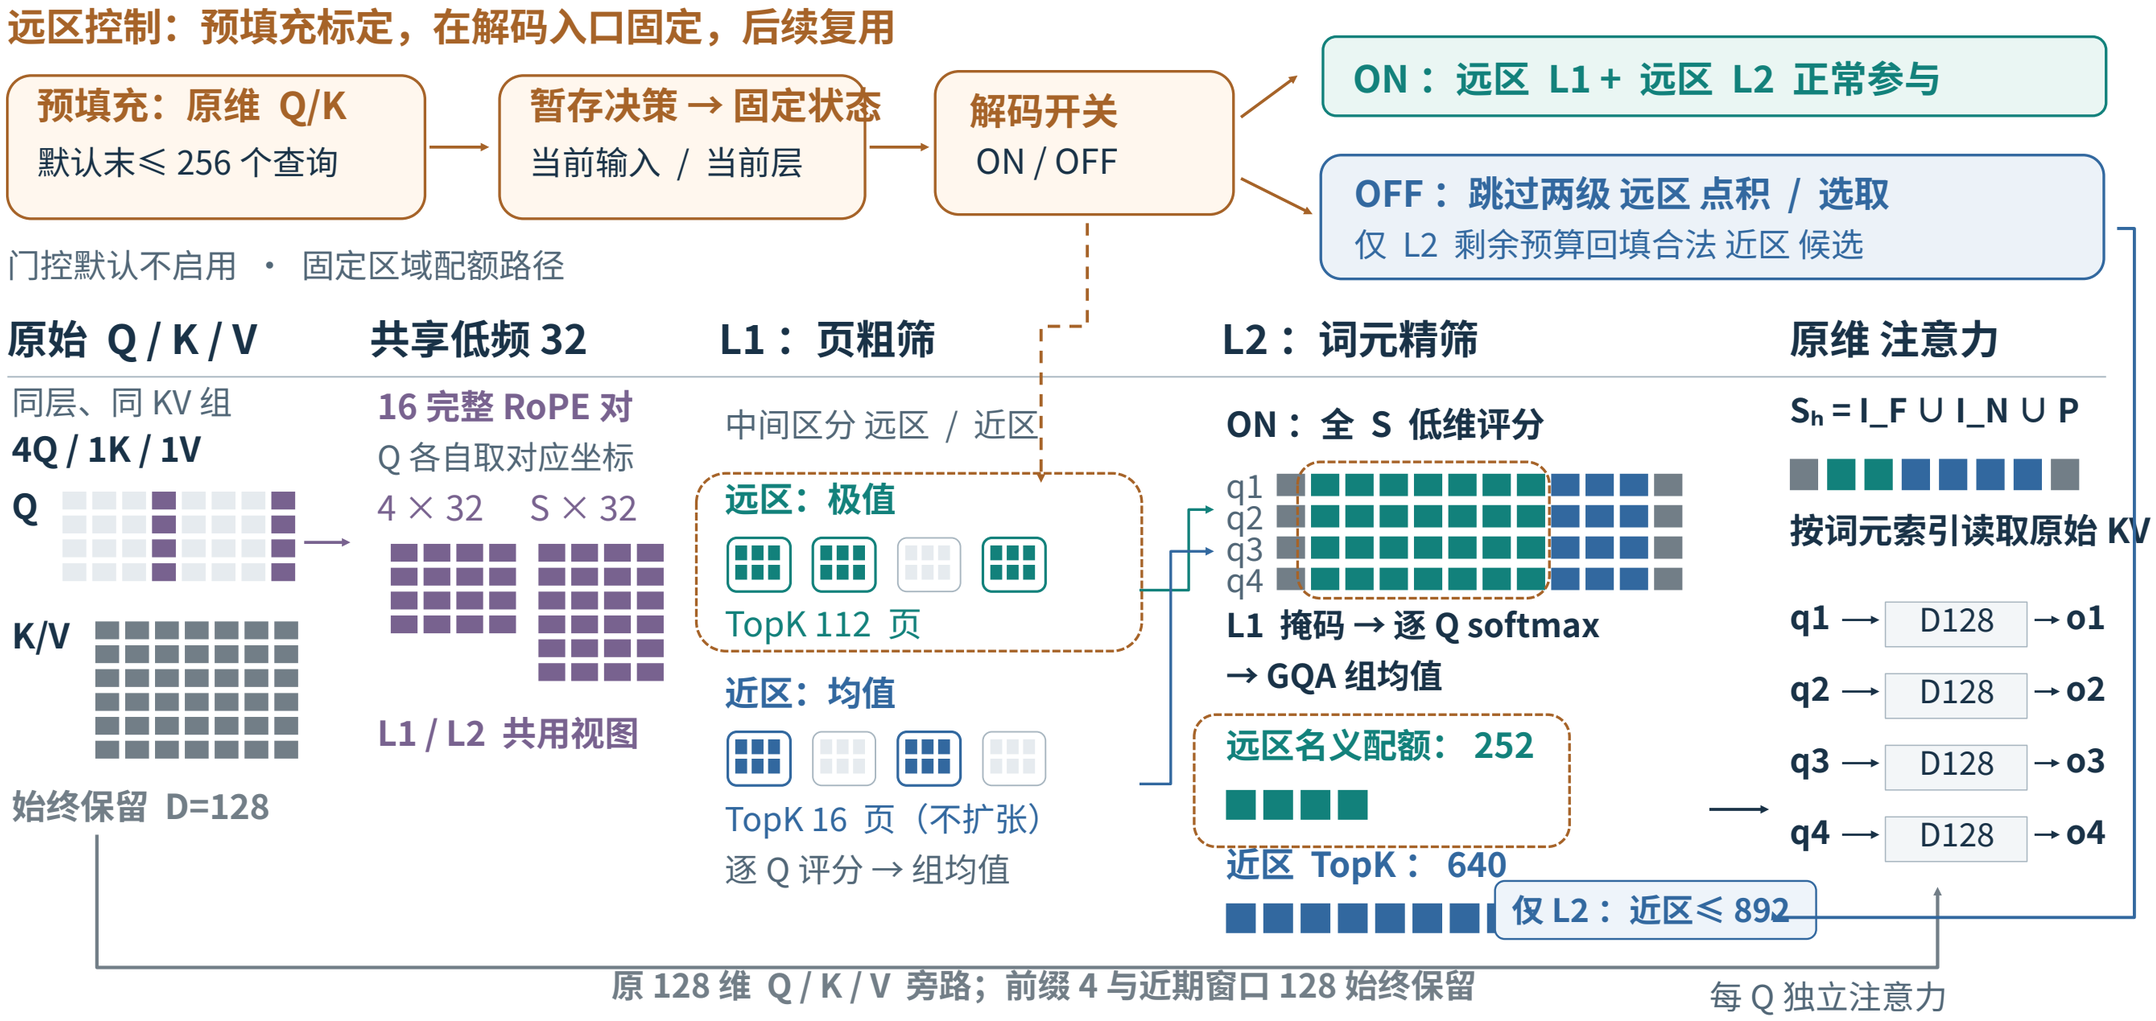
03 可选远区门控

默认关闭；低预填充概率不约束解码误差

预填充阶段为各输入确定逐层决策
解码复用，关闭远区时回填近区配额

总架构：低频索引与可选远区门控

原维 Q/K/V 始终保留；图示正常远区启用， OFF 只回填 L2 近端预算



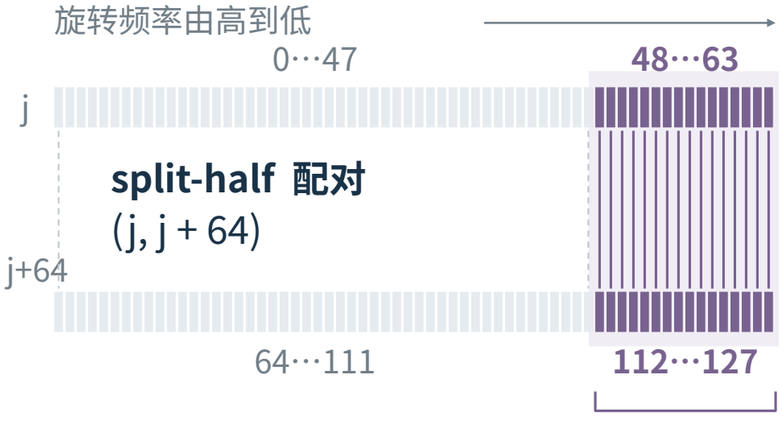
低频子空间： 16 个完整旋转对，共 32 维

16 完整旋转对，两级共用；浮点 16 级量化–反量化，原 128 维注意力

a 完整低频 RoPE 对

RoPE 后 • D = 128

32 个 Q 头 / 8 个 KV 头；每组 4Q + 1K



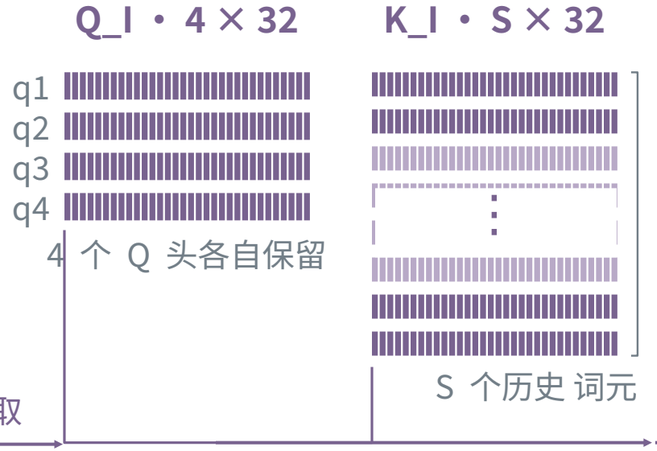
I = [48…63] ∪ [112…127]

32 坐标 = 16 个完整低频 RoPE 对

b 固定坐标选择视图

同一索引 I 作用于每个 Q / K

以下示意一个 KV 组

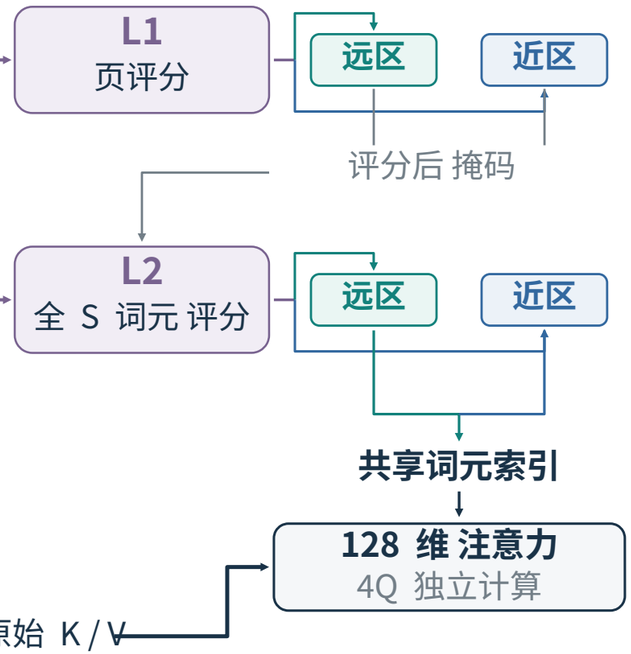


无学习投影；维度索引固定

Q 头独立 • K 视图组内共享

c 两级复用与原维计算

表示共享先于 近区 / 远区 分区





原始 Q / K / V • 128 维

绕过选择视图，按共享词元索引读取原始 K / V

近远两级筛选：位置、页预算与词元预算

候选充足的 4/128 示例；远区可重复选中至多 4 个前缀词元

a 共享 RoPE32

RoPE 后： 4Q / 1 KV 组

Q

0…63　64…127

K

[48…63] ∪ [112…127]
16 对完整 RoPE 坐标

4 × 32　S × 32

$q_1 \ldots q_4$　K_s

L1 / L2 复用同一 RoPE32

b L1： 区域页筛选

按位置划分未保护中间历史

P | 远区 | 近区 | P

$|M_t| = S - |P_t|$

α=.25 定边界；页对齐，近区≥ 64

近区∩ P=∅ ； $|P_t|$=132 示例

每 Q 页分 → 组内 均值 → TopK

远区 • 极值

112 页

近区 • 均值

16 页

L1 候选页 掩码

K_1=128 ； β=.125 → 近区 16 / 远区 112 页

c L2： 区域 词元 筛选

普通 L2： 32 维全 S 评分

S

q1
q2
q3
q4

[4, S]

加 L1 掩码

每 Q softmax　组内 均值

区域 词元 TopK

近区 = min(892, ⌊γ • 16 • 64⌋) = 640

远区名义配额 = 892 − 640 = 252

区域名义槽位： 892

d 原维注意力

原始 128 维 Q / K / V 保留

K　V

P = 前缀 4 ∪ 近期窗口 128

$S_h = I_F \cup I_N \cup P$

名义 1024 = 252 + 640 + 132

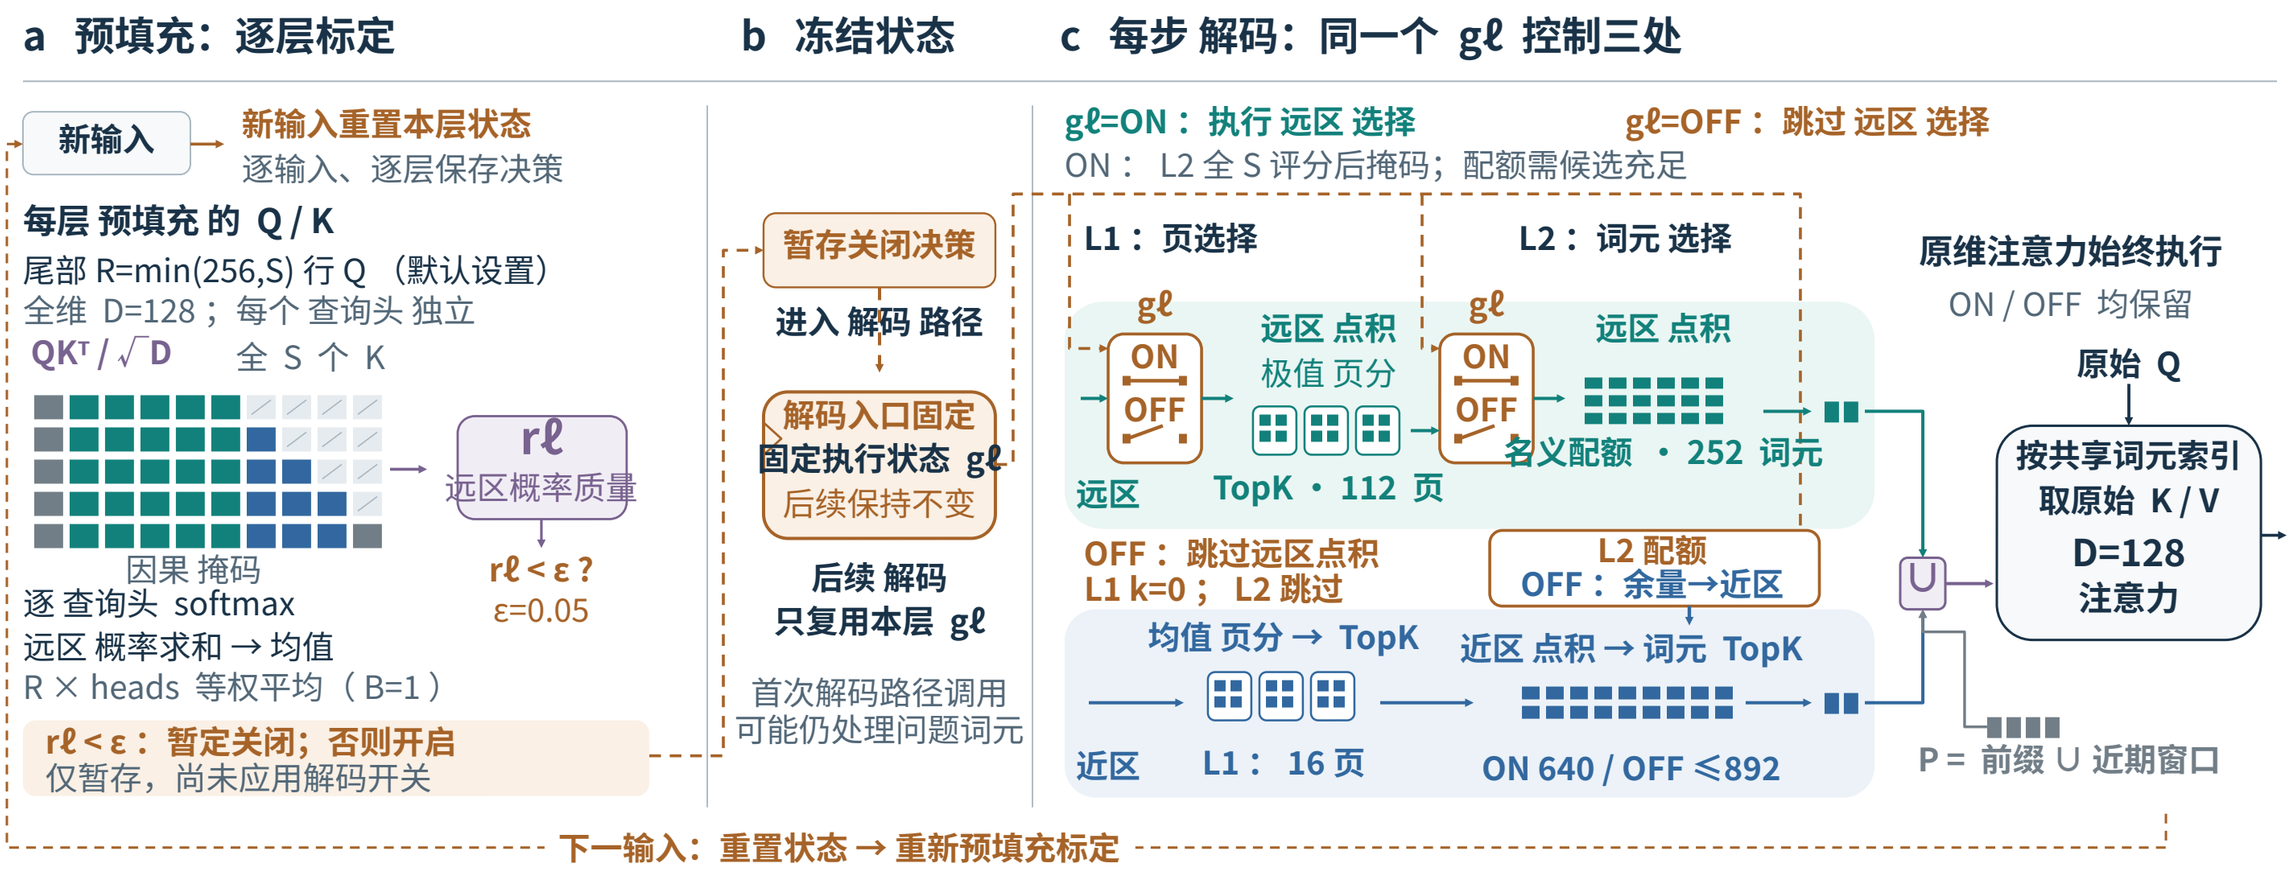
按 S_h 读取原始 K / V

q1 → 128 维 注意力 → o1
q2 → 128 维 注意力 → o2
q3 → 128 维 注意力 → o3
q4 → 128 维 注意力 → o4

4Q 共享词元索引，各自计算
最终 注意力 权重

远区门控：从预填充观测到解码逐层复用

门控默认不启用；固定区域配额、有效历史长度路径；质量与成本尚未验证



GQA： 组共享选择，各查询头独立计算注意力



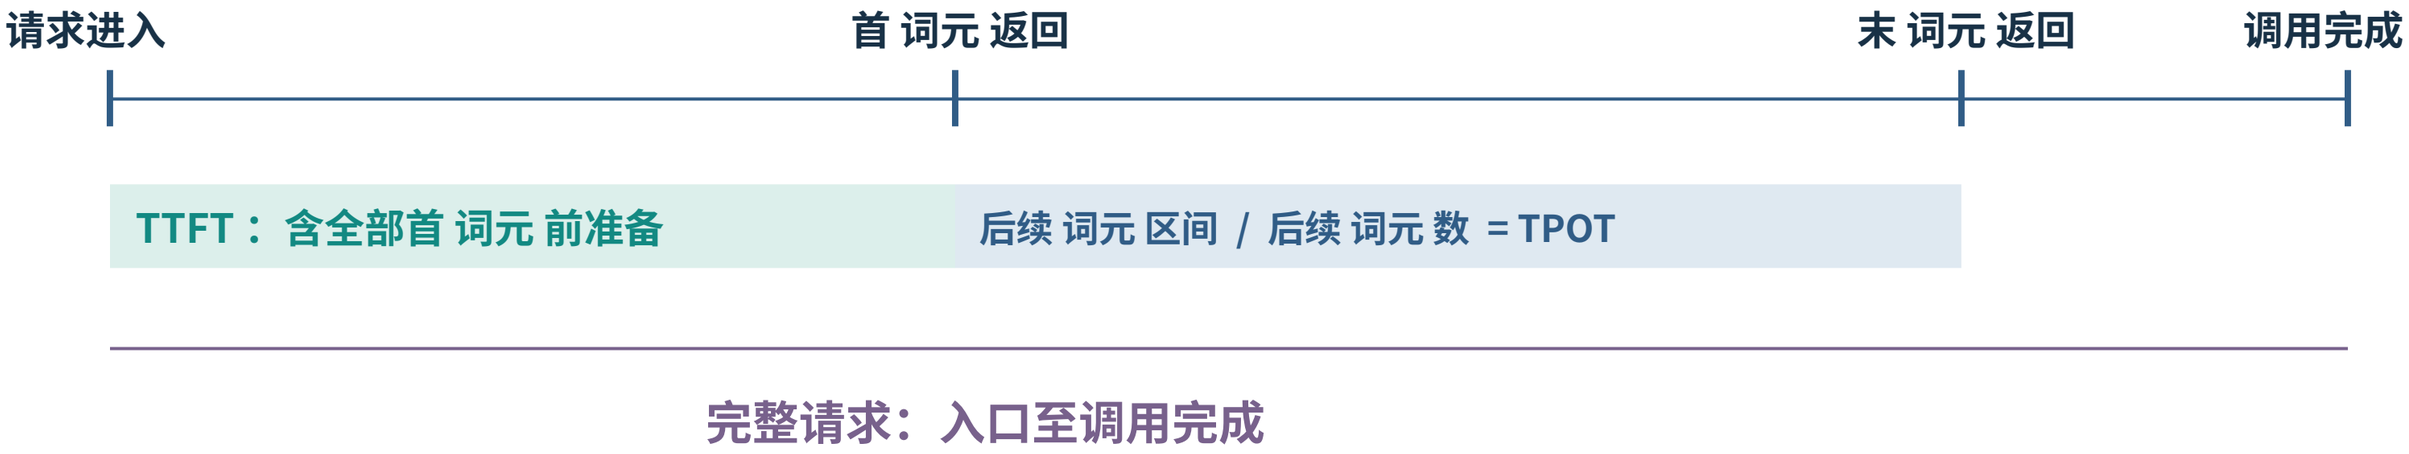
三种名义配置的描述性比较

L1 表示	L2 全维	L2 低频 32
全维	**全维稀疏对照** 未测量	**名义全维页评分** 均值： 47.910
低频 32	**名义全维词元评分** 均值： 47.666	**共享子空间** 均值： 47.588

归档评分实现
L2 张量宽 128 ／有效 32
配置匹配尚未确认

尚缺匹配比较 → **共享子空间与稠密 FullKV** → **文档配对质量评估**

完整请求与解码成本



完整请求成本

尚无匹配测量

输入长度（词元） × 请求实际经过时间（ms）
包含准备／维护／标定／选择／注意力／同步

解码词元成本

尚无匹配测量

输入长度（词元） × 每输出词元时间（ms）
最终去重 K 对齐； L1 页配额与相关成本另行报告

表示、检索范围与门控的初步结果

归档 128/128 保护： L2 宽 128 、有效 32 ； 不代表当前 4/128 候选

低频表示

47.588

五任务均值；较名义全维页评分低 0.322 分。名义全维词元评分高 0.078 分；配置未确认匹配，不能隔离阶段效应。

近远检索

26.09 → 47.91

仅保护词元与中间历史检索比较，预算 256→1024 ，未隔离区域分配效应。

可选远区门控

3 / 5

阈值 0.05/0.10 各 3 项下降。HotpotQA 降 1.05/1.26 分，评分配置不完整，限于此对照。

共享子空间配置相对 FullKV 的质量比较

当前方法

共享子空间

L1 / L2 共用低频 32 维

匹配参考

稠密 FullKV

相同输入、生成协议与评分

Δ 质量 = 共享子空间 − 稠密 FullKV

尚缺匹配测量与文档配对不确定性估计

相同输入上的逐任务差值与文档配对不确定性

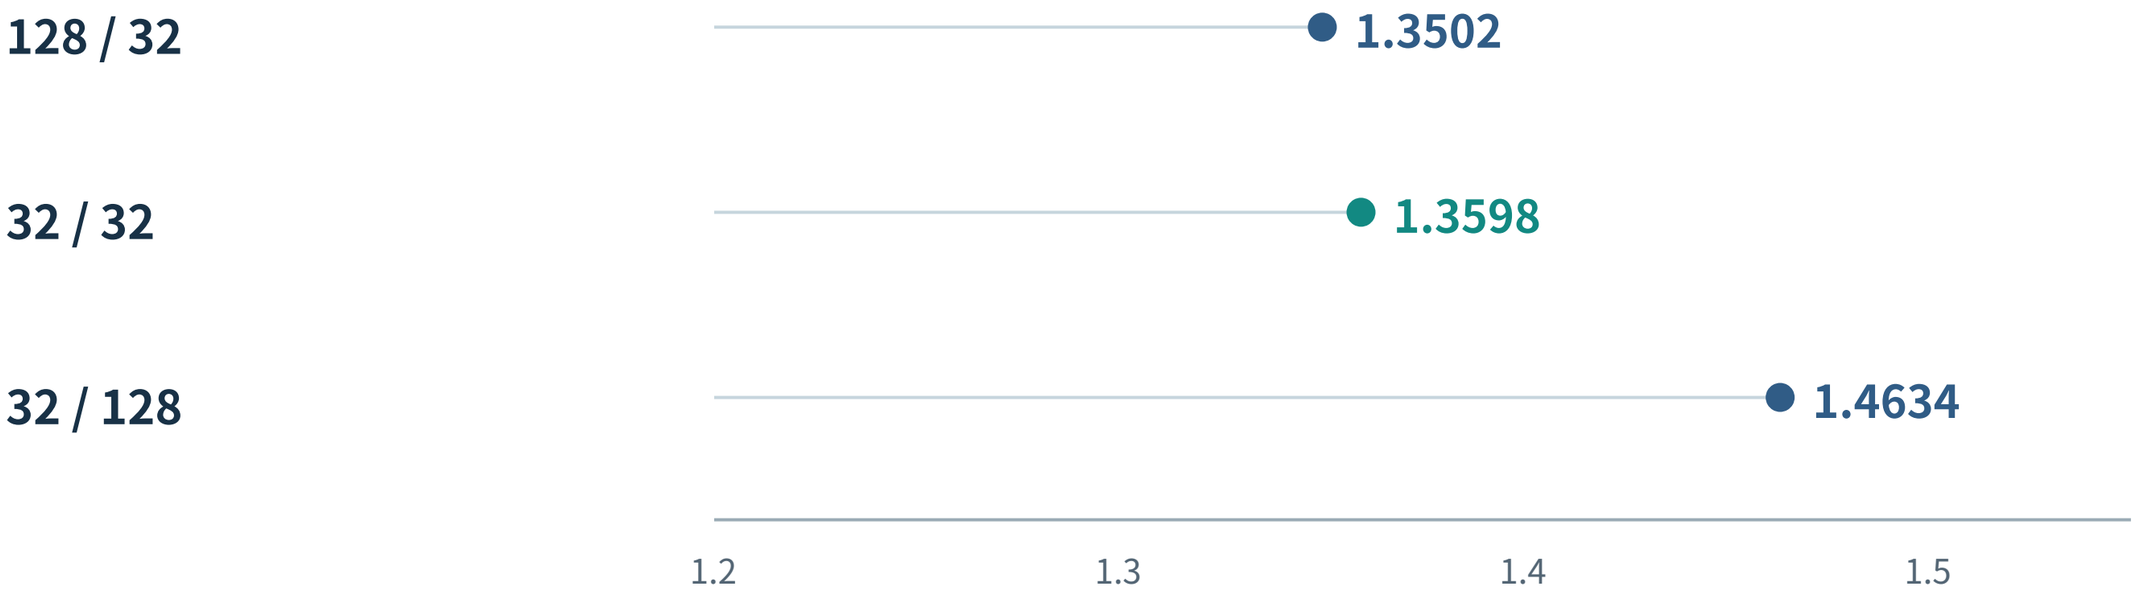
早期实现：五任务初步均值

共享子空间 47.588　　名义全维页评分 47.910　　名义全维词元评分 47.666

归档配置得分，不代表当前 4/128 候选；尚缺匹配稠密 FullKV 比较

评分降维未降低该设置下的局部耗时

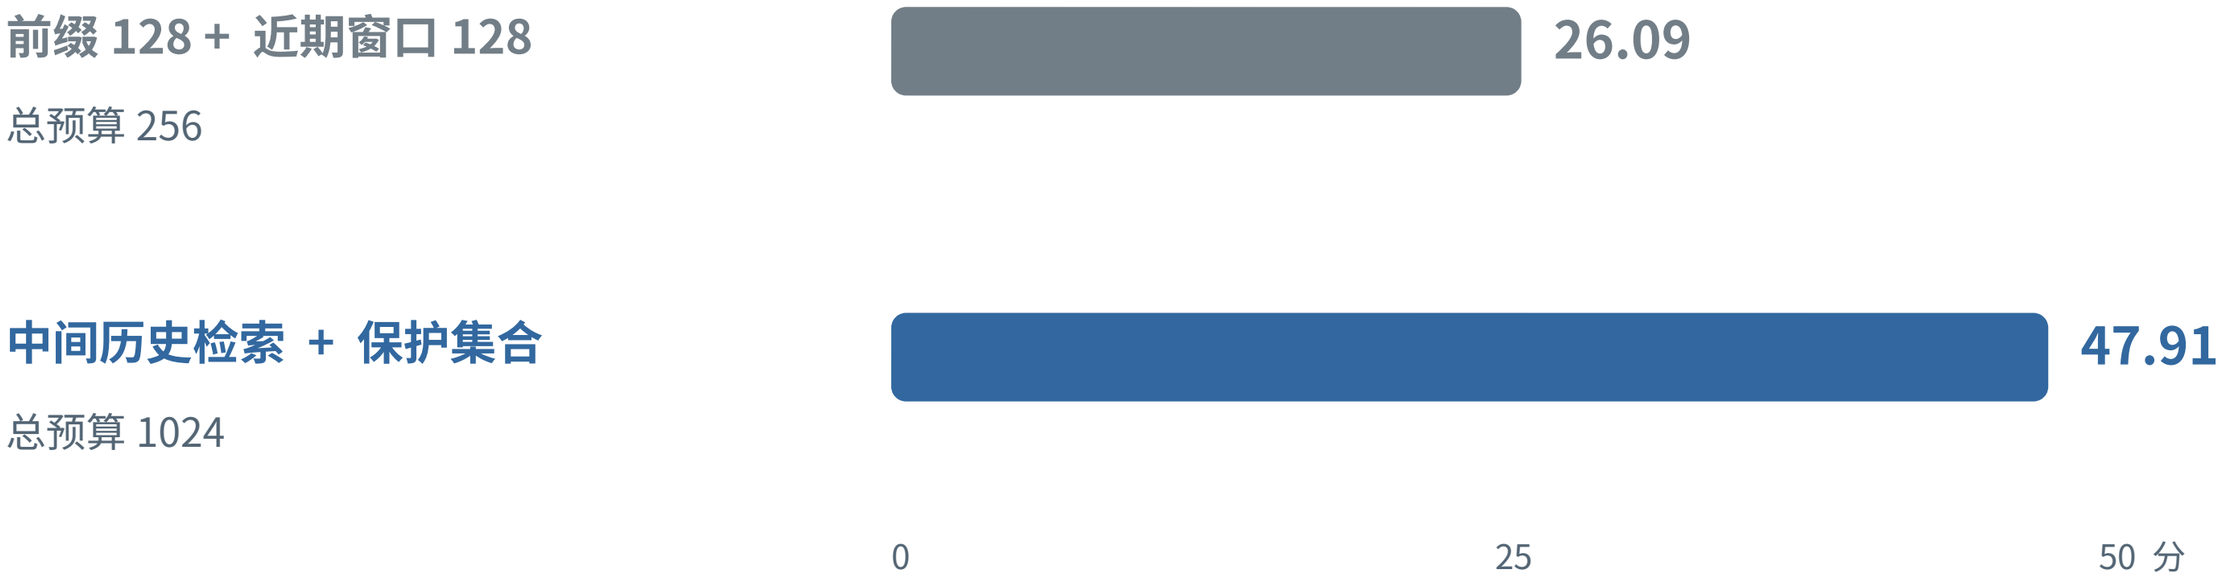
名义页／词元评分坐标数 • 合成 64K • 单层、批量 1 、单查询 • 两轮稳态汇总（ ms ）



采样协议存在未核实差异，小幅时延差值不足以定位瓶颈。

历史 128/128 保护：检索与词元预算的联合变化

预算 256 与 1024 的联合变化，未隔离分区贡献



表示质量与执行成本的取舍

共享低频评分表示

32 维选择 → **共享词元索引**

↓

原 128 维 注意力

五任务均值 47.588
配置差值不能隔离评分阶段效应

可选远区门控

预填充 标定

↓

解码 复用

小幅均值变化掩盖逐任务损失
低预填充概率不能保证解码质量