子空间下的近远两级注意力

共享低维索引，保留原维注意力

32

维 / 16 完整旋转对

近区 / 远区

共享表示，两级选择

128

维原始 Q / K / V

方法设置

共享低频坐标与区域页配额

固定词元预算下：候选访问与选择成本

问题

均值与极值刻画不同评分目标，页注意力和另作参照。
全局 TopK 不提供区域容量保证。

方法

共享 32 坐标映射与区域页配额协同选择，
最终在选集上使用原 128 维 Q / K / V 。

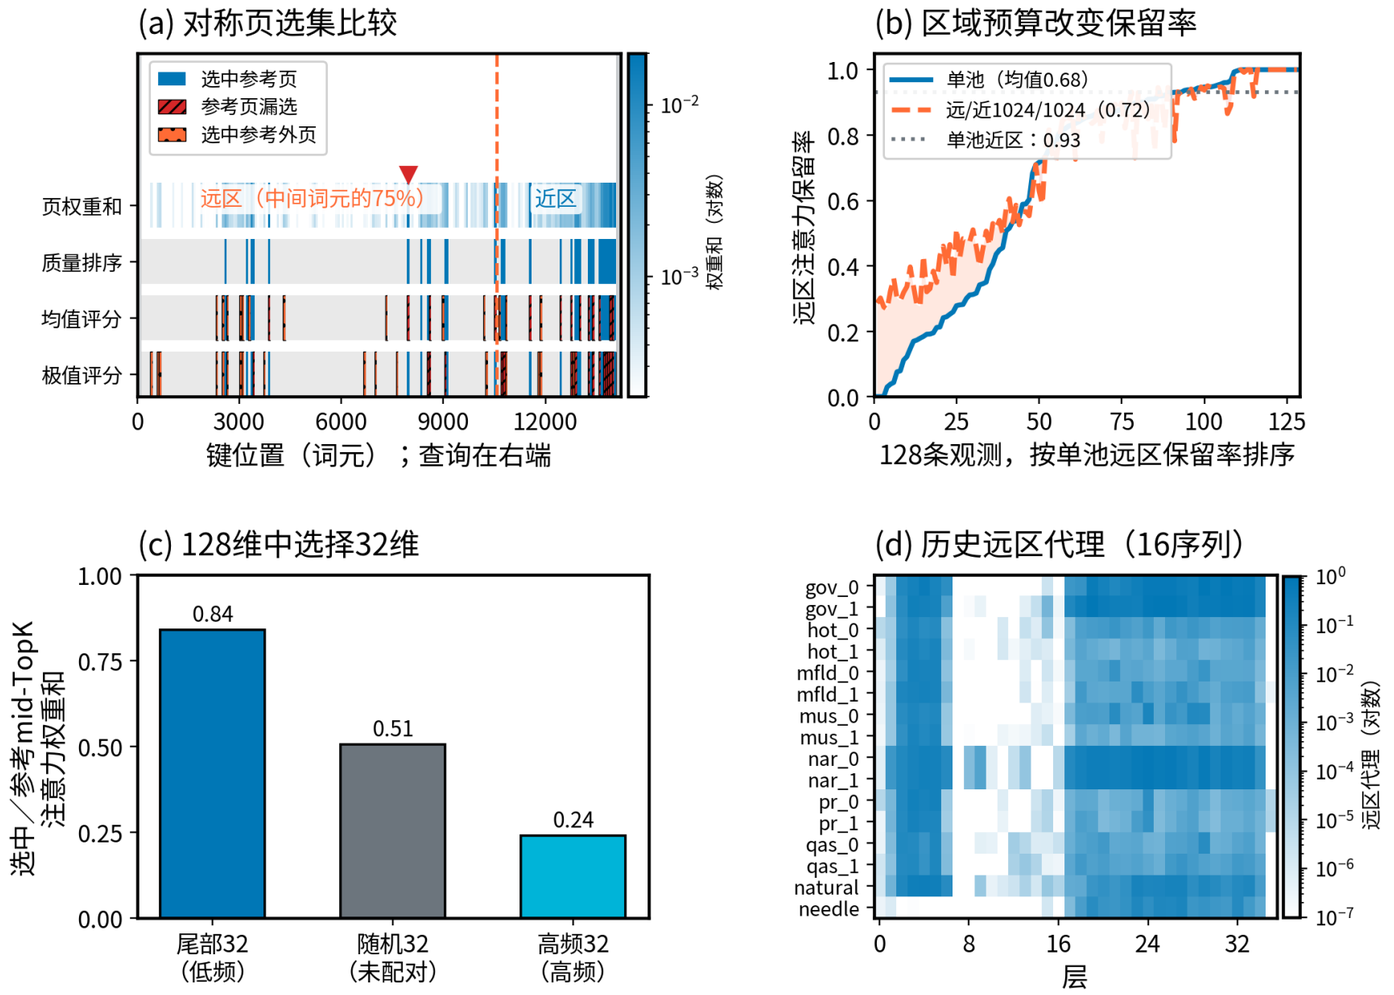
观察与边界

区域预留改变远区覆盖， 43/128 条观测下降；历史稀疏解码更慢，当前 4/128 尚缺匹配质量—成本结果。

可选远区门控

远区门控在预填充阶段逐层标定，在解码入口固定后复用，默认关闭。低预填充概率不保证后续任务质量。

四项观察：区域选集、紧凑坐标与历史层差异



(a) 页权重排序≠词元 TopK；实际 1989/1989/2048 词元；均值／极值同 32 维，参考为全维；不能证明区域分工；
(b) 43/128 条下降；(c) 随机未配对；(d) 历史代理，不是当前门控或解码保证。

检索机制与本方法的设计位置

FullKV	**稠密注意力**	同输入、精度与生成协议的质量 / 成本参照
AsyncTLS	**级联、坐标选择与量化评分**	逐查询概率聚合；原维 KV 最终注意力
Quest	**页级选择**	用页内坐标极值估计候选页相关性
ClusterKV	**聚类选择**	通过聚类组织 KV ，建簇与维护构成额外成本

两项核心机制，一个可选扩展

01 共享低频 RoPE 坐标

共享坐标映射，不要求共享物理缓冲区

同层同 KV 头的 16 完整旋转对
近区 / 远区、 L1 / L2 共用坐标

02 近远两级分配

区域配额保留近端与远端候选入口

固定 α / β / γ 定义区域和配额
最终仍用原 128 维 Q / K / V

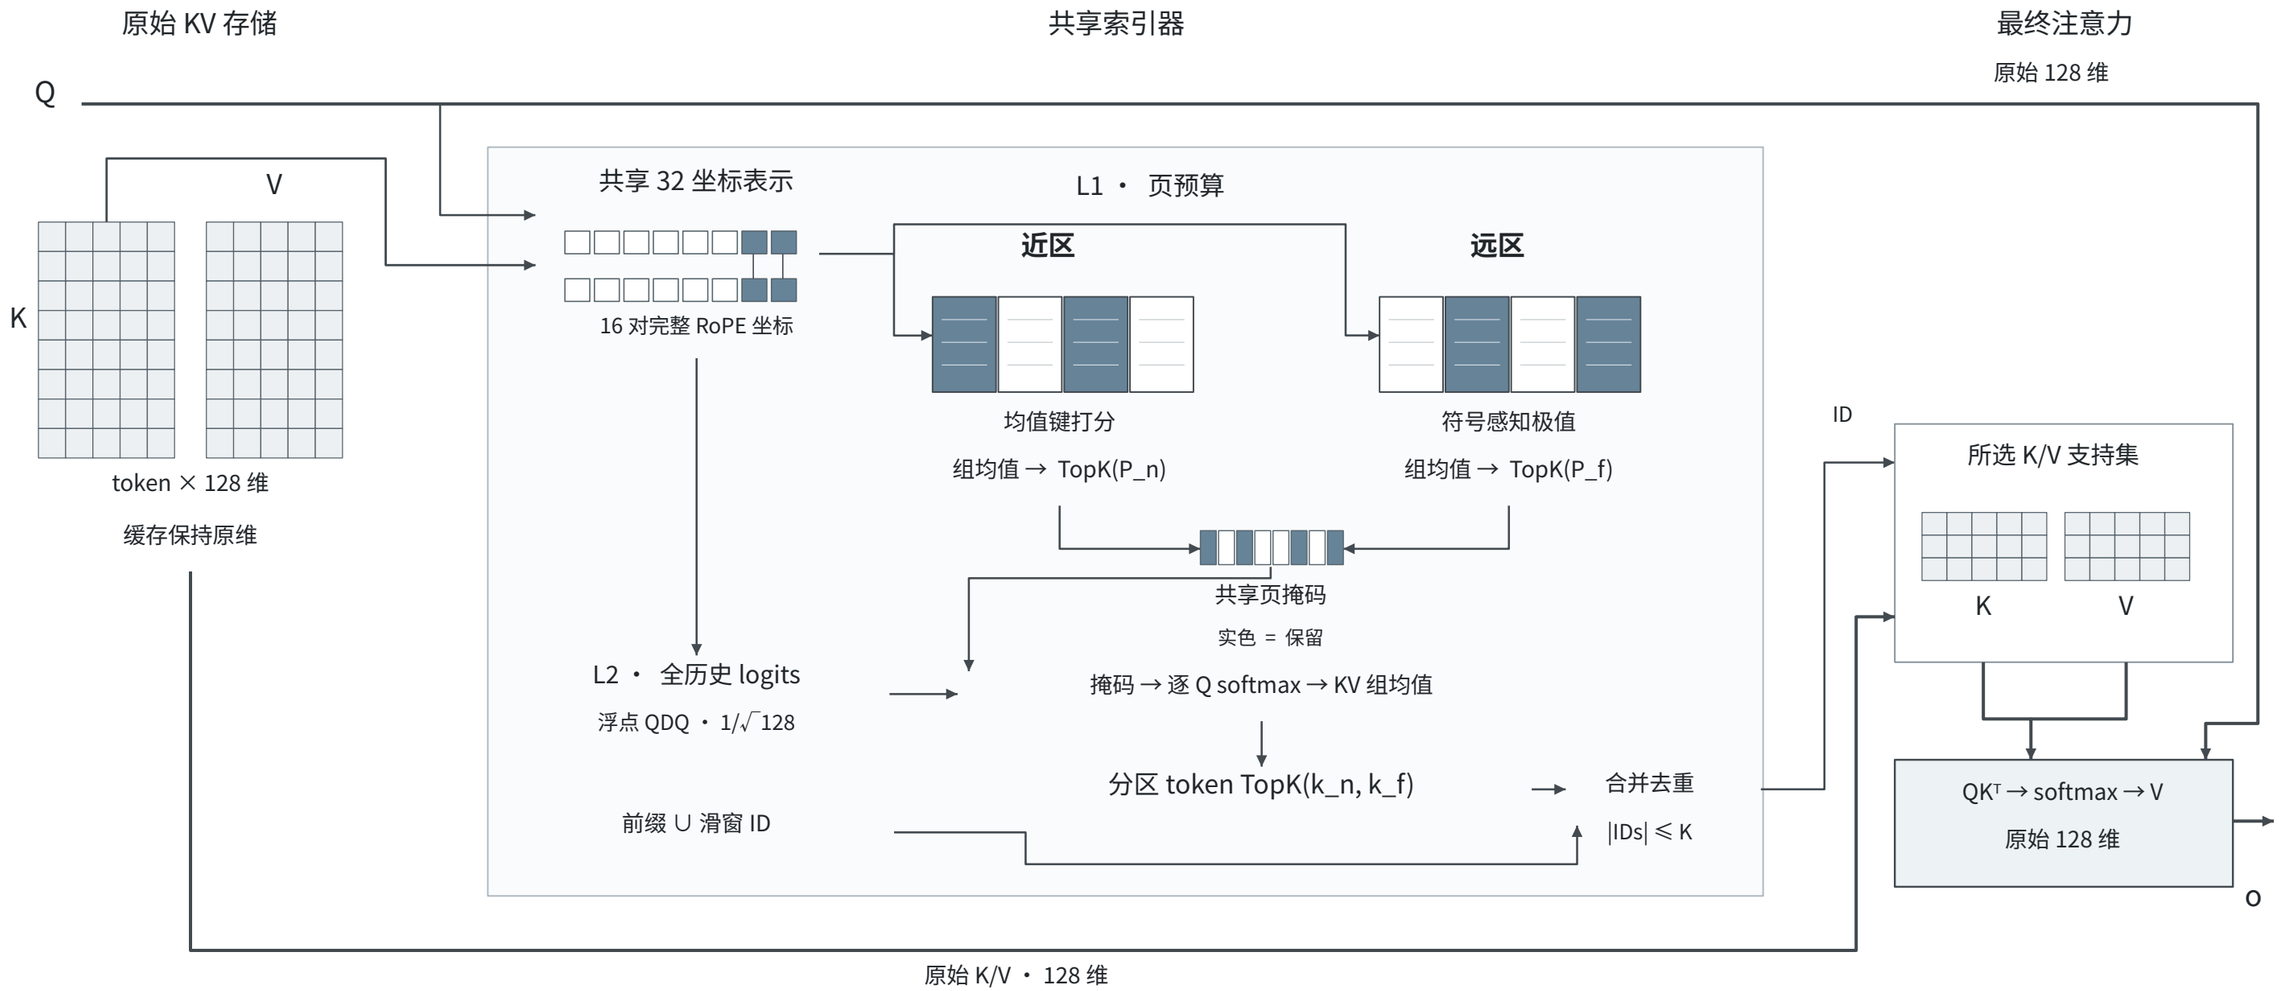
03 可选远区门控

默认关闭；低预填充概率不约束解码误差

预填充阶段为各输入确定逐层决策
解码复用，关闭远区时回填近区配额

总架构：共享索引与原维注意力

门控未启用的普通路径；近区不含保护滑窗， KV 物理访问由后端决定



低频子空间： 16 个完整旋转对，共 32 维

16 完整旋转对，两级共用； L2 用浮点 16 级量化–反量化，最终为原维注意力

a 完整低频 RoPE 对

RoPE 后 • D = 128

32 个 Q 头 / 8 个 KV 头；每组 4Q + 1K

旋转频率由高到低

0…47　48…63

j

split-half 配对

(j, j + 64)

j+64

64…111　112…127

I = [48…63] ∪ [112…127]

32 坐标 = 16 个完整低频 RoPE 对

b 固定坐标选择视图

同一索引 I 作用于每个 Q / K

以下示意一个 KV 组

Q_I • 4 × 32　**K_I • S × 32**

q1
q2
q3
q4

4 个 Q 头各自保留

S 个历史 词元

坐标选取

无学习投影；维度索引固定

Q 头独立 • K 视图组内共享

c 两级复用与原维计算

表示共享先于 近区 / 远区 分区

L1
页评分

远区　近区

评分后 掩码

L2
全 S 词元 评分

远区　近区

共享词元索引

128 维 注意力
4Q 独立计算

Q
K
V

原始 Q / K / V • 128 维

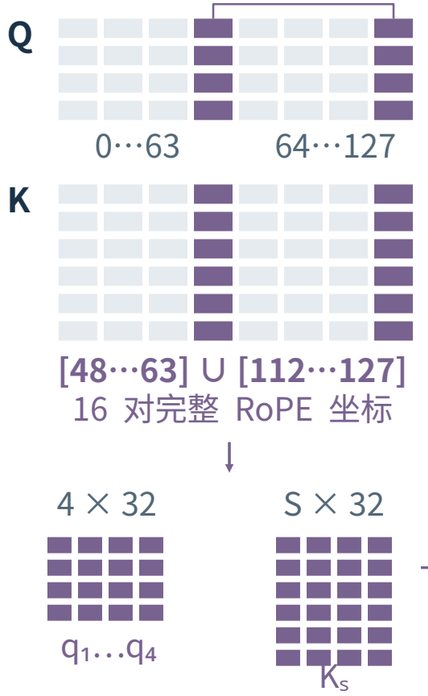
绕过选择视图，按共享词元索引读取原始 K / V

近远两级筛选：位置、页预算与词元预算

4/128 候选充足示例；摘要按完整物理页计算，远区可重复选中至多 4 个前缀词元

a 共享 RoPE32

RoPE 后： 4Q / 1 KV 组



L1 / L2 复用同一 RoPE32

b L1： 区域页筛选

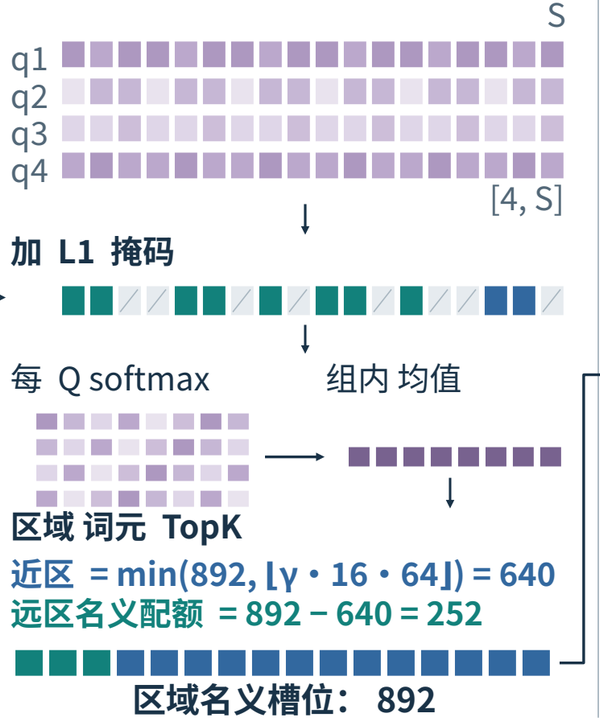
按位置划分未保护中间历史



K_1=128； β=.125 → 近区 16 / 远区 112 页

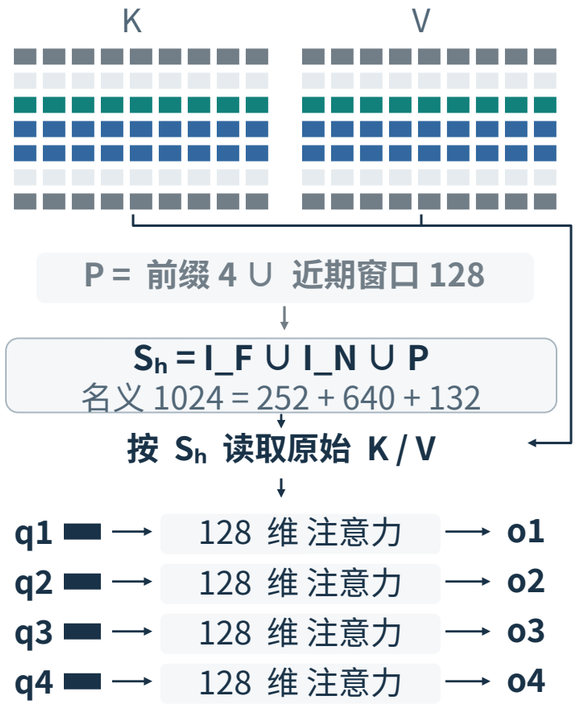
c L2： 区域 词元 筛选

普通 L2： 32 维全 S 评分



d 原维注意力

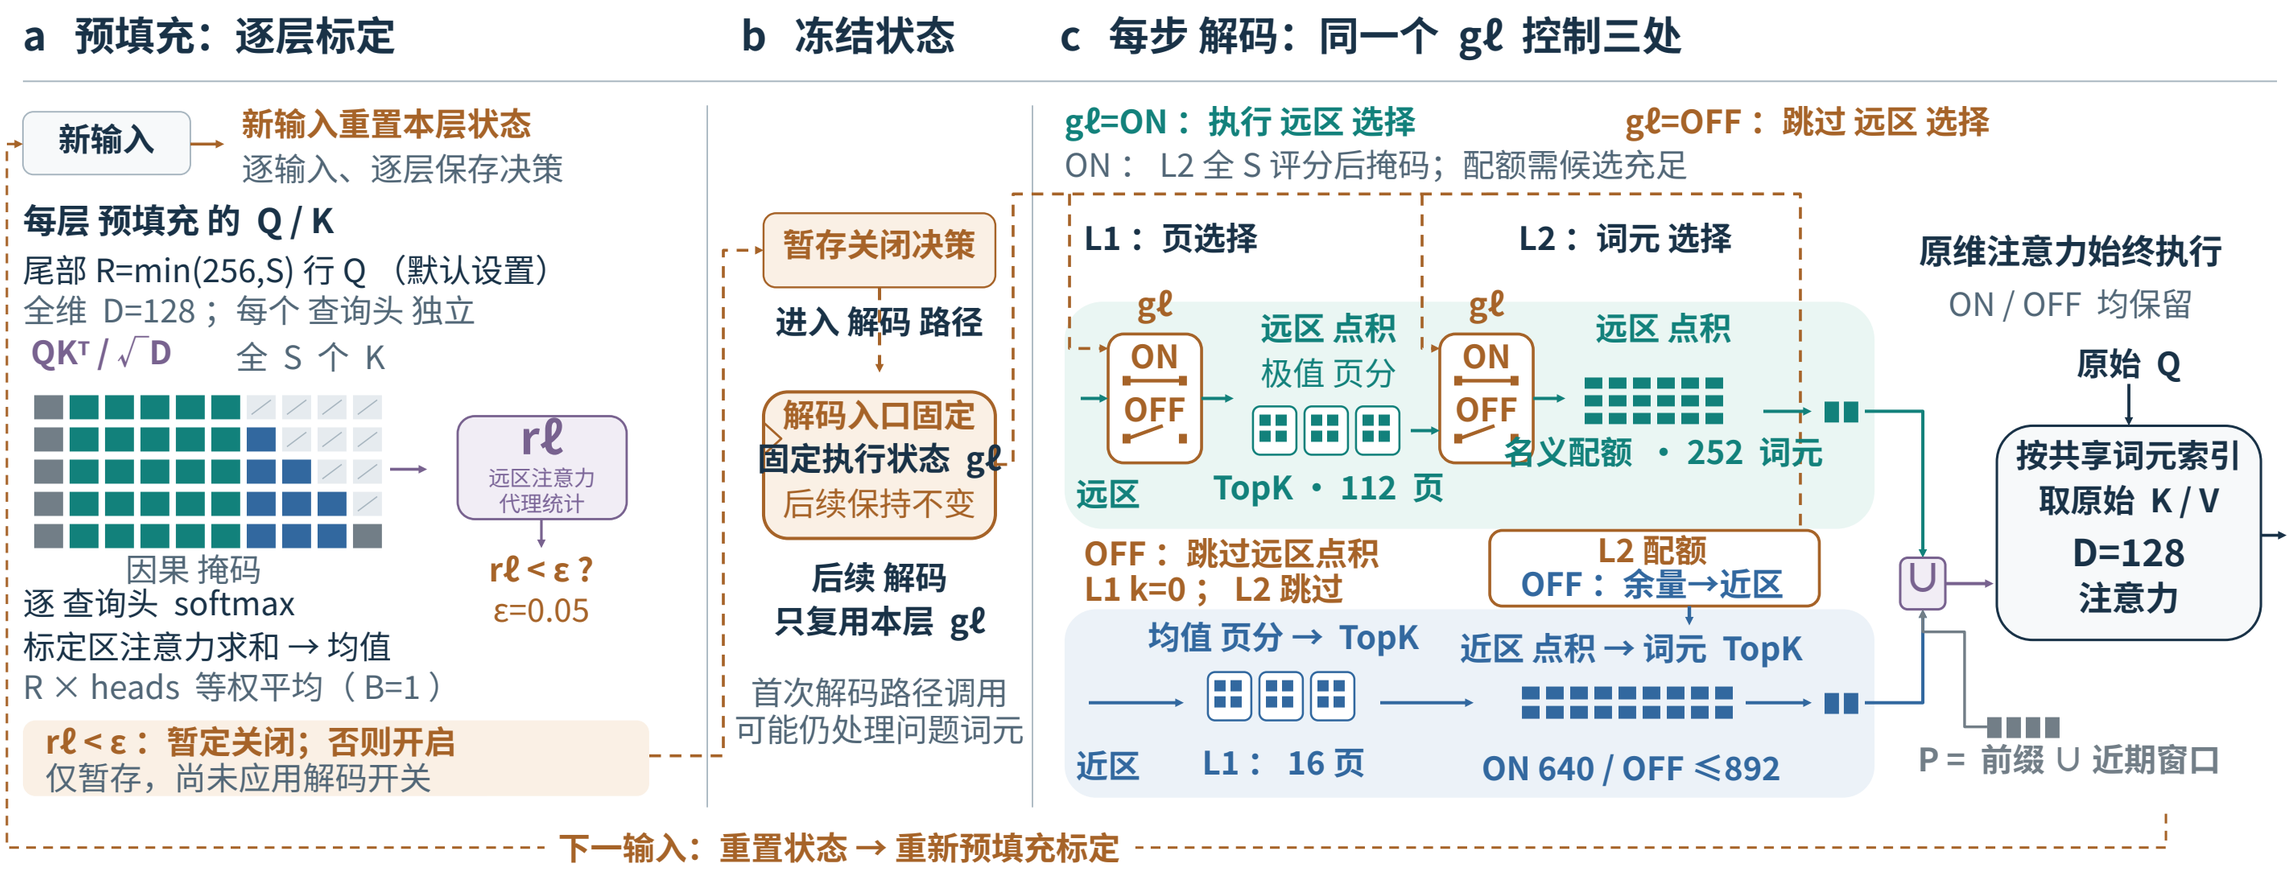
原始 128 维 Q / K / V 保留



4Q 共享词元索引，各自计算最终 注意力 权重

远区门控：从预填充观测到解码逐层复用

门控默认关闭；标定区域与跳过页边界不同，统计量是代理（补充 S5 ）



GQA： 组共享选择，各查询头独立计算注意力



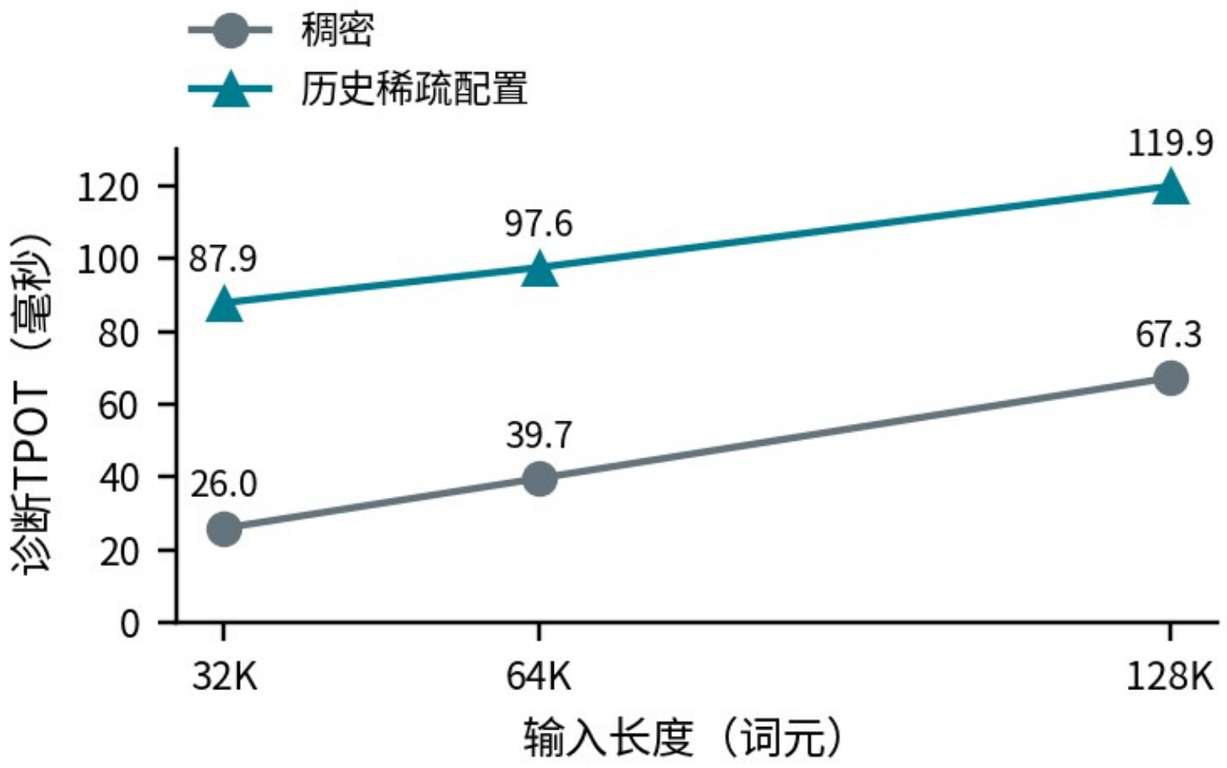
Q1： 缩小评分宽度能否保留任务质量?

L1 表示	L2 全维	L2 低频 32
全维	**全维稀疏对照** 未测量	**名义全维页评分** 均值： 47.910
低频 32	**名义全维词元评分** 均值： 47.666	**共享子空间** 均值： 47.588

归档评分实现
L2 张量宽 128 ／有效 32
配置匹配尚未确认

尚缺匹配比较 → **共享子空间与稠密 FullKV** → **固定任务集 AVG 逐任务解释差异**

历史动态缓存：同步模型级解码计时



作者报告中位数 · 非完整请求 E2E

Qwen3-8B，固定 128 输出词元

127 个首输出后间隔，逐步同步

历史稀疏配置 α=.125 / β=.375 / γ=.625

不同于当前 4/128 候选；
运行路径未独立核验

32K/64K/128K 稀疏／稠密中位数比：
3.38 / 2.46 / 1.78

三档比值减小，但稀疏 TPOT 仍上升且高于稠密；汇总不能定位因果瓶颈。

区域访问与门控：证据支持到哪里?

归档 128/128 保护： L2 宽 128 、有效 32 ； 不代表当前 4/128 候选

低频表示

47.588

五任务均值；相对名义全维页评分
低 0.322 分，相对名义全维词元评分
低 0.078 分；配置未确认匹配，
不能隔离阶段效应。

近远检索

26.09 → 47.91

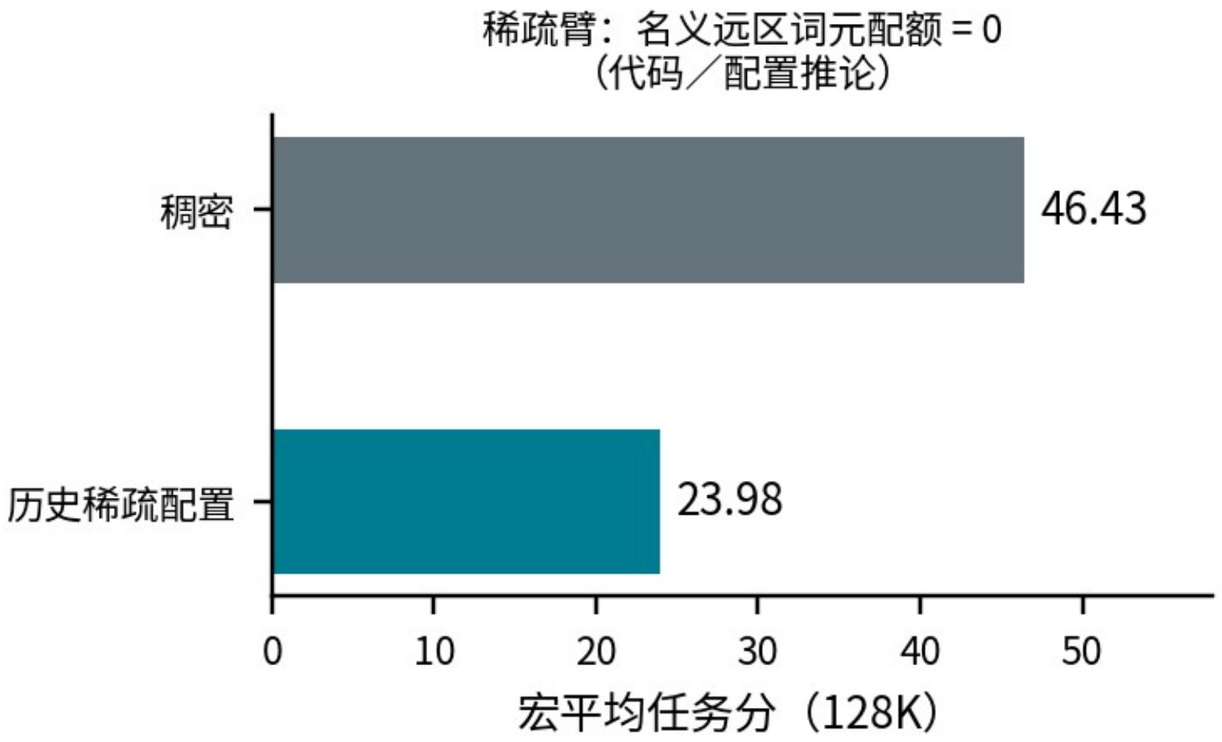
仅保护词元与中间历史检索比较，
预算 256→1024 ，
未隔离区域分配效应。

可选远区门控

47.876 / 47.692

阈值 .05/.10 ； 参考 AVG 47.910
AVG 变化 − .034 / −.218
各 3 项下降； Hotpot 降 1.05/1.26
逐任务仅诊断， AVG 为主
配置 / 配对 / 成本缺失；不证非劣

保留历史 128K 质量负结果



历史 128K 得分： 46.43 / 23.98

11 任务；每任务每臂 100 例

报告 β=.375 ， K1=128 ，保护 128/128

中间预算 768 ； 页长 64 ， γ=.625

按已检公式：名义远区词元配额 =0

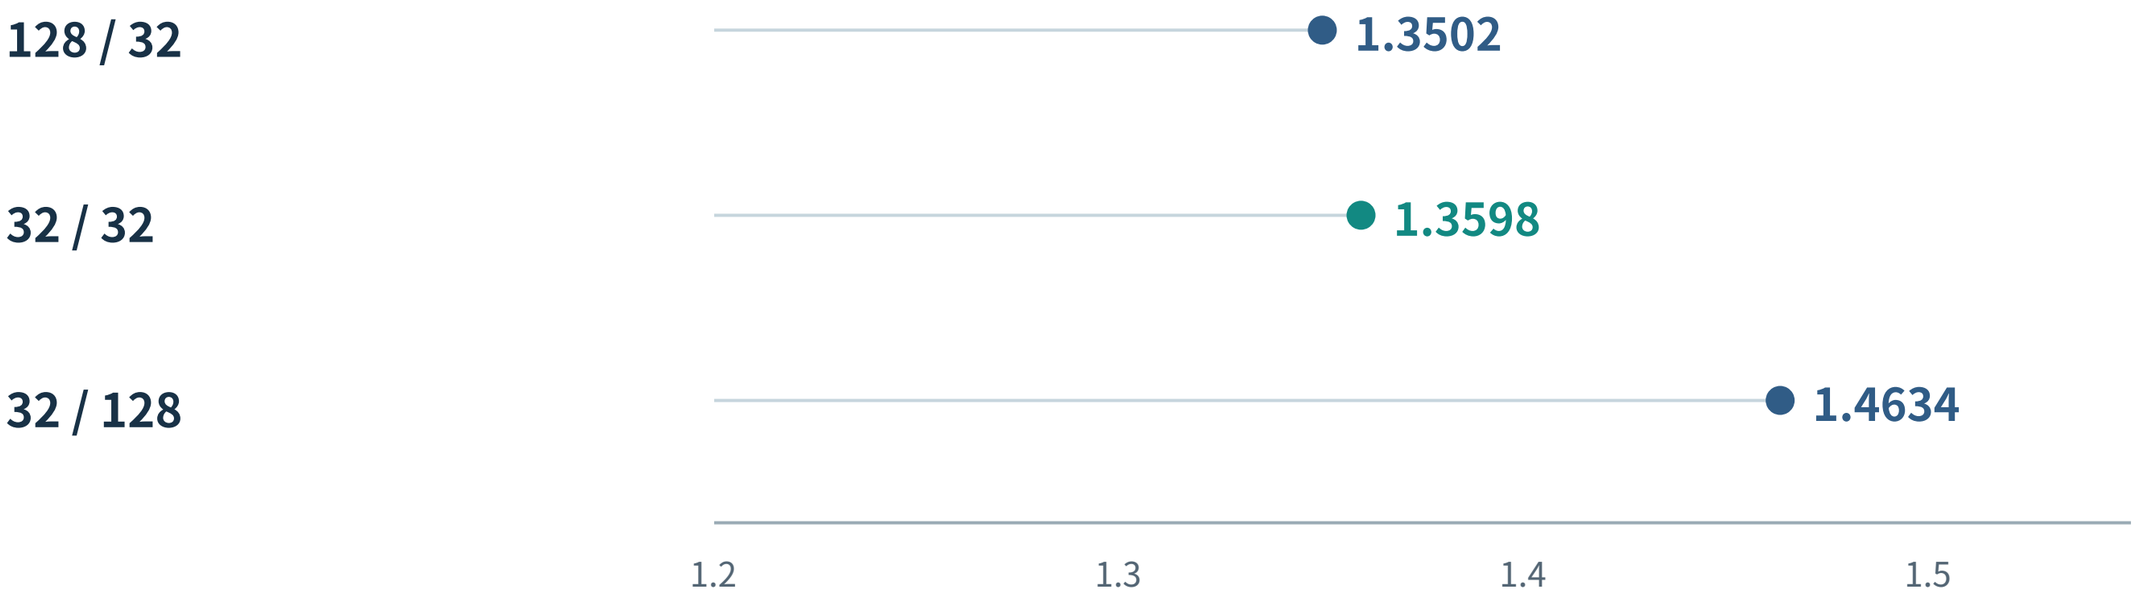
代码／配置推论；实际执行未核验

不能据此认定得分差的唯一原因；不验证当前 4/128 候选。

另项作者报告 • Qwen3-8B / RULER 32K • 11 任务 ×100 例 / 臂 • K=1024 / 保护 4/128
K_1=128 ， β .125→.0625： AVG 58.30→59.29 ； 近 / 远页 16/112→8/120 ，词元 640/252→320/572 。
新增全量 K_1=256 、 β .03125： AVG 58.96 （比 59.29 低 0.33 ）； CWE +3.9 、 FWE −9.67 仅作逐任务诊断。
名义近页仍 8 、词元仍 320/572 、远页 120→248 ； 记录数据 / 评分器身份相同，原预测未独立重放，机制未隔离。
历史 FullKV 59.38 （比 59.29 高 0.09 ）： 身份不完整、评分器版本不同，历史参考链未统一重评分。
主比较为完整 11 任务算术 AVG ； 不证明质量保持、统计非劣或匹配完整请求收益。

共享子空间评分未显示一致计时优势

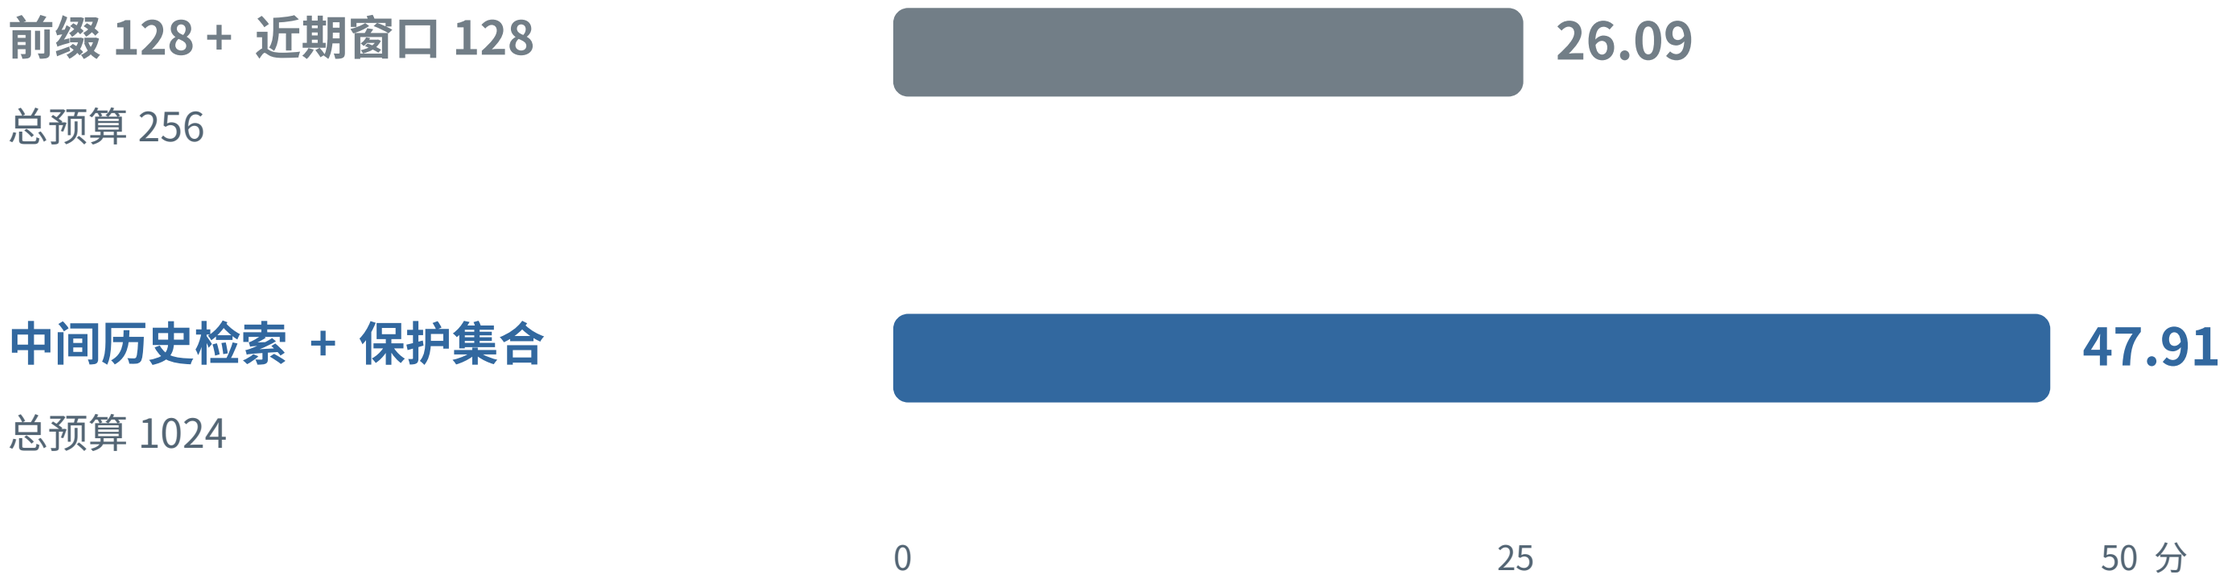
名义页／词元评分坐标数 • 合成 64K • 单层、批量 1 、单查询 • 两轮稳态汇总（ ms ）



相对名义页评分，两轮慢 0.0237 ／快 0.0046 ms ，汇总仍较高。原始样本缺失、协议差异未解，不能认定等价或定位瓶颈。未与质量配对，未测完整请求成本。

历史 128/128 保护：检索与词元预算的联合变化

预算 256 与 1024 的联合变化，未隔离分区贡献



另项作者报告 • Qwen3-32B / RULER 32K • 11 任务 ×100 例 / 臂 • 4/128 保护、 K=1024
稀疏 AVG 50.64 / FullKV 52.22 （− 1.58 ）； MK2 +11 ， CWE −8.80 ， FWE −7.33 。
两臂 MQ/MV 均零不定因；记录模型 / 源数据 / 评分器一致，但跨机且原始预测未独立重放。
限描述性比较：不隔离分配机制，不证明质量保持或匹配质量—成本收益。

评分表示、区域访问与执行成本的取舍

共享低频评分表示

32 维选择 → 共享词元索引

↓

原 128 维 注意力

保留远区页，不保证留有远区词元配额
当前 4/128 尚缺匹配质量—成本验证

可选远区门控

预填充 标定

↓

解码 复用

门控默认关闭；历史任务存在损失
预填充统计不保证解码需求